第二周课后作业标准答案

沈启立，冯赵然

题 1 [⋆ **计算**]　**机器学习损失函数的凸性判断**

背景： 在设计学习算法时，损失函数是否为凸函数直接决定了梯度下降能否收敛到全局最优。

判断以下函数是否为凸函数（请用二阶条件，写出导数过程）：

(a) **逻辑回归损失**：$f(x) = \log(1 + e^x)$，$x \in \mathbb{R}$

(b) **带正则的二次损失**：$f(x) = \|Ax - b\|_2^2 + \lambda\|x\|_2^2$，其中 $A \in \mathbb{R}^{m\times n}$，$\lambda > 0$；写出 Hessian 并判断正半定性。

(c) **负对数似然（多元高斯）**：$f(X) = -\log\det(X)$，$X \in \mathbb{S}_{++}^n$；说明为何此函数是协方差矩阵估计中的核心。

(d) **非凸陷阱**：$f(x_1, x_2) = x_1^2 - x_2^2$；指出其鞍点位置，并解释为何神经网络优化中大量存在此类结构。

标准答案：

(a) $f(x) = \log(1 + e^x)$ **的凸性**　一阶导数：

$$f'(x) = \frac{e^x}{1 + e^x} = \sigma(x)$$

其中 $\sigma(x)$ 为 sigmoid 函数。二阶导数：

$$f''(x) = \sigma(x)(1 - \sigma(x))$$

由于对所有 $x \in \mathbb{R}$，$0 < \sigma(x) < 1$，因此 $f''(x) = \sigma(x)(1 - \sigma(x)) > 0$ 恒成立。

由二阶条件，$f(x)$ 是**严格凸函数**。

(b) $f(x) = \|Ax - b\|_2^2 + \lambda\|x\|_2^2$ **的凸性**　展开目标函数：

$$f(x) = (Ax-b)^\top(Ax-b)+\lambda x^\top x = x^\top A^\top Ax-2b^\top Ax+b^\top b+\lambda x^\top x = x^\top(A^\top A+\lambda I)x-2b^\top Ax+\|b\|^2$$

梯度：

$$\nabla f(x) = 2(A^\top A + \lambda I)x - 2A^\top b$$

Hessian 矩阵：

$$\nabla^2 f(x) = 2(A^\top A + \lambda I)$$

对任意非零向量 $v \in \mathbb{R}^n$：

$$v^\top (A^\top A + \lambda I) v = \|Av\|_2^2 + \lambda \|v\|_2^2 \geq \lambda \|v\|_2^2 > 0$$

因此 Hessian 矩阵是**正定**的，$f(x)$ 是 2λ**-强凸函数**。

(c) $f(X) = -\log\det(X)$**,** $X \in \mathbb{S}_{++}^n$ **的凸性** 我们用限制到一条直线的方法证明凸性。对任意 $X \succ 0$ 和对称矩阵 V，考虑

$$g(t) = f(X + tV) = -\log\det(X + tV)$$

在 t 充分小使得 $X + tV \succ 0$ 的范围内。

利用恒等式 $\det(X+tV) = \det(X)\det(I+tX^{-1/2}VX^{-1/2})$，设 $\lambda_1, \ldots, \lambda_n$ 为 $X^{-1/2}VX^{-1/2}$ 的特征值，则

$$g(t) = -\log\det(X) - \sum_{i=1}^n \log(1 + t\lambda_i)$$

因此

$$g''(t) = \sum_{i=1}^n \frac{\lambda_i^2}{(1 + t\lambda_i)^2} \geq 0$$

$g(t)$ 是 t 的凸函数，由于这对任意直线成立，$f(X) = -\log\det(X)$ 是**凸函数**。

在协方差估计中的核心地位：对多元高斯分布 $\mathcal{N}(\mu, \Sigma)$ 进行最大似然估计时，精度矩阵 $\Theta = \Sigma^{-1}$ 的负对数似然（忽略常数项）为

$$-\log\det(\Theta) + \mathrm{tr}(\Theta S)$$

其中 S 为样本协方差矩阵。这是关于 Θ 的凸函数，因此可以通过凸优化高效求解。在稀疏精度矩阵估计（Graphical Lasso）中，加入 ℓ_1 惩罚后问题仍为凸优化。

(d) $f(x_1, x_2) = x_1^2 - x_2^2$ **的凸性** Hessian 矩阵：

$$\nabla^2 f = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

特征值为 2 和 -2，Hessian 矩阵是**不定**的，因此 f **既不是凸函数也不是凹函数**。

鞍点：梯度 $\nabla f = (2x_1, -2x_2)^\top = 0$ 在 $(0,0)$ 处为零，但该点既不是局部最小值也不是局部最大值（沿 x_1 方向是极小，沿 x_2 方向是极大），因此 $(0,0)$ 是**鞍点**。

神经网络中的鞍点结构：在高维优化中（如 d 维空间），一个驻点的 Hessian 矩阵有 d 个特征值，每个可正可负。要形成局部极小值，需要所有 d 个特征值都为正；在高维空间中，这种情况的概率随 d 的增大而指数级减小。因此，神经网络损失函数中的绝大多数驻点都是鞍点而非局部极小值，这解释了为什么 SGD 等一阶方法在实践中仍能有效优化深度网络。

题 2 [⋆ **概念**] **可行域的凸性分析**

背景：约束优化问题的可行域是否为凸集，直接影响求解器（如 CVXPY、Gurobi）能否保证找到全局最优。

判断以下集合是否为凸集；若不是，给出反例并说明对优化求解的影响：

(a) **功率预算约束**：$\{x \in \mathbb{R}^n : \|x\|_2 \le P\}$（总发射功率限制）

(b) **布尔松弛域**：$\{x \in \mathbb{R}^n : 0 \le x_i \le 1,\ \forall i\}$（整数规划的 LP 松弛可行域）

(c) **归一化非负分配**：$\{x \in \mathbb{R}^n : \mathbf{1}^\top x = 1,\ x \ge 0\}$（概率单纯形）

(d) **协方差矩阵集合**：$\{X \in \mathbb{R}^{n\times n} : X = X^\top,\ X \succeq 0\}$（半正定锥，协方差估计的自然约束）

标准答案：

(a) $\{x \in \mathbb{R}^n : \|x\|_2 \le P\}$ **证明**：

1. 设 $u, v \in C_a$，任取 $\theta \in [0,1]$，令 $z = \theta u + (1-\theta)v$。

由于 $u, v \in C_a$，根据集合 C_a 的定义，有 $\|u\|_2 \le P$，$\|v\|_2 \le P$。

2. 由范数的三角不等式与齐次性，$\|z\|_2 = \|\theta u + (1-\theta)v\|_2 \le \|\theta u\|_2 + \|(1-\theta)v\|_2 = \theta\|u\|_2 + (1-\theta)\|v\|_2$。

因此 $\|z\|_2 \le \theta P + (1-\theta)P = P$。

故 $\|z\|_2 \le P$，从而 $z \in C_a$，因此 C_a 为凸集。

(b) $\{x \in \mathbb{R}^n : 0 \le x_i \le 1, \forall i\}$ **证明：**

1. 任取 $u, v \in C_b$，再任取 $\theta \in [0,1]$，定义 $z = \theta u + (1-\theta)v$。

2. 由于 $u, v \in C_b$，根据 C_b 的定义，对任意 i 有 $0 \le u_i \le 1$，且 $0 \le v_i \le 1$。

又因为 $\theta \in [0,1]$，所以 $\theta \ge 0$ 且 $1-\theta \ge 0$。

因此 $z_i = \theta u_i + (1-\theta)v_i \ge 0$。

3. 另一方面，由于 $u_i \le 1$ 且 $v_i \le 1$，可得 $z_i = \theta u_i + (1-\theta)v_i \le \theta\cdot 1 + (1-\theta)\cdot 1 = 1$。

因此对所有 i 都有 $0 \le z_i \le 1$。于是 $z \in C_b$，从而 C_b 为凸集。

优化角度解释：

从优化角度来看，该集合 $C_b = [0,1]^n$ 可以看作布尔变量约束 $x_i \in \{0,1\}$ 的线性松弛。原始的布尔可行集合是离散且非凸的，因此求解通常较困难。将其放松为区间约束 $0 \le x_i \le 1$ 后，得到的可行域 $[0,1]^n$ 是凸集，可以利用线性规划或凸优化方法高效求解。

(c) $\{x \in \mathbb{R}^n : \mathbf{1}^\top x = 1, x \ge 0\}$ **证明：**

1. 任取 $u, v \in C_c$，再任取 $\theta \in [0,1]$，定义 $z = \theta u + (1-\theta)v$。

【注】证明 C_c 是凸集，即 $z \in C_c$，即证明 $\mathbf{1}^\top z = 1$（等式约束）且 $z \ge 0$（非负性）。

因为 $u, v \in C_c$，因此有 $\mathbf{1}^\top u = 1$，$\mathbf{1}^\top v = 1$，并且 $u \ge 0$，$v \ge 0$。

2. 证明等式约束成立。$\mathbf{1}^\top z = \mathbf{1}^\top(\theta u + (1-\theta)v) = \theta \mathbf{1}^\top u + (1-\theta)\mathbf{1}^\top v = \theta + (1-\theta) = 1$。

3. 证明非负性。由于 $u, v \geq 0$ 且 $\theta, 1-\theta \geq 0$，因此 $z = \theta u + (1-\theta)v \geq 0$。

因此 z 同时满足 $\mathbf{1}^\top z = 1$ 和 $z \geq 0$，从而 $z \in C_c$。因此 C_c 是凸集。

(d) $\{X \in \mathbb{R}^{n\times n} : X = X^\top, X \succeq 0\}$ **证明**：

1. 任取 $U, V \in C_d$，再任取 $\theta \in [0,1]$，定义 $Z = \theta U + (1-\theta)V$。

【注】要证明 C_d 是凸集，只需证明 $Z \in C_d$，即证明 $Z = Z^\top$（对称性）且 $Z \succeq 0$（半正定）。

由于 $U, V \in C_d$，因此 $U = U^\top$，$V = V^\top$，且 $U \succeq 0$，$V \succeq 0$。

2. 证明对称性。利用转置运算的线性性，$Z^\top = (\theta U + (1-\theta)V)^\top = \theta U^\top + (1-\theta)V^\top = \theta U + (1-\theta)V = Z$。因此 Z 仍然是对称矩阵。

3. 证明半正定性。根据定义，只需证明对任意 $y \in \mathbb{R}^n$ 都有 $y^\top Z y \geq 0$。

由于 $Z = \theta U + (1-\theta)V$，可得 $y^\top Z y = y^\top(\theta U + (1-\theta)V)y = \theta y^\top U y + (1-\theta)y^\top V y$。

因为 U, V 都是半正定矩阵，所以 $y^\top U y \geq 0$ 且 $y^\top V y \geq 0$。又由于 $\theta, 1-\theta \geq 0$，因此 $y^\top Z y \geq 0$。

该结论对任意 y 都成立，因此 $Z \succeq 0$。

综上，Z 同时满足对称性和半正定性，因此 $Z \in C_d$。因此 C_d 是凸集。

题 3 [⋆⋆ **证明**] **凸性保持运算：模型组合的理论基础**

背景： 深度学习中常见操作（如 max-pooling、逐点 ReLU 后的损失、仿射变换后接凸损失）之所以保持凸性，源于以下一般性结论。

证明下列命题：

(a) 若 f_1, f_2 均为凸函数，则 $g(x) = \max\{f_1(x), f_2(x)\}$ 也是凸函数。（对应：多类分类中 hinge loss 对各类得分取最大值的操作）

(b) 若 f 是凸函数，A 是矩阵，b 是向量，则 $g(x) = f(Ax+b)$ 也是凸函数。（对应：线性层 $Ax+b$ 接凸损失，整体仍为凸）

(c) 若 $f(x,y)$ 关于 (x,y) 联合凸，则 $g(x) = \inf_y f(x,y)$ 关于 x 是凸函数。（对应：消去隐变量后目标仍凸——EM 算法下界凸性的基础）

标准答案：

(a) $g(x) = \max\{f_1(x), f_2(x)\}$ **的凸性** 1. **定义**：取任意 $x, y \in \mathrm{dom}(g)$ 和 $\theta \in [0,1]$。2. **利用** f_1, f_2 **的凸性**：

$$f_1(\theta x + (1-\theta)y) \leq \theta f_1(x) + (1-\theta) f_1(y)$$
$$f_2(\theta x + (1-\theta)y) \leq \theta f_2(x) + (1-\theta) f_2(y)$$

3. **结合 g 的定义**：

$$\begin{aligned} g(\theta x+(1-\theta)y) &= \max\{f_1(\theta x+(1-\theta)y), f_2(\theta x+(1-\theta)y)\} \\ &\le \max\{\theta f_1(x)+(1-\theta)f_1(y), \theta f_2(x)+(1-\theta)f_2(y)\} \end{aligned}$$

4. **利用最大值的性质**：对任意 a,b,c,d 有 $\max\{a+c,b+d\} \le \max\{a,b\}+\max\{c,d\}$。因此：

$$\begin{aligned} g(\theta x+(1-\theta)y) &\le \max\{\theta f_1(x), \theta f_2(x)\} + \max\{(1-\theta)f_1(y), (1-\theta)f_2(y)\} \\ &= \theta \max\{f_1(x), f_2(x)\} + (1-\theta)\max\{f_1(y), f_2(y)\} \\ &= \theta g(x) + (1-\theta)g(y) \end{aligned}$$

得证 $g(x)$ 是凸函数。

(b) $g(x)=f(Ax+b)$ 的凸性

证明. 对任意 x,y 和 $\theta\in[0,1]$：

$$\begin{aligned} g(\theta x+(1-\theta)y) &= f(A(\theta x+(1-\theta)y)+b) \\ &= f(\theta(Ax+b)+(1-\theta)(Ay+b)) \\ &\le \theta f(Ax+b)+(1-\theta)f(Ay+b) \quad (f \text{ 的凸性}) \\ &= \theta g(x)+(1-\theta)g(y) \end{aligned}$$

□

(c) $g(x)=\inf_y f(x,y)$ 的凸性

证明. 对任意 x_1,x_2 和 $\theta\in[0,1]$。对任意 $\varepsilon>0$，存在 y_1,y_2 使得

$$f(x_1,y_1)\le g(x_1)+\varepsilon, \qquad f(x_2,y_2)\le g(x_2)+\varepsilon$$

由 g 的定义和 f 的联合凸性：

$$\begin{aligned} g(\theta x_1+(1-\theta)x_2) &= \inf_y f(\theta x_1+(1-\theta)x_2,\ y) \\ &\le f(\theta x_1+(1-\theta)x_2,\ \theta y_1+(1-\theta)y_2) \\ &\le \theta f(x_1,y_1)+(1-\theta)f(x_2,y_2) \\ &\le \theta(g(x_1)+\varepsilon)+(1-\theta)(g(x_2)+\varepsilon) \\ &= \theta g(x_1)+(1-\theta)g(x_2)+\varepsilon \end{aligned}$$

由于 $\varepsilon>0$ 可任意小，令 $\varepsilon\to 0$ 即得

$$g(\theta x_1+(1-\theta)x_2)\le \theta g(x_1)+(1-\theta)g(x_2)$$

□

题 4 [⋆⋆ 概念 + 应用] Jensen 不等式与变分自编码器（VAE）的 ELBO

背景： 变分推断的核心是用一个易处理的分布 $q(z|x)$ 近似真实后验 $p(z|x)$。Jensen 不等式给出了对数似然 $\log p(x)$ 的下界，即 ELBO（Evidence Lower BOund），这是 VAE 训练目标的理论依据。

(a) 陈述 Jensen 不等式，并证明：对凸函数 f 和随机变量 Z，有 $f(\mathbb{E}[Z]) \le \mathbb{E}[f(Z)]$。

(b) 利用 Jensen 不等式，对 $-\log$（凸函数）推导以下不等式：

$$\log p(x) = \log \mathbb{E}_{q(z|x)}\left[\frac{p(x,z)}{q(z|x)}\right] \;\ge\; \mathbb{E}_{q(z|x)}\left[\log \frac{p(x,z)}{q(z|x)}\right] =: \mathrm{ELBO}(q)$$

指出等号成立的条件。

(c) 将 ELBO 改写为 $\mathrm{ELBO}(q) = \mathbb{E}_q[\log p(x|z)] - D_{\mathrm{KL}}(q(z|x) \,\|\, p(z))$，并解释两项分别对应 VAE 的哪个训练目标（重建误差 vs. 正则化）。

标准答案：

(a) Jensen 不等式的陈述与证明 **陈述**：若 f 是凸函数，Z 是随机变量（使得期望存在），则

$$f(\mathbb{E}[Z]) \le \mathbb{E}[f(Z)]$$

证明. 由凸函数的一阶条件，对任意点 $\mu = \mathbb{E}[Z]$，有：

$$f(z) \ge f(\mu) + \nabla f(\mu)^\top (z-\mu), \quad \forall z$$

对两边关于 Z 取期望：

$$\mathbb{E}[f(Z)] \ge f(\mu) + \nabla f(\mu)^\top \underbrace{\mathbb{E}[Z-\mu]}_{=0} = f(\mu) = f(\mathbb{E}[Z]) \qquad \square$$

(b) ELBO 的推导 首先，对数似然可以写成：

$$\log p(x) = \log \int p(x,z)\,dz = \log \int \frac{p(x,z)}{q(z|x)} q(z|x)\,dz = \log\, \mathbb{E}_{q(z|x)}\left[\frac{p(x,z)}{q(z|x)}\right]$$

由于 $-\log$ 是凸函数，对 Jensen 不等式应用 $f = -\log$：

$$-\log\, \mathbb{E}_q\left[\frac{p(x,z)}{q(z|x)}\right] \le \mathbb{E}_q\left[-\log \frac{p(x,z)}{q(z|x)}\right]$$

两边取负号并翻转不等号：

$$\log p(x) = \log\, \mathbb{E}_q\left[\frac{p(x,z)}{q(z|x)}\right] \ge \mathbb{E}_q\left[\log \frac{p(x,z)}{q(z|x)}\right] =: \mathrm{ELBO}(q)$$

等号成立条件：Jensen 不等式取等当且仅当随机变量 $p(x,z)/q(z|x)$ 几乎必然为常数，即

$$q(z|x) = p(z|x) \quad \text{（变分分布等于真实后验分布时取等）}$$

(c) ELBO 的分解 将 ELBO 展开：

$$\begin{aligned}\mathrm{ELBO}(q) &= \mathbb{E}_q\left[\log\frac{p(x,z)}{q(z|x)}\right] = \mathbb{E}_q\left[\log\frac{p(x|z)p(z)}{q(z|x)}\right]\\ &= \mathbb{E}_q[\log p(x|z)] + \mathbb{E}_q\left[\log\frac{p(z)}{q(z|x)}\right]\\ &= \underbrace{\mathbb{E}_q[\log p(x|z)]}_{\text{重建项}} - \underbrace{D_{\mathrm{KL}}(q(z|x)\,\|\,p(z))}_{\text{正则项}}\end{aligned}$$

两项的含义：

- $\mathbb{E}_q[\log p(x|z)]$——**重建误差**：衡量从隐变量 z 重建输入 x 的能力。在 VAE 中对应解码器（decoder）的重建损失，鼓励编码后的隐表示能精确还原输入。
- $D_{\mathrm{KL}}(q(z|x)\,\|\,p(z))$——**正则化**：衡量近似后验 $q(z|x)$ 与先验 $p(z)$ 的差异。在 VAE 中对应编码器（encoder）的正则化项，防止 $q(z|x)$ 偏离先验太远，保证隐空间的结构化和可采样性。

题 5 [⋆⋆ 计算] 资源分配中的 KKT 条件

背景： 考虑将单位总算力分配给 n 个任务，第 i 个任务分得算力 x_i 时产生效用 $u_i(x_i)$。当效用函数为严格凹函数时，最优分配由 KKT 条件完全刻画。

具体地，求解以下问题，要求**写出完整 KKT 条件**（稳定性、原始可行性、对偶可行性、互补松弛）并求出 x^* 和所有对偶变量：

$$\min_{x\in\mathbb{R}^2}\quad (x_1-1)^2+(x_2-2)^2 \quad \text{s.t.}\quad x_1+x_2\le 2,\quad x_1\ge 0,\quad x_2\ge 0$$

(a) 写出 Lagrangian $L(x,\lambda)$，引入乘子 λ_1（对应 $x_1+x_2\le 2$），λ_2（对应 $-x_1\le 0$），λ_3（对应 $-x_2\le 0$）。

(b) 列出全部 KKT 条件。

(c) 通过枚举互补松弛的活跃约束组合，求解 x^*、λ_1^*、λ_2^*、λ_3^*。

(d) 验证互补松弛条件均满足，并给出经济学直觉：哪条约束是”紧的”，其对偶变量的正值代表什么？

标准答案：

(a) Lagrangian 将约束写成标准形式 $g_i(x)\le 0$：

- $g_1(x) = x_1+x_2-2\le 0$
- $g_2(x) = -x_1\le 0$

- $g_3(x) = -x_2 \leq 0$

引入对偶乘子 $\lambda_1, \lambda_2, \lambda_3 \geq 0$，Lagrangian 为：

$$L(x, \lambda) = (x_1 - 1)^2 + (x_2 - 2)^2 + \lambda_1(x_1 + x_2 - 2) + \lambda_2(-x_1) + \lambda_3(-x_2)$$

(b) 全部 KKT 条件 由于目标函数 $f(x) = (x_1 - 1)^2 + (x_2 - 2)^2$ 是严格凸函数，约束 g_1, g_2, g_3 均为仿射（因此是凸函数），原问题为凸优化问题。对凸问题，**KKT 条件是全局最优的充要条件**。

1. 稳定性（Stationarity）：

$$\frac{\partial L}{\partial x_1} = 2(x_1 - 1) + \lambda_1 - \lambda_2 = 0$$

$$\frac{\partial L}{\partial x_2} = 2(x_2 - 2) + \lambda_1 - \lambda_3 = 0$$

2. 原始可行性（Primal Feasibility）：

$$x_1 + x_2 \leq 2, \quad x_1 \geq 0, \quad x_2 \geq 0$$

3. 对偶可行性（Dual Feasibility）：

$$\lambda_1 \geq 0, \quad \lambda_2 \geq 0, \quad \lambda_3 \geq 0$$

4. 互补松弛（Complementary Slackness）：

$$\lambda_1(x_1 + x_2 - 2) = 0, \quad \lambda_2 x_1 = 0, \quad \lambda_3 x_2 = 0$$

(c) 求解 三个约束各自可以活跃或不活跃，共有 $2^3 = 8$ 种互补松弛组合需要考虑。我们利用问题结构快速排除大部分情况。

关键观察：无约束最小值点为 $(x_1, x_2) = (1, 2)$，但 $1 + 2 = 3 > 2$ 不满足约束 g_1。因此在最优解处，约束 $x_1 + x_2 \leq 2$ 必然是活跃的（否则最优解就是无约束解），即 $x_1^* + x_2^* = 2$，对应 $\lambda_1 > 0$。

尝试组合：$\lambda_1 > 0$（g_1 活跃：$x_1 + x_2 = 2$），$\lambda_2 = 0$（假设 $x_1 > 0$），$\lambda_3 = 0$（假设 $x_2 > 0$）。

由稳定性条件（令 $\lambda_2 = \lambda_3 = 0$）：

$$2(x_1 - 1) + \lambda_1 = 0 \implies x_1 = 1 - \frac{\lambda_1}{2}$$

$$2(x_2 - 2) + \lambda_1 = 0 \implies x_2 = 2 - \frac{\lambda_1}{2}$$

代入活跃约束 $x_1 + x_2 = 2$：

$$\left(1 - \frac{\lambda_1}{2}\right) + \left(2 - \frac{\lambda_1}{2}\right) = 2 \implies 3 - \lambda_1 = 2 \implies \lambda_1 = 1$$

因此：

$$x_1^* = 1 - \frac{1}{2} = \frac{1}{2}, \quad x_2^* = 2 - \frac{1}{2} = \frac{3}{2}$$

验证所有 KKT 条件：

- 原始可行性：$x_1^* = 1/2 > 0$ ✓，$x_2^* = 3/2 > 0$ ✓，$x_1^* + x_2^* = 2 \le 2$ ✓
- 对偶可行性：$\lambda_1^* = 1 > 0$ ✓，$\lambda_2^* = 0 \ge 0$ ✓，$\lambda_3^* = 0 \ge 0$ ✓
- 互补松弛（见 (d) 部分详细验证）
- 假设 $\lambda_2 = 0, \lambda_3 = 0$ 与求得的 $x_1^* > 0, x_2^* > 0$ 自洽 ✓

因此最优解为：

$$\boxed{x_1^* = \frac{1}{2}, \quad x_2^* = \frac{3}{2}, \quad \lambda_1^* = 1, \quad \lambda_2^* = 0, \quad \lambda_3^* = 0}$$

最优目标值为 $f(x^*) = (1/2 - 1)^2 + (3/2 - 2)^2 = 1/4 + 1/4 = 1/2$。

(d) 互补松弛验证与经济学直觉 **互补松弛验证**：

- $\lambda_1^*(x_1^* + x_2^* - 2) = 1 \times (1/2 + 3/2 - 2) = 1 \times 0 = 0$ ✓
- $\lambda_2^* \cdot x_1^* = 0 \times 1/2 = 0$ ✓
- $\lambda_3^* \cdot x_2^* = 0 \times 3/2 = 0$ ✓

三组互补松弛条件均满足，与 (b) 中的全部 KKT 条件一致。由于原问题为凸优化且 Slater 条件成立（例如 $x = (0.5, 0.5)$ 严格满足所有不等式），KKT 条件是最优性的充要条件，故 $x^* = (1/2, 3/2)$ 是唯一全局最优解。

经济学直觉：

- **紧约束**：$x_1 + x_2 \le 2$ 在最优解处取等号（$x_1^* + x_2^* = 2$），对应 $\lambda_1^* = 1 > 0$。λ_1^* 是该约束的**影子价格（shadow price）**：由灵敏度分析，若将总资源预算右端项从 2 放松到 $2 + \varepsilon$（$\varepsilon > 0$ 足够小），最优目标值将近似减少

  $$\Delta f^* \approx -\lambda_1^* \cdot \varepsilon = -\varepsilon.$$

  即每增加一单位资源，最优目标值下降约 1 个单位。这说明**总资源约束是瓶颈**，增加资源有正的边际价值。

- **松约束**：$x_1 \ge 0$ 和 $x_2 \ge 0$ 在最优解处严格满足（$x_1^* = 1/2 > 0$，$x_2^* = 3/2 > 0$），对偶变量 $\lambda_2^* = \lambda_3^* = 0$。直觉上，非负约束对最优解没有”制约”作用，放松它们不会带来任何改善——**非紧约束的边际价值为零**。

题 6 [⋆⋆ 推导]　岭回归的 Lagrange 对偶与正则化解释

背景： 岭回归（Ridge Regression）既可以写成带 ℓ_2 惩罚的无约束问题，也等价于一个带范数约束的最小二乘问题。两种形式通过 Lagrange 对偶联系，正则化系数 λ 正好是约束的"影子价格"。

考虑带等式约束的二次规划：

$$\min_{x\in\mathbb{R}^n} \quad \tfrac{1}{2}x^\top Qx + c^\top x \quad \text{s.t.} \quad Ax = b, \quad Q \succ 0$$

其中 $Q \in \mathbb{R}^{n\times n}$ 对称正定，$A \in \mathbb{R}^{m\times n}$，$b \in \mathbb{R}^m$。

(a) 写出 Lagrangian $L(x,\nu)$，对 x 求极小（令 $\nabla_x L = 0$），得到最优 $x^*(\nu)$ 关于对偶变量 ν 的解析表达式。

(b) 将 $x^*(\nu)$ 代回，得到对偶函数 $g(\nu)$；写出对偶问题并化简。

(c) 说明强对偶性成立的依据（Slater 条件），并指出对偶变量 ν^* 的统计含义（在普通线性回归 $Q = X^\top X$，$c = -X^\top y$ 的特殊情形下说明）。

标准答案：

(a) Lagrangian 与 $x^*(\nu)$　引入等式约束的对偶变量 $\nu \in \mathbb{R}^m$（注意等式约束的乘子**无符号限制**），Lagrangian 为：

$$L(x,\nu) = \frac{1}{2}x^\top Qx + c^\top x + \nu^\top(Ax - b)$$

对 x 求梯度并令其为零：

$$\nabla_x L = Qx + c + A^\top \nu = 0$$

由于 $Q \succ 0$，Q 可逆，解得原始变量关于对偶变量的表达式：

$$\boxed{x^*(\nu) = -Q^{-1}(c + A^\top \nu)}$$

又因 $Q \succ 0$，$L(x,\nu)$ 关于 x 是严格凸函数，故上述驻点即为唯一的全局极小点。

(b) 对偶函数与对偶问题 将 $x^*(\nu) = -Q^{-1}(c + A^\top \nu)$ 代回 L。记 $u = c + A^\top \nu$ 以简化符号，则 $x^*(\nu) = -Q^{-1}u$：

$$
\begin{aligned}
g(\nu) &= L(x^*(\nu), \nu) \\
&= \frac{1}{2}(-Q^{-1}u)^\top Q(-Q^{-1}u) + c^\top(-Q^{-1}u) + \nu^\top\big(A(-Q^{-1}u) - b\big) \\
&= \frac{1}{2}u^\top Q^{-1} Q\, Q^{-1}u - c^\top Q^{-1}u - \nu^\top A Q^{-1}u - \nu^\top b \\
&= \frac{1}{2}u^\top Q^{-1}u - (c + A^\top\nu)^\top Q^{-1}u - \nu^\top b \\
&= \frac{1}{2}u^\top Q^{-1}u - u^\top Q^{-1}u - \nu^\top b \\
&= -\frac{1}{2}u^\top Q^{-1}u - \nu^\top b
\end{aligned}
$$

还原 u 的定义：

$$
\boxed{g(\nu) = -\frac{1}{2}(c + A^\top\nu)^\top Q^{-1}(c + A^\top\nu) - \nu^\top b}
$$

对偶问题为（等式约束的对偶变量无约束）：

$$
\max_{\nu\in\mathbb{R}^m}\ g(\nu) = \max_{\nu}\left[-\frac{1}{2}(c + A^\top\nu)^\top Q^{-1}(c + A^\top\nu) - b^\top\nu\right]
$$

将 $g(\nu)$ 展开：

$$
g(\nu) = -\frac{1}{2}\big(c^\top Q^{-1}c + 2c^\top Q^{-1}A^\top\nu + \nu^\top A Q^{-1}A^\top\nu\big) - b^\top\nu
$$

最大化 $g(\nu)$ 等价于最小化 $-g(\nu)$，整理得对偶问题的等价最小化形式：

$$
\boxed{\min_{\nu\in\mathbb{R}^m}\ \frac{1}{2}\nu^\top(AQ^{-1}A^\top)\nu + (AQ^{-1}c + b)^\top\nu + \frac{1}{2}c^\top Q^{-1}c}
$$

这是一个关于 ν 的无约束凸二次规划。注意 $Q^{-1} \succ 0$，因此 $AQ^{-1}A^\top \succeq 0$；若进一步 A 行满秩，则 $AQ^{-1}A^\top \succ 0$，对偶问题是严格凸的，ν^* 唯一。

(c) 强对偶性与统计含义 **强对偶性**：原问题是凸二次规划（目标函数 $\frac{1}{2}x^\top Qx + c^\top x$ 为凸函数，$Q \succ 0$），且约束 $Ax = b$ 均为仿射。对于仅含仿射约束的凸优化问题，Slater 条件（即要求存在严格满足不等式约束的可行点）**退化为只需可行域非空**。因此，只要 $\{x : Ax = b\} \neq \emptyset$，强对偶性即成立：

$$
d^* = p^*.
$$

统计含义：在普通线性回归（OLS）的特殊情形下，令 $X \in \mathbb{R}^{N\times n}$ 为设计矩阵，$y \in \mathbb{R}^N$ 为响应变量，取 $Q = X^\top X$，$c = -X^\top y$。此时原问题的目标函数化为：

$$
\frac{1}{2}w^\top X^\top X w - y^\top X w = \frac{1}{2}\|Xw - y\|_2^2 - \frac{1}{2}\|y\|_2^2
$$

（其中第二项 $\frac{1}{2}\|y\|_2^2$ 为常数，不影响优化。）附加等式约束 $Aw = b$ 代表对回归系数的线性约束（例如系数之和等于某个常数）。

对偶变量 ν^* 的统计含义是约束的**影子价格（shadow price）**。具体地，设 $p^*(b)$ 为约束右端项取 b 时的最优值，由灵敏度定理：

$$\nabla_b p^*(b) = -\nu^*$$

即若将约束 $Aw = b$ 扰动为 $Aw = b + \delta$（δ 充分小），则最优回归损失的变化量为：

$$\Delta p^* \approx -\nu^{*\top}\delta$$

$|\nu_j^*|$ 的大小衡量了第 j 个等式约束对最优拟合质量的**边际制约程度**：$|\nu_j^*|$ 越大，说明该约束对回归的限制越紧，放松它能更显著地降低训练损失。

题 7 [⋆⋆ 综合推导]　支持向量机（SVM）对偶推导与支持向量的几何意义

背景： SVM 是凸二次规划的经典应用。其对偶形式不仅降低了问题维度（从特征维 d 降到样本数 m），更揭示了分类边界只由少数”支持向量”决定这一核心几何直觉。

原问题：

$$\min_{w,b} \quad \tfrac{1}{2}\|w\|^2 \quad \text{s.t.} \quad y_i(w^\top x_i + b) \geq 1, \quad i = 1, \ldots, m$$

(a) 写出 Lagrangian $L(w, b, \alpha)$，对 w 和 b 分别求导令其为零，得到 $w = \sum_i \alpha_i y_i x_i$ 及关于 b 的条件。

(b) 将上述结果代回，推导出对偶问题：

$$\max_{\alpha \geq 0} \quad \sum_i \alpha_i - \tfrac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.t.} \quad \sum_i \alpha_i y_i = 0$$

(c) 利用互补松弛条件 $\alpha_i[y_i(w^\top x_i + b) - 1] = 0$ 解释：为何只有”压在间隔边界上”的样本才有 $\alpha_i > 0$？这些样本称为支持向量。

(d) 手算：给定 $x_1 = (1, 0), y_1 = +1$；$x_2 = (0, 1), y_2 = +1$；$x_3 = (-1, 0), y_3 = -1$，求 w^*，b^* 和 α^*，并画出分类超平面示意图。

标准答案：

(a) Lagrangian 与对 w、b 的求导　引入 Lagrange 乘子 $\alpha_i \geq 0$，Lagrangian 为：

$$L(w, b, \alpha) = \frac{1}{2}\|w\|^2 - \sum_{i=1}^{m} \alpha_i \big[y_i(w^\top x_i + b) - 1\big]$$

对 w 求导令其为零：

$$\nabla_w L = w - \sum_{i=1}^{m} \alpha_i y_i x_i = 0 \implies \boxed{w = \sum_{i=1}^{m} \alpha_i y_i x_i}$$

对 b 求导令其为零：

$$\frac{\partial L}{\partial b} = -\sum_{i=1}^{m} \alpha_i y_i = 0 \implies \boxed{\sum_{i=1}^{m} \alpha_i y_i = 0}$$

(b) 对偶问题的推导 将 $w = \sum_i \alpha_i y_i x_i$ 代回 Lagrangian：

$$\begin{aligned}
L &= \frac{1}{2}\left\|\sum_i \alpha_i y_i x_i\right\|^2 - \sum_i \alpha_i y_i \left(\sum_j \alpha_j y_j x_j\right)^\top x_i - b\underbrace{\sum_i \alpha_i y_i}_{=0} + \sum_i \alpha_i \\
&= \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j - \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j + \sum_i \alpha_i \\
&= \sum_i \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j
\end{aligned}$$

对偶问题为：

$$\boxed{\max_{\alpha \geq 0} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^\top x_j \quad \text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0}$$

(c) 互补松弛与支持向量 互补松弛条件为：

$$\alpha_i \big[y_i(w^\top x_i + b) - 1\big] = 0, \quad \forall i$$

这意味着对每个样本 i，以下两种情况之一成立：

- $\alpha_i = 0$：此样本的约束不活跃，即 $y_i(w^\top x_i + b) > 1$，样本远离间隔边界，对分类超平面无贡献。
- $\alpha_i > 0$：此时必须有 $y_i(w^\top x_i + b) = 1$，即样本**恰好在间隔边界上**。

由 $w = \sum_i \alpha_i y_i x_i$ 可知，只有 $\alpha_i > 0$ 的样本才对 w 有贡献。这些样本被称为**支持向量**——它们”支撑”着分类超平面的位置。

(d) 手算 已知 $x_1 = (1, 0)$，$y_1 = +1$；$x_2 = (0, 1)$，$y_2 = +1$；$x_3 = (-1, 0)$，$y_3 = -1$。
内积矩阵：$x_1^\top x_2 = 0$，$x_1^\top x_3 = -1$，$x_2^\top x_3 = 0$，$\|x_i\|^2 = 1$。
对偶问题中各项 $\alpha_i \alpha_j y_i y_j x_i^\top x_j$：

$y_i y_j x_i^\top x_j$	$j = 1$	$j = 2$	$j = 3$
$i = 1$	1	0	1
$i = 2$	0	1	0
$i = 3$	1	0	1

对偶目标函数：

$$W(\alpha) = \alpha_1 + \alpha_2 + \alpha_3 - \frac{1}{2}(\alpha_1^2 + \alpha_2^2 + \alpha_3^2 + 2\alpha_1\alpha_3)$$

约束：$\alpha_1 + \alpha_2 - \alpha_3 = 0$（即 $\alpha_3 = \alpha_1 + \alpha_2$）。

代入 $\alpha_3 = \alpha_1 + \alpha_2$：

$$\begin{aligned} W &= 2\alpha_1 + 2\alpha_2 - \frac{1}{2}[\alpha_1^2 + \alpha_2^2 + (\alpha_1 + \alpha_2)^2 + 2\alpha_1(\alpha_1 + \alpha_2)] \\ &= 2\alpha_1 + 2\alpha_2 - 2\alpha_1^2 - \alpha_2^2 - 2\alpha_1\alpha_2 \end{aligned}$$

求偏导：

$$\frac{\partial W}{\partial \alpha_1} = 2 - 4\alpha_1 - 2\alpha_2 = 0, \qquad \frac{\partial W}{\partial \alpha_2} = 2 - 2\alpha_2 - 2\alpha_1 = 0$$

由第二个方程：$\alpha_2 = 1 - \alpha_1$。代入第一个方程：$2 - 4\alpha_1 - 2(1 - \alpha_1) = -2\alpha_1 = 0$，得 $\alpha_1 = 0$。

因此：

$$\boxed{\alpha_1^* = 0, \quad \alpha_2^* = 1, \quad \alpha_3^* = 1}$$

恢复原始变量：

$$w^* = \alpha_2 y_2 x_2 + \alpha_3 y_3 x_3 = 1 \cdot (+1) \cdot (0,1) + 1 \cdot (-1) \cdot (-1,0) = (0,1) + (1,0) = \boxed{(1,1)}$$

由支持向量 x_2（$\alpha_2 > 0$）计算 b：

$$y_2({w^*}^\top x_2 + b^*) = 1 \implies 1 \cdot (1 + b^*) = 1 \implies \boxed{b^* = 0}$$

验证（用 x_3）：$y_3({w^*}^\top x_3 + b^*) = (-1)(-1 + 0) = 1$ ✓。

分类超平面：${w^*}^\top x + b^* = 0$，即 $x_1 + x_2 = 0$。间隔宽度为 $2/\|w^*\| = 2/\sqrt{2} = \sqrt{2}$。支持向量为 $x_2 = (0,1)$ 和 $x_3 = (-1,0)$。

题 8 [⋆⋆⋆ **综合**] **带风险约束的投资组合优化（QCQP）**

背景： Markowitz 均值-方差模型是金融优化的基石。当引入”最大波动率”约束时，问题升级为带二次约束的二次规划（QCQP）。分析其对偶揭示了”风险预算”的影子价格。

考虑以下 QCQP（$\Sigma \succ 0$ 为协方差矩阵，μ 为期望收益向量）：

$$\min_{w \in \mathbb{R}^n} \quad w^\top \Sigma w \quad \text{s.t.} \quad \mu^\top w \geq r_{\min}, \quad \mathbf{1}^\top w = 1, \quad w \geq 0$$

(a) 写出 Lagrangian $L(w, \lambda, \nu, \gamma)$，列出 KKT 条件（稳定性条件需写出矩阵形式）。

(b) 证明对偶函数 $g(\lambda, \nu, \gamma)$ 是关于 (λ, ν, γ) 的凹函数。

(c) 设 $n = 2$，$\Sigma = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix}$，$\mu = (0.1, 0.2)^\top$，$r_{\min} = 0.12$。手算最优权重 w^* 和对偶变量 λ^*（收益约束的乘子）。

(d) 解释" 影子价格"：若 $r_{\min}$ 从 0.12 提高到 $0.12+\epsilon$，最优方差（目标值）将如何变化？用 λ^* 给出近似表达式。

标准答案：

(a) Lagrangian 与 KKT 条件 将约束写成标准不等式形式：$r_{\min}-\mu^\top w \le 0, -w_i \le 0$。Lagrangian 为：

$$L(w,\lambda,\nu,\gamma) = w^\top \Sigma w + \lambda(r_{\min} - \mu^\top w) + \nu(\mathbf{1}^\top w - 1) - \gamma^\top w$$

其中 $\lambda \ge 0$（收益约束的乘子），$\nu \in \mathbb{R}$（等式约束），$\gamma \ge 0$（非负约束的乘子）。

KKT 条件：

1. 稳定性：$\nabla_w L = 2\Sigma w^* - \lambda^*\mu + \nu^*\mathbf{1} - \gamma^* = 0$，即

$$2\Sigma w^* = \lambda^*\mu - \nu^*\mathbf{1} + \gamma^*$$

2. 原始可行性：$\mu^\top w^* \ge r_{\min}$，$\mathbf{1}^\top w^* = 1$，$w^* \ge 0$

3. 对偶可行性：$\lambda^* \ge 0$，$\gamma^* \ge 0$

4. 互补松弛：$\lambda^*(r_{\min} - \mu^\top w^*) = 0$，$\gamma_i^* w_i^* = 0$，$\forall i$

(b) 对偶函数的凹性 对偶函数定义为

$$g(\lambda,\nu,\gamma) = \inf_w L(w,\lambda,\nu,\gamma)$$

对任意固定的 w，$L(w,\lambda,\nu,\gamma)$ 是关于 (λ,ν,γ) 的仿射函数（线性函数）。对偶函数 g 是一族仿射函数的逐点下确界（pointwise infimum），而仿射函数的逐点下确界是**凹函数**。

形式化证明：对任意 $(\lambda_1,\nu_1,\gamma_1)$、$(\lambda_2,\nu_2,\gamma_2)$ 和 $\theta \in [0,1]$：

$$\begin{aligned}
g(\theta(\lambda_1,\nu_1,\gamma_1) + (1-\theta)(\lambda_2,\nu_2,\gamma_2)) &= \inf_w [\theta L(w,\lambda_1,\nu_1,\gamma_1) + (1-\theta)L(w,\lambda_2,\nu_2,\gamma_2)] \\
&\ge \theta \inf_w L(w,\lambda_1,\nu_1,\gamma_1) + (1-\theta)\inf_w L(w,\lambda_2,\nu_2,\gamma_2) \\
&= \theta\, g(\lambda_1,\nu_1,\gamma_1) + (1-\theta)\, g(\lambda_2,\nu_2,\gamma_2)
\end{aligned}$$

其中不等式利用了 $\inf(f+g) \ge \inf f + \inf g$ 的事实。□

(c) $n=2$ 时的手算 利用 $w_2 = 1 - w_1$，目标函数化为一元二次函数：

$$\begin{aligned}
f(w_1) &= (w_1,\ 1-w_1)\begin{pmatrix} 1 & 0.5 \\ 0.5 & 2 \end{pmatrix}\begin{pmatrix} w_1 \\ 1-w_1 \end{pmatrix} \\
&= w_1^2 + w_1(1-w_1) + 2(1-w_1)^2 = 2w_1^2 - 3w_1 + 2
\end{aligned}$$

收益约束变为：$0.1w_1 + 0.2(1-w_1) \ge 0.12$，即 $-0.1w_1 + 0.2 \ge 0.12$，即 $w_1 \le 0.8$。

无约束最小值点：$f'(w_1) = 4w_1 - 3 = 0 \implies w_1 = 3/4 = 0.75$。
检验可行性：$w_1 = 0.75 \le 0.8$ ✓，$w_1 = 0.75 \ge 0$ ✓，$w_2 = 0.25 \ge 0$ ✓。
此时收益 $= 0.1(0.75) + 0.2(0.25) = 0.125 > 0.12$，收益约束**不紧**。
因此：

$$\boxed{w^* = (0.75,\ 0.25)^\top, \quad \lambda^* = 0}$$

最优方差 $= 2(0.75)^2 - 3(0.75) + 2 = 0.875$。
由稳定性条件 $2\Sigma w^* = -\nu^*\mathbf{1} + \gamma^*$（因 $\lambda^* = 0$），可算出 $\nu^* = -1.75$，$\gamma^* = (0,0)^\top$。

(d) 影子价格的解释 由于 $\lambda^* = 0$，收益约束当前**不活跃**（当前组合已超额满足最低收益要求）。因此：

$$p^*(r_{\min} + \varepsilon) \approx p^*(r_{\min}) + \lambda^* \cdot \varepsilon = 0.875 + 0 \cdot \varepsilon = 0.875$$

即在 ε 足够小时，将 $r_{\min}$ 从 0.12 提高到 $0.12 + \varepsilon$ 不会影响最优方差（因为当前最优组合的收益率 0.125 仍然满足新约束）。

但当 $r_{\min}$ 增大到超过 0.125 时，收益约束变为活跃，λ^* 将变为正值，此时进一步提高 $r_{\min}$ 会导致最优方差增大——投资者需要承担更多风险以追求更高收益。

题 9 [⋆⋆⋆ 证明 + 应用] 弱对偶定理与电力网络的输电容量定价

背景：在电力系统最优潮流（OPF）问题中，输电线路容量约束对应的对偶变量称为”边际阻塞成本”（Locational Marginal Price, LMP）。弱对偶定理保证了 LMP 是发电成本的有效下界，强对偶（在凸 OPF 下成立）则保证这个下界是紧的。

(a) **证明弱对偶定理**：对一般优化问题

$$p^* = \min_x f(x) \quad \text{s.t.} \quad g_i(x) \le 0,\ h_j(x) = 0$$

设 Lagrangian 为 $L(x,\lambda,\nu) = f(x) + \sum_i \lambda_i g_i(x) + \sum_j \nu_j h_j(x)$，对偶函数 $g(\lambda,\nu) = \inf_x L(x,\lambda,\nu)$。利用 $\lambda \ge 0$ 与 $g_i(x) \le 0$，严格证明对所有对偶可行 (λ,ν) 有 $g(\lambda,\nu) \le p^*$，从而 $d^* \le p^*$。

(b) **对偶间隙与凸性的关系**：

(i) 给出一个非凸问题的简单例子，使得对偶间隙 $p^* - d^* > 0$。

(ii) 陈述 Slater 条件，解释为何对凸问题它保证强对偶（$p^* = d^*$）。

(c) **影子价格的精确表述**：设 $p^*(\epsilon)$ 是约束松弛为 $g_i(x) \le \epsilon_i$ 后的最优值函数。在强对偶和适当光滑性假设下，证明

$$\left.\frac{\partial p^*}{\partial \epsilon_i}\right|_{\epsilon=0} = -\lambda_i^*$$

并用电力市场语言解释：λ_i^* 为什么代表”放松第 i 条输电线路容量一个单位所节省的发电成本”。

标准答案：

(a) 弱对偶定理的证明

证明. 设 $\tilde{x}$ 是原问题的任意可行解，即 $g_i(\tilde{x}) \le 0$，$h_j(\tilde{x}) = 0$。对任意对偶可行的 (λ, ν) $(\lambda \ge 0)$：

$$\begin{aligned} g(\lambda,\nu) &= \inf_x L(x,\lambda,\nu) \le L(\tilde{x},\lambda,\nu) \\ &= f(\tilde{x}) + \sum_i \underbrace{\lambda_i}_{\ge 0} \underbrace{g_i(\tilde{x})}_{\le 0} + \sum_j \nu_j \underbrace{h_j(\tilde{x})}_{=0} \\ &\le f(\tilde{x}) \end{aligned}$$

这对**所有**可行解 $\tilde{x}$ 成立，因此：

$$g(\lambda,\nu) \le \inf\{f(\tilde{x}) : \tilde{x} \text{ 可行}\} = p^*$$

这又对**所有**对偶可行 (λ, ν) 成立，故：

$$d^* = \sup_{\lambda \ge 0, \nu} g(\lambda,\nu) \le p^* \qquad \square$$

(b) 对偶间隙与凸性　(i) 非凸问题中正对偶间隙的例子：

考虑非凸问题：

$$\min_x |x| \quad \text{s.t.} \quad x^2 \ge 1 \quad (\text{即 } 1 - x^2 \le 0)$$

可行域为 $\{x : |x| \ge 1\}$（非凸集），$p^* = 1$（在 $x = \pm 1$ 处取得）。

Lagrangian：$L(x,\lambda) = |x| + \lambda(1 - x^2)$，$\lambda \ge 0$。

对 $\lambda > 0$：当 $|x| \to \infty$ 时，$-\lambda x^2$ 项主导，$L \to -\infty$，故 $g(\lambda) = -\infty$。

对 $\lambda = 0$：$g(0) = \inf_x |x| = 0$。

因此 $d^* = \sup_{\lambda \ge 0} g(\lambda) = 0$，**对偶间隙** $p^* - d^* = 1 > 0$。

(ii) Slater 条件：

陈述：对于凸优化问题（f, g_i 凸，h_j 仿射），如果存在**严格可行点** $\tilde{x}$ 使得

$$g_i(\tilde{x}) < 0,\ \forall i = 1,\dots,m; \quad h_j(\tilde{x}) = 0,\ \forall j = 1,\dots,p$$

则**强对偶成立**（$d^* = p^*$）。

Slater 条件保证了对偶间隙为零的核心原因在于：严格可行点的存在确保了约束不会”退化”，使得 Lagrangian 对偶能够”紧贴”原问题。在技术上，Slater 条件保证了对偶最优值可以被达到，且原始-对偶最优解之间没有间隙。对于仅含仿射约束的问题，Slater 条件自动满足（只要可行域非空）。

(c) 影子价格的证明与电力市场解释

证明. 考虑松弛后的问题 $p^*(\varepsilon)$：$\min_x f(x)$ s.t. $g_i(x) \le \varepsilon_i$。

下界：由弱对偶，对任意对偶可行 (λ, ν)：

$$\begin{aligned} p^*(\varepsilon) \ge g_\varepsilon(\lambda^*, \nu^*) &= \inf_x \big[f(x) + \sum_i \lambda_i^*(g_i(x) - \varepsilon_i) + \sum_j \nu_j^* h_j(x) \big] \\ &= \inf_x \big[L(x, \lambda^*, \nu^*) \big] - \sum_i \lambda_i^* \varepsilon_i \\ &= g(\lambda^*, \nu^*) - \sum_i \lambda_i^* \varepsilon_i \\ &= p^*(0) - \sum_i \lambda_i^* \varepsilon_i \quad \text{（强对偶：} g(\lambda^*, \nu^*) = p^*(0)\text{）} \end{aligned}$$

因此 $p^*(\varepsilon) \ge p^*(0) - \sum_i \lambda_i^* \varepsilon_i$，即

$$p^*(\varepsilon) - p^*(0) \ge -\sum_i \lambda_i^* \varepsilon_i$$

另一方面，$p^*(\varepsilon)$ 是凸函数（可行域随 ε 的扩大只会使最优值下降或不变），因此 $p^*(\varepsilon) \le p^*(0)$ 对 $\varepsilon \ge 0$。在适当光滑性假设下，$p^*(\varepsilon)$ 在 $\varepsilon = 0$ 可微，由上述不等式结合凸分析中的次梯度理论可得：

$$\left. \frac{\partial p^*}{\partial \varepsilon_i} \right|_{\varepsilon=0} = -\lambda_i^* \qquad \square$$

电力市场解释：在最优潮流（OPF）问题中，$g_i(x) \le 0$ 表示第 i 条输电线路的潮流不超过其容量限制。当我们将该容量放松 ε_i 个单位（$g_i(x) \le \varepsilon_i$）时，最优发电成本将减少 $\lambda_i^* \cdot \varepsilon_i$。因此 λ_i^* 代表了**放松第 i 条输电线路容量一个单位所节省的发电成本**，即该线路的**边际阻塞成本**（Locational Marginal Price, LMP）。如果 $\lambda_i^* = 0$，说明该线路没有满载，扩容没有经济价值；如果 $\lambda_i^* > 0$，说明该线路是瓶颈，扩容可以节省发电成本。

题 10 [⋆⋆⋆ **推导 + 计算**] **马尔可夫决策过程（MDP）的线性规划对偶**

背景：强化学习的理论基础之一是：值函数迭代（Value Iteration）本质上在求解一个线性规划，而该 LP 的对偶问题恰好对应”状态-动作占用度量”（occupancy measure）的最优化。理解这一对偶关系，是连接经典 DP、线性规划与现代深度强化学习的关键桥梁。

考虑有限状态、有限动作的折扣 MDP，记为 $(\mathcal{S}, \mathcal{A}, P, r, \gamma)$：

- $\mathcal{S} = \{1, \dots, S\}$：状态空间；$\mathcal{A} = \{1, \dots, A\}$：动作空间
- $P(s'|s,a)$：转移概率；$r(s,a) \in \mathbb{R}$：即时奖励；$\gamma \in [0,1)$：折扣因子
- $\rho(s)$：初始状态分布，$\rho(s) > 0$

(a) **原始 LP（Primal LP）——值函数视角**

Bellman 最优方程要求对所有 $s \in \mathcal{S}$：

$$V(s) = \max_{a \in \mathcal{A}} \left[r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s') \right]$$

将此写成线性规划：

$$\min_{V \in \mathbb{R}^S} \quad \sum_s \rho(s) V(s) \quad \text{s.t.} \quad V(s) \geq r(s,a) + \gamma \sum_{s'} P(s'|s,a) V(s'), \quad \forall s \in \mathcal{S},\ a \in \mathcal{A}$$

(i) 说明决策变量数目和约束数目（分别用 S, A 表示）。

(ii) 证明：上述 LP 的最优解 V^* 恰好是 Bellman 最优方程的解（即最优值函数）。*提示：设 V^*_{LP} 是 LP 最优解，V^* 是 Bellman 方程的解，分别证明 $V^*_{LP} \leq V^*$ 和 $V^*_{LP} \geq V^*$。*

(b) **对偶 LP（Dual LP）——占用度量视角**

引入对偶变量 $d(s,a) \geq 0$（对应每条约束 $V(s) \geq r(s,a) + \cdots$），写出原始 LP 的对偶问题：

$$\max_{d \geq 0} \quad \sum_{s,a} r(s,a)\, d(s,a) \quad \text{s.t.} \quad \sum_a d(s,a) - \gamma \sum_{s',a'} P(s|s',a')\, d(s',a') = \rho(s), \quad \forall s \in \mathcal{S}$$

(i) 推导该对偶问题（从 Lagrangian 出发，对 V 求极小并整理）。

(ii) 证明弱对偶：原始 LP 目标值 $\geq$ 对偶 LP 目标值（即 $\sum_s \rho(s) V(s) \geq \sum_{s,a} r(s,a) d(s,a)$ 对任意原始可行 V 和对偶可行 d 均成立）。

(iii) 指出强对偶成立的条件，并说明此时 $d^*(s,a)$ 的概率论含义：

$$d^*(s,a) = \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s,\ a_t = a \mid \pi^*,\ s_0 \sim \rho)$$

解释 $d^*(s,a)$ 为何称为" 折扣状态-动作占用度量"。

(c) **互补松弛与最优策略提取**

设原始 LP 最优解为 V^*，对偶 LP 最优解为 d^*，写出互补松弛条件：

$$d^*(s,a) \left[V^*(s) - r(s,a) - \gamma \sum_{s'} P(s'|s,a) V^*(s') \right] = 0, \quad \forall s, a$$

(i) 解释互补松弛的含义：若 $d^*(s,a) > 0$（该状态-动作对" 被访问"），则对应的 Bellman 约束必须以等号成立，即动作 a 在状态 s 下是最优的。

(ii) 由此给出从 d^* 中提取最优策略 π^* 的方法：

$$\pi^*(a|s) = \frac{d^*(s,a)}{\sum_{a'} d^*(s,a')}$$

说明为何这与直接从 V^* 贪心提取策略等价。

(d) **小型手算**

考虑一个两状态（s_1, s_2）、两动作（a_1, a_2）的 MDP，$\gamma = 0.9$，$\rho = (0.5, 0.5)$：

状态	动作	$r(s,a)$	$P(s_1\|s,a)$	$P(s_2\|s,a)$
s_1	a_1	1	0.8	0.2
s_1	a_2	0	0.1	0.9
s_2	a_1	0	0.5	0.5
s_2	a_2	2	0.3	0.7

(i) 写出原始 LP 的 4 个约束（$S \times A = 2 \times 2$），未知量为 (V_1, V_2)。

(ii) 通过值迭代（Value Iteration）迭代至收敛（误差 < 0.01），得到近似 $V^*(s_1)$，$V^*(s_2)$。

(iii) 对应写出对偶 LP，求解最优占用度量 $d^*(s_1,a_1), d^*(s_1,a_2), d^*(s_2,a_1), d^*(s_2,a_2)$。

(iv) 验证互补松弛条件，并提取最优策略 π^*。

标准答案：

(a) 原始 LP

(i) 决策变量与约束数目

- 决策变量：$V(s)$，每个状态一个，共 S 个。
- 约束：每对 (s,a) 一个，共 $S \times A$ 个。

(ii) 证明 LP 最优解即 Bellman 最优值函数

证明. **第一步**：V^*（Bellman 最优方程的解）是原始 LP 的可行解。

由 Bellman 最优方程 $V^*(s) = \max_a [r(s,a) + \gamma \sum_{s'} P(s'|s,a)V^*(s')]$，对每个动作 a 都有

$$V^*(s) \geq r(s,a) + \gamma \sum_{s'} P(s'|s,a)V^*(s')$$

因此 V^* 满足所有 LP 约束，是可行解。

第二步：任何可行解 V 满足 $V(s) \geq V^*(s)$。

设 V 是 LP 可行解，则 $V \geq TV$，其中 T 是 Bellman 算子。由于 T 是 γ-压缩映射且 V^* 是其唯一不动点，反复应用 T：

$$V \geq TV \geq T^2V \geq \cdots \to V^* \quad (\text{逐分量})$$

因此 $V(s) \geq V^*(s)$ 对所有 s 成立。

结论：由于 $\rho(s) > 0$，$\sum_s \rho(s)V(s) \geq \sum_s \rho(s)V^*(s)$ 对所有可行 V 成立，而 V^* 自身也可行，因此 V^* 是 LP 的最优解。 □

(b) 对偶 LP

(i) 从 Lagrangian 推导对偶 引入对偶变量 $d(s,a) \geq 0$，Lagrangian 为：

$$L(V,d) = \sum_s \rho(s)V(s) - \sum_{s,a} d(s,a)\Big[V(s) - r(s,a) - \gamma \sum_{s'} P(s'|s,a)V(s')\Big]$$

将 $V(s)$ 的系数整理：

$$L = \sum_s V(s)\Big[\rho(s) - \sum_a d(s,a) + \gamma \sum_{s',a'} d(s',a')P(s|s',a')\Big] + \sum_{s,a} d(s,a)\, r(s,a)$$

（其中第二项利用了交换求和顺序的技巧。）

对偶函数 $g(d) = \inf_V L(V,d)$。为使 $g(d)$ 有限（$> -\infty$），$V(s)$ 的系数必须为零：

$$\rho(s) - \sum_a d(s,a) + \gamma \sum_{s',a'} d(s',a')P(s|s',a') = 0, \quad \forall s$$

即 $\sum_a d(s,a) = \rho(s) + \gamma \sum_{s',a'} d(s',a')P(s|s',a')$。

此时 $g(d) = \sum_{s,a} r(s,a)\, d(s,a)$，对偶问题为：

$$\max_{d \geq 0} \sum_{s,a} r(s,a)\, d(s,a) \quad \text{s.t.} \sum_a d(s,a) - \gamma \sum_{s',a'} d(s',a')P(s|s',a') = \rho(s),\ \forall s$$

(ii) 弱对偶的证明 对任意原始可行 V 和对偶可行 $d \geq 0$：

$$\begin{aligned}
\sum_s \rho(s)V(s) &= \sum_s V(s)\Big[\sum_a d(s,a) - \gamma \sum_{s',a'} d(s',a')P(s|s',a')\Big] \\
&= \sum_{s,a} d(s,a)\, V(s) - \gamma \sum_{s',a'} d(s',a') \sum_s P(s|s',a')V(s) \\
&= \sum_{s,a} d(s,a)\Big[V(s) - \gamma \sum_{s'} P(s'|s,a)V(s')\Big] \\
&\geq \sum_{s,a} d(s,a)\, r(s,a)
\end{aligned}$$

最后一步利用了 $d(s,a) \geq 0$ 和原始可行性 $V(s) - \gamma \sum_{s'} P(s'|s,a)V(s') \geq r(s,a)$。□

(iii) 强对偶与占用度量　强对偶成立条件：原始 LP 和对偶 LP 都是标准线性规划，且原始 LP 总是可行的（取 $V(s) = \max_{s,a} |r(s,a)|/(1-\gamma)$ 即可）。由 LP 对偶定理，只要原始问题有有限最优值（在 $\gamma < 1$ 下显然成立），则强对偶成立。

$d^*(s,a)$ **的概率论含义**：

$$d^*(s,a) = \sum_{t=0}^{\infty} \gamma^t \Pr(s_t = s,\ a_t = a \mid \pi^*,\ s_0 \sim \rho)$$

$d^*(s,a)$ 表示在最优策略 π^* 下，从初始分布 ρ 出发，在时刻 t 处于状态 s 并执行动作 a 的折扣概率之和。它被称为**折扣状态-动作占用度量**，直觉上衡量了" 在最优策略下，状态-动作对 (s,a) 被访问的（折扣加权的）总频率"。$d^*(s,a)$ 越大，说明该状态-动作对在最优行为中越重要。

(c) 互补松弛与最优策略提取

(i) 互补松弛的含义　互补松弛条件 $d^*(s,a)\big[V^*(s) - r(s,a) - \gamma \sum_{s'} P(s'|s,a)V^*(s')\big] = 0$ 意味着：

- 若 $d^*(s,a) > 0$（该状态-动作对在最优策略下被执行），则 Bellman 约束取等号：$V^*(s) = r(s,a) + \gamma \sum_{s'} P(s'|s,a)V^*(s')$，即动作 a 在状态 s 下达到 Bellman 最优方程中的最大值，a 是最优动作。
- 若 $V^*(s) > r(s,a) + \gamma \sum_{s'} P(s'|s,a)V^*(s')$（动作 a 不是最优的），则 $d^*(s,a) = 0$，该动作在最优策略下不会被执行。

(ii) 从 d^* 提取最优策略　最优策略为：

$$\pi^*(a|s) = \frac{d^*(s,a)}{\sum_{a'} d^*(s,a')}$$

这与从 V^* 贪心提取等价，因为：由互补松弛，$d^*(s,a) > 0$ 仅当 a 是状态 s 下的最优动作。因此 π^* 将全部概率分配给最优动作，这与贪心策略 $\pi^*(s) = \arg\max_a [r(s,a) + \gamma \sum_{s'} P(s'|s,a)V^*(s')]$ 一致。

(d) 小型手算

(i) 原始 LP 的 4 个约束　未知量为 $V_1 = V(s_1)$，$V_2 = V(s_2)$，目标：$\min\ 0.5V_1 + 0.5V_2$。

$$V_1 \geq 1 + 0.9(0.8V_1 + 0.2V_2) = 1 + 0.72V_1 + 0.18V_2 \qquad (s_1, a_1) \qquad (1)$$

$$V_1 \geq 0 + 0.9(0.1V_1 + 0.9V_2) = 0.09V_1 + 0.81V_2 \qquad (s_1, a_2) \qquad (2)$$

$$V_2 \geq 0 + 0.9(0.5V_1 + 0.5V_2) = 0.45V_1 + 0.45V_2 \qquad (s_2, a_1) \qquad (3)$$

$$V_2 \geq 2 + 0.9(0.3V_1 + 0.7V_2) = 2 + 0.27V_1 + 0.63V_2 \qquad (s_2, a_2) \qquad (4)$$

(ii) 值迭代 初始化 $V^{(0)} = (0,0)$，迭代 $V^{(k+1)}(s) = \max_a[r(s,a)+\gamma\sum_{s'} P(s'|s,a)V^{(k)}(s')]$：

k	$V_1^{(k)}$	$V_2^{(k)}$	$\pi(s_1)$	$\pi(s_2)$
0	0	0	—	—
1	1.000	2.000	a_1	a_2
2	2.080	3.530	a_1	a_2
3	3.133	4.786	a_1	a_2
4	4.158	5.861	a_2	a_2
5	5.122	6.815	a_2	a_2

从第 4 次迭代起，最优策略稳定为 $\pi^*(s_1) = a_2$，$\pi^*(s_2) = a_2$。

直接求解 Bellman 方程（令 $\pi^*(s_1) = a_2$，$\pi^*(s_2) = a_2$）：

$$\begin{cases} V_1 = 0.09V_1 + 0.81V_2 \\ V_2 = 2 + 0.27V_1 + 0.63V_2 \end{cases} \implies \begin{cases} 0.91V_1 = 0.81V_2 \\ 0.37V_2 = 2 + 0.27V_1 \end{cases}$$

由第一个方程 $V_1 = \frac{81}{91}V_2$，代入第二个方程：

$$0.37V_2 = 2 + 0.27 \cdot \frac{81}{91}V_2 \implies \frac{1180}{9100}V_2 = 2 \implies V_2 = \frac{910}{59}$$

因此：

$$\boxed{V^*(s_1) = \frac{810}{59} \approx 13.73, \qquad V^*(s_2) = \frac{910}{59} \approx 15.42}$$

验证最优动作（确认策略正确）：

- s_1: a_1 给出 $1+0.72\times13.73+0.18\times15.42 \approx 13.66$；$a_2$ 给出 $0.09\times13.73+0.81\times15.42 \approx 13.73$。$a_2$ 更优 ✓
- s_2: a_1 给出 $0.45\times13.73+0.45\times15.42 \approx 13.12$；$a_2$ 给出 $2+0.27\times13.73+0.63\times15.42 \approx 15.42$。$a_2$ 更优 ✓

(iii) 对偶 LP 求解 对偶 LP 为：

$$\max\ d_{11}\cdot 1 + d_{12}\cdot 0 + d_{21}\cdot 0 + d_{22}\cdot 2 = d_{11} + 2d_{22}$$

流量守恒约束（s_1 和 s_2）：

$$d_{11} + d_{12} = 0.5 + 0.9(0.8d_{11} + 0.1d_{12} + 0.5d_{21} + 0.3d_{22})$$
$$d_{21} + d_{22} = 0.5 + 0.9(0.2d_{11} + 0.9d_{12} + 0.5d_{21} + 0.7d_{22})$$

化简：

$$0.28d_{11} + 0.91d_{12} - 0.45d_{21} - 0.27d_{22} = 0.5 \tag{5}$$
$$-0.18d_{11} - 0.81d_{12} + 0.55d_{21} + 0.37d_{22} = 0.5 \tag{6}$$

由互补松弛，非最优动作 (s_1, a_1) 和 (s_2, a_1) 的约束不紧，因此 $d^*_{11} = 0$，$d^*_{21} = 0$。代入 (5)–(6)：

$$91d_{12} - 27d_{22} = 50, \qquad -81d_{12} + 37d_{22} = 50$$

联立求解：$1180d_{22} = 8600$，得

$$\boxed{d^*_{11} = 0, \quad d^*_{12} = \frac{160}{59} \approx 2.71, \quad d^*_{21} = 0, \quad d^*_{22} = \frac{430}{59} \approx 7.29}$$

验证强对偶: 对偶目标值 $= 0 + 2 \times \frac{430}{59} = \frac{860}{59}$; 原始目标值 $= 0.5 \times \frac{810}{59} + 0.5 \times \frac{910}{59} = \frac{860}{59}$。两者相等 ✓

(iv) 互补松弛验证与最优策略 **互补松弛验证**:

- $d^*(s_1, a_1) \times [\text{约束间隙}] = 0 \times 0.068 = 0$ ✓
- $d^*(s_1, a_2) \times [\text{约束间隙}] = 2.71 \times 0 = 0$ ✓（约束取等号）
- $d^*(s_2, a_1) \times [\text{约束间隙}] = 0 \times 2.30 = 0$ ✓
- $d^*(s_2, a_2) \times [\text{约束间隙}] = 7.29 \times 0 = 0$ ✓（约束取等号）

提取最优策略:

$$\pi^*(a_2|s_1) = \frac{d^*(s_1, a_2)}{d^*(s_1, a_1) + d^*(s_1, a_2)} = \frac{160/59}{160/59} = 1$$

$$\pi^*(a_2|s_2) = \frac{d^*(s_2, a_2)}{d^*(s_2, a_1) + d^*(s_2, a_2)} = \frac{430/59}{430/59} = 1$$

最优策略：$\pi^*(s_1) = a_2$（不行动，转移到高价值状态），$\pi^*(s_2) = a_2$（获取高额奖励 2 并留在 s_2）。

这与从 V^* 贪心提取的结果完全一致。直觉上，虽然 s_1 下 a_1 的即时奖励为 1，但 a_2 能以高概率（0.9）转移到价值更高的 s_2 状态，从长远看收益更大。