第 3 周：连续化与随机化——NP-Hard 问题的现代武器

当离散问题遇见连续优化和概率论

目录

1 热身：P 问题的凸优化视角——LeetCode 经典例题 3

1.1 P 问题转化为凸优化的通用方法论 4
1.2 复杂度对比总览：通用 LP 求解器 vs 专用算法 5
1.3 例题 1：Two Sum / 子数组和（前缀和视角） 6
1.4 例题 2：最长递增子序列（LIS） 7
1.5 例题 3：零钱兑换（Coin Change） 9
1.6 例题 4：接雨水（Trapping Rain Water） 11
1.7 例题 5：最小生成树（MST） 13
1.8 例题 6：最大流 / 最小割 14
1.9 例题 7：最短路（Dijkstra / Bellman-Ford） 16
1.10 例题 8：区间调度 / 会议室（贪心的凸优化本质） 18
1.11 例题 9：编辑距离（Edit Distance / DP 的 LP 视角） 20
1.12 例题 10：二分图最大匹配（匈牙利算法的 LP 本质） 21
1.13 例题 11：股票买卖（Kadane 算法的凸优化本质） 23
1.14 例题 12：跳跃游戏（Reachability 的 LP 证书） 24
1.15 例题 13：第 K 大元素（分位数优化） 26
1.16 例题 14：分割等和子集（背包 LP 松弛与整数间隙） 27
1.17 例题 15：课程表（拓扑排序的 LP 可行性） 29
1.18 例题 16：任务调度器（调度 LP） 30
1.19 例题 17：打气球（区间 DP = 区间 DAG 上的 LP） 32
1.20 例题 18：分发糖果（两轮贪心 = 两次线性扫描） 33
1.21 例题 19：乘积最大子数组（对数变换化凸） 35
1.22 例题 20：买卖股票含手续费（正则化凸优化） 36
1.23 小结：P 问题的凸优化统一框架 38

2 传统方法：分支定界与分解 46

2.1 把组合优化问题写成整数规划 47
2.2 分支定界算法 49
2.3 完整例子：用分支定界求解背包问题 50
2.4 Benders 分解（选读） 55

3 新思路：近似算法与随机化 **60**

4 连续松弛与舍入：近似算法的核心技术 **61**

4.1 例 1：Vertex Cover（2-近似） 62
4.2 随机化分析方法：从哈希表说起 71
4.3 例 3：Max-SAT（3/4-近似） 78
4.4 例 4：Max-Cut（0.878-近似） 81
4.5 例 5：Scheduling（2-近似） 84
4.6 例 6：Facility Location（3-近似） 87
4.7 更多例子概览 89
4.8 超越期望：随机舍入的深层理论 89

5 GPU 友好性 **91**

6 实验 **94**

6.1 实验 3a：Vertex Cover 舍入策略对比 94
6.2 实验 3b：GPU 批量近似算法 96

7 本周总结 **97**

本讲导读

本周的核心洞察

传统算法设计：

- 离散结构、组合枚举
- 分支定界、动态规划
- 精确但慢，难以并行

现代范式：

- **连续化**：把离散问题嵌入连续空间
- **随机化**：用概率工具分析和舍入
- 近似但快，天然适合 GPU

惊人发现：对很多 NP-Hard 问题，这种“松弛”方法能证明**严格的近似保证**！

内容结构

第零部分：热身——P 问题也能用凸优化（LeetCode 经典例题）
第一部分：传统方法——分支定界（为什么不够好）
第二部分：连续化的魔力（6+ 个经典例子）
第三部分：随机化的威力（概率分析）
第四部分：GPU 友好性（为什么现代范式更适合并行）
第五部分：实验

1 热身：P 问题的凸优化视角——LeetCode 经典例题

为什么先看 P 问题？

很多同学以为凸优化只是处理 NP-Hard 问题的“应急手段”。其实，**大量经典的 P 类算法题，本质上就是在求解某个凸优化问题**：

- 动态规划 $\Leftrightarrow$ 递推求最值，可以写成线性规划或网络流
- 贪心算法 $\Leftrightarrow$ 每步选局部最优，常对应凸函数的次梯度下降
- 双指针 / 滑动窗口 $\Leftrightarrow$ 连续变量的一维凸优化
- 最短路 $\Leftrightarrow$ 线性规划的经典实例

- 最大流 / 最小割 $\Leftrightarrow$ LP 对偶的典范

理解这一点的意义：

1. 统一视角：所有 "求最值" 问题都在同一框架下
2. 掌握松弛：从 P 问题的松弛到 NP 问题的近似，方法论一致
3. GPU 加速：凸优化求解器可以批量并行求解，传统算法难以并行

1.1 P 问题转化为凸优化的通用方法论

转化路线图

步骤一：识别决策变量
将算法中的 "选择" 抽象为变量 $x \in \mathbb{R}^n$（或 $\{0,1\}^n$，之后再松弛）。
步骤二：写出目标函数
将 "最大化/最小化" 的量写为 $f(x)$。若 f 是线性或凸函数，问题立刻变得可解。
步骤三：写出约束
算法的 "合法性条件" 写成 $Ax \le b$ 或 $g_i(x) \le 0$（凸约束）。
步骤四：判断能否直接用 LP 精确求解

原始算法类型	对应优化问题	LP 能否精确求解?
贪心（无约束极值）	无约束凸优化	✓ 直接
DP（线性递推）	线性规划（LP）	✓ 按拓扑序填表
最短路	LP（三角不等式约束）	✓
最大流	LP + 对偶	✓
二分图匹配	LP（松弛后自动整数）	✓ （见下文）
背包（0-1）	ILP $\to$ LP 松弛	$\times$（有间隙，NP-Hard）

核心问题：把 0/1 变量松弛成 $[0,1]$ 上的连续值后，LP 的最优解是否恰好落在整数点?
什么时候 LP 松弛自动给整数解？
直觉上：当约束的结构非常 "规整" 时——具体来说，如果约束图是**无环的（DAG）或二部图**，并且每个变量在每条约束中只以 $+1$、-1 或 0 的系数出现，那么 LP 松弛的最优解就自动是整数。（技术名词叫 "约束矩阵全幺模"，但我们只需要记住这个直觉。）
一旦违反上述规整性——例如背包的单条约束把多个变量加权求和——LP 松弛就会得到分数解，出现**整数间隙**，问题随之变成 NP-Hard。

1.2 复杂度对比总览：通用 LP 求解器 vs 专用算法

为什么专用算法总比 LP 求解器快？

通用 LP 求解器的理论复杂度（n 个变量、m 个约束）：

- **单纯形法**：最坏指数，实践接近 $O(mn)$ 次迭代，每次 $O(mn)$ 工作量
- **内点法（Interior Point）**：$O\big((n+m)^{3.5}\log(1/\varepsilon)\big)$，理论上多项式
- **一阶方法（梯度下降/ADMM）**：$O(1/\varepsilon)$ 次迭代，每次 $O(m)$，只给近似解

专用算法为何快？——它们利用了**问题特定结构**，跳过了通用求解器所有不必要的工作：

问题	专用算法复杂度	通用 LP 内点法	加速比（数量级）
最短路（n 节点 m 边）	$O(m+n\log n)$（Dijkstra）	$O(m^{3.5})$	$m^{2.5}/\log n$
最大流（n,m,C）	$O(mn\log(n^2/m))$（HLPPS）	$O(m^{3.5})$	$\sim m^{1.5}$
最小生成树	$O(m\alpha(n))$（Kruskal+UF）	$O(m^{3.5})$	$m^{2.5}$
二分图匹配（n,m）	$O(m\sqrt{n})$（Hopcroft-Karp）	$O(m^{3.5})$	$m^{2.5}/\sqrt{n}$
最长递增子序列	$O(n\log n)$	$O(n^5)$（n^2 约束）	$n^4/\log n$
编辑距离（长 n）	$O(n^2)$ DP	$O(n^7)$（n^2 变量）	n^5
区间调度（n 区间）	$O(n\log n)$ 排序	$O(n^{3.5})$	$n^{1.5}$
接雨水	$O(n)$ 双指针	$O(n^{3.5})$	$n^{2.5}$

结论：专用算法利用图结构把 $O(m^{3.5})$ 压缩到 $O(m\log m)$ 甚至 $O(m)$，加速倍数通常是**多项式量级**（不是指数）。
但凸优化仍有不可替代的价值：

1. **并行性**：LP 内点法天然矩阵运算，适合 GPU；专用算法大多串行
2. **批量求解**：k 个不同实例同时用 GPU 跑，吞吐量提升 k 倍
3. **NP 问题近似**：专用算法无法处理 NP-Hard 问题，LP 松弛提供近似保证
4. **统一框架**：改动约束即可处理带额外限制的变体，无需重新设计算法

1.3 例题 1：Two Sum / 子数组和（前缀和视角）

LeetCode 1 / 560：Two Sum & 和为 K 的子数组

原题：给定数组 $a_1, \ldots, a_n$，找所有满足 $\sum_{i=l}^{r} a_i = K$ 的 (l, r)。
经典做法：前缀和 + 哈希表，$O(n)$ 时间
核心观察：定义前缀和 $s_0 = 0$，$s_i = a_1 + \cdots + a_i$，则 $\mathrm{sum}(l, r) = s_r - s_{l-1}$。要找 $s_r - s_{l-1} = K$，等价于：对当前的 s_r，查表中是否存在 $s_{l-1} = s_r - K$。
步骤：

1. 初始化哈希表 $\{0 \mapsto 1\}$（前缀和 $s_0 = 0$ 出现过一次）
2. 从左到右遍历，维护当前前缀和 s：
   - 查表：计数 $+=$ 哈希表中 $s - K$ 出现的次数
   - 存表：将 s 加入哈希表（计数 +1）
3. 返回总计数

追踪示例（$[1, 1, 1]$，$K = 2$）：初始表 $\{0{:}1\}$，依次处理：
$s = 1$：查 $1 - 2 = -1$ 无，表变 $\{0{:}1, 1{:}1\}$
$s = 2$：查 $2 - 2 = 0$ 有 1 次，count$= 1$，表变 $\{0{:}1, 1{:}1, 2{:}1\}$
$s = 3$：查 $3 - 2 = 1$ 有 1 次，count$= 2$，最终答案 2
正确性：存表先于查表确保不重复计算同一位置，先查后存确保 $l < r$（LeetCode 1 两数之和变体）。
凸优化视角：LP 可行性建模
定义前缀和变量 $s_i = \sum_{j=1}^{i} a_j$，$s_0 = 0$，子数组和 $s_r - s_l = K$。

$$\begin{aligned} \text{find} \quad & s_0, s_1, \ldots, s_n && (1) \\ \text{s.t.} \quad & s_i - s_{i-1} = a_i, \quad i = 1, \ldots, n && (2) \\ & s_r - s_l = K \quad (\text{至少一对 } (l, r)) && (3) \end{aligned}$$

这是**线性等式约束可行性问题**——在一条直线（凸集）上找满足条件的点。
LP 求解流程：

1. 变量：$s_0, s_1, \ldots, s_n$，共 $n + 1$ 个
2. 约束：$s_i - s_{i-1} = a_i$（n 条等式），$s_0 = 0$（固定起点）
3. 可行性判断：直接代入得 $s_i = \sum_{j=1}^{i} a_j$（唯一解），然后枚举所有 (l, r) 检查 $s_r - s_l = K$

4. 通用 LP 求解器不知道这是等式链，对整个 $n \times n$ 系数矩阵做分解，浪费了大量计算

直觉：前缀和的几何意义

$n+1$ 个前缀和点 $s_0, s_1, \ldots, s_n$ 落在数轴上，子数组和问题 $\Leftrightarrow$ 在点集中查找差值恰好为 K 的两点。哈希表把“查找”压缩到 $O(1)$，而通用 LP 求解器不知道这个“差值查找”结构，只能反复做矩阵运算，慢 $n^{2.5}$ 倍。

复杂度对比：

方法	时间	说明
暴力枚举所有 (l, r)	$O(n^2)$	不用凸优化
前缀和 + 哈希表（专用）	$O(n)$	利用“差值”结构
通用 LP 可行性求解器	$O(n^{3.5})$	内点法，n 个变量 n 个约束

哈希表之所以比 LP 求解器快 $n^{2.5}$ 倍，是因为它完全利用了“约束是等式、一维直线”这一极度特殊的结构。

1.4 例题 2：最长递增子序列（LIS）

LeetCode 300：最长递增子序列（LIS）

原题：给定序列 $a_1, \ldots, a_n$，找最长严格递增子序列的长度。

经典做法一：DP，$O(n^2)$

设 $dp[i]$ = 以 a_i 结尾的最长递增子序列长度。

步骤：初始化 $dp[i] = 1$（每个元素单独成长度 1 的子序列）。对每个位置 i，扫描所有 $j < i$：若 $a_j < a_i$，则 a_i 可以接在以 a_j 结尾的子序列后面，更新 $dp[i] = \max(dp[i], dp[j] + 1)$。

追踪（$[10, 9, 2, 5, 3, 7, 101, 18]$）：

- $i = 0$（值 10）：$dp = [1, \ldots]$
- $i = 1$（值 9）：9<10? 不；$dp = [1, 1, \ldots]$
- $i = 2$（值 2）：无前驱；$dp = [1, 1, 1, \ldots]$
- $i = 3$（值 5）：5>2，$dp[3] = dp[2] + 1 = 2$；$dp = [1, 1, 1, 2, \ldots]$
- $i = 4$（值 3）：3>2，$dp[4] = dp[2] + 1 = 2$；$dp = [1, 1, 1, 2, 2, \ldots]$
- $i = 5$（值 7）：7>2,5,3，$dp[5] = \max(dp[2], dp[3], dp[4]) + 1 = 3$

- $i = 6$（值 101）：101> 全部，$dp[6] = dp[5] + 1 = 4$
- $i = 7$（值 18）：18>2,5,3,7，$dp[7] = dp[5] + 1 = 4$

答案 $\max(dp) = 4$，对应子序列 $[2, 3, 7, 101]$ 或 $[2, 3, 7, 18]$。

经典做法二：耐心排序（Patience Sort），$O(n \log n)$

维护数组 $tails$，其中 $tails[k]$ = 目前已找到的所有长度为 $k+1$ 的递增子序列中，结尾元素的最小值（"最有潜力" 的结尾）。

步骤：对每个 a_i，在 $tails$ 中用二分查找找到第一个 $\geq a_i$ 的位置 p：

- 若 $p = |tails|$（比所有堆顶大）：新增一堆，$tails$ 追加 a_i，LIS 长度 +1
- 否则：替换 $tails[p] \leftarrow a_i$（用更小的结尾代替，以便未来可以接更多元素）

最终 $|tails|$ 即 LIS 长度。

追踪（$[3, 1, 4, 1, 5, 9, 2, 6]$）：

a_i	操作	$tails$
3	空堆，追加	$[3]$
1	替换位置 0（$3 \geq 1$）	$[1]$
4	追加	$[1, 4]$
1	替换位置 0（$1 \geq 1$）	$[1, 4]$
5	追加	$[1, 4, 5]$
9	追加	$[1, 4, 5, 9]$
2	替换位置 1（$4 \geq 2$）	$[1, 2, 5, 9]$
6	替换位置 2（$9 \geq 6$）	$[1, 2, 5, 6]$

$|tails| = 4$，即 LIS 长度为 4。

凸优化视角：DAG 最长路 LP

构造 DAG：若 $j < i$ 且 $a_j < a_i$，连边 $j \to i$。设变量 $d_i \in \mathbb{R}$ = 以 i 结尾的 LIS 长度：

$$\max \quad \max_i d_i \tag{4}$$

$$\text{s.t.} \quad d_i \geq d_j + 1, \quad \forall j < i,\ a_j < a_i \quad (\text{可以在 } j \text{ 后接 } i) \tag{5}$$

$$d_i \geq 1, \quad \forall i \quad (\text{至少长度为 } 1) \tag{6}$$

LP 求解流程：

1. 引入辅助变量 z，最大化 z 且 $z \geq d_i$ 对所有 i
2. 约束矩阵：每条约束 $d_j - d_i \leq -1$ 中，d_j 系数为 +1，d_i 系数为 −1，符合 "系数只有 ±1" 的规整结构

3. LP 松弛的最优解自动为整数（DAG 上的最长路 LP 有此性质）

4. 通用 LP 求解器对全部 $O(n^2)$ 条约束做矩阵分解，等价于 DP 但慢 n^3 倍

$O(n \log n)$ **耐心排序的 LP 解读**：
每个 "牌堆" 对应 LP 对偶中的一条 "递减链覆盖"；Dilworth 定理说明最长链 = 最少链覆盖，即 LP 原始最优值 = 对偶最优值（强对偶）。耐心排序直接构造了 LP 对偶的最优解，因此精确，且利用了单调性 + 二分，远快于通用求解器。
复杂度对比：

方法	时间	说明
DP 暴力（专用）	$O(n^2)$	直接按 DP 填表
Patience Sort（专用）	$O(n \log n)$	利用二分查找
通用 LP 内点法	$O(n^5)$	$O(n^2)$ 条约束、n 个变量

LP 比 DP 慢 n^3 倍：LP 没有利用 "DAG 拓扑序可一次填完" 这一结构，通用求解器对 $O(n^2) \times O(n^2)$ 的约束矩阵做全局矩阵分解。

1.5 例题 3：零钱兑换（Coin Change）

LeetCode 322：零钱兑换

原题：给定硬币面值集合 $C = \{c_1, \ldots, c_k\}$ 和目标金额 S，求使用最少硬币数。
经典做法：DP（Bellman 最优性方程），$O(kS)$
设 $V[s]$ = 凑出金额 s 的最少硬币数。
步骤：

1. 初始化：$V[0] = 0$，$V[s] = +\infty$ 对 $s \geq 1$

2. 逐金额填表：对每个 $s = 1, 2, \ldots, S$，枚举所有面值 $c \in C$：若 $c \leq s$ 且 $V[s-c] < +\infty$，则 $V[s] \leftarrow \min(V[s], V[s-c]+1)$

3. 若 $V[S] = +\infty$，返回 -1；否则返回 $V[S]$

追踪（$C = \{1, 3, 4\}$，$S = 6$）：

s	0	1	2	3	4	5	6
$V[s]$	0	1	2	1	1	2	2
更新来源	初始	用面值 1	用面值 1 两次	用面值 3	用面值 4	用 3+1 或 4+1	用 3+3

贪心为何失败：面值 $\{1,3,4\}$，目标 $S=6$。贪心先用 4，剩 2，再用两个 1，共 3 枚；正确答案是两个 3，共 2 枚。LP 松弛给出 $n_4=1.5$（非整数），已提示有整数间隙，说明贪心不可靠。

凸优化视角：整数线性规划 + Bellman DP

$$\min \quad \sum_{j=1}^{k} n_j \tag{7}$$

$$\text{s.t.} \quad \sum_{j=1}^{k} c_j \cdot n_j = S \tag{8}$$

$$n_j \in \mathbb{Z}_{\geq 0} \tag{9}$$

LP 松弛分析：把 n_j 放宽为 $[0,+\infty)$ 上的实数：

- 贪心面值（如美元硬币 $\{1,5,10,25\}$）：LP 松弛最优解恰好是整数，贪心最优
- 一般面值（如 $\{1,3,4\}$）：LP 松弛给出分数解（$n_4=1.5$，总数 1.5），而整数最优为 2，**整数间隙** $=0.5$，贪心失败，必须用 DP

DP = LP 按 Bellman 方程逐步求解：

$$V(s)=\min_{c\in C}[V(s-c)+1]$$

把函数 V 看作定义在 $\{0,1,\ldots,S\}$ 上的分段线性函数。每步取所有“平移加 1”版本的逐点最小值，即凸分析中的下确界运算，保持函数的分段线性凸性。DP 表的每一格恰好是这个函数在对应点的值。

复杂度对比（k 种硬币、目标金额 S）：

方法	时间	说明
贪心（仅特殊面值正确）	$O(k\log k)$	排序 + 一次遍历
DP（正确，伪多项式）	$O(kS)$	填 S 格表，每格枚举 k 种
通用 ILP 求解器	最坏指数	NP-Hard（S 大时不可用）
LP 松弛（仅给下界）	$O(k^{3.5})$	忽略整数约束，给近似下界

DP 的 $O(kS)$ 是**伪多项式**：S 的数值可以指数大（编码长度仅 $\log S$ 位），所以理论上零钱兑换是 NP-Hard，但实践中 S 不超过 10^4 时 DP 完全够用。

1.6 例题 4：接雨水（Trapping Rain Water）

LeetCode 42：接雨水

原题：给定高度数组 $h_1, \ldots, h_n$，计算能接的总雨水量。

经典做法一：预计算左右最大值，$O(n)$ 时间 $O(n)$ 空间

关键公式：位置 i 能接的水深 $= \max(0, \min(L_i, R_i) - h_i)$，其中：

- $L_i = \max(h_0, h_1, \ldots, h_i)$：位置 i **左侧**（含自身）最高柱子
- $R_i = \max(h_i, h_{i+1}, \ldots, h_{n-1})$：位置 i **右侧**（含自身）最高柱子
- 水面高度 $= \min(L_i, R_i)$（受两侧最低的那堵墙限制），减去地面高度 h_i 即为水深

步骤：

1. 从左到右一遍：$L_0 = h_0$，$L_i = \max(L_{i-1}, h_i)$
2. 从右到左一遍：$R_{n-1} = h_{n-1}$，$R_i = \max(R_{i+1}, h_i)$
3. 累加：$\text{ans} = \sum_{i=0}^{n-1} \max(0, \min(L_i, R_i) - h_i)$

追踪（$h = [0, 1, 0, 2, 1, 0, 1, 3, 2, 1, 2, 1]$）：

i	0	1	2	3	4	5	6	7	8	9	10	11
h	0	1	0	2	1	0	1	3	2	1	2	1
L	0	1	1	2	2	2	2	3	3	3	3	3
R	3	3	3	3	3	3	3	3	2	2	2	1
$\min(L, R) - h$	0	0	1	0	1	2	1	0	0	1	0	0

总水量 $= 0 + 0 + 1 + 0 + 1 + 2 + 1 + 0 + 0 + 1 + 0 + 0 = 6$。

经典做法二：双指针，$O(n)$ 时间 $O(1)$ 空间

关键观察：若当前 $L_{\text{left}} < R_{\text{right}}$（左侧已知最高墙 < 右侧已知最高墙），则不管右侧还有什么柱子，位置 `left` 的水面高度已经由 L_{left} 完全决定（右侧够高），可以立即计算并推进左指针；反之亦然。

步骤：

1. 初始化左右指针 $l = 0$，$r = n - 1$，维护 $L_{\max} = R_{\max} = 0$
2. 若 $h[l] < h[r]$（左侧当前高度更小，左侧是 “短板”）：
   - 若 $h[l] \geq L_{\max}$：更新 $L_{\max} \leftarrow h[l]$（遇到新的左墙），无积水
   - 否则：积水 $+= L_{\max} - h[l]$（左墙已固定，低洼处积水）

- $l \mathrel{+}= 1$

3. 否则（右侧是短板）：对称处理右指针
4. 直到 $l \geq r$

双指针利用了“短板方向的水位已完全确定”这一单调性，无需存储 L、R 数组，$O(1)$ 空间完成。

凸优化视角：正确的 LP 建模

设 w_i 为位置 i 的水面高度，物理约束为：水面不能高于两侧任意一堵墙。最大化总水量等价于：

$$\max \quad \sum_i (w_i - h_i) \tag{10}$$

$$\text{s.t.} \quad w_i \leq L_i \quad \forall i \quad (\text{不超过左侧最高墙}) \tag{11}$$

$$w_i \leq R_i \quad \forall i \quad (\text{不超过右侧最高墙}) \tag{12}$$

$$w_i \geq 0 \tag{13}$$

其中 L_i, R_i 是输入的已知常数（左右前缀/后缀最大值）。由于每个 w_i 的上界已固定，最优解直接读出：$w_i^* = \min(L_i, R_i)$，这是一个**退化的分量独立 LP**——n 个独立的单变量有界优化，各自最优，无需迭代。

注意：之前曾看到“不鼓包”约束 $w_i \leq (w_{i-1} + w_{i+1})/2$，这是错误的。水面的正确约束来自两侧实际最高墙壁（L_i 和 R_i），而不是相邻元素的平均值——水不会因为相邻格子更低而自动降低，它只受两侧实际墙壁高度限制。

直觉：接雨水的几何本质

水面 $w_i^* = \min(L_i, R_i)$ 正是高度序列 h 的“上凸包（concave envelope）”：把“凹坑”用连接两侧最高墙的水平线段填平。双指针利用了 L_i 单调非减、R_i 单调非增这一结构，从两端向中间推进，每步 $O(1)$ 确定一格水量，把 LP 的 $O(n^{3.5})$ 矩阵求解压缩到 $O(n)$ 的线性扫描。

复杂度对比：

方法	时间	说明
暴力（每位置扫两侧）	$O(n^2)$	无优化
预计算左右最大值	$O(n)$，$O(n)$ 空间	三次线性扫描
双指针	$O(n)$，$O(1)$ 空间	利用单调性，一次扫描
通用 LP 内点法	$O(n^{3.5})$	n 变量 $2n$ 约束

1.7 例题 5：最小生成树（MST）

LeetCode 1584 / 经典：最小生成树

原题：给定带权图 $G = (V, E, w)$，找权重之和最小的生成树。
线性规划建模：
设 $x_e \in [0, 1]$ 为边 e 的选取比例，

$$\min \quad \sum_{e \in E} w_e x_e \tag{14}$$

$$\text{s.t.} \quad \sum_{e \in E} x_e = |V| - 1 \quad (\text{树恰好有}|V| - 1\ \text{条边}) \tag{15}$$

$$\sum_{e \in \delta(S)} x_e \geq 1, \quad \forall S \subsetneq V,\ S \neq \emptyset \quad (\text{图保持连通}) \tag{16}$$

$$0 \leq x_e \leq 1 \tag{17}$$

经典做法一：Kruskal 算法，$O(m\alpha(n))$
核心思想：按权重从小到大逐条检验边，若加入该边不形成环则纳入生成树。
步骤：

1. 将所有 m 条边按权重升序排列
2. 初始化并查集：每个节点各自独立
3. 依次取每条边 (u, v, w)：
   - 若 u, v 在不同连通分量（用并查集 $O(\alpha(n))$ 查询）：纳入，合并两分量
   - 否则：跳过（加入会形成环）
4. 取到 $n - 1$ 条边时停止，得到 MST

追踪示例（5 节点图，边按权排序：(1,2,1),(2,3,2),(1,3,3),(3,4,4),(4,5,5),(2,5,6)）：
$(1, 2, 1)$：不成环，纳入。$(2, 3, 2)$：不成环，纳入。$(1, 3, 3)$：1 和 3 已连通，跳过。$(3, 4, 4)$：纳入。$(4, 5, 5)$：纳入。共 4 条边，MST 完成。总权重 $1 + 2 + 4 + 5 = 12$。
经典做法二：Prim 算法，$O(m \log n)$
核心思想：从任意节点开始，每次将 “距当前树最近的节点” 加入树。
步骤：

1. 初始化：将起始节点加入树，其余节点距离为 $+\infty$
2. 用优先队列维护 “未加入树的节点到树的最小边权”
3. 弹出最小距离节点 u，将 u 和对应边加入树

4. 更新 u 的所有邻居到树的距离（若通过 u 可以更近则更新）

5. 重复直到所有节点加入树

令人惊喜的事实：即使把 x_e 放宽为 $[0,1]$ 上的实数，这个 LP 的最优解也**自动是 $\{0,1\}$ 向量**，对应一棵真实的生成树，不需要任何取整！
为什么？直觉：生成树集合中每棵树对应一个 $\{0,1\}$ 向量，这些向量恰好构成凸包的顶点（极点），LP 最优解只落在顶点，所以必然是整数。
Kruskal / Prim = 贪心构造 LP 最优解：
两个算法每步都选“当前代价最低的安全边（不形成环/不离开当前树）”——这正是在 LP 可行域上沿目标函数下降方向走最大步长。能这样做的原因是生成树问题有“子集可以扩展且不违反整体结构”的性质，使得贪心保证全局最优。

核心结论：为什么 MST 是 P 问题

MST 的 LP 有指数多个约束（每个子集 S 对应一条“连通性”约束），但**不需要一次性写出所有约束**：每次只需检查“当前解是否已连通”，这个检查本身只要 $O(m)$。这让椭球法在多项式时间内求解，而最终答案保证是整数。

复杂度对比（n 节点 m 条边）：

方法	时间	说明
Kruskal（专用）	$O(m\alpha(n))$	排序 + 并查集，α 近似常数
Prim + 堆（专用）	$O(m\log n)$	优先队列
通用 LP 内点法	$O(m^{3.5})$	指数条约束用分离预言机处理

差距约 $m^{2.5}$ 倍。Kruskal 的核心加速来自“按权排序后，边的选取只需判断两端是否连通”，把 LP 的矩阵运算替换为并查集的近乎 $O(1)$ 操作。

1.8 例题 6：最大流 / 最小割

LeetCode 1632 / 经典：最大流

原题：在网络 $G=(V,E,c)$ 中，从源点 s 到汇点 t 的最大流量。
线性规划（最大流 LP）：

$$\max \quad f \tag{18}$$

$$\text{s.t.} \quad \sum_{e\in\delta^+(v)} x_e - \sum_{e\in\delta^-(v)} x_e = 0, \quad \forall v \neq s,t \quad (\text{流量守恒}) \tag{19}$$

$$\sum_{e\in\delta^+(s)} x_e = f \quad (\text{源点流出}) \tag{20}$$

$$0 \le x_e \le c_e \quad (\text{容量约束}) \tag{21}$$

经典做法一：Ford-Fulkerson（增广路算法）
核心思想：不断寻找从 s 到 t 的“增广路”（残差图中 s 到 t 有可行路径），沿路增加流量，直到找不到增广路为止。
步骤：

1. 初始化所有边流量为 0
2. 构造**残差图**：每条边 (u,v,c) 对应正向残差边（容量 $c-f_{uv}$）和反向残差边（容量 f_{uv}，用于撤销流量）
3. DFS/BFS 在残差图中找 $s\to t$ 的路径（增广路）
4. 沿增广路所有边取最小残差容量 δ，将流量增加 δ
5. 更新残差图，重复第 3 步，直到残差图中无 $s\to t$ 路径

追踪示例（简单 3 节点图：$s\to a$ 容量 3，$s\to b$ 容量 2，$a\to t$ 容量 2，$b\to t$ 容量 3，$a\to b$ 容量 2）：
增广路 $s\to a\to t$：流量 $+\min(3,2)=2$；再找 $s\to b\to t$：流量 $+\min(2,3)=2$；再找 $s\to a\to b\to t$：流量 $+\min(1,2,1)=1$。最大流 $=5$。
经典做法二：Dinic 算法，$O(n^2m)$
在 Ford-Fulkerson 基础上，先用 BFS 构造“分层图”（按到 s 的距离分层），然后在分层图中找“阻塞流”（一次性消除所有最短增广路）。每轮 BFS 后分层图层数严格增加，最多 $O(n)$ 轮，每轮 $O(nm)$，共 $O(n^2m)$。
这是一个**标准 LP**，且 LP 的最优解自动是整数。原因：约束矩阵（有向图的边-节点关联矩阵）每行只有一个 $+1$ 和一个 -1，其余为 0——这种“每列只进出一次”的结构保证了松弛解的整数性。
LP 对偶 = 最小割（强对偶 = 最大流最小割定理）：
对上述最大化 LP 求**对偶**（将约束翻转，原变量变为约束），得到：

$$\min \quad \sum_{e \in E} c_e y_e \tag{22}$$

$$\text{s.t.} \quad y_e \geq d_v - d_u, \quad \forall (u,v) \in E \tag{23}$$

$$d_s - d_t \geq 1, \; y_e \geq 0 \tag{24}$$

$d_v = 1$ 表示节点 v 在割的 s 侧，$d_v = 0$ 表示在 t 侧，$y_e = 1$ 表示边 e 跨越割。这正是**最小割问题**！

核心结论：最大流最小割 = LP 强对偶

$$\text{最大流} = \text{最小割}$$

这个组合定理等价于说：最大流 LP 和最小割 LP 的最优值相等，即 **LP 的强对偶性**（原始问题和对偶问题有相同的最优值）。最大流最小割定理不需要“证明”，它就是 LP 强对偶的一个特例。

复杂度对比（n 节点 m 条边，最大容量 C）：

方法	时间	说明
Ford-Fulkerson（专用）	$O(mC)$	每次找增广路，最坏 C 次
Edmonds-Karp（专用）	$O(nm^2)$	BFS 找最短增广路
Dinic（专用）	$O(n^2m)$	分层图 + 阻塞流
HLPPS（专用）	$O(n^2\sqrt{m})$	目前最优
通用 LP 内点法	$O((n+m)^{3.5})$	n 个守恒约束 m 个容量约束

在稀疏图（$m \approx n$）上，Dinic 的 $O(n^3)$ 与 LP 内点法的 $O(n^{3.5})$ 相差不大，是所有例题中 LP **最接近**专用算法速度的情形之一。这因为最大流的约束结构与图本身高度一致，LP 的矩阵正好是图的稀疏关联矩阵。

1.9 例题 7：最短路（Dijkstra / Bellman-Ford）

LeetCode 743 / 经典：最短路

原题：在带权有向图中，从源点 s 到所有其他节点的最短路。

线性规划（最短路 LP）：

设 d_v 为 s 到 v 的最短距离，“最短路”等价于：在满足三角不等式的所有 d 中，找让 $\sum d_v$ 最大的那个：

$$\max \quad \sum_v d_v \tag{25}$$

$$\text{s.t.} \quad d_v \le d_u + w_{uv}, \quad \forall (u,v) \in E \quad \text{(三角不等式：不能比走直路更短)} \tag{26}$$

$$d_s = 0 \tag{27}$$

经典做法一：Dijkstra 算法（非负权），$O(m \log n)$

核心思想：维护一个“已确认最短路”节点集合 S。每次从未确认节点中取距离最小的加入 S（贪心：此时该距离已不可能再被更新）。

步骤：

1. 初始化：$d[s] = 0$，其余 $d[v] = +\infty$；将所有节点加入优先队列
2. 弹出距离最小的节点 u（尚未确认）
3. 对 u 的每条出边 (u, v, w)：若 $d[u] + w < d[v]$，更新 $d[v] \leftarrow d[u] + w$（松弛操作）
4. 标记 u 为已确认，重复步骤 2

正确性关键：非负权图中，当 u 被弹出时，$d[u]$ 已是最终最短路距离——因为任何绕路（经过未确认节点）的路径至少一样长（非负权保证）。

追踪示例（4 节点：$s \to a$ 权 1，$s \to b$ 权 4，$a \to b$ 权 2，$a \to t$ 权 5，$b \to t$ 权 1）：初始 $d = [0, \infty, \infty, \infty]$。弹出 $s(0)$，更新 $a : 1, b : 4$。弹出 $a(1)$，更新 $b : \min(4, 3) = 3$，$t : 6$。弹出 $b(3)$，更新 $t : \min(6, 4) = 4$。弹出 $t(4)$。最短路 $s \to a \to b \to t = 4$。

经典做法二：Bellman-Ford 算法（允许负权），$O(nm)$

核心思想：最短路最多经过 $n-1$ 条边。反复松弛所有边 $n-1$ 轮，每轮确保”经过 k 条边的最短路”被正确更新。

步骤：

1. 初始化：$d[s] = 0$，其余 $+\infty$
2. 重复 $n-1$ 次：遍历所有边 (u, v, w)，若 $d[u] + w < d[v]$ 则更新
3. 第 n 次若仍有更新，说明存在负权环

最优解恰好是真实最短路距离。这个 LP 的约束也满足“系数只有 $+1$ 和 -1”，松弛解自动为实数最短路（本来就是实数，无需整数性）。

Dijkstra = 每次“最优确认”一个节点：

每次从优先队列弹出距离最小的未确认节点 u，相当于：确认 d_u 的当前值已经是 LP 最优，然后用它更新邻居。这是 LP 单纯形法中“每步让一个约束变紧”的逻辑。

Bellman-Ford = 轮流松弛所有约束：
每轮对所有边做一次松弛 $d_v \leftarrow \min(d_v, d_u + w_{uv})$，相当于对 LP 做**逐坐标梯度下降**：每个变量 d_v 取当前最小可行值。无负环时，$|V| - 1$ 轮后每个变量恰好收敛到最优。

直觉：Bellman 方程的本质

$d_v = \min_u(d_u + w_{uv})$ 是一个**不动点方程**：把当前距离"压缩更新"后还是它自己。没有负环时这个压缩是收缩映射，保证唯一不动点存在，即最短路距离。这与凸函数的梯度下降收敛到唯一最小值完全类比。

复杂度对比（n 节点 m 条边）：

方法	时间	说明
Bellman-Ford（专用，允许负权）	$O(nm)$	$n-1$ 轮，每轮 m 条边
Dijkstra + 二叉堆（专用，非负权）	$O(m \log n)$	每次确认最小节点
Dijkstra + Fibonacci 堆（专用）	$O(m + n \log n)$	理论最优
通用 LP 内点法	$O(m^{3.5})$	n 个变量 m 个约束

Dijkstra 比 LP 快约 $m^{2.5}/\log n$ 倍。核心原因：Dijkstra 利用了"非负权图上距离具有单调性"，每个节点只需处理一次；而 LP 不知道这一点，需要反复迭代。

1.10 例题 8：区间调度 / 会议室（贪心的凸优化本质）

LeetCode 435 / 253：区间调度与会议室

原题 1（435）：给定 n 个区间 $[s_i, e_i]$，最少移除多少个使剩余区间互不重叠？
原题 2（253）：最少需要多少间会议室？
整数规划建模（435）：

$$\max \quad \sum_i x_i \tag{28}$$

$$\text{s.t.} \quad x_i + x_j \le 1, \quad \forall i, j \text{ 区间重叠} \tag{29}$$

$$x_i \in \{0, 1\} \tag{30}$$

LP 松弛为何自动给整数解？
区间的重叠关系有一个特殊性质：把所有区间按一条时间轴排列，"重叠"约束形成的图（区间图）没有奇数长度的环（奇环）。奇环是导致 LP 松弛出现分数解的根本原因；没有奇环 $\Rightarrow$ LP 松弛最优解恰好是 0/1，无需整数规划。

经典做法（435）：按结束时间贪心，$O(n \log n)$

核心思想：每次选结束最早的、与上一个选定区间不冲突的区间，最大化保留区间数（等价于最小化移除数）。

步骤：

1. 按结束时间 e_i 排序
2. 初始化 $\text{lastEnd} = -\infty$，计数 $\text{count} = 0$
3. 对每个区间 (s_i, e_i)（排序后）：
   - 若 $s_i \geq \text{lastEnd}$（与上个选定区间不冲突）：选它，$\text{lastEnd} \leftarrow e_i$，$\text{count}{+}{+}$
   - 否则：跳过
4. 答案 $= n - \text{count}$（移除数 = 总数 − 保留数）

为何按结束时间排序最优？（交换论证）若存在某个最优方案中，第一个区间 A 的结束时间比贪心选出的 B 晚，那么把 A 换成 B 不会导致更多冲突（B 结束更早），保留数不减，故贪心不差于最优方案。

追踪示例（区间 $\{[1,3],[2,4],[3,6],[5,7]\}$，按结束排序 $\{[1,3],[2,4],[3,6],[5,7]\}$）：选 $[1,3]$，lastEnd$=3$；$[2,4]$ 与 $[1,3]$ 冲突（$2<3$），跳过；$[3,6]$ 起点 $=3\geq 3$，选，lastEnd$=6$；$[5,7]$ 与 $[3,6]$ 冲突，跳过。共保留 2 个，移除 $4-2=2$ 个。

经典做法（253）：扫描线，$O(n \log n)$

将所有开始时间标为 $+1$，结束时间标为 -1，排序后扫描，维护当前并发数的最大值，即所需会议室数。

贪心算法 = 直接构造 LP 最优解：

"每次选结束最早的不冲突区间"——这一贪心按时间轴从左到右逐步确认 $x_i = 1$，每步都使 LP 目标函数严格增加，且不破坏任何约束，最终得到 LP 最优解。

原题 2（253）：会议室数 = 同一时刻最多重叠的区间数（"最大团"）。由于区间图的特殊结构，这个最大值恰好等于将所有区间着色所需的颜色数，可以用扫描线 $O(n \log n)$ 求解。

复杂度对比（n 个区间）：

方法	时间	说明
贪心按结束时间（专用，435）	$O(n \log n)$	排序 + 一次扫描
扫描线（专用，253）	$O(n \log n)$	优先队列维护当前结束时间
通用 LP 内点法	$O(n^{3.5})$	n 个变量，最多 n^2 个约束

贪心比 LP 快约 n^2 倍。关键：贪心知道"按结束时间排序后，选当前最早结束的不冲突区间永远最优"，这是区间图上特有的贪心交换论证，LP 求解器无法利用这一点。

1.11 例题 9：编辑距离（Edit Distance / DP 的 LP 视角）

LeetCode 72：编辑距离

原题：给定字符串 A（长 n）、B（长 m），求最少编辑操作数（插入/删除/替换）。
LP 建模：
定义变量 d_{ij} 为将 $A[1..i]$ 转为 $B[1..j]$ 的最小代价：

$$
\begin{aligned}
\min \quad & d_{nm} && (31)\\
\text{s.t.} \quad & d_{ij} \geq d_{i-1,j} + 1 \quad (\text{删除}A_i) && (32)\\
& d_{ij} \geq d_{i,j-1} + 1 \quad (\text{插入}B_j) && (33)\\
& d_{ij} \geq d_{i-1,j-1} + [A_i \neq B_j] \quad (\text{替换/匹配}) && (34)\\
& d_{0,j} = j,\ d_{i,0} = i && (35)
\end{aligned}
$$

这是一个 **DAG 上的最短路问题**（DAG 节点 = 所有 (i,j) 格，边 = 三种操作），与例题 7 完全同构。约束只涉及相邻格，每个变量系数只有 $+1/-1/0$，松弛解自动为整数。
经典做法：DP，$O(nm)$
设 $d[i][j]$ = 将 $A[1..i]$ 转为 $B[1..j]$ 的最少编辑次数。
转移方程（对每个格 (i,j) 取三种操作的最小值）：

$$
d[i][j] = \min \begin{cases} d[i-1][j] + 1 & (\text{删除}A_i) \\ d[i][j-1] + 1 & (\text{插入}B_j) \\ d[i-1][j-1] + [A_i \neq B_j] & (\text{替换/匹配}) \end{cases}
$$

初始化：$d[0][j] = j$（插入 j 次），$d[i][0] = i$（删除 i 次）。
追踪示例（A = “kitten”，B = “sitting”，节选前 4 列）：

	∅	s	i	t	t
∅	0	1	2	3	4
k	1	1	2	3	4
i	2	2	1	2	3
t	3	3	2	1	2
t	4	4	3	2	1

每格依赖其左、上、左上三格，填表方向（按行从左到右）正是 DAG 的拓扑顺序。
DP 表 = LP 按 DAG 拓扑序填表：
DP 的填表顺序（按行从左到右，或按对角线）正是 DAG 的拓扑序——在 LP 意义上就是 “按依赖顺序逐一确定变量值”，等价于对 DAG 最短路 LP 做**前向代入法**求解。

核心结论：DP 与 LP 的一一对应

动态规划概念	对应 LP 概念
状态 $dp[i][j]$	变量 d_{ij}
转移方程（取 min/max）	约束 $d_{ij} \geq \ldots$（取 min 对应 $\leq$）
初始状态（边界值）	边界约束（固定变量值）
最终答案	目标函数 $\min d_{nm}$
填表顺序（拓扑序）	LP 前向代入求解顺序

复杂度对比（字符串长 n 和 m）：

方法	时间	说明
DP（专用）	$O(nm)$	填 $n \times m$ 表格
Ukkonen 近似（专用）	$O(nd)$	d 为编辑距离，$d \ll n$ 时更快
通用 LP 内点法	$O((nm)^{3.5})$	nm 个变量，nm 个约束

LP 比 DP 慢 $(nm)^{2.5}$ 倍，原因是 LP 内点法对 $nm \times nm$ 的约束矩阵做矩阵分解，而 DP 直接利用格点的局部依赖关系（每格只依赖左、上、左上三格），跳过了所有不必要的计算。

1.12 例题 10：二分图最大匹配（匈牙利算法的 LP 本质）

LeetCode 1349 / 经典：二分图最大匹配

原题：给定二分图 $G = (U \cup V, E)$，找最大匹配（每个节点最多匹配一次）。

线性规划建模：

$$\max \quad \sum_{(u,v)\in E} x_{uv} \tag{36}$$

$$\text{s.t.} \quad \sum_{v:(u,v)\in E} x_{uv} \leq 1, \quad \forall u \in U \quad \text{(每个左节点至多匹配一次)} \tag{37}$$

$$\sum_{u:(u,v)\in E} x_{uv} \leq 1, \quad \forall v \in V \quad \text{(每个右节点至多匹配一次)} \tag{38}$$

$$0 \leq x_{uv} \leq 1 \tag{39}$$

LP 松弛为何自动给 0/1 解？

二分图的约束矩阵每一列（对应一条边 (u, v)）恰好在 u 对应的行有一个 $+1$，在 v 对应的行有一个 $+1$，其余为 0——这种“每列恰好两个 1，且分布在图的两侧”

的结构，使得 LP 的极值点（最优解）自动是 $\{0,1\}$ 向量，不会出现 $x_{uv}=0.5$ 这样的分数解。

König 定理 = LP 强对偶：

对上述 LP 求对偶：每个左节点有对偶变量 p_u，每个右节点有 q_v，对偶问题为：

$$\min \sum_u p_u + \sum_v q_v, \quad \text{s.t.} \quad p_u + q_v \geq 1 \ \forall (u,v) \in E,\ p_u, q_v \geq 0$$

这恰好是**最小顶点覆盖**！LP 强对偶（原始 = 对偶最优值）给出：

$$\text{最大匹配} = \text{最小顶点覆盖} \quad (\text{König 定理})$$

经典做法一：匈牙利算法，$O(nm)$

核心概念：**增广路** = 从未匹配的左节点出发，交替经过 “非匹配边 → 右节点 → 匹配边 → 左节点 → ...”，最终到达未匹配的右节点的路径。沿增广路翻转匹配/非匹配状态，匹配数 +1。

步骤：

1. 初始匹配为空
2. 对每个左节点 u，用 DFS 寻找以 u 为起点的增广路：
   - 对 u 的每个邻居 v：若 v 未匹配，直接匹配 (u,v)，成功
   - 若 v 已匹配到 u'：递归尝试为 u' 找其他增广路（“让位”），若成功则将 (u,v) 加入匹配
3. 若找到增广路，匹配数 +1；否则 u 无法匹配

追踪示例（左节点 $\{1,2,3\}$，右节点 $\{a,b,c\}$，边 $\{(1,a),(1,b),(2,b),(3,c)\}$）：
节点 1 匹配 $(1,a)$；节点 2 尝试 b，b 未匹配，匹配 $(2,b)$；节点 3 匹配 $(3,c)$。最大匹配 3。

经典做法二：Hopcroft-Karp，$O(m\sqrt{n})$

同时为所有未匹配左节点找**同一长度**的增广路（BFS 确定长度层次，DFS 并行找所有不相交路径）。每轮最短增广路长度严格增加，最多 $O(\sqrt{n})$ 轮，每轮 $O(m)$。

匈牙利算法 = 在 LP 里找增广路：

每次找从未匹配节点出发的 “增广路”，沿路将匹配/非匹配交替翻转，使匹配数加 1。这等价于 LP 单纯形法的一次 “枢轴操作”：沿一个可行方向走一步，目标函数严格改善。

复杂度对比（$|U|=|V|=n$，$|E|=m$）：

方法	时间	说明
匈牙利算法（专用）	$O(nm)$	每次增广 $O(m)$，最多 n 次
Hopcroft-Karp（专用）	$O(m\sqrt{n})$	批量找增广路
通用 LP 内点法	$O((n+m)^{3.5})$	通用求解

Hopcroft-Karp 比 LP 快约 $(n+m)^{2.5}/\sqrt{n}$ 倍，核心是它利用了“增广路长度单调递增”这一性质，批量处理同一长度的增广路。

1.13 例题 11：股票买卖（Kadane 算法的凸优化本质）

LeetCode 121/122/123：股票买卖系列

原题（121，一次交易）：给定价格序列 $p_1, \ldots, p_n$，一次买卖的最大利润。

凸优化视角：

定义差分序列 $r_i = p_i - p_{i-1}$（日涨跌），则一次买卖的利润 $= \sum_{i=l+1}^{r} r_i$，即**最大连续子数组和（Kadane 问题）**。

经典做法（121）：Kadane 算法 / DP，$O(n)$

设 $r_i = p_i - p_{i-1}$（第 i 天涨跌），问题化为最大连续子数组和。

设 $f_i =$ 以第 i 天结尾的最大收益：

$$f_i = \max(\underbrace{f_{i-1} + r_i}_{\text{续用之前的买入点}}, \underbrace{r_i}_{\text{今天重新买入}}) = \max(f_{i-1}, 0) + r_i$$

直觉：若前一天结束后的累积收益 f_{i-1} 为正，今天继续持有更好；若为负，今天重新买入更好（抛弃之前的亏损）。

等价地，也可以直接维护“最低历史价格”：扫描价格序列，记录 minPrice，对每天计算 $p_i - \text{minPrice}$，取最大值。

经典做法（122）：贪心，$O(n)$

允许无限次交易时：只要明天涨（$r_i = p_i - p_{i-1} > 0$），就买入卖出，累加所有正涨幅：$\text{profit} = \sum_{i:r_i>0} r_i$。

经典做法（123）：两次交易 DP，$O(n)$

维护四个状态：buy1（第一次买入后的最大收益）、sell1（第一次卖出后的最大收益）、buy2（第二次买入后的最大收益）、sell2（第二次卖出后的最大收益）。从左到右滚动更新：

- $\text{buy1} = \max(\text{buy1}, -p_i)$
- $\text{sell1} = \max(\text{sell1}, \text{buy1} + p_i)$
- $\text{buy2} = \max(\text{buy2}, \text{sell1} - p_i)$

- sell2 = max(sell2, buy2 + p_i)

Kadane 算法 = 在线“是否重置”决策：
每步做一个二选一决策：“之前的收益值得带入今天”vs“今天重新开始”。这是一个**在线一维凸优化**：每步投影到 $\{f \geq 0\}$（不亏损才持有），累积目标函数值。
原题（122，无限次交易）：
所有涨的天都买，所有跌的天都不持有：利润 $= \sum_{i:r_i>0} r_i$。等价于对每个 r_i 独立做“是否纳入”的最优决策，完全分解，$O(n)$ 一次扫描。
原题（123，最多两次交易）：
用两套 DP 变量（“第一次交易状态”和“第二次交易状态”）独立滚动，相当于对两个独立凸优化问题的**联合求解**，$O(n)$ 时间。
复杂度对比：

问题	专用算法	通用 LP 内点法
最大子数组和（121）	$O(n)$ Kadane	$O(n^{3.5})$，n 变量 n 约束
无限次交易（122）	$O(n)$ 贪心	$O(n^{3.5})$
至多两次交易（123）	$O(n)$ DP	$O(n^{3.5})$
至多 k 次交易（188）	$O(kn)$ DP	$O((kn)^{3.5})$

LP 比 Kadane 慢 $n^{2.5}$ 倍。原因：Kadane 利用了“子数组是连续区间”的时序结构，每步只需看前一步的值；LP 不知道这一点，对所有变量做全局矩阵运算。

1.14 例题 12：跳跃游戏（Reachability 的 LP 证书）

LeetCode 55/45：跳跃游戏

原题（55）：数组 $a_1, \ldots, a_n$，a_i 表示从位置 i 最多可跳 a_i 步，能否到达终点？
LP 可行性建模：
设 $d_j \in [0,1]$ 为位置 j 的“可达性分数”，

$$\text{find} \quad d_1, \ldots, d_n \tag{40}$$

$$\text{s.t.} \quad d_j \leq \sum_{i:\ i+a_i \geq j,\ i<j} d_i, \quad \forall j \quad (\text{至少一个前驱可达}) \tag{41}$$

$$d_1 = 1 \tag{42}$$

若 $d_n \geq 1$ 有解则可达。LP 松弛（允许 d_j 为实数）的解与 0/1 解一致——要么能跳到 j，要么不能。
经典做法（55）：贪心维护最远可达位置，$O(n)$

步骤：维护变量 reach（当前从位置 0 出发能到达的最远下标）：

1. 初始化 reach $= 0$
2. 对 $i = 0, 1, \ldots, n-1$：
   - 若 $i >$ reach：位置 i 不可达，返回 `False`
   - 否则：reach $\leftarrow \max(\text{reach}, i + a[i])$
3. 扫描完毕，返回 `True`

追踪 ($a = [2, 3, 1, 1, 4]$)：$i = 0$: reach$= \max(0, 2) = 2$；$i = 1$: reach$= \max(2, 4) = 4$；$i = 2$: reach$= \max(4, 3) = 4$；$i = 3$: reach$= \max(4, 4) = 4$；$i = 4$: reach$= \max(4, 8) = 8 \geq 4$，True。

经典做法（45）：分层贪心，$O(n)$

每一“跳”对应一个区间，在区间内选择下一跳能到达最远的位置：

1. 初始化当前区间 $[0, 0]$，跳数 $= 0$，下一区间右端 nextReach $= 0$
2. 扫描当前区间 $[l, r]$ 内所有位置 i，更新 nextReach $= \max(\text{nextReach}, i + a[i])$
3. 若 $r < n - 1$：跳数 $+1$，下一区间 $= [r + 1, \text{nextReach}]$
4. 重复直到 $r \geq n - 1$

每轮“跳”对应 BFS 的一层展开，每层贪心选可达最远点作为下一层边界。

贪心 = 维护可达区间的右端点：

这等价于 LP 中：对每个位置取“是否可达”的最大值，一次线性扫描求解。“可达性”具有单调性（一旦能到 i，能到的最远位置只增不减），贪心直接维护这个单调量，无需矩阵分解。

原题（45）最少跳跃次数：

每一轮在“当前跳跃能覆盖的范围”内，选能到达最远的下一跳。这等价于每轮解一个“在约束集合内最大化下界”的线性子问题，贪心给出最优次数。

复杂度对比：

方法	时间	说明
贪心（55，专用）	$O(n)$	维护 reach 指针
贪心（45，专用）	$O(n)$	按轮分层扩展
通用 LP 可行性（内点）	$O(n^{3.5})$	n 变量，最多 n^2 约束

贪心比 LP 快 $n^{2.5}$ 倍。原因：“可达性”在这道题里是单调的——一旦能到达位置 i，能到达的最远位置只会单调增，贪心直接维护这个单调量，无需任何方程求解。

1.15 例题 13：第 K 大元素（分位数优化）

LeetCode 215：数组中的第 K 大元素

原题：在未排序数组 $a_1, \ldots, a_n$ 中找第 k 大的元素。

凸优化建模：

第 k 大等价于求 "分 $\tau = 1 - k/n$ 处的分位数"，即：

$$\hat{a} = \arg\min_{t \in \mathbb{R}} \underbrace{\sum_{i=1}^{n} \rho_\tau(a_i - t)}_{\text{分段线性凸函数}}$$

其中 $\rho_\tau(u) = u \cdot \tau$ 若 $u \geq 0$，$\rho_\tau(u) = u \cdot (\tau - 1)$ 若 $u < 0$。

直觉：对 "超过 t" 的元素和 "低于 t" 的元素分别给不同的惩罚权重，最优的 t 恰好是 τ 分位数。

特例：中位数 $= \ell_1$ 最小化

$\tau = 0.5$ 时，目标退化为 $\min_t \sum |a_i - t|$。最优解是中位数。相比之下，ℓ_2（$\min_t \sum (a_i - t)^2$）的最优解是均值。两者都是凸优化，但 ℓ_1 对异常值更鲁棒。

经典做法：Quickselect，期望 $O(n)$

思路：类似快速排序，每轮选 pivot 将数组三分：大于 pivot、等于 pivot、小于 pivot。根据 k 与各分区的大小关系，只需递归处理 k 所在的分区。

步骤：

1. 随机选一个 pivot 值 p
2. 将数组分为三部分：large（$> p$）、equal（$= p$）、small（$< p$）
3. 若 $k \leq |\text{large}|$：在 `large` 中递归找第 k 大
4. 若 $k \leq |\text{large}| + |\text{equal}|$：答案就是 p
5. 否则：在 `small` 中递归找第 $k - |\text{large}| - |\text{equal}|$ 大

期望复杂度分析：每轮期望将问题规模缩小到 3/4，故期望总操作数 $= n + 3n/4 + (3/4)^2 n + \ldots = O(n)$。最坏情形（每次选到极端 pivot）$O(n^2)$，可用随机打乱避免。

快速选择（Quickselect）= 随机缩小搜索范围：

等价于对分位数凸目标做 "随机降维"：每次把问题规模减半，期望 $O(n)$ 步找到最优的 t。连续凸优化（次梯度法）每步只缩小 $O(1/t)$ 的误差，不能精确终止；而 Quickselect 利用 "比较大小" 的离散结构，每步直接消去一半候选，精确找到答案。

直觉：不同损失函数对应不同统计量

ℓ_1 给中位数，ℓ_2 给均值，ℓ_∞（最大绝对值）给极值，一般的分位数损失给任意分位数。**选择哪种损失函数 = 选择哪种统计汇总方式**。

复杂度对比：

方法	时间	说明
排序（专用）	$O(n \log n)$	找所有分位数
Quickselect（专用，期望）	$O(n)$	随机 pivot，期望线性
Quickselect（专用，最坏）	$O(n^2)$	退化情形（可用 median-of-medians 避免）
Median-of-medians（专用）	$O(n)$ 最坏	线性选择算法
次梯度凸优化（一阶方法）	$O(n/\varepsilon^2)$	只给 ε-近似
通用 LP	$O(n^{3.5})$	可转化为 LP，但无必要

Quickselect 期望 $O(n)$ 远快于 LP 的 $O(n^{3.5})$。关键：Quickselect 利用了“比较大小可以快速缩小搜索空间”，而凸优化框架（次梯度法）每步只减小 $O(1/t)$ 的误差，收敛到精确解需要无穷多步（只给近似）。

1.16 例题 14：分割等和子集（背包 LP 松弛与整数间隙）

LeetCode 416：分割等和子集 & 贪心背包

原题（416）：给定正整数数组，能否分割成两个等和子集？
原题（分数背包）：物品可以任意切割，容量 W，求最大价值。
分数背包 = 精确 LP：

$$\max \quad \sum_{i=1}^{n} v_i x_i \tag{43}$$

$$\text{s.t.} \quad \sum_{i=1}^{n} w_i x_i \le W, \quad 0 \le x_i \le 1 \tag{44}$$

这是标准 LP，只有 1 条背包约束和 n 条上界约束。此 LP 的最优解**自动接近整数**——只有最多一个物品会被“切割”（取分数值），其余都是 0 或 1。原因：LP 最多在一个“非整数边界”处徘徊，单条约束的结构使最优解极点只有 $n+1$ 种。贪心策略：按性价比 v_i/w_i 降序，尽量整件取，背包快满时切割一件——恰好对应 LP 单纯形法一步求解。
0-1 背包 = 出现整数间隙（进入 NP-Hard 领域）：

强制 $x_i \in \{0,1\}$，LP 松弛值 $\geq$ 真正整数最优值，差值称为**整数间隙**。
例子：$n=2$，$w=[3,4]$，$v=[3,4]$，$W=6$。LP 松弛：取 $x_1=1, x_2=0.75$，价值 $=6$。0-1 整数：最优 $x_1=1, x_2=0$，价值 $=3$。间隙 $=3$。
经典做法（分数背包）：贪心，$O(n\log n)$
步骤：

1. 按性价比 v_i/w_i 降序排列所有物品
2. 从高性价比物品开始贪心取：若背包剩余容量 $\geq w_i$，整件取；否则取能放入的比例 $x_i = \text{remain}/w_i$
3. 背包满（$\text{remain}=0$）后停止

最多只有**一个物品被切割**（取分数），其余全取或全不取，对应 LP 最多在一个“非整数边界”处徘徊的性质。
经典做法（0-1 背包）：DP，$O(nW)$
设 $dp[j]$ = 背包容量 j 时的最大价值（滚动数组优化空间至 $O(W)$）。
步骤：

1. 初始化 $dp[0..W]=0$
2. 对每件物品 (w_i, v_i)，**从右向左**更新（保证每件物品只用一次）：
   对 $j=W, W-1, \ldots, w_i$：$dp[j] \leftarrow \max(dp[j], dp[j-w_i]+v_i)$
3. 答案为 $dp[W]$

为何从右向左：若从左向右更新，$dp[j-w_i]$ 已经包含了当前物品，会让同一物品被使用多次（无限背包）；从右向左则 $dp[j-w_i]$ 仍是上一轮的值，保证每件物品最多用一次。
分割等和子集 = 背包可行性：
目标 $S/2$，问能否凑出恰好 $S/2$。LP 松弛几乎总可行（只要 $S/2 \leq \sum w_i$），但整数解不一定存在——LP 给不出有用信息，必须用 DP。
复杂度对比（n 件物品，目标/容量 W）：

方法	时间	说明
分数背包贪心（专用）	$O(n\log n)$	排序后线性扫描
0-1 背包 DP（专用）	$O(nW)$	伪多项式，W 小时实用
0-1 背包通用 ILP	最坏指数	NP-Hard
LP 松弛（只给下界）	$O(n^{3.5})$	忽略整数约束

DP 的 $O(nW)$ 是**伪多项式**：W 的数值大小不等于其编码长度（编码长度是 $\log W$）。若 W 指数大，DP 也是指数慢的，与 NP-Hard 的定义一致。

1.17 例题 15：课程表（拓扑排序的 LP 可行性）

LeetCode 207/210：课程表

原题：给定 n 门课和先修关系，判断是否能完成所有课程，或输出合法学习顺序。
LP 可行性建模：
设 $t_i \in \mathbb{R}$ 为课程 i 的 "完成时间"，先修约束写为：

$$\text{find} \quad t_1, \ldots, t_n \tag{45}$$

$$\text{s.t.} \quad t_j \geq t_i + 1, \quad \forall (i \to j) \in E \quad (\text{必须先上完}i\text{ 再上}j) \tag{46}$$

无解 ⇔ 图中有环：若有环 $i \to j \to \ldots \to i$，约束累加得 $t_i \geq t_i + k$（$k \geq 1$），矛盾，LP 不可行。有向无环图（DAG）则 LP 总有解。
"不可行证书" 的直觉：凸优化中，判断 LP 不可行的标准方法（Farkas 引理）要求找一组非负权重，使约束的加权和产生矛盾 $0 \geq c > 0$。对本题而言，这组权重就是沿有向环的边，权重之和 > 0 即矛盾，等价于 "找到了一个有向环"。
经典做法一：Kahn 算法（BFS），$O(n+m)$
步骤：

1. 计算所有节点的入度
2. 将所有入度为 0 的节点加入队列
3. 从队列取出节点 u，加入结果序列；对 u 的每个后继 v：入度减 1，若入度变为 0 则加入队列
4. 若最终结果序列包含全部 n 个节点，无环，输出合法顺序；否则有环，返回失败

追踪示例（课程 $0 \to 1, 0 \to 2, 1 \to 3, 2 \to 3$）：
初始入度：$\{0:0, 1:1, 2:1, 3:2\}$。队列 $= [0]$。取 0，输出，1 和 2 入度变 0，队列 $= [1, 2]$。取 1，输出，3 入度 $= 1$，队列 $= [2]$。取 2，输出，3 入度 $= 0$，队列 $= [3]$。取 3，输出。顺序：$[0, 1, 2, 3]$。
经典做法二：DFS + 完成时间，$O(n+m)$
对每个未访问节点 DFS，访问完所有后继后将该节点压栈，最终栈的出栈顺序即拓扑序（完成时间逆序）。途中若遇到 "正在访问" 的节点，说明有环。
拓扑排序算法 = LP 的构造求解：

- **Kahn (BFS)**：每次取入度为 0 的节点 i，令 t_i 为当前最小合法值。相当于逐步代入求解约束系统，先确定没有前驱的变量。

- **DFS**：递归到最深处（所有后继都已完成）后赋最大时间戳。完成时间逆序 = 拓扑序。

核心结论：无环 = LP 可行 = 存在合法学习顺序

有向图无环 ⇔ 偏序约束的 LP 有解 ⇔ 存在将所有课程排序的合法顺序（拓扑序）。三者完全等价。

复杂度对比（n 门课，m 条先修关系）：

方法	时间	说明
Kahn / DFS（专用）	$O(n+m)$	线性时间，经典结论
通用 LP 可行性（内点）	$O((n+m)^{3.5})$	通用求解器

差距 $(n+m)^{2.5}$ 倍。Kahn 算法之所以线性，是因为它完全利用了“每次只处理入度为 0 的节点”，本质是“按依赖顺序依次确定变量”，不需要矩阵分解。

1.18 例题 16：任务调度器（调度 LP）

LeetCode 621：任务调度器

原题：n 个任务，各任务有执行频率 f_i，同类任务之间至少间隔 k 轮冷却，求最少总轮数。

LP 建模（决策变量 $x_{i,t}$：第 t 轮是否执行任务 i）：

$$\min \quad T \tag{47}$$

$$\text{s.t.} \quad \sum_{t=1}^{T} x_{i,t} \geq f_i \quad \forall i \quad (\text{每类任务执行足够次}) \tag{48}$$

$$\sum_{i} x_{i,t} \leq 1 \quad \forall t \quad (\text{每轮最多一个任务}) \tag{49}$$

$$x_{i,t} + x_{i,t'} \leq 1 \quad \forall |t-t'| \leq k \quad (\text{冷却约束}) \tag{50}$$

$$x_{i,t} \in \{0,1\} \tag{51}$$

LP 松弛给出精确答案（无整数间隙）：

最优轮数的精确公式：

$$T^* = \max\Big(\underbrace{n}_{\text{任务总数}},\ \underbrace{(f_{\max}-1)(k+1)+c_{\max}}_{\text{最高频任务撑开的最小空间}}\Big)$$

其中 $f_{\max}$ 为最高频率，$c_{\max}$ 为达到 $f_{\max}$ 的任务数量。

为什么 LP 松弛无间隙？
冷却约束形成的结构与“等间隔分配”完全兼容——可以把 T 轮分成 $(f_{\max}-1)$ 个大小为 $(k+1)$ 的块，每块独立安排，块内用 idle 填充。这种“均匀分配”结构使得 LP 最优解可以直接取整。

经典做法一：公式直接计算，$O(K)$
统计各任务出现频率，令最高频率为 $f_{\max}$，达到该频率的任务数为 $c_{\max}$：

$$T^* = \max(n,\ (f_{\max}-1)(k+1)+c_{\max})$$

解释：最高频任务需要执行 $f_{\max}$ 次，每两次之间至少间隔 k 轮（冷却），形成 $(f_{\max}-1)$ 个“冷却块”，每块 $(k+1)$ 个位置；加上最后一批 $c_{\max}$ 个最高频任务。若任务总数 n 更大，则按 n 算（全部排满无需 idle）。

追踪示例（任务 [A,A,A,B,B,B,C,C]，冷却 $k=2$）：$f_{\max}=3$（A 和 B），$c_{\max}=2$，$n=8$。公式：$\max(8,(3-1)(2+1)+2)=\max(8,8)=8$。排布：$A\,B\,C\,A\,B\,C\,A\,B$，共 8 轮。

经典做法二：模拟贪心 + 优先队列，$O(n\log K)$
每轮从优先队列取最高频率的（最多 $k+1$ 种）任务各执行一次，不足 $k+1$ 种时用 idle 填充，然后更新频率重新入队。

贪心 = 按频率优先填槽：
每轮先安排频率最高的任务（优先队列），冷却期填 idle 或其他任务。贪心直接构造出 LP 整数最优解，不需要求解方程。

直觉：对偶下界的直觉

$T \geq (f_{\max}-1)(k+1)$：最高频任务每执行一次需要等 k 轮，共执行 $f_{\max}$ 次，所以至少需要这么多轮。这个不等式正是 LP 对偶变量给出的“冷却约束的代价”——每个冷却间隔的“影子价格”。

复杂度对比（共 n 个任务，K 种类型）：

方法	时间	说明
公式直接计算（专用）	$O(K)$	一次统计即可
贪心 + 优先队列（专用）	$O(n\log K)$	逐轮安排
通用 LP 内点法	$O((KT)^{3.5})$	$T\sim n$ 时极慢

1.19 例题 17：打气球（区间 DP = 区间 DAG 上的 LP）

LeetCode 312：戳气球

原题：n 个气球，数值为 $a_1, \ldots, a_n$，戳破气球 i 得分 $a_l \cdot a_i \cdot a_r$（l, r 为当前左右邻居），求最高总分。

区间 DP = 区间 DAG 最长路 LP：

构造区间 DAG：节点为所有区间 (i, j)（$0 \le i < j \le n+1$），边 $(i, j) \to (i, k)$ 和 $(i, j) \to (k, j)$（$i < k < j$）。设 d_{ij} 为区间内气球全部戳完的最大得分：

$$\max \quad d_{0,n+1} \tag{52}$$

$$\text{s.t.} \quad d_{ij} \ge d_{ik} + a_i \cdot a_k \cdot a_j + d_{kj}, \quad \forall i < k < j \tag{53}$$

$$d_{ij} = 0, \quad j = i + 1 \tag{54}$$

有 $O(n^2)$ 个变量，$O(n^3)$ 个约束，约束图是 DAG（区间按长度有序，无环），LP 最优解自动为精确值。

经典做法：区间 DP，$O(n^3)$

关键技巧：不问“第一个戳哪个”，而是问“最后一个戳哪个”，规避了戳气球后邻居改变的复杂性。

设 $dp[i][j]$ = 在开区间 (i, j) 内（i 和 j 是边界气球，不被戳）将所有气球戳完的最大得分：

$$dp[i][j] = \max_{k \in (i,j)} \big[dp[i][k] + a_i \cdot a_k \cdot a_j + dp[k][j]\big]$$

含义：枚举“区间 (i, j) 内最后戳破的气球 k”——当 k 被戳时，其左邻是 i，右邻是 j（因为 k 两侧的气球已全部被戳完），得分 $a_i a_k a_j$，加上两侧子区间的最优得分。

填表顺序：按区间长度从 2 到 $n+2$ 依次填（短区间先，保证子问题已解决）。

追踪示例（$a = [3, 1, 5, 8]$，加哨兵 $a = [1, 3, 1, 5, 8, 1]$）：

$dp[0][2]$（区间 $(0, 2)$ = 只有 $a_1 = 3$）：$k = 1$，得分 $1 \times 3 \times 1 = 3$。

$dp[0][3]$（区间含 a_1, a_2）：$k = 1$: $1 \times 3 \times 1 + dp[1][3]$；$k = 2$: $1 \times 1 \times 5 + dp[0][2]$；取最大值 = 15。

最终 $dp[0][5] = 167$。

“最后戳 k” 技巧的 LP 意义：

把“最后戳破气球 k”等价于将大区间的贡献分解为三个子区间——这将 $a_i a_k a_j$ 的非线性乘积枚举，变成了对三个 LP 变量的线性加和约束（每条约束对应一种“最后戳”选择）。

按区间长度从短到长填表 = 按 DAG 拓扑序求解 LP：

短区间先于长区间，依赖关系形成 DAG，按长度顺序填表恰好是 DAG 的拓扑序，等价于前向代入法直接求解 LP。

复杂度对比（n 个气球）：

方法	时间	说明
区间 DP（专用）	$O(n^3)$	$O(n^2)$ 区间，每个枚举 $O(n)$ 分割点
通用 LP 内点法	$O(n^{10.5})$	$O(n^2)$ 变量，$O(n^3)$ 约束

差距约 $n^{7.5}$ 倍——这是所有例题中 LP 与专用算法差距最大的情形之一。LP 需要处理 $O(n^3)$ 条约束组成的巨型矩阵，而 DP 按 DAG 拓扑序每步只看 $O(n)$ 个子区间，极大利用了稀疏结构。

1.20 例题 18：分发糖果（两轮贪心 = 两次线性扫描）

LeetCode 135：分发糖果

原题：n 个孩子排一排，评分 $r_1, \ldots, r_n$，要求评分高的孩子比左右邻居糖多，每人至少 1 颗，求最少总糖数。

LP 建模：

$$\min \quad \sum_{i=1}^{n} c_i \tag{55}$$

$$\text{s.t.} \quad c_i \geq c_{i-1} + 1, \quad \forall i: \ r_i > r_{i-1} \quad (\text{左侧约束}) \tag{56}$$

$$c_i \geq c_{i+1} + 1, \quad \forall i: \ r_i > r_{i+1} \quad (\text{右侧约束}) \tag{57}$$

$$c_i \geq 1 \tag{58}$$

LP 松弛为何自动给整数解？

所有约束系数只有 $+1$ 或 -1，约束图是**路径图**（无环，每个节点只连左右相邻节点）。这种链状结构使 LP 最优解自动为整数——最优的 c_i 一定是某个正整数（每段上坡的三角数）。

经典做法：两轮贪心扫描

核心思路：把“比两侧都高的要多”这个双向约束拆成两个单向约束分别满足，最后取最大值。

第一轮（左 → 右）：只看左侧约束——若我比左边评分高，糖就多一颗。

- 初始化：$c_1 = 1$（每人至少 1 颗）。
- 从左向右遍历 $i = 2, \ldots, n$：
  - 若 $r_i > r_{i-1}$：$c_i = c_{i-1} + 1$（比左邻多一颗）
  - 否则：$c_i = 1$（重置为最少）

第二轮（右 → 左）：只看右侧约束——若我比右边评分高，糖不能少。

- 初始化：$c'_n = 1$。
- 从右向左遍历 $i = n-1, \ldots, 1$：
  - 若 $r_i > r_{i+1}$：$c'_i = c'_{i+1} + 1$
  - 否则：$c'_i = 1$

合并：$c_i = \max(c_i, c'_i)$，总糖数 $= \sum_i c_i$。
追踪示例（评分 $r = [1, 0, 2]$）：

位置 i	评分 r_i	第一轮 c_i	第二轮 c'_i	$\max(c_i, c'_i)$
1	1	1	2	2
2	0	1	1	1
3	2	2	1	2

总糖数 $= 2 + 1 + 2 = 5$（LP 最优值相同）。
为什么两轮就够？链状结构保证：第一轮满足所有“上坡向左”约束，第二轮满足所有“上坡向右”约束；两约束系统之间没有循环依赖（路径图无环），取最大值后自动全局最优。如果图有环（比如三人成环评分 $1 > 2 > 3 > 1$），两轮就不够，需要迭代——这正是为什么 LP 内点法对有环约束仍需 $O(n^{3.5})$。
这等价于对 LP 做两次单向扫描（前向/后向代入），链状约束图保证两轮后恰好收敛，无需迭代。
对偶直觉：
最优总糖数 $= \sum_{\text{上坡段}}$ 三角数（即 $1 + 2 + 3 + \ldots$）。这些三角数正是 LP 对偶问题的最优值——每段上坡的“斜率约束”对应的影子价格之和。
复杂度对比：

方法	时间	说明
两轮贪心扫描（专用）	$O(n)$	两次线性遍历
通用 LP 内点法	$O(n^{3.5})$	n 变量，$O(n)$ 约束

差距 $n^{2.5}$ 倍。贪心之所以能做到 $O(n)$，是因为链状结构让前向/后向代入两步就完全求解，而通用 LP 求解器面对 $n \times n$ 的矩阵，做了大量不必要的全局线性代数。

1.21 例题 19：乘积最大子数组（对数变换化凸）

LeetCode 152：乘积最大子数组

原题：给定整数数组 $a_1, \ldots, a_n$，找乘积最大的连续子数组。

为什么乘积问题可以化为凸优化？

若数组全为正数：

$$\log \prod_{i=l}^{r} a_i = \sum_{i=l}^{r} \log a_i$$

对数变换将乘积化为**加法和**，问题变为最大子数组和（Kadane），是标准凸优化，$O(n)$ 解决。

经典做法：双状态 DP（同时维护最大和最小乘积）

关键洞察：负数一旦出现，乘积符号翻转，“当前最小” 乘以负数会变成 “当前最大”。因此必须同时跟踪以 i 结尾的最大乘积和最小乘积。

状态定义：

- mx：以当前元素结尾的子数组的最大乘积
- mn：以当前元素结尾的子数组的最小乘积
- ans：全局最大乘积

转移规则（遍历每个元素 a_i）：

- 若 $a_i > 0$：乘以正数，最大仍最大，最小仍最小。
- 若 $a_i < 0$：乘以负数，最大变最小，最小变最大（符号翻转）。
- 若 $a_i = 0$：子数组乘积归零，重新从 1 开始。
- 每步均考虑 “重新从 a_i 开始”（子数组不延伸到前面）：

$$\text{new_mx} = \max(a_i,\ a_i \cdot \text{mx},\ a_i \cdot \text{mn})$$

$$\text{new_mn} = \min(a_i,\ a_i \cdot \text{mx},\ a_i \cdot \text{mn})$$

注意要先保存旧的 mx、mn 再同时更新（否则 mn 更新时会用到已被覆盖的 mx）。

追踪示例（$a = [2, 3, -2, 4]$）：

i	a_i	mx（更新后）	mn（更新后）	ans	说明
1	2	2	2	2	初始
2	3	6	6	6	$\max(3, 2{\cdot}3, 2{\cdot}3) = 6$
3	-2	-2	-12	6	$\max(-2, 6{\cdot}(-2), 6{\cdot}(-2)) = -2$
4	4	4	-48	6	$\max(4, -2{\cdot}4, -12{\cdot}4) = 4$

答案为 6（子数组 $[2,3]$）。

第二个追踪示例（含两个负数，$a=[-2,3,-4]$）：

i	a_i	mx	mn	ans	说明
1	-2	-2	-2	-2	初始
2	3	3	-6	3	$\max(3,-6,3)=3$，$\min(3,-6,3)=-6$
3	-4	24	-12	24	$\max(-4,12,-6\cdot(-4))=24$，负负得正！

答案为 24（整个数组 $[-2,3,-4]$），两个负号相消后乘积最大。

在**对数绝对值空间**（取 $\log|a_i|$，符号单独记录）中，这两个递推都是分段线性的 Bellman 方程，与 Kadane 完全同构：两条“赛道”（正/负号）交替，取每步的最大值。

通用框架：乘法 → 对数 → 凸加法：

$$\max\prod x_i \xrightarrow{\log} \max\sum \log x_i \quad \text{（凹函数最大化，等价于凸优化）}$$

这是“几何规划（Geometric Programming）”的核心思想，广泛用于电路设计、通信容量优化等。

复杂度对比：

方法	时间	说明
双状态 DP（专用）	$O(n)$	维护 maxProd, minProd
对数变换 + Kadane（全正数）	$O(n)$	同上，更清晰
通用 LP（化为线性后）	$O(n^{3.5})$	对数空间中线性化

LP 比专用 DP 慢 $n^{2.5}$ 倍。DP 利用“符号翻转只在乘以负数时发生”的一维时序结构，每步只需比较三个值；LP 不知道这种局部结构。

1.22 例题 20：买卖股票含手续费（正则化凸优化）

LeetCode 714：买卖股票含手续费

原题：每次卖出需支付手续费 f，无限次买卖，求最大利润。

经典做法：两状态 DP（持仓 / 空仓）

状态定义：每天有两种状态——

- hold：今天结束时持有股票，能获得的最大利润
- cash：今天结束时不持股（空仓），能获得的最大利润

转移方程（每天根据当日价格 p_i 更新）：

$$\text{hold} \leftarrow \max(\text{hold},\ \text{cash} - p_i)$$

$$\text{cash} \leftarrow \max(\text{cash},\ \text{hold}_{\text{旧}} + p_i - f)$$

注意：卖出时支付手续费 f，因此要用更新前的 hold 计算卖出收益（避免同日买卖）。

追踪示例（$p = [1, 3, 2, 8, 4, 9]$，$f = 2$）：

天 i	价格 p_i	hold（更新后）	cash（更新后）	操作
初始	—	$-\infty$	0	—
1	1	-1	0	买入：$\text{hold} = 0 - 1 = -1$
2	3	-1	0	卖出：$\text{cash} = -1 + 3 - 2 = 0$，不提升
3	2	-1	0	买入无收益
4	8	-1	5	卖出：$\text{cash} = -1 + 8 - 2 = 5$
5	4	1	5	买入：$\text{hold} = 5 - 4 = 1$
6	9	1	8	卖出：$\text{cash} = 1 + 9 - 2 = 8$

最终答案 $\text{cash} = 8$（第 1 天买，第 4 天卖得 5；第 5 天买，第 6 天卖得 3；共 8）。

为什么只需两个变量？每天的最优决策只取决于昨天的两个状态，历史不再重要——这是马尔可夫性，因此不需要维护完整的 DP 数组，滚动更新两个变量即可。

DP 建模（两状态：持仓 / 空仓）：

$$\text{hold}[i] = \max(\text{hold}[i-1],\ \text{cash}[i-1] - p_i)$$

$$\text{cash}[i] = \max(\text{cash}[i-1],\ \text{hold}[i-1] + p_i - f)$$

凸优化视角：手续费 $= \ell_1$ 稀疏惩罚

总利润 $= \sum_{\text{每笔交易}} (\text{卖价} - \text{买价} - f)$，等价于：

$$\max_x \Big[\underbrace{\sum_i r_i x_i}_{\text{每日收益}} - \underbrace{f \cdot (\text{交易次数})}_{\ell_1\ \text{惩罚}}\Big]$$

手续费 f 就是**稀疏惩罚系数**：f 越大，最优策略越倾向于减少交易次数（解越稀疏）。

与机器学习 LASSO 的完美类比：

股票手续费问题	LASSO 回归
每日价差 r_i	特征 x_i
买卖操作向量	回归系数 β
手续费 f	正则化系数 λ
减少无谓交易	压缩系数到 0
$f \to 0$：贪心全买	$\lambda \to 0$：过拟合
$f \to \infty$：不交易	$\lambda \to \infty$：全零解

核心结论：ℓ_1 惩罚产生稀疏解的直觉

无论是 LASSO 还是手续费问题，ℓ_1 惩罚的几何效果是把最优解“推向角点”（坐标轴上），使尽量多的分量为零。在股票问题中，“交易次数为零”就是“不交易”——手续费正是强制最优策略忽略微小的价差波动。

复杂度对比：

方法	时间	说明
双状态 DP（专用）	$O(n)$	滚动两个变量
贪心修正版（专用）	$O(n)$	只在净利润 $> f$ 时交易
通用 LP + ℓ_1 正则化	$O(n^{3.5})$	线性化后 LP 求解

DP 比 LP 快 $n^{2.5}$ 倍。DP 状态机（两状态）完全利用了“持仓/空仓的状态转移是马尔可夫链”，每步只需比较两个值；LP 面对 n 个时间步的所有可能交易序列，做全局矩阵优化。

1.23 小结：P 问题的凸优化统一框架

总结表 A：各题凸优化模型与整数性来源

题目	LP 模型	LP 松弛有整数解吗?	关键结构
前缀和 / Two Sum	仿射可行性	本身连续	一维等式
最长递增子序列	DAG 最长路	✓	DAG 链状 ± 1 系数
零钱兑换	整数规划	×（一般情形）	单行约束加权和
接雨水	凸包最小化	✓	局部 ± 1 约束
最小生成树	连通性 LP	✓	生成树多胞体
最大流	流量守恒 LP	✓	关联矩阵 ± 1
最短路	三角不等式 LP	✓（实数解）	关联矩阵 ± 1
区间调度	独立集 LP	✓	区间图无奇环
编辑距离	DAG 最短路	✓	网格 DAG ± 1
二分图匹配	匹配 LP	✓	二部图 ± 1
股票买卖	在线凸优化	本身实数	一维时序
跳跃游戏	可行性 LP	✓	单调可达性
第 K 大元素	分位数凸优化	本身实数	分段线性
分割等和子集	背包 LP	×（有间隙）	加权和约束
课程表	偏序可行性	✓	DAG ± 1
任务调度器	调度 LP	✓	区间图结构
打气球	区间 DAG LP	✓	DAG 拓扑序
分发糖果	路径图 LP	✓	链状 ± 1
乘积最大子数组	对数化后凸	本身实数	对数变换
股票含手续费	ℓ_1 正则化 LP	✓	稀疏角点解

总结表 B：复杂度对比（专用算法 vs 通用 LP 内点法）

符号约定：n = 输入规模（数组长/节点数），m = 边数，W = 数值大小

题目	专用算法	LP 内点法	差距（数量级）
Two Sum	$O(n)$ 哈希	$O(n^{3.5})$	$n^{2.5}$
LIS	$O(n \log n)$	$O(n^5)$	$n^4/\log n$
零钱兑换	$O(kW)$ DP	$O(k^{3.5})$ LP（仅下界）	各有优劣
接雨水	$O(n)$ 双指针	$O(n^{3.5})$	$n^{2.5}$
MST（m 边）	$O(m\alpha(n))$	$O(m^{3.5})$	$m^{2.5}$
最大流（n, m）	$O(n^2\sqrt{m})$ HLPPS	$O((n+m)^{3.5})$	$\sim m$
最短路（n, m）	$O(m + n \log n)$ Dijkstra	$O(m^{3.5})$	$m^{2.5}/\log n$
区间调度	$O(n \log n)$ 贪心	$O(n^{3.5})$	$n^{2.5}$
编辑距离（长 n）	$O(n^2)$ DP	$O(n^7)$	n^5
二分图匹配（n, m）	$O(m\sqrt{n})$ HK	$O((n+m)^{3.5})$	$m^{2.5}/\sqrt{n}$
股票买卖	$O(n)$ Kadane	$O(n^{3.5})$	$n^{2.5}$
跳跃游戏	$O(n)$ 贪心	$O(n^{3.5})$	$n^{2.5}$
第 K 大	$O(n)$ Quickselect	$O(n^{3.5})$	$n^{2.5}$
打气球	$O(n^3)$ 区间 DP	$O(n^{10.5})$	$n^{7.5}$
分发糖果	$O(n)$ 两轮扫描	$O(n^{3.5})$	$n^{2.5}$
乘积最大子数组	$O(n)$ DP	$O(n^{3.5})$	$n^{2.5}$
股票含手续费	$O(n)$ DP	$O(n^{3.5})$	$n^{2.5}$

重要观察：

1. **差距普遍是多项式级**（$n^{2.5}$ 到 $n^{7.5}$），**不是指数级**。这意味着对规模较小的问题（$n \le 100$），LP 求解器实践上也完全可用。
2. **最大流是差距最小的情形**：稀疏图上 LP 与专用算法仅差常数倍，因为最大流的约束矩阵就是稀疏的图关联矩阵，LP 内点法天然利用稀疏性。
3. **区间 DP（打气球）差距最大**：$O(n^3)$ 约束让 LP 的规模爆炸，专用算法利用 DAG 拓扑序完全规避了矩阵分解。
4. **LP 的真正优势不在速度，在于通用性和可扩展性**：只需修改约束，即可处理带额外限制的变体，而专用算法往往需要从头重新设计。

三条核心规律

规律一：约束系数只有 ± 1 和 $0 \Rightarrow$ LP 松弛自动给整数解
图论类问题（最短路、最大流、匹配）的约束矩阵（每条边/每个操作对每个节点/状态的影响系数）都满足这一性质，因此 LP 松弛精确等于整数最优解。一旦

约束系数出现任意整数（如背包的 w_i），整数间隙就可能出现。

规律二：贪心有效 ⇔ 问题具有“独立选择”结构

贪心算法在下述情况最优：子集的“可行性”可以独立验证（任何可行子集的子集也可行），且小可行集可以扩展为大可行集。MST、区间调度、分数背包都满足这一点。不满足时贪心失效，必须用 DP 或更复杂的算法。

规律三：DP = 按 DAG 拓扑序填写 LP 变量

所有 DP 都等价于在某个 DAG（状态转移图）上求最短/最长路。DP 的高效性来自 DAG 的稀疏结构和拓扑序，使得每个变量只需处理一次——这是对 LP 的一种极度特化的求解方法，跳过了通用矩阵分解的所有开销。

直觉：P vs NP 的凸优化本质

P 类问题之所以“容易”，正是因为它们的 LP 松弛**没有整数间隙**——连续优化与离散优化完美吻合。一旦 LP 松弛出现正整数间隙，问题往往就变成 NP-Hard，需要本讲后续介绍的近似算法。

为什么 GPU 能加速组合优化？

核心矛盾：经典组合算法虽然复杂度优，但天然**串行**。

算法	复杂度	瓶颈
Dijkstra	$O((V+E)\log V)$	堆操作，每次只扩展 1 个节点
Hungarian	$O(n^3)$	增广路搜索，逐条增广
逐行 DP	$O(mn)$	每格依赖上一格，逐格填表

GPU 有数千个核心，但这些算法**喂不饱**——每一步只有 $O(1)$ 个操作可以并行。

关键观察：把问题写成 LP 或连续优化后，同一步的更新往往**全部独立**，可以同时交给 GPU 的所有核心。

LP 视角：串行算法的并行替代

例 1：最短路

Dijkstra = 贪心逐点扩展（串行）

Bellman-Ford = 对 Bellman LP $\{d_v - d_u \le w_{uv}\}$ 做次梯度上升：

$$d_v \leftarrow \min_u (d_u + w_{uv}), \quad \forall v(\text{所有边同时松弛})$$

每轮 $|E|$ 个松弛操作**完全独立** → GPU 并行。

代价：需要 $O(V)$ 轮（vs Dijkstra 只需 1 轮），但每轮 GPU 做 $|E|/P$ 时间。

赢的条件：$V \cdot E/P < (V+E)\log V$，即 GPU 核心数 P 足够大、图足够稠密。

LP 视角：串行算法的并行替代（续）

例 2：指派问题

Hungarian = 增广路逐条搜索（串行），$O(n^3)$

Sinkhorn = 对指派 LP 的熵正则化版本做坐标上升：

$$\min_{P\geq 0} -\langle C, P\rangle + \varepsilon\langle P, \log P\rangle \quad \text{s.t. } P\mathbf{1} = \mathbf{1},\ P^T\mathbf{1} = \mathbf{1}$$

每次迭代：对 n^2 个元素做 log-sum-exp 归一化，**全部独立** → GPU 并行。

$O(K)$ 轮迭代（$K \approx 100$），每轮 $O(n^2/P)$，总时间 $O(Kn^2/P)$。

例 3：编辑距离

逐行 DP = 每格依赖左、上、左上（串行）

反对角线 wavefront：同一条对角线 $i + j = d$ 上的所有格子**互不依赖**。

$O(m + n)$ 轮 × 每轮 $\min(m, n)/P$ 个并行操作，总时间 $O(mn/P)$。

全幺模：LP 松弛不丢精度

三个问题的约束矩阵都是**全幺模**的：

问题	约束矩阵	LP 松弛误差
指派（1947）	二分图关联矩阵	**0%**
最短路（743）	网络节点-弧矩阵	**0%**
编辑距离（72）	DAG 关联矩阵	**0%**

全幺模 ⇒ LP 最优解自动是整数 ⇒ **松弛成连续问题不丢任何精度**。

这意味着我们可以放心地用 GPU 连续优化方法（Sinkhorn、并行 Bellman-Ford、wavefront）替代离散算法，**得到精确解**，同时享受 GPU 并行加速。

总结：GPU 什么时候赢？

GPU LP 方法胜出的条件：

1. **规模足够大**——GPU 核函数启动开销（∼ 微秒级）需要被大量并行计算摊薄
2. **每步有大量独立操作**——LP/连续化后的迭代天然满足（全边松弛、矩阵归一化、反对角线更新）
3. **LP 松弛不丢精度**——全幺模保证，否则还需额外的舍入步骤

问题	CPU 赢（小规模）	GPU 赢（大规模）
指派	$m < 50$	$m > 100$
最短路（稠密图）	$n < 200$	$n > 500$
编辑距离	$\text{len} < 1000$	$\text{len} > 2000$

一句话：经典算法用“聪明的串行顺序”减少总操作数；GPU 方法用“笨但并行的迭代”在每一步铺满所有核心。规模一大，核心数的暴力碾压聪明的串行。

最优传输问题

问题：有 m 个工厂（供给 μ_i）和 n 个商店（需求 ν_j），从工厂 i 运到商店 j 的单位成本为 C_{ij}。求最小总运输成本。

LP 形式：

$$\begin{aligned} \min_{P\geq 0} \quad & \langle C, P\rangle = \sum_{i,j} C_{ij}P_{ij} \\ \text{s.t.} \quad & P\mathbf{1} = \mu \quad (\text{行和} = \text{供给}) \\ & P^\top \mathbf{1} = \nu \quad (\text{列和} = \text{需求}) \end{aligned}$$

其中 P_{ij} 是从 i 运到 j 的量，可行域 $U(\mu,\nu)$ 称为**传输多面体**。

例子：2 个工厂，3 个商店

$$\mu = \begin{pmatrix} 0.4 \\ 0.6 \end{pmatrix}, \quad \nu = \begin{pmatrix} 0.2 \\ 0.3 \\ 0.5 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 1 & 2 \end{pmatrix}$$

这是一个标准 LP，可用单纯形法求解。但当 m, n 很大时（如图像处理中 $m = n = 10^4$），LP 的 $O(n^3 \log n)$ 复杂度太高。

熵正则化：从 LP 到光滑优化

核心思想（Cuturi, 2013）：加一个**熵正则项**，把 LP 变成强凸问题。

熵正则化最优传输：

$$\min_{P\in U(\mu,\nu)} \langle C, P\rangle - \varepsilon\, H(P)$$

其中 $H(P) = -\sum_{i,j} P_{ij}(\log P_{ij} - 1)$ 是传输矩阵的熵，$\varepsilon > 0$ 是正则化参数。

为什么加熵？

- 原始 LP 的最优解是传输多面体的顶点，**稀疏**且不光滑
- 加熵后目标函数**强凸**，最优解唯一且光滑

- $\varepsilon \to 0$ 时解收敛到原始 LP 的最优解
- 关键收益：可以用 Sinkhorn 迭代快速求解（只需矩阵-向量乘法！）

熵正则化的最优解结构

写 KKT 条件：引入对偶变量 f_i（行约束）和 g_j（列约束），Lagrangian 为：

$$\mathcal{L} = \sum_{ij} C_{ij} P_{ij} + \varepsilon \sum_{ij} P_{ij} \log P_{ij} - \sum_i f_i \left(\sum_j P_{ij} - \mu_i \right) - \sum_j g_j \left(\sum_i P_{ij} - \nu_j \right)$$

对 P_{ij} 求导令其为零：

$$\frac{\partial \mathcal{L}}{\partial P_{ij}} = C_{ij} + \varepsilon \log P_{ij} + \varepsilon - f_i - g_j = 0$$

解出：

$$P^*_{ij} = e^{f_i/\varepsilon} \cdot e^{-C_{ij}/\varepsilon} \cdot e^{g_j/\varepsilon}$$

定义 $u_i = e^{f_i/\varepsilon}$，$v_j = e^{g_j/\varepsilon}$，$K_{ij} = e^{-C_{ij}/\varepsilon}$（Gibbs 核），则：

$$\boxed{P^* = \mathrm{diag}(u) \cdot K \cdot \mathrm{diag}(v)}$$

即 $P^*_{ij} = u_i K_{ij} v_j$。最优传输矩阵一定是 Gibbs 核 K 的**对角缩放**！

Sinkhorn 迭代

已知 $P^* = \mathrm{diag}(u)\, K\, \mathrm{diag}(v)$，需要找 u, v 使得边际约束成立：

$$P^* \mathbf{1} = \mu \implies \mathrm{diag}(u)\, K\, v = \mu$$

$$(P^*)^\top \mathbf{1} = \nu \implies \mathrm{diag}(v)\, K^\top u = \nu$$

Sinkhorn 算法：交替投影，依次满足行约束和列约束。
初始化 $v^{(0)} = \mathbf{1}$，然后交替：

$$u^{(\ell+1)} = \frac{\mu}{K v^{(\ell)}} \quad (\text{修正行和} = \mu)$$
$$v^{(\ell+1)} = \frac{\nu}{K^\top u^{(\ell+1)}} \quad (\text{修正列和} = \nu)$$

其中除法是**逐元素**的。
每步复杂度：一次矩阵-向量乘法 $O(mn)$，没有矩阵求逆！

手算例子

$\mu = (0.4, 0.6)^\top$，$\nu = (0.2, 0.3, 0.5)^\top$，$C = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 1 & 2 \end{pmatrix}$，$\varepsilon = 1$。

Step 0：计算 Gibbs 核 $K_{ij} = e^{-C_{ij}/\varepsilon}$

$$K = \begin{pmatrix} e^{-1} & e^{-2} & e^{-3} \\ e^{-4} & e^{-1} & e^{-2} \end{pmatrix} \approx \begin{pmatrix} 0.368 & 0.135 & 0.050 \\ 0.018 & 0.368 & 0.135 \end{pmatrix}$$

初始化 $v^{(0)} = (1, 1, 1)^\top$。

Step 1：更新 u

$$Kv^{(0)} = \begin{pmatrix} 0.368 + 0.135 + 0.050 \\ 0.018 + 0.368 + 0.135 \end{pmatrix} = \begin{pmatrix} 0.553 \\ 0.521 \end{pmatrix}$$

$$u^{(1)} = \mu \oslash (Kv^{(0)}) = \begin{pmatrix} 0.4/0.553 \\ 0.6/0.521 \end{pmatrix} = \begin{pmatrix} 0.723 \\ 1.151 \end{pmatrix}$$

Step 2：更新 v

$$K^\top u^{(1)} = \begin{pmatrix} 0.368 \times 0.723 + 0.018 \times 1.151 \\ 0.135 \times 0.723 + 0.368 \times 1.151 \\ 0.050 \times 0.723 + 0.135 \times 1.151 \end{pmatrix} = \begin{pmatrix} 0.287 \\ 0.521 \\ 0.192 \end{pmatrix}$$

$$v^{(1)} = \nu \oslash (K^\top u^{(1)}) = \begin{pmatrix} 0.2/0.287 \\ 0.3/0.521 \\ 0.5/0.192 \end{pmatrix} = \begin{pmatrix} 0.697 \\ 0.576 \\ 2.604 \end{pmatrix}$$

继续迭代直到收敛，最终 $P^* = \mathrm{diag}(u)\, K\, \mathrm{diag}(v)$。

Sinkhorn 的收敛性

定理（Sinkhorn, 1967；Franklin & Lorenz, 1989）：若 K 的所有元素 > 0（即成本有限），则 Sinkhorn 迭代**线性收敛**到唯一最优解。

收敛速度：与 ε 有关。

- ε 大：收敛快，但正则化误差大（解偏离原始 LP 最优）
- ε 小：解更接近 LP 最优，但收敛慢（K 的元素接近 0，数值不稳定）
- 实际中取 $\varepsilon \sim 0.01$–$0.1 \times \mathrm{median}(C)$

复杂度对比：

方法	复杂度
单纯形法	$O(n^3 \log n)$
内点法	$O(n^3)$
Sinkhorn	$O(n^2/\varepsilon^2)$（近似）

Sinkhorn 的优势：每步只需矩阵-向量乘，天然适合 *GPU* 并行，且可同时计算一个点到多个点的传输距离（*batch* 模式）。

Sinkhorn 与 LP 对偶的联系

原始 LP 的对偶：

$$\max_{f,g} \quad f^\top \mu + g^\top \nu \quad \text{s.t.} \quad f_i + g_j \le C_{ij} \ \ \forall i, j$$

熵正则化的对偶（无约束优化！）：

$$\max_{f,g} \quad f^\top \mu + g^\top \nu - \varepsilon \sum_{i,j} e^{(f_i + g_j - C_{ij})/\varepsilon}$$

Sinkhorn 迭代等价于对这个**光滑无约束对偶**做**坐标上升**：

- 固定 g，最优化 f（对应更新 u）
- 固定 f，最优化 g（对应更新 v）

每步有闭式解（就是取 log 再做逐元素运算），所以每步 $O(mn)$。
这也解释了为什么 *Sinkhorn* 线性收敛：坐标上升在强凸问题上线性收敛。

2 传统方法：分支定界与分解

本节目标

问题：组合优化问题如何求解？
第一步：把问题写成**整数规划**（ILP）
第二步：用**分支定界**求解 ILP
本节内容：

1. 展示如何把各种问题统一写成 ILP
2. 介绍分支定界的通用框架
3. 用背包问题演示完整求解过程
4. 分析传统方法的局限性

2.1 把组合优化问题写成整数规划

整数规划（ILP）的一般形式

标准形式：

$$\min\ c^T x \quad \text{s.t.} \quad Ax \le b, \quad x \in \{0,1\}^n$$

各部分的含义：

- $x = (x_1, x_2, \ldots, x_n)$：$n$ 个**决策变量**，每个只能取 0 或 1
- $c^T x = c_1x_1 + c_2x_2 + \cdots + c_nx_n$：**目标函数**（要最小化）
- $Ax \le b$：若干个**线性约束**

关键思想：用 $x_i = 1$ 表示“选择第 i 个东西”，$x_i = 0$ 表示“不选”
下面我们展示几个经典问题如何写成这个形式。

例 1：背包问题 → ILP

问题：背包容量 W，n 个物品，第 i 个价值 v_i、重量 w_i。选物品使总价值最大且不超重。
决策变量：$x_i = 1$ 表示选第 i 个物品，$x_i = 0$ 表示不选
目标函数：总价值 $= v_1x_1 + v_2x_2 + \cdots + v_nx_n = \sum_i v_ix_i$
要最大化，所以写成：$\max \sum_i v_ix_i$
约束：总重量不超过容量
$w_1x_1 + w_2x_2 + \cdots + w_nx_n \le W$，即 $\sum_i w_ix_i \le W$

完整 ILP：

$$\max \sum_{i=1}^{n} v_i x_i \quad \text{s.t.} \quad \sum_{i=1}^{n} w_i x_i \le W, \quad x_i \in \{0,1\}$$

例 2：Vertex Cover → ILP

问题：图 $G=(V,E)$，选最少的顶点，使每条边至少有一个端点被选中。
决策变量：$x_v = 1$ 表示选顶点 v，$x_v = 0$ 表示不选
目标函数：选的顶点数 $= \sum_{v\in V} x_v$，要最小化
约束：每条边 (u,v) 至少有一个端点被选
对于边 (u,v)：要么选 u（$x_u = 1$），要么选 v（$x_v = 1$），或两个都选
数学表达：$x_u + x_v \ge 1$
完整 ILP：

$$\min \sum_{v\in V} x_v \quad \text{s.t.} \quad x_u + x_v \ge 1 \ \forall (u,v) \in E, \quad x_v \in \{0,1\}$$

例 3：Set Cover → ILP

问题：全集 U，子集 $S_1, S_2, \ldots, S_m$，每个子集有成本 c_i。选最小总成本的子集覆盖 U。
决策变量：$x_i = 1$ 表示选子集 S_i，$x_i = 0$ 表示不选
目标函数：总成本 $= \sum_i c_i x_i$，要最小化
约束：每个元素 $e \in U$ 必须被至少一个选中的子集覆盖
对于元素 e：在所有包含 e 的子集中，至少选一个
数学表达：$\sum_{i: e\in S_i} x_i \ge 1$
完整 ILP：

$$\min \sum_{i=1}^{m} c_i x_i \quad \text{s.t.} \quad \sum_{i: e\in S_i} x_i \ge 1 \ \forall e \in U, \quad x_i \in \{0,1\}$$

把问题写成 ILP 的通用方法

步骤 1：确定决策变量
问：我要做哪些“选或不选”的决定？
每个决定对应一个 0-1 变量 x_i
步骤 2：写出目标函数
问：我要最大化/最小化什么？
通常是决策变量的线性组合：$\sum_i c_i x_i$
步骤 3：写出约束条件

问：有哪些限制条件?
把每个限制写成 x_i 的线性不等式
验证：
每个约束都是 x_i 的线性组合 $\leq$ 或 $\geq$ 某个常数? ✓
所有 $x_i \in \{0,1\}$? ✓
那就是一个合法的 0-1 整数规划!

为什么要写成 ILP ?

好处 1：统一的数学框架
不管是背包、Vertex Cover、Set Cover 还是其他问题，
写成 ILP 后，可以用**同一套方法**求解。
好处 2：有成熟的求解器
商业软件（Gurobi、CPLEX）和开源软件（SCIP、CBC）都能求解 ILP。
好处 3：理论分析的基础
后面我们会用 LP 松弛来设计近似算法。
接下来：介绍求解 ILP 的经典方法——分支定界。

2.2 分支定界算法

分支定界的核心思想

暴力方法：枚举所有 2^n 种 0-1 组合，找最优的。
$n = 50$ 时，$2^{50} \approx 10^{15}$，不可行。
分支定界的思想：通过 "剪枝" 避免枚举所有情况。
三个核心概念：
1. 搜索树：把求解过程组织成一棵树
根节点 = 原问题
分支 = 固定某个变量的值（$x_i = 0$ 或 $x_i = 1$）
叶节点 = 所有变量都固定了，得到一个具体解
2. 界（Bound）：估计子树中最优解的范围
下界（对于最小化问题）：子树中任何解的目标值 $\geq$ 下界
3. 剪枝：如果子树的下界已经比当前最优解差，就不用继续探索了

LP 松弛：计算下界的方法

ILP：$\min c^T x \quad \text{s.t.} \quad Ax \leq b, \quad x \in \{0,1\}^n$
LP 松弛：把 $x \in \{0,1\}^n$ 改成 $x \in [0,1]^n$
$\min c^T x \quad \text{s.t.} \quad Ax \leq b, \quad x \in [0,1]^n$

为什么 LP 最优值是 ILP 最优值的下界？
LP 的可行域 $[0,1]^n$ 包含了 ILP 的可行域 $\{0,1\}^n$
（每个 0-1 点都在 $[0,1]$ 区间内）
所以 LP 能找到的最小值 $\leq$ ILP 能找到的最小值
LP 的优势：可以在多项式时间内求解！
（用单纯形法或内点法）
用途：在分支定界的每个节点，求解 LP 松弛得到下界

分支定界的剪枝规则

设置（最小化问题）：
当前找到的最优整数解的目标值 = UB（上界）
某个节点的 LP 松弛最优值 = LB（下界）
剪枝规则：如果 LB $\geq$ UB，则剪掉这个节点的整个子树
为什么？
LB 是这个子树中所有整数解的下界
如果 LB 已经 $\geq$ 当前最优解 UB
那这个子树里不可能有更好的解，不用继续探索了

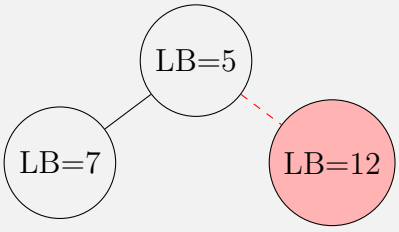

当前最优 UB = 10

右子树 LB = 12 > 10
剪枝！

2.3 完整例子：用分支定界求解背包问题

问题设置

背包问题：容量 $W = 10$ 公斤，4 个物品

物品编号	1	2	3	4
价值（元）	6	5	8	9
重量（公斤）	2	3	4	5
性价比	3.0	1.67	2.0	1.8

ILP 形式：

$$\begin{aligned} \max\ & 6x_1 + 5x_2 + 8x_3 + 9x_4 \\ \text{s.t.}\quad & 2x_1 + 3x_2 + 4x_3 + 5x_4 \le 10 \\ & x_1, x_2, x_3, x_4 \in \{0, 1\} \end{aligned}$$

注意：这是最大化问题，所以 LP 松弛给出**上界**，我们维护的最优解是**下界**。

第一步：求解根节点的 LP 松弛

LP 松弛：把 $x_i \in \{0, 1\}$ 改为 $x_i \in [0, 1]$

背包 LP 的贪心解法：按性价比从高到低选取

性价比排序：物品 1 (3.0) > 物品 3 (2.0) > 物品 4 (1.8) > 物品 2 (1.67)

贪心过程：

第一步：选物品 1，$x_1 = 1$

已用重量 $= 2$，剩余容量 $= 10 - 2 = 8$

第二步：选物品 3，$x_3 = 1$

已用重量 $= 2 + 4 = 6$，剩余容量 $= 10 - 6 = 4$

第三步：物品 4 重量 5 > 剩余容量 4，只能选一部分

$x_4 = \frac{\text{剩余容量}}{\text{物品 4 重量}} = \frac{4}{5} = 0.8$

已用重量 $= 6 + 5 \times 0.8 = 10$，剩余容量 $= 0$

第四步：物品 2，没有剩余容量，$x_2 = 0$

LP 解：$(x_1, x_2, x_3, x_4) = (1, 0, 1, 0.8)$

LP 值：$6 \times 1 + 5 \times 0 + 8 \times 1 + 9 \times 0.8 = 6 + 8 + 7.2 = \mathbf{21.2}$

第二步：分支

根节点：LP 值 $= 21.2$，LP 解 $= (1, 0, 1, 0.8)$

$x_4 = 0.8$ 是分数 $\Rightarrow$ 需要分支

分支策略：选取值为分数的变量，固定它为 0 或 1

产生两个子节点：

子节点 A：增加约束 $x_4 = 0$（不选物品 4）

子节点 B：增加约束 $x_4 = 1$（必须选物品 4）

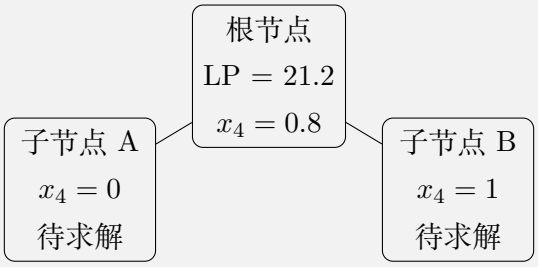

当前状态：还没有找到整数解，下界 LB $= -\infty$

第三步：求解子节点 A

子节点 A：$x_4 = 0$（不选物品 4）
子问题：在物品 1, 2, 3 中选择，容量仍为 10
LP 贪心：
选物品 1：$x_1 = 1$，已用重量 2，剩余 8
选物品 3：$x_3 = 1$，已用重量 6，剩余 4
选物品 2：重量 $3 \leq$ 剩余 4，$x_2 = 1$，已用重量 9，剩余 1
LP 解：$(x_1, x_2, x_3, x_4) = (1, 1, 1, 0)$
这是整数解！
验证可行性：总重量 $= 2 + 3 + 4 + 0 = 9 \leq 10$ ✓
目标值：$6 + 5 + 8 + 0 = \mathbf{19}$
更新下界：LB $= 19$（找到了一个价值为 19 的整数解）

第四步：求解子节点 B

子节点 B：$x_4 = 1$（必须选物品 4）
物品 4 占用重量 5，剩余容量 $= 10 - 5 = 5$
子问题：在物品 1, 2, 3 中选择，容量为 5
LP 贪心：
选物品 1：$x_1 = 1$，已用重量 2，剩余 3
选物品 3：重量 $4 >$ 剩余 3，$x_3 = \frac{3}{4} = 0.75$，已用重量 5，剩余 0
物品 2：$x_2 = 0$
LP 解：$(x_1, x_2, x_3, x_4) = (1, 0, 0.75, 1)$
$x_3 = 0.75$ 是分数，**不是整数解**
LP 值：$6 \times 1 + 5 \times 0 + 8 \times 0.75 + 9 \times 1 = 6 + 6 + 9 = \mathbf{21}$
剪枝判断：LP 值 $21 >$ 当前下界 19
这个子树**可能**有更好的解，不能剪枝，需要继续分支

第五步：对子节点 B 继续分支

子节点 B：LP 解 $= (1, 0, 0.75, 1)$，$x_3 = 0.75$ 是分数

分支：固定 $x_3 = 0$ 或 $x_3 = 1$

孙节点 B1：$x_4 = 1, x_3 = 0$

剩余容量 $= 10 - 5 = 5$，只能选物品 1 和 2

$x_1 = 1$（重量 2），$x_2 = 1$（重量 3），总重量 $= 5 \leq 5$ ✓

解：$(1, 1, 0, 1)$，**整数解**！

目标值 $= 6 + 5 + 0 + 9 = \mathbf{20}$

更新下界：LB $= \max(19, 20) = \mathbf{20}$

孙节点 B2：$x_4 = 1, x_3 = 1$

物品 3 和 4 占用重量 $= 4 + 5 = 9$，剩余容量 $= 1$

物品 1 重量 $2 > 1$，物品 2 重量 $3 > 1$，都放不下

解：$(0, 0, 1, 1)$，**整数解**

目标值 $= 0 + 0 + 8 + 9 = \mathbf{17} < 20$，不更新

完整搜索树

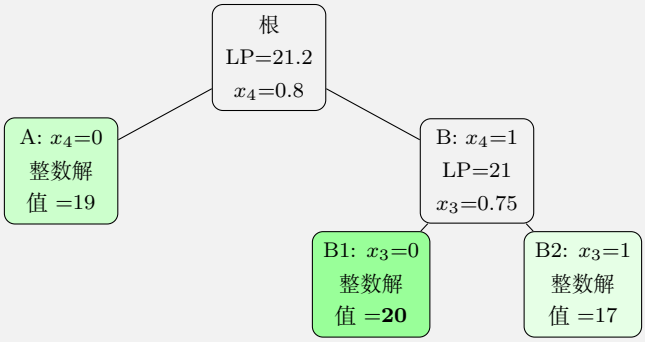

搜索顺序：根 → A（得 19）→ B（LP=21>19，继续）→ B1（得 20）→ B2（得 17）

最优解：$(x_1, x_2, x_3, x_4) = (1, 1, 0, 1)$

含义：选物品 1、2、4，总价值 **20** 元，总重量 $2 + 3 + 5 = 10$ 公斤

分支定界小结

我们做了什么：

1. 把背包问题写成 ILP
2. 用分支定界求解：在每个节点解 LP 松弛，根据界来剪枝
3. 找到了最优解，只探索了 5 个节点（而不是 $2^4 = 16$ 个）

分支定界对哪些问题有效？

问题类型	实际可解规模	原因
背包问题	$\sim 10^4$ 物品	LP 松弛非常紧
旅行商问题	~ 100 城市	有好的下界技术
一般 0-1 ILP	$\sim 10^3$ 变量	取决于问题结构
随机生成的 ILP	~ 50 变量	无结构，剪枝少

最坏情况：仍然是 $O(2^n)$，当 LP 松弛不紧时几乎无法剪枝

分支定界的执行过程

根节点：LP 最优 $= 21.2$，$x_D = 0.8$（分数），分支

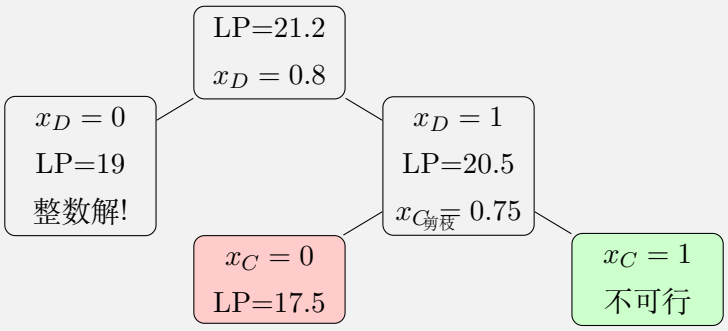

分支 $x_D = 0$：LP $= 6 + 5 + 8 = 19$（整数解！）$\Rightarrow$ UB $= 19$
分支 $x_D = 1$：剩余容量 5，LP $= 9 + 6 + 5.5 = 20.5$
继续分支 x_C... 最终发现 19 是最优

分支定界的局限性

最坏情况：仍然是 $O(2^n)$

问题类型	实际可解规模	原因
背包	$\sim 10^4$ 物品	LP 松弛非常紧
TSP	~ 100 城市	好的下界技术
一般 0-1 ILP	$\sim 10^3$ 变量	看 LP 松弛质量
随机 ILP	~ 50 变量	无结构，难剪枝

致命问题：顺序依赖
每一步的分支选择依赖之前的结果，**本质上是串行算法**

2.4 Benders 分解（选读）

为什么需要 Benders 分解？

问题：有些整数规划问题规模太大，分支定界也搞不定
例子：设施选址问题
有 m 个候选设施位置，n 个客户
决策：

- $y_i \in \{0,1\}$：是否在位置 i 开设设施
- $x_{ij} \geq 0$：设施 i 服务客户 j 的比例

关键观察：如果 y 固定了，x 的最优解可以**快速求出**
(每个客户选择离它最近的**已开设**设施即可)
Benders 的思想：把 y 和 x 分开处理

一个具体的小例子

问题：2 个候选设施，3 个客户
开设成本：$f_1 = 10$，$f_2 = 8$
服务成本（设施 i 到客户 j 的距离)：

	客户 1	客户 2	客户 3
设施 1	2	5	6
设施 2	7	3	4

目标：选择开哪些设施，并分配客户，使总成本最小
总成本 = 开设成本 + 服务成本
暴力枚举：y 有 $2^2 = 4$ 种可能，逐个算总成本

暴力枚举的结果

对每种 y，计算最优服务分配（每个客户选最近的已开设施)：
$y = (0,0)$：没有设施开，无法服务，**不可行**
$y = (1,0)$：只开设施 1
所有客户都必须由设施 1 服务
服务成本 $= 2 + 5 + 6 = 13$
总成本 $= 10 + 13 = \mathbf{23}$
$y = (0,1)$：只开设施 2
所有客户都必须由设施 2 服务
服务成本 $= 7 + 3 + 4 = 14$

总成本 $= 8 + 14 = \mathbf{22}$
$y = (1, 1)$：两个设施都开
客户 1 选设施 1（成本 $2 < 7$），客户 2 选设施 2（成本 $3 < 5$），客户 3 选设施 2（成本 $4 < 6$）
服务成本 $= 2 + 3 + 4 = 9$
总成本 $= 10 + 8 + 9 = \mathbf{27}$
最优：$y = (0, 1)$，总成本 $= 22$

Benders 的准备工作

把问题分成两部分：
主问题（关于 y）：

$$\min_{y,\theta} \quad \underbrace{f_1 y_1 + f_2 y_2}_{\text{开设成本}} + \underbrace{\theta}_{\text{服务成本的估计}}$$

约束：$y_1, y_2 \in \{0, 1\}$，$\theta \geq 0$，以及一些**待添加的 cut**
子问题（给定 y，关于 x）：
给定哪些设施开了，求最优服务分配的成本 $\theta(y)$
初始状态：
主问题中没有任何 cut，θ 可以取 0
主问题会选择开设成本最小的方案

Benders 迭代：第 1 轮

Step 1：求解主问题
当前主问题：min $10y_1 + 8y_2 + \theta$，没有 cut 约束
θ 可以取 0，所以主问题只看开设成本
最小开设成本：$y = (0, 1)$，开设成本 $= 8$
主问题给出：$y^{(1)} = (0, 1)$，下界 LB $= 8$
Step 2：求解子问题
给定 $y = (0, 1)$（只开设施 2），求服务成本
所有客户由设施 2 服务：$\theta(0, 1) = 7 + 3 + 4 = 14$
Step 3：更新上界
实际总成本 $= 8 + 14 = 22$
上界 UB $= 22$
Step 4：生成 Benders Cut
"当 $y_2 = 1, y_1 = 0$ 时，服务成本至少是 14"
Cut 1：$\theta \geq 14 - M \cdot y_1$（当 $y_1 = 0$ 时生效）
这里简化为：$\theta \geq 14(1 - y_1)$ 当 $y_2 = 1$

Benders Cut 的含义

Cut 告诉主问题什么信息？

第 1 轮我们发现：只开设施 2 时，服务成本 $= 14$

这个信息被编码成约束加到主问题里

Cut 的一般形式（简化版）：

对于我们尝试过的 $y^{(k)}$，生成约束：

$\theta \geq \theta(y^{(k)}) - \sum_i \pi_i(y_i - y_i^{(k)})$

其中 π_i 来自子问题的对偶解（这里略去推导）

直觉：

Cut 说"如果你选类似的 y，服务成本大概是这么多"

主问题在选 y 时必须考虑这个约束

Benders 迭代：第 2 轮

Step 1：求解主问题（带 Cut 1）

主问题：$\min\ 10y_1 + 8y_2 + \theta$

约束：$\theta \geq 14(1 - y_1)$（简化的 Cut 1）

分析各种 y 的主问题目标值：

$y = (0, 1)$：开设成本 8，$\theta \geq 14$，目标 $\geq 8 + 14 = 22$

$y = (1, 0)$：开设成本 10，$\theta \geq 0$（cut 不生效），目标 $\geq 10 + 0 = 10$

$y = (1, 1)$：开设成本 18，$\theta \geq 0$，目标 $\geq 18 + 0 = 18$

主问题选择下界最小的：$y^{(2)} = (1, 0)$，下界 LB $= 10$

Step 2：求解子问题

给定 $y = (1, 0)$（只开设施 1），服务成本 $= 2 + 5 + 6 = 13$

Step 3：更新上界

总成本 $= 10 + 13 = 23 > 22$，不更新 UB

Step 4：生成 Cut 2

$\theta \geq 13(1 - y_2)$（当只开设施 1 时）

Benders 迭代：第 3 轮

Step 1：求解主问题（带 Cut 1 和 Cut 2）

约束：$\theta \geq 14(1 - y_1)$，$\theta \geq 13(1 - y_2)$

分析各种 y：

$y = (0, 1)$：$\theta \geq \max(14, 0) = 14$，目标 $\geq 8 + 14 = 22$

$y = (1, 0)$：$\theta \geq \max(0, 13) = 13$，目标 $\geq 10 + 13 = 23$

$y = (1, 1)$：$\theta \geq \max(0, 0) = 0$，目标 $\geq 18 + 0 = 18$

主问题选择：$y^{(3)} = (1, 1)$，下界 LB $= 18$

Step 2：求解子问题
给定 $y = (1, 1)$，服务成本 $= 2 + 3 + 4 = 9$
Step 3：更新上界
总成本 $= 18 + 9 = 27 > 22$，不更新 UB
Step 4：生成 Cut 3
$\theta \geq 9$（当两个设施都开时）

Benders 迭代：第 4 轮（收敛）

Step 1：求解主问题（带 Cut 1, 2, 3）
约束：$\theta \geq 14(1 - y_1)$，$\theta \geq 13(1 - y_2)$，$\theta \geq 9 \cdot y_1 \cdot y_2$（简化）
分析各种 y：
$y = (0, 1)$：$\theta \geq 14$，目标 $\geq 8 + 14 = \mathbf{22}$
$y = (1, 0)$：$\theta \geq 13$，目标 $\geq 10 + 13 = 23$
$y = (1, 1)$：$\theta \geq 9$，目标 $\geq 18 + 9 = 27$
$y = (0, 0)$：不可行
所有可行的 y **的下界都** ≥ 22
而我们已经找到了成本为 22 的解 $y = (0, 1)$
收敛：下界 = 上界 = 22，最优解找到！

Benders 的剪枝效果

这个例子：4 种 y，Benders 做了 3 轮迭代
看起来没有节省？因为例子太小了。
剪枝发生在哪里？
在第 4 轮，主问题通过 cut 约束**直接算出**每种 y 的下界
不需要真的去求解子问题！
对于大规模问题：$m = 20$ 个设施，$2^{20} \approx 100$ 万种 y
Benders 可能只需要几十到几百轮迭代
每轮只需要：

- 求解一个小的主问题（带 cut 约束的 ILP）
- 求解一个子问题（LP，很快）

关键：Cut 积累的信息让主问题能够 “预判” 哪些 y 不好

Benders 分解总结

准备工作：

1. 把变量分成“难的” y（整数）和“容易的” x（连续）
2. 建立主问题（关于 y 和 θ）和子问题（给定 y，关于 x）
3. 初始化：主问题没有 cut，上界 UB $= \infty$

迭代过程：

1. 求解主问题，得到 $y^{(k)}$ 和下界 LB
2. 求解子问题，得到 $\theta(y^{(k)})$
3. 更新上界 UB $= \min(\text{UB}, \text{开设成本} + \theta(y^{(k)}))$
4. 生成 Benders Cut，加入主问题
5. 如果 LB $\geq$ UB，停止；否则继续

为什么能剪枝：Cut 让主问题能估计各种 y 的服务成本下界

Benders 分解的局限性

优点：

- 把大问题分解成小问题
- 子问题是 LP，可以快速求解
- 对于结构化问题效率高

局限性：

1. 迭代是串行的

第 $k+1$ 轮的主问题依赖第 k 轮生成的 cut

无法并行化这个过程

2. 主问题仍是整数规划

虽然规模变小了，但主问题本身还是 NP-Hard

3. 收敛速度不可预测

有些问题需要很多轮迭代才收敛

传统方法的共同困境

分支定界：

- 树搜索，每个节点依赖父节点的界
- 剪枝决策是串行的

Benders 分解：

- 迭代生成 cuts
- 每轮依赖前一轮的信息

共同问题：都是“一步一步”的算法

$$\boxed{\text{第 } k \text{ 步}} \xrightarrow{\text{依赖}} \boxed{\text{第 } k+1 \text{ 步}} \xrightarrow{\text{依赖}} \boxed{\text{第 } k+2 \text{ 步}}$$

在 GPU 时代，我们需要“一次性”的并行友好方法

3 新思路：近似算法与随机化

新思路：放弃精确，换取效率

关键观察：在很多应用中，我们不一定需要**精确**的最优解

- 物流调度：成本比最优多 5% 也可以接受
- 广告投放：效果比最优差 10% 也能盈利
- 芯片布局：面积比最优大 20% 也能用

近似算法的承诺：
我不保证找到最优解，但我保证：

1. **时间可控**：多项式时间完成
2. **质量有保证**：解的质量不会比最优差太多

形式化：α-近似算法
对于最小化问题：算法输出 $\text{ALG} \leq \alpha \cdot \text{OPT}$
对于最大化问题：算法输出 $\text{ALG} \geq \frac{1}{\alpha} \cdot \text{OPT}$
例如：2-近似算法保证解最多是最优的 2 倍差

近似算法的设计思路

回顾 LP 松弛：

ILP（难）$\xrightarrow{\text{松弛}}$ LP（易）$\xrightarrow{\text{求解}}$ 分数解 x^*

问题：分数解 $x^* \in [0,1]^n$ 没有实际意义（不能选“半个物品”）

需要：把分数解**舍入**成整数解 $\hat{x} \in \{0,1\}^n$

舍入的两种方式：

方式 1：确定性舍入

例如：$x_i^* \geq 0.5$ 则 $\hat{x}_i = 1$，否则 $\hat{x}_i = 0$

问题：对某些问题效果不好

方式 2：随机舍入

以概率 x_i^* 令 $\hat{x}_i = 1$，以概率 $1 - x_i^*$ 令 $\hat{x}_i = 0$

为什么随机舍入可能更好？

这需要理解“随机化的威力”，让我们从一个简单的例子开始。

4 连续松弛与舍入：近似算法的核心技术

LP 松弛 + 舍入框架

核心技术：**LP 松弛 + 舍入**

$$\boxed{\text{ILP（难）}} \xrightarrow{\text{松弛}} \boxed{\text{LP（易）}} \xrightarrow{\text{舍入}} \boxed{\text{近似解}}$$

舍入方式：确定性或随机化

接下来：通过 6 个经典例子，展示这套技术如何工作

连续化的核心思想

离散优化：$x \in \{0,1\}^n$（2^n 个点）

连续松弛：$x \in [0,1]^n$（凸集，无穷多点）

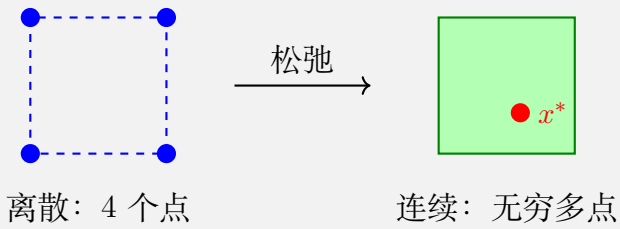

为什么有效？

1. 连续优化有**多项式时间**算法

2. 松弛解提供**下界**（对于最小化问题）
3. 分数解包含**结构信息**，指导舍入

连续化的统一框架

Step 1：写出整数规划 (ILP)

$$\min c^T x \quad \text{s.t.} \quad Ax \le b, \quad x \in \{0,1\}^n$$

Step 2：松弛为线性规划 (LP)

$$\min c^T x \quad \text{s.t.} \quad Ax \le b, \quad x \in [0,1]^n$$

Step 3：求解 LP，得到分数解 x^*
Step 4：**舍入** x^* 为整数解 $\hat{x}$
Step 5：分析 $\hat{x}$ 的质量

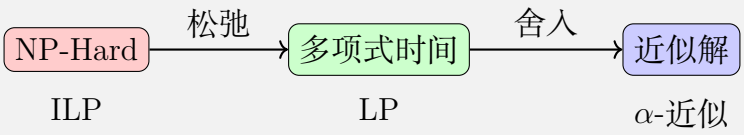

关键：证明 $\text{ALG} \le \alpha \cdot \text{OPT}_{\text{LP}} \le \alpha \cdot \text{OPT}$

4.1 例 1：Vertex Cover（2-近似）

什么是 Vertex Cover 问题？

问题描述：
给定一个图 $G = (V, E)$，选择一些顶点，使得**每条边至少有一个端点被选中**。
目标：选择尽可能少的顶点。
为什么叫“覆盖”？
被选中的顶点“覆盖”了与它相连的所有边。我们要用最少的顶点覆盖所有边。
应用：

- 监控系统：在路口放摄像头，覆盖所有道路
- 生物网络：选关键蛋白质，影响所有相互作用

一个具体的例子：8 顶点连通图

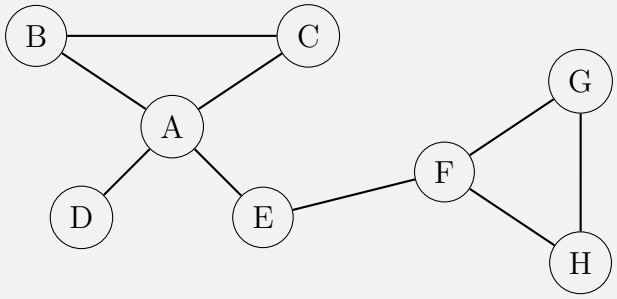

9 条边：(A,B), (A,C), (A,D), (A,E), (B,C), (E,F), (F,G), (G,H), (F,H)
结构：星形（A 为中心）+ 三角形（F,G,H）+ 连接边 (E,F)
这是一个连通图：可以从任意顶点走到任意其他顶点

方法 0：暴力枚举（精确最优）

枚举所有可能的顶点子集：$2^8 = 256$ 种
分析最优解：
星形部分：A 连接 4 条边，选 A 可以覆盖 (A,B), (A,C), (A,D), (A,E)
但还剩边 (B,C)，需要 B 或 C 至少选一个
$\Rightarrow$ 星形部分最少需要 **2 个**顶点
连接部分：边 (E,F) 需要 E 或 F 至少选一个
三角形部分：3 条边，每个顶点覆盖 2 条
$\Rightarrow$ 三角形最少需要 **2 个**顶点
最优解：选 $\{A, B, F, G\}$ 或 $\{A, C, F, G\}$ 等，$\mathbf{OPT = 4}$
验证 $\{A, B, F, G\}$：覆盖所有 9 条边 ✓
计算量：$O(2^n \cdot m)$，$n = 8$ 时 256 次检查，$n = 100$ 时 10^{30} 次！

方法 1：贪心算法（选度数最大的顶点）

贪心策略：每次选**覆盖最多未覆盖边**的顶点
初始：未覆盖边 = 全部 9 条
各顶点度数：A:4, B:2, C:2, D:1, E:2, F:3, G:2, H:2
Round 1：选 A（度数 4），覆盖 (A,B), (A,C), (A,D), (A,E)
剩余未覆盖：(B,C), (E,F), (F,G), (G,H), (F,H)
Round 2：F 覆盖 3 条 (E,F), (F,G), (F,H)，选 F
剩余未覆盖：(B,C), (G,H)
Round 3：B 或 C 覆盖 1 条，G 或 H 覆盖 1 条
选 B，剩余：(G,H)
Round 4：选 G

贪心解：$\{A, F, B, G\}$，**成本 = 4**
这次恰好等于最优！但贪心不总是最优...

贪心算法的问题

贪心的近似比：$O(\log n)$，不是常数！
为什么贪心可能差？
贪心每次选“当前最好”，但可能错过“全局更优”的组合

贪心差的例子：双梯形图

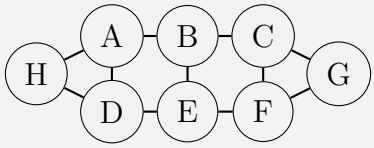

11 条边，度数：B:3, E:3, C:3, F:3, A:3, D:3, G:2, H:2
贪心（度数都是 3 时可能选错）：
假设选 B → 剩余 8 条边 → 选 E → 剩余 5 条边 → 选 C → 剩余 2 条边 → 选 H
贪心解：$\{B, E, C, H\}$，**成本 = 4**
最优解：$\{A, F, G\}$ 或 $\{D, C, H\}$？让我们检验：
$\{B, E, G, H\}$：覆盖所有 11 条边，**成本 = 4**
能否成本 3？尝试 $\{B, F, H\}$：
B 覆盖 (A,B), (B,C), (B,E) ✓
F 覆盖 (E,F), (C,F), (F,G) ✓
H 覆盖 (A,H), (D,H) ✓
剩余：(D,E), (A,D), (C,G) 未覆盖！**成本 3 不够**
结论：这个例子最优是 4，贪心也是 4——**贪心运气好**

贪心真正差的例子：层次覆盖

构造（n 个元素）：
层 1：1 个集合覆盖全部 n 个，成本 $= \log n$
层 2：2 个集合各覆盖 $n/2$ 个，每个成本 $= \log n - 1$
层 3：4 个集合各覆盖 $n/4$ 个，每个成本 $= \log n - 2$
...
层 $\log n$：n 个集合各覆盖 1 个，每个成本 $= 1$
性价比：每层都是 $\frac{\text{覆盖数}}{\text{成本}} = \frac{n/2^{k-1}}{\log n - k + 1}$
关键：底层集合的性价比更高！
贪心：从底层开始选，需要选 $\Theta(n)$ 个集合

最优：选顶层 1 个集合，成本 $= \log n$
近似比：$\frac{n}{\log n} = \Theta\left(\frac{n}{\log n}\right)$
实际上：贪心的严格近似比是 $H_n \approx \ln n$（调和级数）

具体数值：顶点覆盖的 LP 与阈值舍入

图：6 个顶点，3 条互不相交的边（一个完美匹配）

$$1-2 \qquad 3-4 \qquad 5-6$$

顶点覆盖的 LP 松弛：

$$\min \sum_{v=1}^{6} x_v$$

满足

$$x_1 + x_2 \geq 1, \qquad x_3 + x_4 \geq 1, \qquad x_5 + x_6 \geq 1,$$

以及

$$0 \leq x_v \leq 1 \qquad (\forall v).$$

LP 最优值：
由于三条边彼此独立，问题可以分解为 3 个相同的小问题：对每一条边 $\{u, v\}$，都要解

$$\min x_u + x_v \quad \text{s.t.} \quad x_u + x_v \geq 1, \quad 0 \leq x_u, x_v \leq 1.$$

这个小问题的最优值显然是 1，因此总的 LP 最优值为

$$\mathrm{LP}^\star = 1 + 1 + 1 = 3.$$

例如，下面这个分数解就是一个 LP 最优解：

$$x_1 = x_2 = x_3 = x_4 = x_5 = x_6 = 0.5.$$

整数最优解：
对于每条边，至少要选一个端点，因此整数最优解也恰好是每条边选一个点，例如

$$\{1, 3, 5\}, \qquad \mathrm{ILP}^\star = 3.$$

所以在这个例子中，

$$\mathrm{LP}^\star = \mathrm{ILP}^\star = 3.$$

注意：这里没有整数间隙，但这并不意味着所有 LP 最优解都是整数解；上面的全 0.5 解仍然是一个最优的分数解。
阈值舍入（选择所有满足 $x_v \geq 0.5$ 的顶点）：
由于上面的分数最优解满足

$$x_v = 0.5 \qquad (\forall v),$$

所以按阈值规则，6 个顶点会被全部选入。于是舍入后的顶点覆盖大小为

$$|S| = 6.$$

而真正的最优整数解大小只有

$$\mathrm{OPT} = 3.$$

因此该舍入解与最优解的比值为

$$\frac{6}{3} = 2.$$

结论：
这个例子说明：

- LP 本身在这里是精确的：$\mathrm{LP}^\star = \mathrm{ILP}^\star$；
- 但是简单的阈值舍入 $x_v \geq 0.5 \Rightarrow 1$ 仍可能把代价放大到 2 倍；
- 因而，顶点覆盖的 2-近似紧性可以来自**舍入步骤**，而不一定来自 LP 与 ILP 之间的整数间隙。

把这个例子推广到任意 $n/2$ 条独立边时，结论完全一样：LP 最优值始终为 $n/2$，而阈值舍入会选出全部 n 个顶点，因此比值始终达到 2。

贪心 vs LP 舍入：关键区别

贪心：

- 优点：简单快速，$O(nm)$
- 缺点：只看局部，近似比 $O(\log n)$

- 无理论保证！

LP 舍入：

- 优点：考虑全局约束，近似比是**常数**（Vertex Cover 是 2）
- 缺点：需要求解 LP，$O(n^{2.5})$
- **有严格理论保证**！

实践中：
小规模（$n < 100$）：两者差不多，贪心更快
大规模（$n > 10^4$）：LP 舍入更可靠
为什么 LP 舍入更好？
LP“看到”了所有约束的全局结构
贪心只看当前一步的局部最优

方法 2：匹配算法（2-近似）

另一种 2-近似：基于极大匹配
算法：

1. 找任意极大匹配 M（贪心：每次选一条边，删除两端点）
2. 选择 M 中所有边的端点

应用到我们的图：
选边 (A,B)，删除 A, B 及其相邻边
选边 (E,F)，删除 E, F 及其相邻边
选边 (G,H)，删除 G, H 及其相邻边
极大匹配：$M = \{(A, B), (E, F), (G, H)\}$
解：选 $\{A, B, E, F, G, H\}$，**成本 = 6**
分析：每条匹配边至少需要 1 个端点覆盖，所以 $|M| \leq \mathrm{OPT}$
选了 $2|M|$ 个顶点，所以 $\leq 2 \cdot \mathrm{OPT}$
计算量：$O(m)$，非常快！

方法 3：LP 舍入（2-近似）

LP 松弛：
$\min \sum_v x_v \quad \text{s.t.} \quad x_u + x_v \geq 1 \ \forall (u, v) \in E, \quad x_v \in [0, 1]$
求解 LP（用单纯形法或内点法）：

$x_A = 1$（中心，值得选）
$x_B = 0.5, x_C = 0.5$（满足 $x_B + x_C \geq 1$）
$x_D = 0$（A 已覆盖）
$x_E = 0.5, x_F = 0.5$（满足 $x_E + x_F \geq 1$）
$x_G = 0.5, x_H = 0.5$（三角形经典解）
LP 最优值 $= 1 + 0.5 \times 6 = \mathbf{4}$
舍入：$x_v \geq 0.5$ 则选
舍入后：选 $\{A, B, C, E, F, G, H\}$，**成本 = 7**
计算量：LP 求解 $O(n^{2.5})$ 或更快

方法比较：这个例子

方法	解	成本	计算量
暴力枚举	$\{A, B, F, G\}$	**4**（最优）	$O(2^n m)$
贪心	$\{A, F, B, G\}$	4	$O(nm)$
匹配	$\{A, B, E, F, G, H\}$	6	$O(m)$
LP 舍入	$\{A, B, C, E, F, G, H\}$	7	$O(n^{3.5})$

这个例子的观察：
贪心恰好找到最优（运气好）
匹配得到 1.5 倍最优
LP 舍入得到 1.75 倍最优
但是：LP 舍入有**最坏情况保证** ≤ 2，贪心没有！

写成整数规划（ILP）

决策变量：$x_v = \begin{cases} 1 & \text{选择顶点} v \\ 0 & \text{不选} \end{cases}$
目标函数：$\min\ x_A + x_B + x_C + x_D + x_E + x_F + x_G + x_H$
约束条件（9 条边，每条至少一个端点被选）：
$x_A + x_B \geq 1 \quad x_A + x_C \geq 1 \quad x_A + x_D \geq 1$
$x_A + x_E \geq 1 \quad x_B + x_C \geq 1 \quad x_E + x_F \geq 1$
$x_F + x_G \geq 1 \quad x_G + x_H \geq 1 \quad x_F + x_H \geq 1$
整数约束：所有 $x_v \in \{0, 1\}$
Gurobi 求解：< 0.01 秒得到最优解

LP 松弛的详细分析

LP 解：$x^* = (1, 0.5, 0.5, 0, 0.5, 0.5, 0.5, 0.5)$

验证所有约束：

(A, B): $1 + 0.5 = 1.5 \geq 1$ ✓ (A, C): $1 + 0.5 = 1.5 \geq 1$ ✓

(A, D): $1 + 0 = 1 \geq 1$ ✓ (A, E): $1 + 0.5 = 1.5 \geq 1$ ✓

(B, C): $0.5 + 0.5 = 1 \geq 1$ ✓ (E, F): $0.5 + 0.5 = 1 \geq 1$ ✓

(F, G): $0.5 + 0.5 = 1 \geq 1$ ✓ (G, H): $0.5 + 0.5 = 1 \geq 1$ ✓

(F, H): $0.5 + 0.5 = 1 \geq 1$ ✓

LP 最优值 $= 1 + 0.5 \times 6 = \mathbf{4}$

Integrality Gap：$\frac{\text{ILP}}{\text{LP}} = \frac{4}{4} = 1$（这个例子没有 gap!）

确定性舍入

舍入规则：如果 $x_v^* \geq 0.5$，就选择顶点 v

应用到 LP 解：

$x_A = 1 \geq 0.5 \Rightarrow$ 选 A ✓

$x_B = 0.5 \geq 0.5 \Rightarrow$ 选 B ✓

$x_C = 0.5 \geq 0.5 \Rightarrow$ 选 C ✓

$x_D = 0 < 0.5 \Rightarrow$ 不选 D

$x_E = 0.5 \geq 0.5 \Rightarrow$ 选 E ✓

$x_F = 0.5 \geq 0.5 \Rightarrow$ 选 F ✓

$x_G = 0.5 \geq 0.5 \Rightarrow$ 选 G ✓

$x_H = 0.5 \geq 0.5 \Rightarrow$ 选 H ✓

舍入后的解：选 {A, B, C, E, F, G, H}，共 **7** 个顶点

分析近似比

这个例子的结果：

ILP 最优 $= 4$

LP 最优 $= 4$

舍入后 $= 7$

近似比 $= \frac{7}{4} = 1.75 < 2$ ✓

为什么舍入后选了 7 个而不是 4 个？

因为 LP 解中有 6 个变量 $= 0.5$，舍入规则把它们都选了

但最优解只需要从每对“互补”的顶点中选一个

例如：边 (B,C) 只需要选 B 或 C，不需要都选

这是确定性舍入的局限：无法区分“都是 0.5”的情况

2-近似的证明

定理：确定性舍入是 Vertex Cover 的 2-近似算法

证明：

Step 1：舍入后的解一定可行

对于任意边 (u, v)，LP 约束保证 $x_u^* + x_v^* \geq 1$

$\Rightarrow$ 至少有一个 ≥ 0.5（否则和 < 1）

$\Rightarrow$ 舍入后至少选一个端点

$\Rightarrow$ 边 (u, v) 被覆盖 ✓

Step 2：舍入后的值 $\leq$ 2 倍 LP

对于每个顶点 v：

如果 $\hat{x}_v = 1$（选了），则 $x_v^* \geq 0.5$，所以 $\hat{x}_v \leq 2x_v^*$

如果 $\hat{x}_v = 0$（没选），则 $\hat{x}_v = 0 \leq 2x_v^*$

求和：$\sum_v \hat{x}_v \leq 2\sum_v x_v^* = 2 \cdot \text{LP}$

Step 3：LP $\leq$ ILP

算法 $\leq 2 \cdot \text{LP} \leq 2 \cdot \text{ILP} = 2 \cdot \text{OPT}$ $\square$

方法总结：Vertex Cover

方法	近似比	时间复杂度	特点
暴力枚举	1（精确）	$O(2^n m)$	只能小规模
贪心	$O(\log n)$	$O(nm)$	快但不稳定
匹配	2	$O(m)$	最快，保证 2 倍
LP 舍入	2	$O(n^{2.5})$	有理论保证

实践建议：

$n < 30$：用 Gurobi/CPLEX 求精确解

$n < 10^4$：匹配算法（快速，保证 2 倍）

n 很大：LP 舍入 + GPU 并行

理论极限：除非 P=NP，不存在 $(2 - \epsilon)$-近似算法！

思考：为什么不同方法差这么多？

贪心：局部最优 $\neq$ 全局最优

每步选“当前最好”，可能错过更好的整体方案

匹配：简单但保守

每条匹配边选两个端点，肯定覆盖，但可能多选

LP 舍入：利用全局信息

LP 考虑了所有约束，但舍入时丢失了分数信息

最优：考虑所有可能性
指数级搜索，小规模可行，大规模不可行
核心权衡：计算时间 vs 解的质量

4.2 随机化分析方法：从哈希表说起

为什么在这里讲哈希？

Vertex Cover 用的是确定性舍入（≥ 0.5 就选）
但很多问题需要随机舍入（以概率 x^* 选）
随机舍入的分析需要概率工具
哈希表是理解这些工具的最简单例子：

哈希表	随机舍入
随机选择哈希函数	随机决定选不选
冲突 = 坏事件	约束被违反 = 坏事件
分析期望冲突数	分析期望成本
Chernoff 得高概率保证	Chernoff 得高概率保证

先在哈希上理解方法，再应用到近似算法

哈希的问题：为什么需要它？

场景：存储 1000 个学号（8 位数字），支持快速查找
天真想法：用学号当数组下标
array[20210001] 存学号 20210001
问题：学号最大 10^8，需要开 10^8 大小的数组
但只有 1000 个学生，99.999% 空间浪费！
哈希的解决方案：压缩映射
$h(x) = x \mod 1000$
只需要大小 1000 的数组
$h(20210001) = 1$，$h(20210537) = 537$
查找只需要 1 次！

哈希冲突与对手攻击

冲突：不同学号可能映射到同一位置
$h(20210001) = 1$，$h(20211001) = 1$，$h(20221001) = 1$
都要存在 array[1]，查找变慢
对手攻击：如果对手知道 $h(x) = x \mod 1000$

故意选：1, 1001, 2001, ..., 999001（哈希值都是 1）
全部冲突，查找退化到 $O(n)$
2011 年真实攻击：构造大量冲突的 HTTP 参数，让服务器变慢
根本原因：确定性算法 $\Rightarrow$ 对手知道策略 $\Rightarrow$ 可针对攻击
解决方案：**随机化**

随机哈希：Universal Hash Family

思想：不用固定的 h，而是随机选一个
Universal Hash Family：一族函数 $\mathcal{H}$，满足
对任意 $x \neq y$：$P_{h\sim\mathcal{H}}[h(x) = h(y)] \leq \frac{1}{m}$
具体构造：$h_{a,b}(x) = ((ax + b) \mod p) \mod m$
随机选 a, b，对手不知道选了哪个！
例子：$m = 8$，$p = 17$，选 $a = 3$，$b = 5$
$h(7) = ((3 \times 7 + 5) \mod 17) \mod 8 = 26 \mod 17 \mod 8 = 9 \mod 8 = 1$
$h(15) = (50 \mod 17) \mod 8 = 16 \mod 8 = 0$
$h(23) = (74 \mod 17) \mod 8 = 6$
对比：$x \mod 8$ 会让 7, 15, 23 全冲突到位置 7
随机哈希后分散到 1, 0, 6

期望分析

问题：随机选 h 后，查找 x_i 期望比较多少次？
定义指示变量：$X_{ij} = \begin{cases} 1 & h(x_i) = h(x_j) \\ 0 & \text{否则} \end{cases}$
查找时间 $= 1 + \sum_{j\neq i} X_{ij}$（1 次 + 与冲突元素比较）
关键：$\mathbb{E}[X_{ij}] = P[h(x_i) = h(x_j)] \leq \frac{1}{m}$
期望的线性性（**不要求独立**！）：

$$\mathbb{E}\left[1 + \sum_{j\neq i} X_{ij}\right] = 1 + \sum_{j\neq i} \mathbb{E}[X_{ij}] \leq 1 + \frac{n-1}{m}$$

取 $m = n$：期望查找时间 < 2
对比：遍历 1000 次，二分 10 次，哈希期望 < 2 次

高概率保证：Chernoff Bound

问题：期望好，但会不会运气差？

Chernoff Bound：$X_1, \ldots, X_n$ 独立 0-1 变量，$\mu = \mathbb{E}[\sum_i X_i]$

$$P\left[\sum_i X_i > (1+\delta)\mu\right] \le e^{-\frac{\delta^2\mu}{3}}$$

应用：某位置期望元素数 $\mu = 1$
$P[\text{元素数} > 10] \le e^{-27} \approx 10^{-12}$
Union Bound：1000 个位置
$P[\text{存在某位置} > 10] \le 1000 \times 10^{-12} = 10^{-9}$
结论：以 $> 99.9999999\%$ 概率，所有查找 ≤ 10 次

Chernoff Bound 证明

定理：$X_1, \ldots, X_n$ 独立 0-1 变量，$\mu = \mathbb{E}[\sum_i X_i]$，则对 $0 < \delta \le 1$：

$$P\left[\sum_i X_i > (1+\delta)\mu\right] \le e^{-\frac{\delta^2\mu}{3}}$$

第一步：指数放大 + Markov

直接用 Markov 不等式太松。技巧：对任意 $t > 0$，做指数变换：

$$P\left[\sum_i X_i > (1+\delta)\mu\right] = P\left[e^{t\sum_i X_i} > e^{t(1+\delta)\mu}\right] \le \frac{\mathbb{E}\left[e^{t\sum_i X_i}\right]}{e^{t(1+\delta)\mu}}$$

最后一步是对非负随机变量 $e^{t\sum X_i}$ 用 Markov 不等式。
为什么要做指数变换？
把加法变成乘法——独立性在乘法下可以拆开：

$$\mathbb{E}\left[e^{t\sum_i X_i}\right] = \prod_i \mathbb{E}\left[e^{tX_i}\right]$$

第二步：控制每个因子

X_i 是 0-1 变量，设 $p_i = \mathbb{E}[X_i]$：

$$\mathbb{E}[e^{tX_i}] = (1-p_i)\cdot 1 + p_i \cdot e^t = 1 + p_i(e^t - 1)$$

利用 $1 + x \le e^x$（对所有实数 x 成立）：

$$1 + p_i(e^t - 1) \le e^{p_i(e^t-1)}$$

连乘：

$$\prod_i \mathbb{E}[e^{tX_i}] \le \prod_i e^{p_i(e^t-1)} = e^{(e^t-1)\sum_i p_i} = e^{(e^t-1)\mu}$$

代回第一步：

$$P\left[\sum_i X_i > (1+\delta)\mu\right] \le \frac{e^{(e^t-1)\mu}}{e^{t(1+\delta)\mu}} = e^{\left[(e^t-1)-t(1+\delta)\right]\mu}$$

第三步：选最优的 t

令 $f(t) = (e^t - 1) - t(1+\delta)$，求导：

$$f'(t) = e^t - (1+\delta) = 0 \implies t^* = \ln(1+\delta)$$

代入：

$$\begin{aligned} f(t^*) &= (e^{\ln(1+\delta)} - 1) - \ln(1+\delta)\cdot(1+\delta) \\ &= \delta - (1+\delta)\ln(1+\delta) \end{aligned}$$

精确的 Chernoff Bound：

$$\boxed{P\left[\sum_i X_i > (1+\delta)\mu\right] \le e^{[\delta-(1+\delta)\ln(1+\delta)]\mu}}$$

第四步：化简为常用形式

需要证明：当 $0 < \delta \le 1$ 时，

$$\delta - (1+\delta)\ln(1+\delta) \le -\frac{\delta^2}{3}$$

即证 $(1+\delta)\ln(1+\delta) \ge \delta + \frac{\delta^2}{3}$。
Taylor 展开 $\ln(1+\delta) = \delta - \frac{\delta^2}{2} + \frac{\delta^3}{3} - \frac{\delta^4}{4} + \cdots$，所以：

$$\begin{aligned} (1+\delta)\ln(1+\delta) &= (1+\delta)\left(\delta - \frac{\delta^2}{2} + \frac{\delta^3}{3} - \cdots\right) \\ &= \delta + \frac{\delta^2}{2} - \frac{\delta^3}{6} + \cdots \end{aligned}$$

需要 $\delta + \frac{\delta^2}{2} - \frac{\delta^3}{6} + \cdots \ge \delta + \frac{\delta^2}{3}$，即 $\frac{\delta^2}{6} - \frac{\delta^3}{6} + \cdots \ge 0$。
当 $0 < \delta \le 1$ 时，高阶项交替递减，可以逐对配对证明非负。
代入精确版本即得：

$$\boxed{P\left[\sum_i X_i > (1+\delta)\mu\right] \le e^{-\frac{\delta^2\mu}{3}}}$$

注：此形式要求 $0 < \delta \le 1$。精确版本 $e^{[\delta-(1+\delta)\ln(1+\delta)]\mu}$ 对所有 $\delta > 0$ 成立且更紧。

直觉：随机化分析的三板斧

工具 1：指示随机变量
把复杂事件分解成简单的 0-1 变量
工具 2：期望的线性性
$\mathbb{E}[\sum X_i] = \sum \mathbb{E}[X_i]$，**不要求独立**！
工具 3：Chernoff + Union Bound
从 "期望好" 到 "高概率好"
接下来：用这三板斧分析随机舍入的近似算法

例 2: Set Cover：具体例子

问题：用最小成本的子集覆盖全集
例子：$U = \{1, 2, 3, 4, 5, 6\}$，4 个子集

子集	包含元素	成本
S_1	$\{1, 2, 3\}$	3
S_2	$\{2, 4, 5\}$	3
S_3	$\{3, 4, 6\}$	3
S_4	$\{1, 2, 3, 4, 5, 6\}$	5

ILP：

$$\begin{aligned} \min \quad & \sum_j c_j x_j \\ \text{s.t.} \quad & \sum_{j:\, e \in S_j} x_j \geq 1, \quad \forall e \in U \\ & x_j \in \{0, 1\} \end{aligned}$$

ILP 最优：选 $\{S_4\}$，成本 $= \mathbf{5}$

Set Cover：单轮随机舍入的问题

LP 松弛：$x_j \in [0, 1]$，设最优解为 x^*，最优值 $\mathrm{LP}^* \leq \mathrm{OPT}$。
朴素舍入：以概率 x_j^* 选择 S_j。
期望成本很好：$\mathbb{E}[\text{成本}] = \sum_j c_j x_j^* = \mathrm{LP}^*$
但覆盖性很差。对元素 e，设包含 e 的子集的 LP 值之和 ≥ 1：

$$P[e \text{ 未覆盖}] = \prod_{j:\, e \in S_j} (1 - x_j^*) \leq \prod_{j:\, e \in S_j} e^{-x_j^*} = e^{-\sum_{j:\, e \in S_j} x_j^*} \leq \frac{1}{e} \approx 0.368$$

每个元素有约 37% 的概率没被覆盖——单轮不够！

Set Cover：正确的算法

关键思路：放大选择概率 + 确定性兜底。
算法：

1. 解 LP 松弛，得最优解 x^*
2. **随机步**：独立地以概率 $p_j = \min(1, \ln n \cdot x_j^*)$ 选择 S_j
3. **兜底步**：对每个仍未覆盖的元素 e，选包含 e 的最便宜子集 $S(e)$

注意：选择概率是 $\ln n \cdot x_j^*$ 而不是 x_j^*——放大了 $\ln n$ 倍！
算法一定输出可行解（兜底步保证），问题只是成本有多大。

Set Cover：成本分析

总成本 = 随机步成本 + 兜底步成本。由期望的线性性：

$$\mathbb{E}[\text{总成本}] = \mathbb{E}[\text{alg}_1] + \mathbb{E}[\text{alg}_2]$$

第一部分：随机步的期望成本

$$\mathbb{E}[\text{alg}_1] = \sum_j c_j \cdot p_j \le \sum_j c_j \cdot \ln n \cdot x_j^* = \ln n \cdot \text{LP}^*$$

第二部分：兜底步的期望成本
先证一个引理：对任意元素 e，包含 e 的最便宜子集 $S(e)$ 的成本满足

$$c(S(e)) \le \text{LP}^*$$

证明：$\text{LP}^* = \sum_j c_j x_j^* \ge \sum_{j:\, e \in S_j} c_j x_j^* \ge c(S(e)) \cdot \underbrace{\sum_{j:\, e \in S_j} x_j^*}_{\ge 1}$

Set Cover：兜底成本的控制

设 Y_e 为元素 e 在随机步后仍未覆盖的指示变量。

$$\mathbb{E}[\text{alg}_2] = \sum_{e \in U} c(S(e)) \cdot \mathbb{E}[Y_e] \le \text{LP}^* \cdot \sum_{e \in U} \mathbb{E}[Y_e]$$

关键：放大概率后，e 未覆盖的概率非常小：

$$\mathbb{E}[Y_e] = \prod_{j:\, e \in S_j} (1 - p_j) \le \prod_{j:\, e \in S_j} e^{-\ln n \cdot x_j^*} = e^{-\ln n \cdot \sum_{j:\, e \in S_j} x_j^*} \le e^{-\ln n} = \frac{1}{n}$$

因此：

$$\mathbb{E}[\text{alg}_2] \le \text{LP}^* \cdot \sum_{e \in U} \frac{1}{n} = \text{LP}^* \cdot \frac{n}{n} = \text{LP}^*$$

合并：

$$\boxed{\mathbb{E}[\text{总成本}] \le \ln n \cdot \text{LP}^* + \text{LP}^* = (1 + \ln n) \cdot \text{LP}^* \le (1 + \ln n) \cdot \text{OPT}}$$

Set Cover：总结

定理：上述随机舍入算法是 $(1 + \ln n)$-近似算法。

- **一定可行**：兜底步保证所有元素被覆盖
- **期望成本** $\le (1 + \ln n) \cdot \text{OPT}$
- 随机步贡献 $\ln n \cdot \text{LP}^*$（放大概率的代价）
- 兜底步贡献 $\le \text{LP}^*$（因为未覆盖概率 $\le 1/n$，很小）

注：这个 $O(\log n)$ 近似比是**紧**的——除非 P = NP，Set Cover 不存在 $(1 - \varepsilon) \ln n$ 近似算法（Dinur & Steurer, 2014）。

回到具体例子

$n = 6$，$\ln 6 \approx 1.79$。LP 最优解 $x^* = (0.6, 0.5, 0.4, 0)$，$\text{LP}^* = 4.5$。
放大后的选择概率：$p_j = \min(1, \ln 6 \cdot x_j^*)$

子集	x_j^*	$p_j = \min(1, 1.79 \cdot x_j^*)$
S_1	0.6	$\min(1, 1.07) = \mathbf{1.0}$
S_2	0.5	$\min(1, 0.90) = 0.90$
S_3	0.4	$\min(1, 0.72) = 0.72$
S_4	0	0

S_1 必选（$p_1 = 1$），这就覆盖了元素 1, 2, 3。
剩余未覆盖概率：

元素	未覆盖概率
4 ($\in S_2, S_3$)	$(1 - 0.90)(1 - 0.72) = 0.028$
5 ($\in S_2$)	$1 - 0.90 = 0.10$
6 ($\in S_3$)	$1 - 0.72 = 0.28$

都远小于朴素舍入时的概率，兜底步几乎不需要额外花钱。

4.3 例 3：Max-SAT（3/4-近似）

什么是 Max-SAT 问题？

SAT 问题回顾：
给定一个布尔公式，判断是否存在一个变量赋值使公式为真。
Max-SAT 问题：
给定一个布尔公式（由多个子句组成），找一个变量赋值，使得**满足的子句数最多**。
例子：3 个变量 x_1, x_2, x_3，4 个子句

$$
\begin{aligned}
C_1 &= (x_1 \vee x_2) \quad (x_1 \text{ 为真或 } x_2 \text{ 为真}) \\
C_2 &= (\bar{x}_1 \vee x_3) \quad (x_1 \text{ 为假或 } x_3 \text{ 为真}) \\
C_3 &= (x_2 \vee \bar{x}_3) \quad (x_2 \text{ 为真或 } x_3 \text{ 为假}) \\
C_4 &= (\bar{x}_2) \quad (x_2 \text{ 为假})
\end{aligned}
$$

注意：$\bar{x}$ 表示 x 的否定（x 为真时 $\bar{x}$ 为假，反之亦然）
目标：找一个赋值，让尽可能多的子句为真。

枚举所有可能的赋值

3 个变量，每个可以是 True 或 False，共有 $2^3 = 8$ 种可能的赋值。
赋值 1：$x_1 = T, x_2 = T, x_3 = T$
$C_1 = T \vee T = T$ ✓ $C_2 = F \vee T = T$ ✓ $C_3 = T \vee F = T$ ✓ $C_4 = F$ ×
满足 **3** 个子句。
赋值 2：$x_1 = T, x_2 = F, x_3 = T$
$C_1 = T \vee F = T$ ✓ $C_2 = F \vee T = T$ ✓ $C_3 = F \vee F = F$ × $C_4 = T$ ✓
满足 **3** 个子句。
赋值 3：$x_1 = F, x_2 = T, x_3 = F$
$C_1 = F \vee T = T$ ✓ $C_2 = T \vee F = T$ ✓ $C_3 = T \vee T = T$ ✓ $C_4 = F$ ×
满足 **3** 个子句。
赋值 4：$x_1 = F, x_2 = F, x_3 = F$
$C_1 = F \vee F = F$ × $C_2 = T \vee F = T$ ✓ $C_3 = F \vee T = T$ ✓ $C_4 = T$ ✓
满足 **3** 个子句。
观察：无论怎么赋值，最多只能满足 3 个子句（$\mathbf{OPT = 3}$）。
原因：$C_1 = (x_1 \vee x_2)$ 和 $C_4 = (\bar{x}_2)$ 存在结构性冲突——$x_2 = T$ 则 C_4 不满足；$x_2 = F$ 则要满足 C_1 就需要 $x_1 = T$，这又压缩了 C_2 的空间。

方法 1：纯随机算法（不用 LP！）

算法：对每个变量，独立地以 50% 概率设为 True，50% 概率设为 False。

分析子句 $C_1 = (x_1 \vee x_2)$ 被满足的概率：

C_1 不满足 $\Leftrightarrow x_1 = F$ 且 $x_2 = F$

$P[C_1$ 不满足$] = 0.5 \times 0.5 = 0.25$，故 $P[C_1$ 满足$] = 1 - 0.25 = \mathbf{0.75}$

一般规律：含 k 个文字的子句

$P[\text{满足}] = 1 - \frac{1}{2^k}$

子句大小 k	满足概率
1	$1 - \frac{1}{2} = 0.5$
2	$1 - \frac{1}{4} = 0.75$
3	$1 - \frac{1}{8} = 0.875$
∞	$\to 1$

特点：k 越大概率越高——纯随机对**长子句**很好，但对**短子句**差（$k = 1$ 时仅 0.5）。

计算我们例子的期望

四个子句的满足概率：

$C_1 = (x_1 \vee x_2)$：$k = 2$，$P = 0.75$

$C_2 = (\bar{x}_1 \vee x_3)$：$k = 2$，$P = 0.75$

$C_3 = (x_2 \vee \bar{x}_3)$：$k = 2$，$P = 0.75$

$C_4 = (\bar{x}_2)$：$k = 1$，$P = 0.5$

期望满足的子句数（期望的线性性）：

$\mathbb{E}[\text{满足数}] = 0.75 + 0.75 + 0.75 + 0.5 = \mathbf{2.75}$

近似比 $= \frac{2.75}{3} \approx 0.917$

一般保证：每个子句至少有 1 个文字，满足概率 ≥ 0.5

$\Rightarrow$ 期望满足数 $\geq \frac{1}{2}\times$ 子句总数 $\geq \frac{1}{2} \times \mathrm{OPT}$

纯随机是 $\frac{1}{2}$-近似算法！

方法 2：LP 随机舍入

LP 松弛：

对每个变量 x_i，定义 $y_i \in [0, 1]$（x_i 为真的” 程度”）

对每个子句 C_j，定义 $z_j \in [0, 1]$（C_j 被满足的” 程度”）

约束（以 $C_2 = (\bar{x}_1 \vee x_3)$ 为例）：

$z_2 \leq (1 - y_1) + y_3$

（C_2 被满足需要 $\bar{x}_1$ 或 x_3 为真，$\bar{x}_1$ 为真的程度是 $1 - y_1$）

完整 LP：

$$\begin{aligned} \max \quad & z_1 + z_2 + z_3 + z_4 \\ \text{s.t.} \quad & z_1 \le y_1 + y_2 \\ & z_2 \le (1 - y_1) + y_3 \\ & z_3 \le y_2 + (1 - y_3) \\ & z_4 \le (1 - y_2) \\ & 0 \le z_j \le 1, \quad 0 \le y_i \le 1 \end{aligned}$$

随机舍入：解 LP 得 (y^*, z^*)，以概率 y_i^* 令 $x_i = \text{True}$。

LP 舍入的近似保证

定理：对含 k 个文字的子句 C_j，LP 舍入的满足概率 $\ge (1 - (1 - \frac{1}{k})^k) \cdot z_j^*$。
证明思路：设子句 C_j 含 k 个文字，LP 解中各文字为真的程度之和 $\ge z_j^*$。由 AM-GM 不等式，不满足的概率：

$$\prod_{i=1}^{k}(1 - p_i) \le \left(\frac{\sum(1 - p_i)}{k}\right)^k = \left(1 - \frac{\sum p_i}{k}\right)^k \le \left(1 - \frac{z_j^*}{k}\right)^k$$

满足概率 $\ge 1 - (1 - z_j^*/k)^k \ge (1 - (1 - 1/k)^k) \cdot z_j^*$（因为 $z_j^* \le 1$）。

子句大小 k	LP 舍入保证 $\ge \alpha_k \cdot z_j^*$
1	$1.0 \cdot z_j^*$
2	$0.75 \cdot z_j^*$
3	$\approx 0.704 \cdot z_j^*$
∞	$\to (1 - 1/e) \cdot z_j^* \approx 0.632 \cdot z_j^*$

特点：LP 舍入对**短子句**很好（$k = 1$ 时系数为 1.0），但对**长子句**退化到 $1 - 1/e$。
直觉：短子句文字少，LP 解给出的方向很精确，舍入几乎不丢信息；长子句文字多，LP 的"部分赋值"优势被稀释。

组合两种方法：3/4 近似

关键观察——两种方法互补：
方法 1（纯随机）对**长**子句好：k 越大，$1 - 1/2^k \to 1$
方法 2（LP 舍入）对**短**子句好：$k = 1$ 时系数 1.0，几乎完美
组合方法：两套都跑一遍取最好的那一个
组合后的满足概率（利用 $z_j^* \le 1$，且 $\text{OPT} \le \sum z_j^*$）：

k	方法 1：$1-1/2^k$	方法 2：$\alpha_k \cdot z_j^*$	组合（取 $z_j^*=1$）
1	0.500	1.000	$\frac{0.500+1.000}{2} = \mathbf{0.750}$
2	0.750	0.750	$\frac{0.750+0.750}{2} = \mathbf{0.750}$
3	0.875	0.704	$\frac{0.875+0.704}{2} \approx 0.790$
∞	$\to 1$	$\to 0.632$	$\to 0.816$

关键：无论 k 是多少，组合后的概率都 ≥ 0.75！
更严格地，可以证明对任意 k：

$$\frac{1}{2}\left(1-\frac{1}{2^k}\right)+\frac{1}{2}\left(1-\left(1-\frac{1}{k}\right)^k\right) \geq \frac{3}{4}$$

结论：组合方法是 **3/4-近似算法**！

4.4 例 4：Max-Cut（0.878-近似）

什么是 Max-Cut 问题？

问题描述：
给定一个图，要把所有顶点分成两组 S 和 $\bar{S}$。
一条边叫做 “被切” 的，如果它的两个端点分别在 S 和 $\bar{S}$ 中。
目标：找一种分组方式，使被切的边数最多。
为什么叫 “Cut”？
想象用一把刀沿着 S 和 $\bar{S}$ 的边界切下去，会切断多少条边？
例子：考虑一个有 4 个顶点、5 条边的图

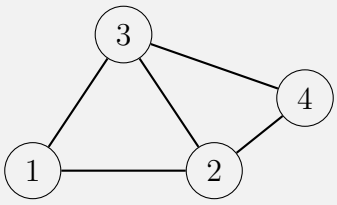

5 条边分别是：(1,2), (1,3), (2,3), (2,4), (3,4)

枚举一些分组方案

方案 1：$S=\{1\}$，$\bar{S}=\{2,3,4\}$
哪些边被切？一条边被切当且仅当一个端点在 S，另一个在 $\bar{S}$。
边 (1,2)：1 在 S，2 在 $\bar{S} \Rightarrow$ **被切** ✓
边 (1,3)：1 在 S，3 在 $\bar{S} \Rightarrow$ **被切** ✓
边 (2,3)：2 和 3 都在 $\bar{S} \Rightarrow$ 不被切

边 (2,4)：2 和 4 都在 $\bar{S} \Rightarrow$ 不被切
边 (3,4)：3 和 4 都在 $\bar{S} \Rightarrow$ 不被切
被切的边数 = 2
方案 2：$S = \{1, 3\}$，$\bar{S} = \{2, 4\}$
边 (1,2)：1 在 S，2 在 $\bar{S} \Rightarrow$ **被切** ✓
边 (1,3)：1 和 3 都在 $S \Rightarrow$ 不被切
边 (2,3)：2 在 $\bar{S}$，3 在 $S \Rightarrow$ **被切** ✓
边 (2,4)：2 和 4 都在 $\bar{S} \Rightarrow$ 不被切
边 (3,4)：3 在 S，4 在 $\bar{S} \Rightarrow$ **被切** ✓
被切的边数 = 3

继续枚举

方案 3：$S = \{1, 4\}$，$\bar{S} = \{2, 3\}$
边 (1,2)：被切 ✓
边 (1,3)：被切 ✓
边 (2,3)：不被切
边 (2,4)：被切 ✓
边 (3,4)：被切 ✓
被切的边数 = 4
方案 4：$S = \{2, 3\}$，$\bar{S} = \{1, 4\}$
（和方案 3 一样，只是 S 和 $\bar{S}$ 互换）
被切的边数 = **4**
OPT = 4（最多能切 4 条边，剩下的边 (2,3) 无论怎样都切不到）
为什么？因为顶点 2 和 3 之间有边，它们必须在同一组才能不被切，
但如果它们在同一组，(2,3) 这条边就切不到。
最优分组把 $\{2, 3\}$ 放在一起，其他 4 条边都被切了。

为什么 LP 松弛不好用？

尝试用 LP：
用 $x_v \in \{-1, +1\}$ 表示顶点 v 在哪一组（+1 表示在 S，-1 表示在 $\bar{S}$）
边 (u, v) 被切 $\Leftrightarrow x_u \neq x_v \Leftrightarrow x_u \cdot x_v = -1$
边 (u, v) 被切的“程度”可以写成：$\frac{1 - x_u x_v}{2}$
（当 $x_u x_v = -1$ 时，这个值是 1；当 $x_u x_v = +1$ 时，这个值是 0）
目标函数：$\max \sum_{(u,v) \in E} \frac{1 - x_u x_v}{2}$
问题：$x_u x_v$ 是**二次**的，不是线性的！
这不是 LP（线性规划），而是 QP（二次规划）。

简单的松弛：把 $x_v \in \{-1, +1\}$ 松弛为 $x_v \in [-1, +1]$
如果令所有 $x_v = 0$，每条边贡献 $\frac{1-0}{2} = 0.5$
总共 $5 \times 0.5 = 2.5$，但 OPT $= 4$，这个上界太松了！
结论：简单的 LP 松弛对 Max-Cut 不好用，我们需要更强的工具。

SDP（半定规划）松弛

关键思想：$x_v \in \{-1, +1\}$ 可以看成**一维单位向量**
把 -1 看成向量 (-1)，+1 看成向量 $(+1)$。
推广到高维：用 n 维单位向量 $\mathbf{v}_v$ 代替标量 x_v
约束：$\|\mathbf{v}_v\| = 1$（向量长度为 1）
两个向量的 "相似程度" 用**点积**衡量：$\mathbf{v}_u \cdot \mathbf{v}_v = \cos\theta$
其中 θ 是两个向量的夹角。
SDP 目标函数：
$\max \sum_{(u,v)\in E} \frac{1-\mathbf{v}_u \cdot \mathbf{v}_v}{2}$
当两个向量夹角大时（接近相反方向），$\cos\theta$ 接近 -1，贡献接近 1。
当两个向量夹角小时（接近同方向），$\cos\theta$ 接近 +1，贡献接近 0。
好消息：SDP 可以在多项式时间内求解！（用椭球法或内点法）

Goemans-Williamson 算法（1995 年）

步骤 1：求解 SDP，得到每个顶点对应的单位向量 $\mathbf{v}_1, \mathbf{v}_2, \ldots, \mathbf{v}_n$
步骤 2：随机选一个过原点的**超平面**
具体做法：随机选一个方向 $\mathbf{r}$（在单位球面上均匀随机）
超平面就是所有与 $\mathbf{r}$ 垂直的点构成的平面
步骤 3：根据向量在超平面的哪一侧来分组
$S = \{\text{顶点} v : \mathbf{v}_v \cdot \mathbf{r} > 0\}$（向量和 $\mathbf{r}$ 同侧）
$\bar{S} = \{\text{顶点} v : \mathbf{v}_v \cdot \mathbf{r} \leq 0\}$（向量和 $\mathbf{r}$ 异侧）
直觉：如果两个向量 $\mathbf{v}_u$ 和 $\mathbf{v}_v$ 夹角大（接近相反），
它们很可能被超平面分到不同侧，边 (u, v) 就会被切。

分析：边被切的概率

关键问题：边 (u, v) 被切的概率是多少？
答案：$P[(u, v) \text{ 被切}] = \frac{\theta_{uv}}{\pi}$
其中 θ_{uv} 是向量 $\mathbf{v}_u$ 和 $\mathbf{v}_v$ 的夹角。
为什么？
想象在二维平面上，$\mathbf{v}_u$ 和 $\mathbf{v}_v$ 是两个单位向量，夹角为 θ。
随机选一条过原点的直线（超平面在二维就是直线）。

u 和 v 被分开 $\Leftrightarrow$ 直线穿过 $\mathbf{v}_u$ 和 $\mathbf{v}_v$ 之间的扇形区域
这个扇形区域占整个圆的比例是 $\frac{\theta}{\pi}$（因为直线把圆分成两半）
所以 $P[\text{被分开}] = \frac{\theta}{\pi}$
例子：如果 $\theta = 90^\circ = \frac{\pi}{2}$，则 $P = \frac{\pi/2}{\pi} = 0.5$
如果 $\theta = 180^\circ = \pi$（完全相反），则 $P = 1$
如果 $\theta = 0^\circ$（完全相同），则 $P = 0$

0.878 近似比的来源

期望被切的边数：
$\mathbb{E}[\text{CUT}] = \sum_{(u,v)\in E} P[(u,v) \text{ 被切}] = \sum_{(u,v)\in E} \frac{\theta_{uv}}{\pi}$
SDP 的目标值：
$\text{SDP} = \sum_{(u,v)\in E} \frac{1-\cos\theta_{uv}}{2}$
我们需要比较 $\frac{\theta}{\pi}$ 和 $\frac{1-\cos\theta}{2}$
数值计算：

θ（度）	θ/π	$(1-\cos\theta)/2$	比值
60°	$1/3 = 0.333$	$(1-0.5)/2 = 0.25$	$0.333/0.25 = 1.33$
90°	$1/2 = 0.5$	$(1-0)/2 = 0.5$	$0.5/0.5 = 1.0$
120°	$2/3 = 0.667$	$(1-(-0.5))/2 = 0.75$	$0.667/0.75 = 0.89$
134°	0.744	0.845	$0.744/0.845 = \mathbf{0.878}$
180°	1	1	1.0

最小比值出现在 $\theta \approx 134^\circ$，值约为 **0.878**
结论：$\mathbb{E}[\text{CUT}] \geq 0.878 \times \text{SDP} \geq 0.878 \times \text{OPT}$
这是一个 0.878-近似算法！

4.5 例 5：Scheduling（2-近似）

无关机器调度问题

问题：

- n 个作业，m 台机器
- 作业 j 在机器 i 上需时间 p_{ij}（无关机器）
- 目标：最小化 makespan（最后完成时间）

具体例子：3 个作业，2 台机器

	机器 A	机器 B
作业 1	3	5
作业 2	4	2
作业 3	2	4

目标：安排作业，使最后完成时间最短

调度问题：枚举方案

方案 1：全给机器 A
机器 A 负载 $= 3 + 4 + 2 = 9$，机器 B 负载 $= 0$
Makespan $= \max(9, 0) = \mathbf{9}$
方案 2：作业 1 给 A，作业 2,3 给 B
机器 A 负载 $= 3$，机器 B 负载 $= 2 + 4 = 6$
Makespan $= \max(3, 6) = \mathbf{6}$
方案 3：作业 1,3 给 A，作业 2 给 B
机器 A 负载 $= 3 + 2 = 5$，机器 B 负载 $= 2$
Makespan $= \max(5, 2) = \mathbf{5}$
最优方案：作业 3 给 A（耗时 2），作业 1,2 给 B（耗时 $5 + 2 = 7$）
Makespan $= \max(2, 7) = 7$? 不对，让我重新算...
方案 4：作业 2 给 B，作业 1,3 给 A
机器 A $= 3 + 2 = 5$，机器 B $= 2$
Makespan $= \mathbf{5}$（这是最优！）

调度问题：LP 松弛

ILP：$x_{ij} = 1$ 表示作业 j 分配给机器 i

$$\begin{aligned} \min \quad & T \\ \text{s.t.} \quad & 3x_{A1} + 4x_{A2} + 2x_{A3} \le T \quad \text{（机器 A 负载）} \\ & 5x_{B1} + 2x_{B2} + 4x_{B3} \le T \quad \text{（机器 B 负载）} \\ & x_{A1} + x_{B1} = 1,\ x_{A2} + x_{B2} = 1,\ x_{A3} + x_{B3} = 1 \end{aligned}$$

LP 松弛：允许 $x_{ij} \in [0, 1]$（作业可以 “分割”）
LP 解：$x^*_{A1} = 1, x^*_{B2} = 1, x^*_{A3} = 1$
机器 A 负载 $= 3 + 2 = 5$，机器 B 负载 $= 2$
$T^* = 5$（刚好等于 ILP 最优！这个例子没有 Gap）

调度问题：有 Gap 的例子

3 个相同作业，2 台机器，处理时间全为 1：

	机器 A	机器 B
作业 1	1	1
作业 2	1	1
作业 3	1	1

ILP 最优：3 个作业分给 2 台机器，鸽巢原理某台至少分到 2 个
Makespan $T^*_{\text{ILP}} = \mathbf{2}$
LP 松弛：允许分割作业，每个作业各一半给两台机器

$$x^*_{A,j} = x^*_{B,j} = 0.5, \quad j = 1, 2, 3$$

每台机器负载 $= 3 \times 0.5 \times 1 = 1.5$
$T^*_{\text{LP}} = \mathbf{1.5}$

$$\boxed{\text{Integrality Gap} = \frac{T^*_{\text{ILP}}}{T^*_{\text{LP}}} = \frac{2}{1.5} = \frac{4}{3}}$$

LP 可以把作业"切开"均匀摊给两台机器，但整数解无法均分奇数个相同作业。

Scheduling 的舍入

LP 解的结构：
每个作业 j 最多被 "分割" 到 m 台机器
$\Rightarrow$ 作业-机器的分配形成一个**二分图**
舍入方法：
使用二分图匹配，把分数分配转为整数分配
分析：
每台机器最多增加一个 "额外" 作业
$\Rightarrow$ 负载最多翻倍
结论：**2-近似**
更好的结果：通过更复杂的舍入，可以达到 $(2 - 1/m)$-近似

4.6 例 6：Facility Location（3-近似）

设施选址问题

问题：

- m 个可能的设施位置，开设成本 f_i
- n 个客户，客户 j 到设施 i 的服务成本 c_{ij}
- 目标：最小化总成本（开设 + 服务）

具体例子：2 个设施，3 个客户
设施开设成本：$f_1 = 10$，$f_2 = 8$
服务成本：

	客户 A	客户 B	客户 C
设施 1	2	5	3
设施 2	4	1	6

设施选址：枚举方案

方案 1：只开设施 1
开设成本 $= 10$
服务成本 $= 2 + 5 + 3 = 10$
总成本 $= \mathbf{20}$
方案 2：只开设施 2
开设成本 $= 8$
服务成本 $= 4 + 1 + 6 = 11$
总成本 $= \mathbf{19}$
方案 3：两个都开
开设成本 $= 10 + 8 = 18$
服务成本 $= \min(2, 4) + \min(5, 1) + \min(3, 6) = 2 + 1 + 3 = 6$
总成本 $= \mathbf{24}$（虽然服务便宜，但开设太贵）
最优：方案 2，总成本 $= 19$

设施选址：LP 松弛

ILP：

$$
\begin{aligned}
\min \quad & 10y_1 + 8y_2 + 2x_{1A} + 5x_{1B} + 3x_{1C} + 4x_{2A} + x_{2B} + 6x_{2C} \\
\text{s.t.} \quad & x_{1A} + x_{2A} = 1 \quad \text{（客户 A 被服务）} \\
& x_{1B} + x_{2B} = 1 \quad \text{（客户 B 被服务）} \\
& x_{1C} + x_{2C} = 1 \quad \text{（客户 C 被服务）} \\
& x_{1j} \le y_1,\ x_{2j} \le y_2 \quad \forall j
\end{aligned}
$$

LP 解（可能）：$y_1^* = 0.5, y_2^* = 0.5$
$x_{1A}^* = 0.5, x_{2A}^* = 0.5$（客户 A 各一半）
$x_{1B}^* = 0, x_{2B}^* = 1$（客户 B 全给设施 2，便宜）
$x_{1C}^* = 0.5, x_{2C}^* = 0.5$（客户 C 各一半）
LP 成本：$10 \times 0.5 + 8 \times 0.5 + ...$

Facility Location 的随机舍入

LP 解的含义：

- y_i^*：设施 i 的“开设程度”
- x_{ij}^*：客户 j 被设施 i 服务的“程度”

随机舍入：

1. 每个客户 j 按概率 x_{ij}^* 选择“首选”设施 i

   例：客户 A 以 50% 选设施 1，50% 选设施 2

2. 开设所有被选为首选的设施

   例：假设客户 A 选了 1，客户 B 选了 2，客户 C 选了 1

   $\Rightarrow$ 开设设施 1 和 2

3. 客户连接到最近的开设设施

分析（Shmoys, Tardos, Aardal）：
期望成本 $\le 3 \cdot \mathrm{OPT}_{\mathrm{LP}} \le 3 \cdot \mathrm{OPT}$
目前最好：1.488-近似（Li, 2013）

4.7 更多例子概览

连续化近似算法大全

问题	松弛	舍入方法	近似比
Vertex Cover	LP	确定性阈值	2
Set Cover	LP	随机 + 重复	$O(\log n)$
Max-SAT	LP	随机组合	3/4
Max-Cut	**SDP**	随机超平面	0.878
Scheduling	LP	二分图匹配	2
Facility Location	LP	随机首选	3
k-Median	LP	随机 + 贪心	3.25
Multiway Cut	LP	随机球	1.5
Sparsest Cut	**SDP**	随机投影	$O(\sqrt{\log n})$
Graph Coloring	**SDP**	随机向量	$O(n^{0.25})$
Correlation Clustering	LP	随机 pivot	3

模式：几乎所有经典组合优化都有“松弛 + 舍入”！

4.8 超越期望：随机舍入的深层理论

随机化为何能超越简单松弛？

核心问题：随机舍入凭什么能得到好的近似?

答案：三个数学工具

工具 1：期望的线性性

$$\mathbb{E}\left[\sum_j X_j\right] = \sum_j \mathbb{E}[X_j]$$

即使 X_j 之间**不独立**，也成立！

工具 2：初等不等式 $1 - x \le e^{-x}$

数值验证：$x = 0.5$ 时，$1 - 0.5 = 0.5$，$e^{-0.5} \approx 0.607$，确实 $0.5 \le 0.607$ ✓

工具 3：Union Bound

$$P\left[\bigcup_i A_i\right] \le \sum_i P[A_i]$$

例子：10 个事件，每个发生概率 0.01，则至少一个发生的概率 ≤ 0.1

Gurobi / CPLEX 内部技术

商业求解器的核心组件：

1. 预处理（Presolve）

- 变量固定：$x_i^* = 0$ 或 1 时直接固定
- 约束传播：利用约束推导更多固定
- 冗余约束删除、变量聚合

2. 割平面（Cutting Planes）

- LP 解不是整数时，添加新约束“切掉”它
- Gomory cuts：从 LP 单纯形表推导
- 问题特定割：Cover cuts, Clique cuts

3. 分支定界 + 启发式

- 用 LP 松弛计算界
- Feasibility Pump, RINS 找可行解
- **内部也用随机舍入**！

求解器 vs 近似算法

	商业求解器	**近似算法**
目标	精确最优	α-近似
时间保证	无（可能指数级）	多项式时间
适用规模	10^3-10^6 变量	任意大
GPU 友好	通常不	可以设计

实践建议：
小规模（$< 10^4$）：Gurobi/CPLEX，几秒到几分钟
大规模/实时：近似算法（时间可预测）
大量实例：近似算法 + GPU 并行

条件期望法：去随机化

定理：如果随机算法期望给出 α-近似，则存在**确定性**解
方法：依次确定每个变量，每步选使条件期望更好的值

条件期望法：MAX-SAT 详细例子

回到之前的例子：4 个子句

$C_1 = x_1$，$C_2 = x_1 \vee x_2$，$C_3 = \neg x_1 \vee x_3$，$C_4 = x_1 \vee x_2 \vee x_3$

用纯随机策略（每个变量 1/2 概率 True）

初始期望：$W() = P[C_1] + P[C_2] + P[C_3] + P[C_4] = 0.5 + 0.75 + 0.75 + 0.875 = 2.875$

Step 1：决定 x_1

$W(x_1 = T)$：C_1 必满足，$C_3 = \neg T \vee x_3 = x_3$

$= 1 + 1 + 0.5 + 1 = 3.5$（C_2, C_4 必满足，C_3 概率 0.5）

$W(x_1 = F)$：C_1 必不满足

$= 0 + 0.5 + 1 + 0.75 = 2.25$

选 $x_1 = T$（$3.5 > 2.25$）

随机化与并行的天然契合

随机化的四大优势：

1. 打破对称性

三角形三个顶点对称，确定性算法难以选择

随机化：各 1/2 概率选，天然打破对称

2. 期望线性性

$\mathbb{E}[\sum X_i] = \sum \mathbb{E}[X_i]$，不要求独立！

MAX-SAT 证明的核心

3. 与 LP 完美配合

LP 解 $x^* \in [0, 1]$：天然的概率

4. 天然可并行

100 次独立舍入，GPU 同时进行

取最好的，几乎免费改进！

5 GPU 友好性

传统 vs 现代方法

	传统算法	连续化 + 随机化
典型方法	分支定界、DP	LP/SDP + 随机舍入
计算模式	树搜索、顺序依赖	矩阵运算、独立采样
并行性	差	好
GPU 友好	否	是
精度	精确	近似（有保证）
可扩展性	$\sim 10^3$	$\sim 10^6$

GPU 视角：连续优化天然适合 GPU

LP/SDP 求解的核心操作：

- 矩阵-向量乘法：Ax，$A^T y$
- 投影到简单集合：$\text{proj}_{x\geq 0}(x) = \max(x, 0)$
- 向量加法和数乘

所有这些都是高度并行的！
一阶方法（PDHG）：

- 每步只需矩阵乘法，无需解线性系统
- 收敛慢但每步快
- 特别适合 GPU

GPU 视角：随机舍入的批量并行

场景：求解 1000 个 Vertex Cover 实例
传统方法：

- 每个实例调用一次求解器
- 总时间 = 1000 × 单个时间

GPU 方法：

1. 把 1000 个 LP 打包成批量问题
2. GPU 并行求解，得到 1000 个分数解
3. GPU 并行生成随机数

4. GPU 并行舍入
5. 总时间 ≈ 单个时间！

加速比：接近 1000×

批量 Max-Cut 的 GPU 实现

```python
import torch

def batch_maxcut_gw(V, num_hyperplanes=100):
    """
    批量 Goemans-Williamson 舍入
    V: (batch, n, d) - SDP 解（单位向量）
    """
    batch, n, d = V.shape
    device = V.device

    # 批量生成随机超平面
    R = torch.randn(batch, num_hyperplanes, d, device=device)
    R = R / R.norm(dim=-1, keepdim=True)

    # 批量计算分组：(batch, num_hyperplanes, n)
    # V: (batch, n, d), R: (batch, num_hyperplanes, d)
    signs = torch.sign(torch.einsum('bnd,bhd->bhn', V, R))

    return signs  # 每个超平面给出一种切割

# 1000 个图，每个 100 顶点
batch, n, d = 1000, 100, 20
V = torch.randn(batch, n, d, device='cuda')
V = V / V.norm(dim=-1, keepdim=True)

cuts = batch_maxcut_gw(V)  # 瞬间完成！
```

关键：所有随机舍入**同时**进行，无顺序依赖

多次采样取最好

随机算法的特点：单次运行有方差
策略：运行 k 次，取最好的结果
GPU 优势：k 次运行可以**并行**！
分析：如果单次成功概率 $\geq p$
k 次后成功概率 $\geq 1-(1-p)^k$

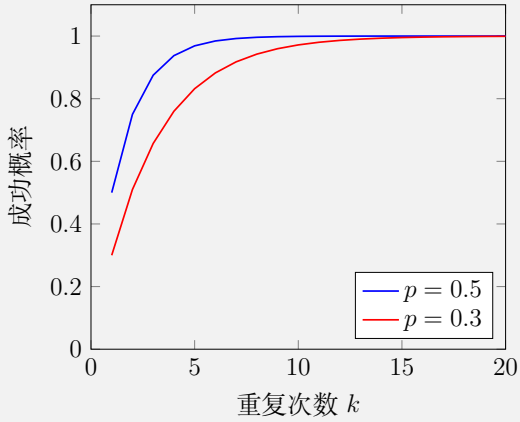

CPU：k 次 $= k$ 倍时间
GPU：k 次 ≈ 1 倍时间（只要 k 不太大）

6 实验

6.1 实验 3a：Vertex Cover 舍入策略对比

实验：确定性 vs 随机舍入

目标：比较不同舍入策略的效果

实验代码

```python
import numpy as np
import cvxpy as cp
import networkx as nx

def vertex_cover_lp(G):
    """Vertex Cover LP 松弛"""
    n = G.number_of_nodes()
    nodes = list(G.nodes())
    idx = {v: i for i, v in enumerate(nodes)}
```

```python

    x = cp.Variable(n)
    obj = cp.Minimize(cp.sum(x))
    cons = [x >= 0, x <= 1]
    for (u, v) in G.edges():
        cons.append(x[idx[u]] + x[idx[v]] >= 1)

    cp.Problem(obj, cons).solve()
    return {nodes[i]: x.value[i] for i in range(n)}, obj.value

def deterministic_round(x_lp, threshold=0.5):
    """确定性舍入"""
    return {v: 1 if x >= threshold else 0 for v, x in x_lp.items
        ()}

def random_round(x_lp):
    """随机舍入"""
    return {v: int(np.random.rand() < x) for v, x in x_lp.items
        ()}

def repair(cover, G, x_lp):
    """修复不可行解"""
    cover = cover.copy()
    for (u, v) in G.edges():
        if cover[u] == 0 and cover[v] == 0:
            cover[u if x_lp[u] >= x_lp[v] else v] = 1
    return cover

# 实验
np.random.seed(42)
G = nx.erdos_renyi_graph(100, 0.1)
x_lp, opt_lp = vertex_cover_lp(G)

# 确定性舍入
det = deterministic_round(x_lp)
det_size = sum(det.values())

# 随机舍入（100次取平均和最好）
```

```
rand_sizes = []
for _ in range(100):
    r = repair(random_round(x_lp), G, x_lp)
    rand_sizes.append(sum(r.values()))

print(f"LP 最优: {opt_lp:.2f}")
print(f"确定性: {det_size} (ratio: {det_size/opt_lp:.3f})")
print(f"随机平均: {np.mean(rand_sizes):.1f} (ratio: {np.mean(rand_sizes)/opt_lp:.3f})")
print(f"随机最好: {min(rand_sizes)} (ratio: {min(rand_sizes)/opt_lp:.3f})")
```

6.2 实验 3b：GPU 批量近似算法

实验：批量 Max-Cut 性能测试

目标：验证 GPU 批量处理的加速效果

GPU 批量实验

```
import torch
import time

def generate_sdp_solution(batch, n, d, device):
    """生成模拟的 SDP 解（随机单位向量）"""
    V = torch.randn(batch, n, d, device=device)
    return V / V.norm(dim=-1, keepdim=True)

def batch_gw_cut(V, adj, num_cuts=50):
    """批量 GW 舍入"""
    batch, n, d = V.shape

    # 随机超平面
    R = torch.randn(batch, num_cuts, d, device=V.device)
    R = R / R.norm(dim=-1, keepdim=True)

    # 计算切割
    signs = torch.sign(torch.einsum('bnd,bcd->bcn', V, R))

```

```python
    # 计算每个切割的值
    diff = signs.unsqueeze(-1) != signs.unsqueeze(-2)  # (batch, cuts, n, n)
    cut_vals = (diff.float() * adj.unsqueeze(1)).sum(dim=(-1,-2)) / 2

    return cut_vals.max(dim=1).values  # 每个图的最佳切割

# 性能测试
device = 'cuda' if torch.cuda.is_available() else 'cpu'
n, d = 100, 20

for batch in [1, 10, 100, 1000]:
    V = generate_sdp_solution(batch, n, d, device)
    adj = (torch.rand(batch, n, n, device=device) < 0.1).float()
    adj = ((adj + adj.transpose(-1,-2)) > 0).float()
    adj *= 1 - torch.eye(n, device=device)

    torch.cuda.synchronize() if device == 'cuda' else None
    start = time.time()

    cuts = batch_gw_cut(V, adj)

    torch.cuda.synchronize() if device == 'cuda' else None
    elapsed = time.time() - start

    print(f"Batch={batch:4d}: {elapsed:.4f}s, {elapsed/batch*1000:.2f}ms/instance")
```

预期：batch=1000 时每实例时间 $\ll$ batch=1 时

7 本周总结

核心结论：连续化的威力

核心思想：$\{0,1\}^n \to [0,1]^n$

为什么有效：

- 连续优化多项式时间可解

- 松弛解提供下界
- 分数解指导舍入

松弛层次：LP $\subset$ SDP $\subset$ 一般凸
LP 足够：Vertex Cover, Set Cover, Scheduling
需要 SDP：Max-Cut, Coloring, Sparsest Cut

核心结论：随机化的威力

优势：

- 打破对称性
- 期望分析简洁
- 与连续化完美配合
- 天然可并行

关键技术：

- 线性舍入：$P[\hat{x} = 1] = x^*$
- 重复采样：提高成功率
- 随机超平面：几何问题
- Chernoff bound：集中性分析

核心结论：GPU 友好性

为什么现代范式适合 GPU：

1. 连续优化 $\to$ 矩阵运算
2. 随机舍入 $\to$ 独立采样
3. 批量求解 $\to$ 数据并行
4. 多次采样 $\to$ 完美并行

对比：分支定界是串行树搜索，无法并行