第 5 周习题：SGD 基础与线性缩放

共 10 题，覆盖 GD 收敛、SGD 方差、偏差-方差分解、
线性缩放、Regret、归一化、初始化、Warmup

习题 1：一维 GD 的收敛因子

$f(x) = \frac{1}{2} \cdot 5x^2$（即 $k = 5$），初始点 $x_0 = 2$。

(a) 写出 GD 的稳定性条件（η 的范围）。

(b) 分别计算 $\eta = 0.1,\ 0.2,\ 0.35,\ 0.42$ 时的收敛因子 $\rho = |1 - \eta k|$，并判断每种情况是**单调收敛**（$0 < 1 - \eta k < 1$）、**振荡收敛**（$-1 < 1 - \eta k < 0$）还是**发散**（$|1 - \eta k| \geq 1$）。

(c) 对 $\eta = 0.2$，写出 x_t 的通项公式 $x_t = x_0 \cdot (1 - \eta k)^t$，并手算 x_0, x_1, x_2, x_3, x_4。

(d) 对 (b) 中的四个 η，分别计算达到 $|x_t| < 0.01$ 需要多少步。（对发散的情形说明为什么无法达到。）

提示

$\rho^T < 0.01/2 = 0.005$ 意味着 $T > \log(0.005)/\log(\rho)$。

习题 2：二维最优步长

$f(x, y) = \frac{1}{2}(2x^2 + 50y^2)$，即 $\mu = 2$，$L = 50$，$\kappa = 25$。

(a) 计算 GD 稳定上界 $\eta_{\max} = 2/L$。

(b) 计算最优步长 $\eta^* = 2/(\mu + L)$ 和最优收敛因子 $\rho^* = (\kappa - 1)/(\kappa + 1)$。

(c) 分别对 $\eta_A = 1/L$（保守）和 $\eta_B = \eta^*$（最优），计算两个方向的收敛因子 $\rho_x = |1 - \eta\mu|$，$\rho_y = |1 - \eta L|$，以及整体 $\rho = \max(\rho_x, \rho_y)$。

(d) 从 $(x_0, y_0) = (1, 1)$ 出发，用 η^* 手算 3 步迭代。每步写出 (x_t, y_t) 和 $f(x_t, y_t)$。y 方向是否振荡？为什么？

(e) 将误差降到初始值的 0.1% 需要 $\rho^T < 0.001$。分别计算 η_A 和 η_B 所需的步数 T。η^* 比 $\eta = 1/L$ 快了多少倍？

习题 3：SGD 无偏性与梯度方差

一维线性回归：$x \sim \mathcal{N}(0, \lambda)$，$y = \theta^* x + \varepsilon$，$\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$。定义参数误差 $e_t = a_t - \theta^*$。单样本随机梯度为 $g_t = e_t \cdot x_t^2 - \varepsilon_t \cdot x_t$。

(a) 计算条件期望 $\mathbb{E}[g_t \mid e_t]$。（利用 x_t, ε_t 与 e_t 独立，$\mathbb{E}[x^2] = \lambda$，$\mathbb{E}[\varepsilon] = 0$。）证明随机梯度是**无偏**的。

(b) 计算 $\mathbb{E}[g_t^2 \mid e_t]$。展开 $g_t^2 = e_t^2 x_t^4 - 2e_t x_t^3 \varepsilon_t + \varepsilon_t^2 x_t^2$，然后取期望。需要用到高斯分布的矩：$\mathbb{E}[x^3] = 0$，$\mathbb{E}[x^4] = 3\lambda^2$。

(c) 由此推导梯度方差 $\mathrm{Var}[g_t \mid e_t] = \mathbb{E}[g_t^2] - (\mathbb{E}[g_t])^2 = 2e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2$。

(d) 解释两项的物理意义：$2e_t^2\lambda^2$ 在前期和后期哪个主导？$\lambda\sigma_\varepsilon^2$ 呢？

(e) 如果使用 mini-batch $B = 16$，方差变为多少？写出公式并代入 $\lambda = 4$，$\sigma_\varepsilon^2 = 0.01$，$e_t = 1$。

提示

$\mathbb{E}[x^4] = 3(\mathbb{E}[x^2])^2$ 对高斯分布成立（四阶矩公式）。

习题 4：稳态方差与偏差-方差分解

延续习题 3 的设置：$\lambda = 4$，$\sigma_\varepsilon^2 = 0.01$，$B = 1$，$\eta = 0.2$，初始误差 $e_0 = 5$。

(a) 写出误差二阶矩的递推公式（后期近似，忽略方差中与 e_t^2 相关的项）：

$$\mathbb{E}[e_{t+1}^2] = (1 - \eta\lambda)^2\, \mathbb{E}[e_t^2] + \frac{\eta^2 \lambda \sigma_\varepsilon^2}{B}$$

计算 $(1 - \eta\lambda)^2$ 和噪声注入项 $\eta^2\lambda\sigma_\varepsilon^2/B$ 的数值。

(b) 求稳态方差 V_∞。列出完整推导：从不动点条件出发，展开 $1-(1-\eta\lambda)^2 = \eta\lambda(2-\eta\lambda)$，解出 $V_\infty = \eta\sigma_\varepsilon^2/[B(2 - \eta\lambda)]$。代入数值。

(c) 计算稳态预测误差 $\lambda \cdot V_\infty$。

(d) 分别计算以下修改后的 V_∞，验证 $V_\infty \propto \eta/B$：

	$\eta = 0.2,\ B = 1$	$\eta = 0.1,\ B = 1$
V_∞	（来自 (b)）	
	$\eta = 0.2,\ B = 1$	$\eta = 0.2,\ B = 2$
V_∞	（来自 (b)）	

(e) 用偏差-方差分解公式填写下表（$\rho = |1-\eta\lambda| = |1-0.8| = 0.2$）：

$$\mathbb{E}[e_t^2] = \rho^{2t}\, e_0^2 + V_\infty(1-\rho^{2t})$$

t	$\text{Bias}^2 = 0.04^t \times 25$	$\text{Variance} = V_\infty(1-0.04^t)$	总误差
0			
1			
3			
5			
10			

估算转折步数（$\text{Bias}^2 \approx \text{Variance}$ 的 t）。在转折点之后，应该如何调整 η？为什么？

习题 5：线性缩放法则与临界 Batch Size

$d = 50$ 维线性回归，各向同性 $\lambda_i = 1$（$\text{tr}(\mathbf{\Sigma}) = 50$），$\sigma_\varepsilon^2 = 0.04$，目标精度 $\epsilon = 10^{-3}$。

(a) 写出稳态预测误差的小步长近似：预测误差$_\infty \approx \frac{\eta\sigma_\varepsilon^2\,\text{tr}(\mathbf{\Sigma})}{2B}$。

(b) 当前 $\eta = 0.1$，$B = 32$。代入计算稳态预测误差。是否满足 $\le \epsilon$？

(c) 将 B 增大到 128。按线性缩放法则 $\eta/B = \text{const}$，η 应调到多少？验证稳态误差不变。Bias 衰减速度如何变化？

(d) 计算临界 batch size。取 $\eta_{\max} = 2/L = 2$（各向同性时 $L = 1$）：

$$B_{\text{crit}} = \frac{\eta_{\max}\,\text{tr}(\mathbf{\Sigma})\,\sigma_\varepsilon^2}{2\epsilon}$$

(e) 令 $B = 10000 \gg B_{\text{crit}}$。此时 η 最大只能取 $\eta_{\max} = 2$。计算对应的稳态预测误差。与 $B = B_{\text{crit}}$ 时比较：B 增大了多少倍？误差降低了多少倍？说明收益递减。

习题 6：Regret 的计算与学习率衰减

一维问题：$\lambda = 1$，$\sigma_\varepsilon^2 = 1$，$B = 1$，$e_0 = 10$。

(a) 对固定步长 η，期望累积 regret 近似为：

$$\text{Regret}_T \approx \underbrace{\frac{e_0^2}{4\eta}}_{\text{Bias 总贡献}} + \underbrace{\frac{T\eta\lambda\sigma_\varepsilon^2}{4}}_{\text{Variance 累积}}$$

解释两项的来源（Bias 的几何级数求和、Variance 的线性累积）。

(b) 取 $T = 10000$，分别计算 $\eta = 0.01$、$\eta = 0.1$、$\eta = 1.0$ 时的 Regret。填表：

η	Bias 项 $e_0^2/(4\eta)$	Var 项 $T\eta/(4)$	总 Regret
0.01			
0.1			
1.0			

哪个 η 最好？最好的那个两项是否接近平衡？

(c) 对 η 求导令其为零，推导最优固定步长 $\eta^* = e_0/(\sigma_\varepsilon\sqrt{T\lambda})$。代入 $T = 10000$ 计算 η^* 和 Regret_T^*。验证 $\text{Regret}^* = O(\sqrt{T})$。

(d) 对衰减步长 $\eta_t = 1/(\lambda t)$，每步期望 excess loss $\approx c/t$。估算 $\text{Regret}_{10000} \approx c\sum_{t=1}^{10000} 1/t \approx c(\ln 10000 + 0.577)$。取 $c = L/(2\mu) = 1/2$，计算结果。与 (c) 比较差多少倍？

(e) 如果训练开始前不知道 T（不知道要训练多久），固定步长需要 T 来选 η^*，而衰减步长 $\eta_t = 1/t$ 不需要。从实用角度，你推荐哪种？如果 T 已知呢？

习题 7：Xavier 与 He 初始化的方差传播

3 层 MLP，结构 $784 \to 256 \to 64 \to 10$。前两层用 ReLU 激活，最后一层无激活。

(a) 计算每层的 Xavier 初始化方差 $\sigma_W^2 = 2/(n_{\text{in}} + n_{\text{out}})$：

层	n_{in}	n_{out}	Xavier σ_W^2
1	784	256	
2	256	64	
3	64	10	

(b) 计算每层的 He 初始化方差 $\sigma_W^2 = 2/n_{\text{in}}$：

层	n_{in}	He σ_W^2
1	784	
2	256	
3	64	

(c) 用 He 初始化，假设输入方差 $\text{Var}[x] = 1$，逐层计算前向方差。每层的放大因子为 $n_{\text{in}} \cdot \sigma_W^2 \cdot \frac{1}{2}$（ReLU 减半），最后一层无 ReLU 所以不乘 1/2：

层	$n_{\text{in}}\sigma_W^2$	ReLU?	放大因子	累积方差
输入	—	—	—	1
1		是		
2		是		
3		否		

(d) 如果错误地用固定 $\sigma_W^2 = 0.001$，重复 (c) 的计算。输出方差是多少？与 (c) 差多少倍？

(e) 将网络加深到 6 层 $784 \to 256 \to 256 \to 256 \to 256 \to 256 \to 10$（前 5 层 ReLU，最后一层无激活），分别用 He 和固定 $\sigma_W^2 = 0.001$ 计算输出方差。深度如何放大初始化偏差？

提示

He 初始化下每层（带 ReLU）的放大因子 $= n_{\text{in}} \cdot (2/n_{\text{in}}) \cdot 1/2 = 1$，所以方差严格保持。

习题 8：两层网络的 Warmup 体验

两层线性网络 $f(x; u, v) = v \cdot u \cdot x$，单样本 $(x, y) = (1, 1)$，MSE 损失 $L(u, v) = \frac{1}{2}(vu - 1)^2$。

梯度：$\partial L/\partial u = (vu - 1)v$，$\partial L/\partial v = (vu - 1)u$。

Hessian：$\mathbf{H} = \begin{pmatrix} v^2 & 2uv - 1 \\ 2uv - 1 & u^2 \end{pmatrix}$。

(a) 初始化 $u_0 = v_0 = 3$。计算：初始 Loss、梯度、Hessian 矩阵。求 Hessian 的特征值（$\lambda = \frac{u^2+v^2}{2} \pm \sqrt{(\frac{u^2-v^2}{2})^2 + (2uv-1)^2}$，对称初始化时简化为 $v^2 \pm (2uv - 1)$）。

(b) 计算 $\eta_{\max} = 2/\lambda_{\max}$。

(c) 用 $\eta = 0.05$（满足稳定性），执行 3 步 GD。每步写出 (u_t, v_t)、L_t。

(d) 用 $\eta = 0.15$（**不**满足稳定性），执行 3 步 GD。Loss 是上升还是下降？

(e) Warmup 方案：前若干步用 $\eta_w = 0.03$，每步之后检查当前点的 $\lambda_{\max}$ 是否满足 $\eta = 0.15 < 2/\lambda_{\max}$。找到最早可以安全切换的步数 T_w，然后切到 $\eta = 0.15$ 继续执行 2 步。

填写汇总表：

步	(u_t, v_t)	L_t	阶段
0	$(3, 3)$		
1			Warmup (η_w)
$\vdots$			
T_w			切换
$T_w + 1$			$\eta = 0.15$
$T_w + 2$			$\eta = 0.15$

对比：无 Warmup 的 $\eta = 0.15$ 在第 3 步的 Loss vs 有 Warmup 方案在同一步的 Loss。

习题 9：归一化对收敛速度的影响

$f(x, y) = \frac{1}{2}(10000\,x^2 + y^2)$，$\kappa = 10000$。

(a) 计算 $\eta^* = 2/(\mu + L) = 2/(1 + 10000)$，$\rho^* = (\kappa - 1)/(\kappa + 1)$。降到 1% 需要多少步？（$T = \log(100)/\log(1/\rho^*)$）

(b) 做变量替换 $\tilde{x} = 100\,x$，代入 f：

$$f(\tilde{x}/100,\, y) = \frac{1}{2}\left(10000 \cdot \frac{\tilde{x}^2}{10000} + y^2\right) = \frac{1}{2}(\tilde{x}^2 + y^2)$$

归一化后 $\kappa =?$

(c) 对归一化后的问题，$\eta^* =?$，$\rho^* =?$，降到 1% 需要多少步?

(d) 归一化将步数从 (a) 的结果降到了 (c) 的结果。加速比是多少?

(e) 推广：$d = 100, \lambda_{\max} = 10^6, \lambda_{\min} = 1$。不归一化 $\kappa = 10^6$，收敛步数 $\sim \kappa/2 \cdot \log(100) \approx$?。标准化后 $\kappa \approx 1$，步数 $\approx$?。

习题 10：综合设计题

你拿到一个回归数据集：$d = 200$ 个特征，$n = 50000$ 个样本。经过初步分析：

- 特征未归一化，方差范围从 0.01 到 10^4
- 观测噪声 $\sigma_\varepsilon^2 \approx 0.1$
- 你打算用 5 层 MLP（隐藏层宽度 512）+ ReLU 训练
- GPU 内存支持 micro-batch $B_{\text{micro}} = 128$

(a) **条件数分析**：未归一化时 $\kappa \approx \lambda_{\max}/\lambda_{\min} = 10^4/0.01 =$?。用最优步长 GD，消除 Bias 到 1% 需要 $\sim (\kappa/2)\log(100) \approx$? 步。

(b) **归一化**：标准化后各特征方差 ≈ 1，$\kappa \approx$?。收敛步数变为多少？加速多少倍?

(c) **初始化**：ReLU 网络应选 Xavier 还是 He？写出每层的 σ_W^2（结构 $200 \to 512 \to 512 \to 512 \to 512 \to 1$）。

(d) **学习率估算**：利用 $\lambda_{\max} \sim nL$（$n = 512$，$L = 5$），估算 $\eta_{\max} \sim 2/(nL)$。你会选择 $\eta_{\text{target}} \approx \eta_{\max}/3$ 到 $\eta_{\max}/4$——这是多少?

(e) **Batch size 与线性缩放**：你决定用 $B = 1024$（gradient accumulation 8 步）。如果 $B = 128$ 时最优 $\eta = 0.001$，线性缩放给出 $B = 1024$ 时 $\eta =$?。

(f) **临界 batch size**：$B_{\text{crit}} \approx d_{\text{eff}} \cdot \sigma_\varepsilon^2/\epsilon$。取 $d_{\text{eff}} \approx d = 200$，目标 $\epsilon = 10^{-3}$。$B_{\text{crit}} =$?。$B = 1024$ 是否超过 B_{crit}？还有增大 B 的空间吗?

(g) **完整训练方案**：综合以上分析，写出你的训练方案（一段话即可）：

- 数据预处理
- 初始化方法
- 学习率与 batch size
- Warmup 策略（步数、形状）
- 学习率衰减（Cosine/Step Decay）
- 是否需要 Gradient Clipping

对每个选择，用一句话说明理由（引用本讲的哪个结论）。