第 5 周：SGD 基础与线性缩放

从二次模型建立随机优化的完整分析框架

目录

1 深度学习与优化：全景概览 **6**
1.1 深度学习的基本范式 6
1.2 反向传播：高效计算梯度 6
1.3 从梯度到训练：核心问题 6

2 贯穿全课的简单模型 **7**
2.1 模型定义 8

3 GD 在二次函数上的完整分析 **8**
3.1 一般二次型与特征值分解 8
3.2 GD 更新与解耦 9
3.3 一维例子：$f(x) = \frac{1}{2}kx^2$ 9
3.3.1 手算：$k = 2$，$x_0 = 4$，$\eta = 0.3$ 9
3.3.2 不同 η 的效果 10
3.4 二维例子：条件数的影响 10
3.4.1 $\eta = 1/L = 0.1$（保守选择） 11
3.4.2 $\eta^* = 2/(k_1 + k_2) = 2/11 \approx 0.182$（最优） 11
3.4.3 $\eta = 0.19$（接近稳定上界 $2/10 = 0.2$） 11

4 从二次函数到线性回归：数据决定 k_i **12**
4.1 线性回归的总体损失 12
4.2 数据决定了弹簧常数 k_i 14
4.3 为什么需要 SGD? 14

5 随机梯度与无偏性 **14**
5.1 单样本梯度的推导 14
5.2 无偏性证明 15
5.3 梯度方差的计算 15

6 Mini-batch SGD 更新 **16**
6.1 Mini-batch 梯度 16
6.2 Mini-batch 梯度的期望 16
6.3 Mini-batch 梯度的方差 16

6.4 更新规则与误差递推 17
6.5 手算例子：一维 SGD 的逐步追踪 17
6.6 Mini-batch 的效果：数值对比 18

7 均值的收敛与最优步长 18
7.1 均值递推 18
7.2 收敛条件 18
7.3 各方向的收敛速度 18
7.4 最优步长的推导 19
7.4.1 Case 1：$\eta \le 1/L$ 19
7.4.2 Case 2：$\eta \in (1/L,\ 2/L)$ 19
7.4.3 比较两种选择 19
7.4.4 为什么比 $\eta = 1/L$ 快一倍? 20
7.4.5 手算例子：二维 GD 的逐步迭代 21
7.5 附录 A：SGD 最优学习率的数值分析 22
7.5.1 单样本 SGD 的局部曲率波动 22
7.5.2 期望对数下降率 22
7.5.3 数值计算 22
7.5.4 Mini-batch 的效果 23

8 方差的演化与稳态误差 23
8.1 将梯度分解为信号和噪声 23
8.2 二阶矩的递推 23
8.3 稳态方差的求解 24
8.4 参数误差与预测误差 24
8.5 小步长近似 24

9 偏差-方差分解与线性缩放法则 24
9.1 完整的偏差-方差分解 24
9.1.1 Variance 演化的推导 24
9.2 线性缩放法则 25

10 在线学习视角：Regret 分析 25
10.1 Regret 的定义 26
10.2 SGD 就是在线梯度下降 26
10.3 固定步长的 Regret 26
10.3.1 期望过量损失 26
10.3.2 Regret 的两个组成部分 27
10.3.3 总 Regret 与最优步长 28

10.4 衰减步长：$O(\log T)$ Regret . . . 28
10.4.1 $\eta_t = c/t$ 的分析 . . . 28
10.4.2 Regret 的计算 . . . 29
10.4.3 与固定步长的对比 . . . 29
10.4.4 手算例子 . . . 29
10.5 Regret 视角的独特洞察 . . . 30
10.5.1 Learning Rate Decay 的必要性 . . . 30
10.5.2 与偏差-方差分解的对应 . . . 30
10.5.3 $O(\log T)$ 是最优的 . . . 30
10.6 文献指引 . . . 30

11 临界 Batch Size 与 Scaling 的天花板 31
11.1 B_{crit} 的推导 . . . 31
11.2 动态视角 . . . 31

12 统计物理连接：温度与 Gibbs 分布 31
12.1 稳态分布的等温性 . . . 31
12.2 SGD 温度的定义 . . . 32
12.3 温度的物理意义 . . . 32
12.4 与线性缩放法则的统一 . . . 32
12.5 退火（Annealing）策略 . . . 33
12.6 温度与泛化的关系 . . . 33
12.7 数值例子：温度对稳态的影响 . . . 33

13 数据归一化：为什么对训练至关重要 34
13.1 条件数与归一化 . . . 34
13.2 深度网络的条件数爆炸 . . . 34
13.3 Batch Normalization . . . 34
13.4 Layer Normalization . . . 34
13.5 回归的无偏性分析 . . . 34
13.6 可学习参数 γ，β . . . 35
13.7 手算例子：归一化前后的收敛速度 . . . 35

14 初始化：Xavier/He 的方差传播推导 35
14.1 第一步：线性网络的方差传播 . . . 35
14.1.1 前向传播 . . . 35
14.1.2 反向传播 . . . 36
14.1.3 冲突与 Xavier 折中 . . . 36
14.2 第二步：Tanh/Sigmoid 激活函数 . . . 37

14.3 第三步：ReLU 激活函数 37
14.3.1 He/Kaiming 初始化 37
14.4 三种初始化的总结 38
14.5 深度放大初始化偏差 38
14.6 手算练习：二阶矩传播的逐层计算 38
14.7 初始化与 Hessian 曲率的关系 39

15 Warmup 的必要性：非线性的曲率困境 39
15.1 线性模型不需要 Warmup 39
15.2 两层网络：Hessian 随位置变化 39
15.3 带 Sigmoid 的两层网络：更真实的非线性 39
15.3.1 Sigmoid 参考表 40
15.3.2 手算：小初始化——稳定训练 40
15.3.3 手算：大初始化——需要 Warmup 40
15.4 L 层网络：深度指数放大 41
15.5 Warmup 步数的估计 42
15.5.1 从简单模型出发 42
15.5.2 推广到实际网络的困难 42
15.5.3 经验观察 43
15.5.4 从标量模型推导 $T_{\text{warmup}} \sim L \log n$ 43

16 实用技巧速览 45
16.1 Gradient Clipping 45
16.2 Cosine Annealing 45
16.3 Gradient Accumulation 45

17 本周总结 45

A 宽度、深度与 Warmup 步数的详细推导 46
A.1 标量模型回顾 47
A.1.1 Hessian 与稳定性 47
A.1.2 Warmup 动力学 47
A.2 从标量到矩阵：谱范数替换 48
A.2.1 对应关系 48
A.2.2 He 初始化下的谱范数 48
A.2.3 激活函数和架构的修正 48
A.3 矩阵网络中的 $O(n)$ 曲率因子 48
A.3.1 单层 Hessian 的 Kronecker 结构 49
A.3.2 $\lambda_{\max}(\mathbf{A})$ 的分析 49

A.3.3 $\lambda_{\max}(\mathbf{G})$ 的分析 49
A.4 主定理：$T_{\text{warmup}} \sim L \log n$ 49
A.4.1 合并所有因子 49
A.4.2 目标条件 50
A.4.3 Warmup 步数 50
A.5 数值验证 50
A.6 讨论：推导的局限性 51

1 深度学习与优化：全景概览

1.1 深度学习的基本范式

深度学习的核心是用**参数化函数**拟合数据。给定数据集 $\{(\boldsymbol{x}_i, y_i)\}_{i=1}^n$，我们选择一个参数化模型 $f(\boldsymbol{x};\boldsymbol{\theta})$（如神经网络），通过最小化损失函数来找到最优参数：

$$\min_{\boldsymbol{\theta}} \quad L(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^{n} \ell\big(f(\boldsymbol{x}_i;\boldsymbol{\theta}),\ y_i\big) \tag{1}$$

其中 ℓ 是逐样本损失（如均方误差 $\ell(\hat{y}, y) = \frac{1}{2}(\hat{y} - y)^2$ 或交叉熵）。

现代神经网络的参数量 $\boldsymbol{\theta} \in \mathbb{R}^d$ 可达 $d \sim 10^9$（GPT-2）甚至 10^{12}（GPT-4 级别）。这意味着我们需要在一个**极高维**空间中做优化。

1.2 反向传播：高效计算梯度

优化的核心工具是**梯度下降**，而梯度下降需要计算 $\nabla_{\boldsymbol{\theta}} L$。对于多层神经网络

$$f = f_L \circ f_{L-1} \circ \cdots \circ f_1, \quad f_l(\boldsymbol{h}) = \sigma(\boldsymbol{W}_l \boldsymbol{h} + \boldsymbol{b}_l) \tag{2}$$

梯度通过**反向传播**（backpropagation）高效计算。反向传播本质上是链式法则的系统化应用：

$$\frac{\partial L}{\partial \boldsymbol{W}_l} = \underbrace{\frac{\partial L}{\partial \boldsymbol{h}_L}}_{\text{输出层误差}} \cdot \underbrace{\frac{\partial \boldsymbol{h}_L}{\partial \boldsymbol{h}_{L-1}} \cdots \frac{\partial \boldsymbol{h}_{l+1}}{\partial \boldsymbol{h}_l}}_{\text{逐层回传}} \cdot \underbrace{\frac{\partial \boldsymbol{h}_l}{\partial \boldsymbol{W}_l}}_{\text{本层局部梯度}} \tag{3}$$

反向传播的计算量与前向传播同阶（$O(d)$），使得在 $d \sim 10^{12}$ 的规模下计算梯度成为可能。

1.3 从梯度到训练：核心问题

有了梯度之后，如何更新参数？这正是本节课的主题。看似简单的 $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L$ 背后有大量关键问题：

- **学习率 η 怎么选？**太大会发散，太小会太慢。最优值是多少？
- **Batch size B 怎么选？**用全部数据太贵，用少量样本噪声太大。如何平衡？
- **η 和 B 之间有什么关系？**线性缩放法则从何而来？有什么极限？
- **数据预处理为什么重要？**归一化对训练速度的影响有多大？
- **初始化为什么讲究？**Xavier/He 初始化的数学依据是什么？
- **Warmup 为什么需要？**线性模型不需要，为什么深度网络需要？

为了回答这些问题，我们从一个可以完全手算的简单模型出发，建立精确的定量分析框架。

本节课的路线图

我们从一个基本的二次函数出发，逐步建立完整的分析框架：

Part 1：确定性 GD 在 $f = \frac{1}{2}\sum k_i x_i^2$ 上的分析

- GD 更新、收敛条件、最优步长 $\eta^* = 2/(k_1 + k_d)$
- 条件数 κ 如何拖慢收敛

Part 2：从二次函数到线性回归

- 数据的协方差决定了 $k_i \to$ 数据质量决定优化难度
- 为什么需要 SGD

Part 3：SGD 的完整分析

- 无偏性证明、梯度方差
- 偏差-方差分解、稳态误差 $V_\infty \propto \eta/B$
- Linear Scaling Rule、临界 batch size B_{crit}
- 温度 $T = \eta\sigma^2/(2B)$ 与 Gibbs 分布

Part 4：走向深度学习的实践

- 数据归一化（BN/LN）
- 初始化（Xavier/He）
- Warmup 的必要性
- Gradient Clipping、Cosine Annealing、Gradient Accumulation

2 贯穿全课的简单模型

整堂课围绕一个结构极为简单的函数展开所有分析。它的每一步推导都可以精确手算，但得到的结论却能解释深度学习训练中的大部分关键现象。

2.1 模型定义

我们的主角：

$$f(\boldsymbol{x}) = \frac{1}{2}\sum_{i=1}^{d} k_i x_i^2, \quad 0 < k_1 \le k_2 \le \cdots \le k_d \tag{4}$$

这是最简单的非平凡函数——d 个独立的”弹簧”，第 i 个方向的”弹性系数”是 k_i。最优点在原点 $\boldsymbol{x}^* = \boldsymbol{0}$。

为什么从它开始？

- 各方向独立，d 维问题解耦为 d 个一维问题
- 梯度 $\nabla f = (k_1x_1, k_2x_2, \ldots, k_dx_d)^\top$——每个方向独立计算
- Hessian $= \mathrm{diag}(k_1, \ldots, k_d)$ 是常数——不随位置变化
- 所有定量结论可以精确手算
- 推出来的结论惊人地普适，能解释深度学习训练中的大部分现象

关键参数：

- 最小曲率：$\mu = k_1$（最”软”的弹簧）
- 最大曲率：$L = k_d$（最”硬”的弹簧）
- 条件数：$\kappa = L/\mu = k_d/k_1$（衡量各方向曲率的不均衡程度）

3 GD 在二次函数上的完整分析

在引入任何随机性之前，我们先把**确定性**梯度下降在 $f(\boldsymbol{x}) = \frac{1}{2}\sum k_i x_i^2$ 上的行为分析透彻。

3.1 一般二次型与特征值分解

实际中遇到的二次函数往往不是对角的，而是一般形式：

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^\top A\boldsymbol{x}, \quad A \succ 0 \tag{5}$$

A 是对称正定矩阵，可以做特征值分解 $A = Q\Lambda Q^\top$，其中 Q 是正交矩阵（列为特征向量），$\Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$。

做变量替换 $\boldsymbol{z} = Q^\top\boldsymbol{x}$（旋转坐标），则：

$$f = \frac{1}{2}\boldsymbol{z}^\top\Lambda\boldsymbol{z} = \frac{1}{2}\sum_{i=1}^{d}\lambda_i z_i^2 \tag{6}$$

回到了对角形式！所以我们分析 $f = \frac{1}{2}\sum k_i x_i^2$ 不失一般性——任何二次函数通过旋转坐标都可以化成这个形式。

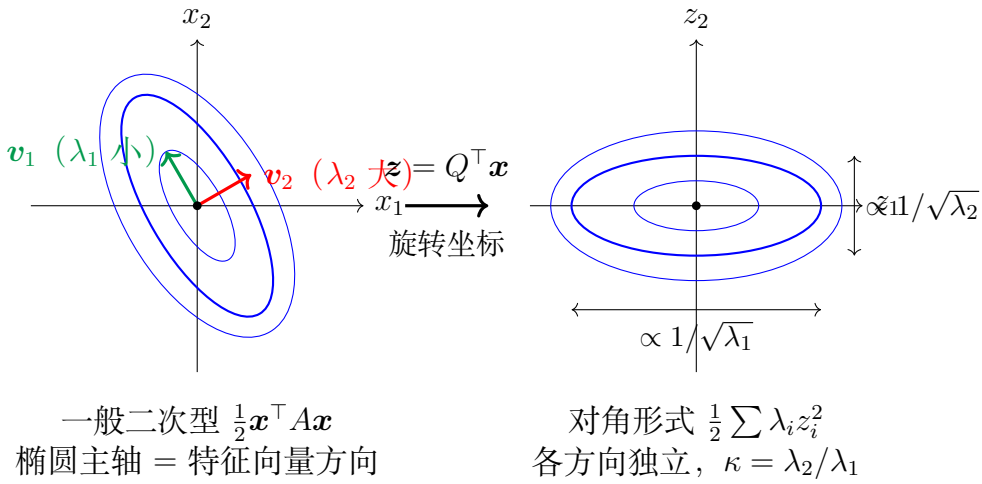

一般二次型 $\frac{1}{2}\boldsymbol{x}^\top A\boldsymbol{x}$
椭圆主轴 = 特征向量方向

对角形式 $\frac{1}{2}\sum \lambda_i z_i^2$
各方向独立，$\kappa = \lambda_2/\lambda_1$

图 1: 一般二次型通过特征值分解化为对角形式。等高线是椭圆，长轴对应最小特征值（最平坦方向），短轴对应最大特征值（最陡峭方向）。条件数 $\kappa = \lambda_{\max}/\lambda_{\min}$ 衡量椭圆的扁率。

3.2 GD 更新与解耦

梯度下降：$\boldsymbol{x}_{t+1} = \boldsymbol{x}_t - \eta \nabla f(\boldsymbol{x}_t)$。
对第 i 个方向，$\nabla_i f = k_i x_i$，所以：

$$x_{t+1,i} = x_t - \eta k_i x_{t,i} = (1 - \eta k_i)\, x_{t,i} \tag{7}$$

这是一个简单的等比数列！递推展开：

$$\boxed{x_{t,i} = (1 - \eta k_i)^t \cdot x_{0,i}} \tag{8}$$

各方向完全独立，每个方向是收敛因子 $\rho_i = |1 - \eta k_i|$ 的等比衰减。

3.3 一维例子：$f(x) = \frac{1}{2}kx^2$

3.3.1 手算：$k = 2$，$x_0 = 4$，$\eta = 0.3$

$x_{t+1} = (1 - 0.6)x_t = 0.4x_t$。收敛因子 $\rho = 0.4$。

t	x_t	$f(x_t) = x_t^2$	$f'(x_t) = 2x_t$	$x_{t+1} = x_t - 0.3f'$
0	4.000	16.00	8.000	1.600
1	1.600	2.56	3.200	0.640
2	0.640	0.41	1.280	0.256
3	0.256	0.066	0.512	0.102
4	0.102	0.010	0.205	0.041

$x_t = 4 \times 0.4^t$，指数收敛！5 步后误差衰减 $0.4^5 = 0.010$，即到原来的 1%。

3.3.2 不同 η 的效果

同样 $k = 2$，$x_0 = 4$：

η	ηk	$\rho = \lvert 1 - \eta k \rvert$	行为	x_5	$\lvert x_5/x_0 \rvert$
0.1	0.2	0.8	缓慢衰减	1.311	0.328
0.3	0.6	0.4	快速衰减	0.041	0.010
0.5	1.0	**0**	一步到位	0	0
0.7	1.4	0.4	振荡衰减	−0.041	0.010
0.9	1.8	0.8	剧烈振荡	−1.311	0.328
1.0	2.0	1.0	临界振荡	−4	1.000
1.1	2.2	1.2	**发散**	8.88	2.22

关键观察：

- $\eta k < 1$：单调收敛，η 越大越快
- $\eta k = 1$：一步到位！$x_1 = (1-1)x_0 = 0$
- $1 < \eta k < 2$：**振荡**收敛——每步 x 变号，但幅度衰减
- $\eta k = 2$：临界——振幅不变，永远在 $+x_0$ 和 $-x_0$ 之间跳
- $\eta k > 2$：发散！

稳定条件：$\lvert 1 - \eta k \rvert < 1$，即 $0 < \eta < 2/k$。

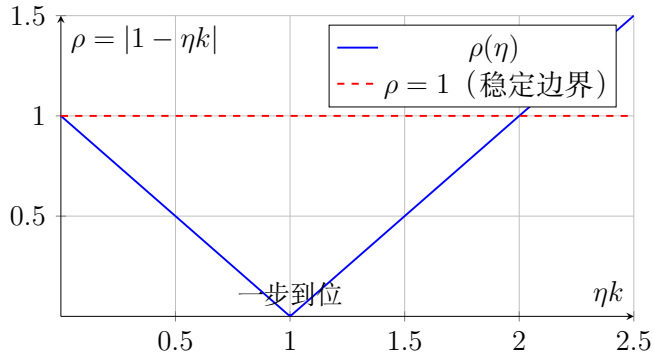

图 2: 收敛因子 $\rho = \lvert 1 - \eta k \rvert$ 关于 ηk 的函数。最优点在 $\eta k = 1$，稳定区间 $\eta k \in (0, 2)$。

3.4 二维例子：条件数的影响

$f(x, y) = \frac{1}{2}(k_1 x^2 + k_2 y^2)$，$k_1 = 1$（软方向），$k_2 = 10$（硬方向），$\kappa = 10$。
GD 用**同一个** η 处理两个方向。

3.4.1 $\eta = 1/L = 0.1$（保守选择）

$\rho_x = |1 - 0.1| = 0.9$（慢），$\rho_y = |1 - 1| = 0$（一步到位）。
从 $(x_0, y_0) = (1, 1)$ 出发：

t	x_t	y_t	f
0	1.000	1.000	5.50
1	0.900	**0.000**	0.405
2	0.810	0.000	0.328
5	0.590	0.000	0.174
10	0.349	0.000	0.061
22	0.098	0.000	0.005

y 方向**一步到位**，但 x 方向需要 ~ 22 步！浪费了 y 方向的收敛能力。

3.4.2 $\eta^* = 2/(k_1 + k_2) = 2/11 \approx 0.182$（最优）

$\rho_x = |1 - 0.182| = 0.818$，$\rho_y = |1 - 1.82| = 0.818$。两方向收敛因子**相等**！

t	x_t	y_t	f
0	1.000	1.000	5.50
1	0.818	-0.818	3.69
2	0.669	0.669	2.47
5	0.367	-0.367	0.74
10	0.135	0.135	0.10
12	0.090	0.090	0.045

y 方向在振荡（每步变号），但幅度和 x 方向同步衰减。$t = 12$ 步就到 1%，比 $\eta = 0.1$ 的 22 步快了将近一倍。

3.4.3 $\eta = 0.19$（接近稳定上界 $2/10 = 0.2$）

$\rho_x = 0.81$，$\rho_y = |1 - 1.9| = 0.9$。y 方向振荡剧烈，拖慢了整体！

t	x_t	y_t	f
0	1.000	1.000	5.50
1	0.810	-0.900	4.38
5	0.349	-0.590	1.80
10	0.122	0.349	0.62
22	0.015	0.098	0.048

结果：$\eta = 0.19$ 需要 22 步（和 $\eta = 0.1$ 一样慢！），但 $\eta^* = 0.182$ 只需要 12 步。

直觉：GD 收敛的核心矛盾

GD 用**同一个** η 处理所有方向：

- 硬方向（k_i 大）：需要小 η 避免过冲/发散
- 软方向（k_i 小）：需要大 η 加速收敛

η 的上界被最硬方向卡住：$\eta < 2/k_d$。但此时软方向的收敛因子 $\rho_1 = 1 - \eta k_1 \approx 1 - 2k_1/k_d = 1 - 2/\kappa$，接近 1。
条件数 κ 越大，这个矛盾越严重。$\kappa = 100$ 时，最慢方向每步只减少 2% 的误差，需要 ~ 230 步。$\kappa = 10^6$（常见于未归一化的数据）时，需要 $\sim 10^6$ 步。
这就是为什么**预条件**（不同方向用不同步长）和**数据归一化**（降低 κ）如此重要。

4 从二次函数到线性回归：数据决定 k_i

现在我们把二次函数 $f = \frac{1}{2}\sum k_i x_i^2$ 和机器学习联系起来。

4.1 线性回归的总体损失

考虑 d 维线性回归：

$$y = \mathbf{x}^\top \boldsymbol{\theta}^* + \varepsilon \tag{9}$$

其中：

- $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \boldsymbol{\Sigma})$：$d$ 维输入，$\boldsymbol{\Sigma} = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$，$0 < \lambda_1 \le \cdots \le \lambda_d$
- $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$：观测噪声，与 $\mathbf{x}$ 独立
- $\boldsymbol{\theta}^* \in \mathbb{R}^d$：真实参数

关键简化：$\boldsymbol{\Sigma}$ 为对角阵意味着各坐标方向独立，问题解耦为 d 个一维问题，但各方向曲率 λ_i 不同。

总体损失函数定义为预测误差的期望（对 $\mathbf{x}$ 和 ε 的分布取期望）：

$$L(\mathbf{a}) = \frac{1}{2}\mathbb{E}\left[(y - \mathbf{x}^\top \mathbf{a})^2\right] \tag{10}$$

下面逐步展开。首先代入 $y = \mathbf{x}^\top \boldsymbol{\theta}^* + \varepsilon$：

$$y - \mathbf{x}^\top \mathbf{a} = \mathbf{x}^\top \boldsymbol{\theta}^* + \varepsilon - \mathbf{x}^\top \mathbf{a} = \mathbf{x}^\top (\boldsymbol{\theta}^* - \mathbf{a}) + \varepsilon \tag{11}$$

定义误差向量 $\mathbf{e} = \mathbf{a} - \boldsymbol{\theta}^*$（即 $\boldsymbol{\theta}^* - \mathbf{a} = -\mathbf{e}$），则：

$$y - \mathbf{x}^\top \mathbf{a} = -\mathbf{x}^\top \mathbf{e} + \varepsilon \tag{12}$$

平方展开：

$$(y - \mathbf{x}^\top \mathbf{a})^2 = (-\mathbf{x}^\top \mathbf{e} + \varepsilon)^2 \tag{13}$$

$$= (\mathbf{x}^\top \mathbf{e})^2 - 2\varepsilon\, \mathbf{x}^\top \mathbf{e} + \varepsilon^2 \tag{14}$$

取期望。注意 ε 与 $\mathbf{x}$ 独立，且 $\mathbb{E}[\varepsilon] = 0$：

$$\mathbb{E}\big[(y - \mathbf{x}^\top \mathbf{a})^2\big] = \mathbb{E}\big[(\mathbf{x}^\top \mathbf{e})^2\big] - 2\,\underbrace{\mathbb{E}[\varepsilon]}_{=0}\,\mathbb{E}[\mathbf{x}^\top \mathbf{e}] + \underbrace{\mathbb{E}[\varepsilon^2]}_{=\sigma_\varepsilon^2} \tag{15}$$

$$= \mathbb{E}\big[(\mathbf{x}^\top \mathbf{e})^2\big] + \sigma_\varepsilon^2 \tag{16}$$

现在处理 $\mathbb{E}[(\mathbf{x}^\top \mathbf{e})^2]$。注意这里 $\mathbf{e}$ 是关于参数 $\mathbf{a}$ 的确定量（不是随机的），期望只对 $\mathbf{x}$ 取。展开：

$$(\mathbf{x}^\top \mathbf{e})^2 = \left(\sum_{i=1}^{d} x_i e_i\right)^2 = \sum_{i=1}^{d}\sum_{j=1}^{d} x_i x_j e_i e_j \tag{17}$$

取期望，利用 $\mathbf{\Sigma} = \mathrm{diag}(\lambda_1, \ldots, \lambda_d)$（即 x_i 之间独立）和 $\mathbb{E}[x_i] = 0$：

$$\mathbb{E}[x_i x_j] = \begin{cases} \lambda_i & i = j \\ 0 & i \neq j \end{cases} \tag{18}$$

因此交叉项全部消失：

$$\mathbb{E}\big[(\mathbf{x}^\top \mathbf{e})^2\big] = \sum_{i=1}^{d} \mathbb{E}[x_i^2]\, e_i^2 = \sum_{i=1}^{d} \lambda_i\, e_i^2 \tag{19}$$

代回，并乘以 $\frac{1}{2}$：

$$\boxed{L(\mathbf{a}) = \frac{1}{2}\sum_{i=1}^{d} \lambda_i (a_i - \theta_i^*)^2 + \frac{1}{2}\sigma_\varepsilon^2} \tag{20}$$

第一项是参数误差的加权和，权重正是协方差矩阵的特征值 λ_i——它们扮演了”各方向弹簧常数”的角色。第二项 $\frac{1}{2}\sigma_\varepsilon^2$ 是不可消除的噪声下界（即使 $\mathbf{a} = \boldsymbol{\theta}^*$，预测误差仍为 σ_ε^2），在优化中是常数，不影响梯度。

定义：

- 强凸参数（最小曲率）：$\mu = \lambda_1$
- Lipschitz 常数（最大曲率）：$L = \lambda_d$
- 条件数：$\kappa = L/\mu = \lambda_d/\lambda_1$

4.2 数据决定了弹簧常数 k_i

对比我们之前分析的 $f(\boldsymbol{x}) = \frac{1}{2}\sum k_i x_i^2$ 和线性回归的总体损失 $L(\mathbf{a}) = \frac{1}{2}\sum \lambda_i (a_i - \theta_i^*)^2$，结构完全一样！

k_i **就是** λ_i**——数据的协方差特征值决定了优化的"弹簧常数"！**

这意味着：

- 上一节关于 GD 的所有结论直接适用
- 条件数 $\kappa = \lambda_d/\lambda_1$ 由**数据分布**决定，而非模型
- 如果特征 x_1 的方差是 1，特征 x_2 的方差是 10^6，则 $\kappa \geq 10^6$
- **数据预处理**（归一化）直接改变 κ，从而改变收敛速度

直觉：数据的质量直接决定了优化的难度

好的数据（特征经过标准化，λ_i 接近）$\to \kappa$ 小 $\to$ 各方向同步收敛 $\to$ 训练快
坏的数据（特征尺度差异大）$\to \kappa$ 大 $\to$ 软方向拖后腿 $\to$ 训练慢
这就是为什么**数据工程**（特征缩放、归一化、PCA 降维）往往比调超参数更重要。在后面的章节中我们会详细分析 Batch Normalization 和 Layer Normalization 如何在深度网络中自动实现这一点。

4.3 为什么需要 SGD？

全梯度 $\nabla L(\mathbf{a}) = \mathbb{E}[(y - \mathbf{x}^\top \mathbf{a})\mathbf{x}]$ 需要对整个数据分布取期望——实践中不可能（数据量太大，或分布未知，只有样本）。

SGD 的核心想法：用一个样本（或一小批）的梯度代替全梯度。每步计算量从 $O(n)$（n 为数据量）降到 $O(B)$（B 为 batch size）。

代价是引入了**梯度噪声**。接下来我们精确分析这个噪声的结构。

5 随机梯度与无偏性

5.1 单样本梯度的推导

给定样本 $(\mathbf{x}_t, y_t)$，其中 $y_t = \mathbf{x}_t^\top \boldsymbol{\theta}^* + \varepsilon_t$。瞬时损失：

$$\ell_t(\mathbf{a}) = \frac{1}{2}(y_t - \mathbf{x}_t^\top \mathbf{a})^2 \tag{21}$$

对 a_i 求导：

$$\frac{\partial \ell_t}{\partial a_i} = -(y_t - \mathbf{x}_t^\top \mathbf{a}_t) \cdot x_{t,i} \tag{22}$$

$$= -(\mathbf{x}_t^\top \boldsymbol{\theta}^* + \varepsilon_t - \mathbf{x}_t^\top \mathbf{a}_t) \cdot x_{t,i} \tag{23}$$

$$= -\big(\mathbf{x}_t^\top (\boldsymbol{\theta}^* - \mathbf{a}_t) + \varepsilon_t\big) \cdot x_{t,i} \tag{24}$$

$$= (a_{t,i} - \theta_i^*) x_{t,i}^2 + \sum_{j \neq i} (a_{t,j} - \theta_j^*) x_{t,i} x_{t,j} - \varepsilon_t x_{t,i} \tag{25}$$

由于 $\mathbf{\Sigma}$ 是对角阵，x_i 和 x_j（$i \neq j$）独立，且 $\mathbb{E}[x_i] = 0$，所以交叉项 $x_{t,i} x_{t,j}$ 的期望为零。

定义误差 $e_{t,i} = a_{t,i} - \theta_i^*$，随机梯度简化为：

$$g_{t,i} = e_{t,i} \cdot x_{t,i}^2 - \varepsilon_t \cdot x_{t,i} \tag{26}$$

5.2 无偏性证明

计算 $\mathbb{E}[g_{t,i} \mid e_{t,i}]$（给定当前误差）：

$$\mathbb{E}[g_{t,i} \mid e_{t,i}] = \mathbb{E}[e_{t,i} \cdot x_{t,i}^2 - \varepsilon_t \cdot x_{t,i} \mid e_{t,i}] \tag{27}$$

$$= e_{t,i} \cdot \mathbb{E}[x_i^2] - \mathbb{E}[\varepsilon_t] \cdot \mathbb{E}[x_{t,i}] \quad (x_t,\, \varepsilon_t \text{ 与 } e_t \text{ 独立}) \tag{28}$$

$$= e_{t,i} \cdot \lambda_i - 0 \cdot 0 \tag{29}$$

$$= e_{t,i} \lambda_i \tag{30}$$

这正是真实梯度 $\frac{\partial L}{\partial a_i} = \lambda_i (a_i - \theta_i^*) = \lambda_i e_i$。

结论：随机梯度是**无偏**的，$\mathbb{E}[\mathbf{g}_t] = \nabla L(\mathbf{a}_t)$。

5.3 梯度方差的计算

方差 $\mathrm{Var}[g_{t,i} \mid e_{t,i}] = \mathbb{E}[g_{t,i}^2 \mid e_{t,i}] - (\mathbb{E}[g_{t,i} \mid e_{t,i}])^2$。

先计算 $\mathbb{E}[g_{t,i}^2]$。展开平方：

$$g_{t,i}^2 = (e_{t,i} x_{t,i}^2 - \varepsilon_t x_{t,i})^2 \tag{31}$$

$$= e_{t,i}^2 x_{t,i}^4 - 2 e_{t,i} x_{t,i}^3 \varepsilon_t + \varepsilon_t^2 x_{t,i}^2 \tag{32}$$

取期望。对于 $x_i \sim \mathcal{N}(0, \lambda_i)$，高斯分布的矩为：

- $\mathbb{E}[x_i^2] = \lambda_i$
- $\mathbb{E}[x_i^3] = 0$（奇数阶矩为零）
- $\mathbb{E}[x_i^4] = 3\lambda_i^2$（四阶矩：$\mathbb{E}[x^4] = 3(\mathbb{E}[x^2])^2$ 对高斯成立）

利用 $x_{t,i}$ 和 ε_t 独立：

$$\mathbb{E}[g_{t,i}^2 \mid e_{t,i}] = e_{t,i}^2 \cdot 3\lambda_i^2 - 2e_{t,i} \cdot 0 \cdot 0 + \sigma_\varepsilon^2 \cdot \lambda_i = 3e_{t,i}^2\lambda_i^2 + \lambda_i\sigma_\varepsilon^2 \tag{33}$$

因此方差为：

$$\mathrm{Var}[g_{t,i} \mid e_{t,i}] = 3e_{t,i}^2\lambda_i^2 + \lambda_i\sigma_\varepsilon^2 - (e_{t,i}\lambda_i)^2 = \boxed{2e_{t,i}^2\lambda_i^2 + \lambda_i\sigma_\varepsilon^2} \tag{34}$$

直觉：梯度方差的两个来源

- $2e_{t,i}^2\lambda_i^2$：来自曲率的**方向不确定性**——x_t^2 的波动导致对”真实曲率”估计不准。前期 $|e_t|$ 大时主导。
- $\lambda_i\sigma_\varepsilon^2$：来自**观测噪声** ε。后期 $|e_t|$ 小时主导。

这两个来源在前期和后期的主次关系切换，是理解学习率调度的关键。

6 Mini-batch SGD 更新

6.1 Mini-batch 梯度

使用 batch size B，第 i 个坐标的 mini-batch 梯度：

$$g_{B,i} = \frac{1}{B}\sum_{b=1}^{B} g_{t,i}^{(b)} \tag{35}$$

6.2 Mini-batch 梯度的期望

由于各样本独立同分布：

$$\mathbb{E}[g_{B,i} \mid e_{t,i}] = \frac{1}{B}\sum_{b=1}^{B}\mathbb{E}[g_{t,i}^{(b)} \mid e_{t,i}] = \frac{1}{B} \cdot B \cdot e_{t,i}\lambda_i = e_{t,i}\lambda_i \tag{36}$$

期望不变，仍然**无偏**。

6.3 Mini-batch 梯度的方差

由于各样本独立：

$$\mathrm{Var}[g_{B,i} \mid e_{t,i}] = \frac{1}{B^2}\sum_{b=1}^{B}\mathrm{Var}[g_{t,i}^{(b)} \mid e_{t,i}] = \frac{2e_{t,i}^2\lambda_i^2 + \lambda_i\sigma_\varepsilon^2}{B} \tag{37}$$

$$\boxed{\mathrm{Var}[g_{B,i}] = \frac{1}{B}\mathrm{Var}[g_{t,i}]} \tag{38}$$

Mini-batch 将方差缩小 B 倍！这是”以计算换精度”的核心机制。

6.4 更新规则与误差递推

参数更新 $a_{t+1,i} = a_{t,i} - \eta \cdot g_{B,i}$，误差更新：

$$e_{t+1,i} = e_{t,i} - \eta \cdot g_{B,i} \tag{39}$$

6.5 手算例子：一维 SGD 的逐步追踪

设置：一维线性回归，$\lambda = 4$（即 $x \sim \mathcal{N}(0,4)$），$\sigma_\varepsilon^2 = 0.01$，$\theta^* = 0$，初始参数 $a_0 = 1$（即 $e_0 = 1$），$\eta = 0.3$，$B = 1$（纯 SGD）。

第 0 步：$e_0 = 1$。

真实梯度 $= \lambda e_0 = 4$。

抽一个样本 $x_0 \sim \mathcal{N}(0,4)$，比如 $x_0 = 2.5$。$\varepsilon_0 \sim \mathcal{N}(0,0.01)$，比如 $\varepsilon_0 = 0.08$。

随机梯度 $g_0 = e_0 x_0^2 - \varepsilon_0 x_0 = 1 \times 6.25 - 0.08 \times 2.5 = 6.05$

更新：$e_1 = e_0 - 0.3 \times 6.05 = 1 - 1.815 = -0.815$

观察：过冲了！真实梯度是 4，最优步应该是 $e_0 - 0.3 \times 4 = -0.2$，但随机梯度是 6.05（比真实大），导致过冲到 -0.815。

第 1 步：$e_1 = -0.815$。

新样本 $x_1 = -1.3$，$\varepsilon_1 = -0.05$。

$g_1 = (-0.815) \times 1.69 - (-0.05)(-1.3) = -1.378 - 0.065 = -1.443$

$e_2 = -0.815 - 0.3 \times (-1.443) = -0.815 + 0.433 = -0.382$

观察：方向对了（往回拉），但幅度受随机性影响。

第 2 步：$e_2 = -0.382$，$x_2 = 3.1$，$\varepsilon_2 = 0.02$。

$g_2 = (-0.382)(9.61) - (0.02)(3.1) = -3.671 - 0.062 = -3.733$

$e_3 = -0.382 - 0.3 \times (-3.733) = -0.382 + 1.120 = 0.738$

又过冲了！从 -0.382 跳到 0.738，符号翻转。

t	e_t	x_t	g_t	e_{t+1}
0	1.000	2.5	6.05	-0.815
1	-0.815	-1.3	-1.44	-0.382
2	-0.382	3.1	-3.73	0.738
3	0.738	0.8	0.46	0.600

关键观察：

- 轨迹非常”抖”——这就是 SGD 的本质。每步的随机梯度与真实梯度可能差很远。
- 期望在衰减（$\mathbb{E}[e_t] = (1 - 0.3 \times 4)^t = (-0.2)^t$，振荡趋于 0），但实际轨迹的**方差**很大。
- 增大 B 可以”平滑”轨迹——B 个样本的平均比单样本稳定得多。

6.6 Mini-batch 的效果：数值对比

同样参数，但 $B = 10$。mini-batch 梯度 $g_B = \frac{1}{10}\sum_{b=1}^{10} g^{(b)}$。
由中心极限定理，g_B 的方差约为单样本的 1/10，所以：

	$B = 1$（纯 SGD）	$B = 10$
单步梯度方差	$2e_t^2\lambda^2 + \lambda\sigma_\varepsilon^2 \approx 32$	≈ 3.2
典型梯度偏差	± 5.7	± 1.8
轨迹	剧烈抖动	相对平滑

但两者的**期望轨迹**完全相同——mini-batch 不改变期望，只减小方差。

7 均值的收敛与最优步长

7.1 均值递推

从更新规则取期望：

$$\mathbb{E}[e_{t+1,i}] = \mathbb{E}[e_{t,i}] - \eta\mathbb{E}[g_{B,i}] \tag{40}$$

利用全期望公式 $\mathbb{E}[g_{B,i}] = \mathbb{E}[\mathbb{E}[g_{B,i} \mid e_{t,i}]] = \mathbb{E}[e_{t,i}\lambda_i] = \lambda_i\mathbb{E}[e_{t,i}]$：

$$\mathbb{E}[e_{t+1,i}] = (1 - \eta\lambda_i)\mathbb{E}[e_{t,i}] \tag{41}$$

递推展开：

$$\boxed{\mathbb{E}[e_{t,i}] = (1 - \eta\lambda_i)^t \cdot e_{0,i}} \tag{42}$$

7.2 收敛条件

要使所有方向收敛，需要 $|1 - \eta\lambda_i| < 1$ 对所有 i 成立。
对于 $\lambda_i > 0$，$|1-\eta\lambda_i| < 1$ 等价于 $0 < \eta\lambda_i < 2$。最严格的约束来自最大曲率 $\lambda_d = L$：

$$\boxed{0 < \eta < \frac{2}{L}} \tag{43}$$

步长上界由**最大曲率**决定。

7.3 各方向的收敛速度

定义第 i 个方向的收敛因子 $\rho_i = |1 - \eta\lambda_i|$：

- 大曲率方向（λ_i 大）：ρ_i 小，收敛快
- 小曲率方向（λ_i 小）：ρ_i 大，收敛慢

整体收敛由最慢方向决定：$\rho = \max_i \rho_i$。

7.4 最优步长的推导

7.4.1 Case 1：$\eta \le 1/L$

此时对所有 i，$\eta\lambda_i \le 1$，所以 $\rho_i = 1 - \eta\lambda_i$（无振荡）。

最大收敛因子来自最小曲率：$\rho = \rho_1 = 1 - \eta\lambda_1 = 1 - \eta\mu$。

要最小化 ρ，应取 η 尽量大，即 $\eta = 1/L$，此时：

$$\rho = 1 - \mu/L = 1 - 1/\kappa = \frac{\kappa - 1}{\kappa}$$

这是 $\eta = 1/L$ 的结果。

7.4.2 Case 2：$\eta \in (1/L,\ 2/L)$

此时 $\eta\lambda_d > 1$，所以 $1 - \eta\lambda_d < 0$，方向 d 会**振荡**——每步误差变号。但只要 $|1 - \eta\lambda_d| < 1$，振荡幅度衰减，仍然收敛。

此时：

$$\rho_1 = 1 - \eta\mu \quad (\text{递减，无振荡}) \tag{44}$$

$$\rho_d = \eta L - 1 \quad (\text{递增，振荡}) \tag{45}$$

最优策略：让两端的收敛因子相等 $\rho_1 = \rho_d$：

$$1 - \eta\mu = \eta L - 1 \quad \Rightarrow \quad 2 = \eta(\mu + L) \quad \Rightarrow \quad \eta^* = \frac{2}{\mu + L} \tag{46}$$

此时最优收敛因子：

$$\rho^* = 1 - \eta^*\mu = 1 - \frac{2\mu}{\mu + L} = \frac{L - \mu}{L + \mu} = \frac{\kappa - 1}{\kappa + 1} \tag{47}$$

7.4.3 比较两种选择

由于 $\frac{\kappa-1}{\kappa+1} < \frac{\kappa-1}{\kappa}$（分子相同，分母更大），**Case 2 更优**！

下图展示了为什么 $\eta^* = 2/(\lambda_1 + \lambda_d)$ 是最优的。考虑 4 个方向（$\lambda_1 = 1, \lambda_2 = 3, \lambda_3 = 6, \lambda_4 = 10$），每条 V 形线 $\rho_i(\eta) = |1 - \eta\lambda_i|$ 表示第 i 个方向的收敛因子。整体收敛速度由所有方向中**最慢的**决定，即上包络 $\rho(\eta) = \max_i \rho_i(\eta)$。最优 η^* 就是使上包络取到最小值的点。

从图中可以读出的关键信息：

- 每条 V 形线在 $\eta = 1/\lambda_i$ 处触底——如果只有这一个方向，选 $\eta = 1/\lambda_i$ 即可一步收敛。
- 但多方向共用同一个 η，整体被最慢方向（上包络）卡住。
- 上包络只由**两个极端方向**决定：λ_1（最小）和 λ_d（最大）。中间的特征值虽然画了线，但它们的 V 形都落在上包络之下，对最优 η 的选取没有影响。

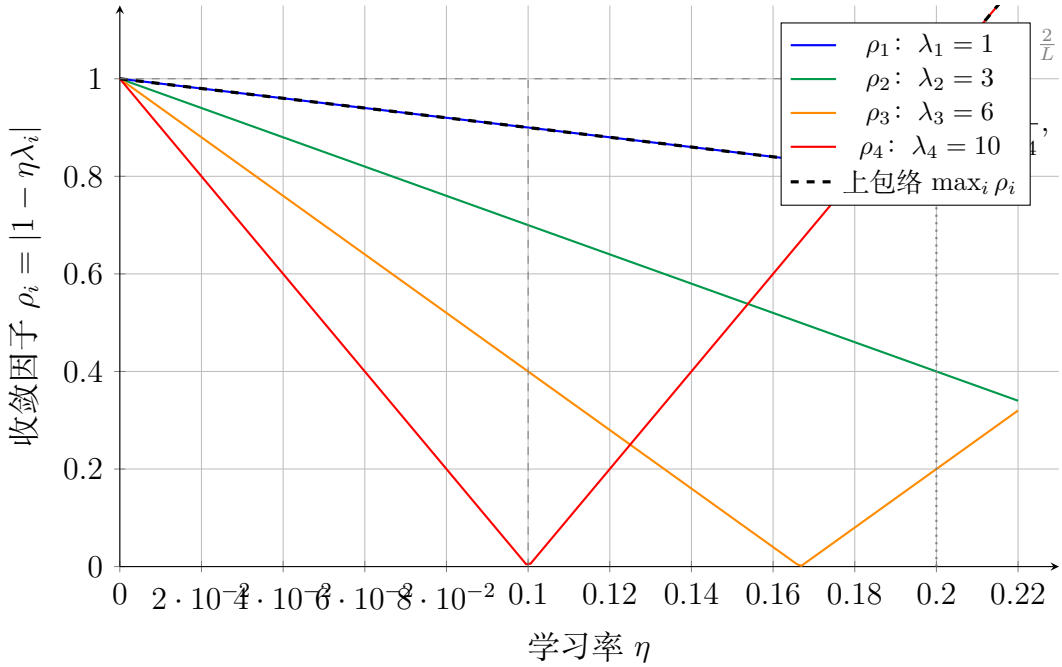

图 3: 四个方向的收敛因子 $\rho_i(\eta) = |1 - \eta\lambda_i|$ 及其上包络。每条 V 形线在 $\eta = 1/\lambda_i$ 处触底为 0（该方向一步收敛）。整体收敛由最慢方向（上包络）决定。上包络在 $\eta < \eta^*$ 时由 ρ_1（最平坦方向）主导，在 $\eta > \eta^*$ 时由 ρ_4（最陡峭方向）主导。最优 η^* 恰好在 $\rho_1 = \rho_4$ 的交叉点。注意中间方向（λ_2, λ_3）的 V 形线都在上包络之下——它们不是瓶颈，不影响最优 η 的选取。

- 最优 η^* 在 $\rho_1 = \rho_d$ 的交叉点。几何上，这是上包络”谷底”的位置。
- $\eta < \eta^*$：上包络沿蓝线（ρ_1）下降——此时增大 η 有益（平坦方向是瓶颈）。
- $\eta > \eta^*$：上包络沿红线（ρ_d）上升——此时增大 η 有害（陡峭方向变成瓶颈）。

核心结论：最优步长与收敛因子

$$\boxed{\eta^* = \frac{2}{\mu + L}, \quad \rho^* = \frac{\kappa - 1}{\kappa + 1}} \tag{48}$$

7.4.4 为什么比 $\eta = 1/L$ 快一倍？

当 $\kappa \gg 1$ 时：$\eta = 1/L$ 给出 $\rho \approx 1 - 1/\kappa$，步数 $\sim \kappa \log(1/\epsilon)$；而 η^* 给出 $\rho^* \approx 1 - 2/\kappa$，步数 $\sim \frac{\kappa}{2} \log(1/\epsilon)$。**快了将近一倍！**

数值例子. （$\mu = 1$，$L = 9$，$\kappa = 9$）：

	$\eta_A = 1/L = 0.111$	$\eta^* = 0.2$	$\eta_C = 0.22$（接近上界）
$\rho_1 = \lvert 1 - \eta\mu \rvert$	0.889	0.800	0.780
$\rho_d = \lvert 1 - \eta L \rvert$	0.000	0.800	0.980
$\rho = \max$	**0.889**	**0.800**	**0.980**
降到 1% 步数	39 步	**21 步**	230 步

教训：η_A（太保守）方向 1 太慢；η^* 两方向平衡，最快；η_C（太大）方向 d 剧烈振荡，反而最慢。学习率不是越大越好！

7.4.5 手算例子：二维 GD 的逐步迭代

设置：$f(x, y) = \frac{1}{2}(9x^2 + y^2)$，$\mu = 1$，$L = 9$，$\kappa = 9$。初始点 $(x_0, y_0) = (1, 9)$。

用 $\eta = 1/L = 0.111$：

梯度 $\nabla f = (9x, y)$。

t	x_t	y_t	$\partial f/\partial x$	$\partial f/\partial y$	f
0	1.000	9.000	9.000	9.000	45.00
1	0.000	8.000	0.000	8.000	32.00
2	0.000	7.111	0.000	7.111	25.28
5	0.000	4.990	0.000	4.990	12.45
10	0.000	2.774	0.000	2.774	3.85

x 方向一步到位（$\rho_x = 0$），但 y 方向 $\rho_y = 0.889$，到 $t = 10$ 还有 $y = 2.774$。

用 $\eta^* = 0.2$：

t	x_t	y_t	f
0	1.000	9.000	45.00
1	−0.800	7.200	28.80
2	0.640	5.760	18.43
3	−0.512	4.608	11.80
5	−0.328	2.949	4.83
10	0.107	0.967	0.52

x 方向振荡（$\rho_x = 0.8$，每步变号且缩小），y 方向也 $\rho_y = 0.8$。两方向同步衰减！到 $t = 10$ 已经很接近最优点。

对比：$\eta = 0.111$ 在 $t = 10$ 时 $f = 3.85$；$\eta^* = 0.2$ 在 $t = 10$ 时 $f = 0.52$。**快了 7 倍！**

代价是 x 方向有振荡，但振荡幅度在指数衰减。

直觉：最优学习率大概是能稳定训练的最大学习率的一半再小一点

GD 的稳定上界是 $\eta_{\max}^{GD} = 2/L$。最优 $\eta^* = 2/(\mu + L)$，当 κ 不太大时在 $\eta_{\max}$ 的 1/2 附近（上例 $\eta_{\max} = 0.222$，$\eta^* = 0.2$）。

对 SGD（有梯度噪声），数值积分表明 SGD 稳定上界 $\eta_{\max}^{SGD} \approx 2.4/\lambda$，最优 $\eta_{SGD}^* \approx 0.6/\lambda \approx \eta_{\max}^{SGD}/4$。

实践经验法则：先找到刚好发散的临界学习率，然后除以 3–4。

7.5 附录 A：SGD 最优学习率的数值分析

以上最优步长 $\eta^* = 2/(\mu + L)$ 是对**期望**动力学的分析。加入梯度噪声后，情况更微妙。

7.5.1 单样本 SGD 的局部曲率波动

考虑一维 $\lambda = \sigma^2$。单样本的" 局部 Hessian" 是 $H_t = x_t^2$。由于 $x_t \sim \mathcal{N}(0, \sigma^2)$：

$$H_t = \sigma^2 \cdot Z, \quad Z = (x_t/\sigma)^2 \sim \chi^2(1) \tag{49}$$

$\chi^2(1)$ 是重尾分布：$\mathbb{E}[Z] = 1$，但 $P(Z > 4) \approx 0.046$，$P(Z > 9) \approx 0.003$。偶尔的大 Z 会让局部曲率远超期望。

7.5.2 期望对数下降率

多步更新（忽略观测噪声）：$e_T = e_0 \prod_{t=0}^{T-1}(1 - \eta\sigma^2 Z_t)$。

取对数并由大数定律：

$$\frac{1}{T}\log|e_T/e_0| \to r(\eta) = \mathbb{E}[\log|1 - \eta\sigma^2 Z|], \quad Z \sim \chi^2(1) \tag{50}$$

$r(\eta) < 0$ 时期望收敛。SGD 稳定上界 $\eta_{\max}^{SGD}$ 定义为 $r(\eta) = 0$ 的点。

7.5.3 数值计算

数值积分 $r(\eta)$（以 $u = \eta\sigma^2$ 为横轴）：

$u = \eta\sigma^2$	0.3	0.5	0.6	0.8	1.0	1.5	2.0	2.2	2.4	2.5
$r(\eta)$	-0.36	-0.48	$\mathbf{-0.49}$	-0.47	-0.41	-0.28	-0.13	-0.05	≈ 0	$+0.02$

结论：

- SGD 稳定上界：$\eta_{\max}^{SGD}\sigma^2 \approx 2.4$，即 $\eta_{\max}^{SGD} \approx 2.4/\sigma^2$
- **最优学习率**：$\eta^*\sigma^2 \approx 0.6$，即 $\eta^* \approx 0.6/\sigma^2 \approx \eta_{\max}^{SGD}/4$

- 对比 GD：$\eta_{\max}^{GD} = 2/\sigma^2$，SGD 的上界反而**更大**（$2.4 > 2$）

为什么 SGD 上界更大？ $\log|1 - uZ|$ 在 $uZ \approx 1$ 时趋于 $-\infty$（超收敛），但发散时只有限增长。两者不对称，所以" 偶尔超收敛" 可以补偿" 偶尔轻微过冲"。

7.5.4 Mini-batch 的效果

Batch size B 时，$\bar{Z} \sim \frac{1}{B}\chi^2(B)$。$B$ 增大时 $\bar{Z}$ 集中于 1，曲率波动减小，$\eta_{\max}^{SGD} \to \eta_{\max}^{GD} = 2/\sigma^2$。

同时最优学习率从 $\approx 0.6/\sigma^2$（$B = 1$）逐渐接近 $1/\sigma^2$（$B = \infty$，即 GD 最优点）。

8 方差的演化与稳态误差

这是理解 η/B 关系的核心。

8.1 将梯度分解为信号和噪声

将 mini-batch 梯度写成：

$$g_{B,i} = \underbrace{e_{t,i}\lambda_i}_{\text{信号}} + \underbrace{\xi_{t,i}}_{\text{噪声}} \tag{51}$$

误差更新变为：

$$e_{t+1,i} = (1 - \eta\lambda_i)e_{t,i} - \eta\xi_{t,i} \tag{52}$$

8.2 二阶矩的递推

计算 $\mathbb{E}[e_{t+1,i}^2]$：

$$e_{t+1,i}^2 = \big((1 - \eta\lambda_i)e_{t,i} - \eta\xi_{t,i}\big)^2 \tag{53}$$

$$= (1 - \eta\lambda_i)^2 e_{t,i}^2 - 2(1 - \eta\lambda_i)e_{t,i} \cdot \eta\xi_{t,i} + \eta^2\xi_{t,i}^2 \tag{54}$$

取期望。交叉项：$\xi_{t,i}$ 与 $e_{t,i}$ 条件独立（噪声来自新样本），所以 $\mathbb{E}[e_{t,i} \cdot \xi_{t,i}] = 0$。

后期 e_t 小时噪声方差 $\approx \lambda_i\sigma_\varepsilon^2/B$，得到：

$$\boxed{\mathbb{E}[e_{t+1,i}^2] = (1 - \eta\lambda_i)^2\mathbb{E}[e_{t,i}^2] + \frac{\eta^2\lambda_i\sigma_\varepsilon^2}{B}} \tag{55}$$

一阶线性递推：每步旧方差衰减 + 新噪声注入。

8.3 稳态方差的求解

$t \to \infty$ 时，不动点条件：

$$V_{\infty,i} = (1-\eta\lambda_i)^2 V_{\infty,i} + \frac{\eta^2\lambda_i\sigma_\varepsilon^2}{B} \tag{56}$$

移项：$V_{\infty,i}[1-(1-\eta\lambda_i)^2] = \frac{\eta^2\lambda_i\sigma_\varepsilon^2}{B}$
展开 $1-(1-\eta\lambda_i)^2 = 2\eta\lambda_i - \eta^2\lambda_i^2 = \eta\lambda_i(2-\eta\lambda_i)$，代入：

$$\boxed{V_{\infty,i} = \frac{\eta\sigma_\varepsilon^2}{B(2-\eta\lambda_i)}} \tag{57}$$

8.4 参数误差与预测误差

参数误差：$\|\mathbf{e}\|_\infty^2 = \sum_i V_{\infty,i}$
预测误差：$\mathbb{E}[(\mathbf{x}^\top\mathbf{e})^2] = \sum_i \lambda_i V_{\infty,i}$
代入 $V_{\infty,i}$：

$$\boxed{\text{预测误差}_\infty = \sum_{i=1}^{d} \frac{\lambda_i\eta\sigma_\varepsilon^2}{B(2-\eta\lambda_i)}} \tag{58}$$

8.5 小步长近似

$\eta\lambda_i \ll 2$ 时，$2-\eta\lambda_i \approx 2$：
参数误差 $\approx \frac{d\eta\sigma_\varepsilon^2}{2B}$，预测误差 $\approx \frac{\eta\sigma_\varepsilon^2\cdot\mathrm{tr}(\mathbf{\Sigma})}{2B}$。

核心结论：稳态误差 $\propto \eta/B$

无论参数误差还是预测误差，稳态时都 $\propto \eta/B$。平坦方向参数误差大但对预测影响小，陡峭方向反之。

9 偏差-方差分解与线性缩放法则

9.1 完整的偏差-方差分解

$$\mathbb{E}[e_{t,i}^2] = \underbrace{(1-\eta\lambda_i)^{2t}e_{0,i}^2}_{\text{Bias}^2\text{:指数衰减，与}B\text{无关}} + \underbrace{V_{\infty,i}(1-(1-\eta\lambda_i)^{2t})}_{\text{Variance: 从 0 累积到}V_{\infty,i}} \tag{59}$$

9.1.1 Variance 演化的推导

需要计算 $\mathrm{Var}[e_{t,i}] = \mathbb{E}[e_{t,i}^2] - (\mathbb{E}[e_{t,i}])^2$。
$\mathbb{E}[e_{t,i}^2]$ 满足递推 $\mathbb{E}[e_{t+1}^2] = (1-\eta\lambda)^2\mathbb{E}[e_t^2] + c$，其中 $c = \eta^2\lambda\sigma_\varepsilon^2/B$。

这是一阶线性递推 $a_{t+1} = \alpha^2 a_t + c$（$\alpha = 1 - \eta\lambda$），通解为：

$$\mathbb{E}[e_t^2] = \alpha^{2t}\mathbb{E}[e_0^2] + c \cdot \frac{1-\alpha^{2t}}{1-\alpha^2} \tag{60}$$

其中 $\frac{c}{1-\alpha^2} = \frac{\eta^2\lambda\sigma_\varepsilon^2/B}{\eta\lambda(2-\eta\lambda)} = \frac{\eta\sigma_\varepsilon^2}{B(2-\eta\lambda)} = V_\infty$。
因此 $\mathbb{E}[e_t^2] = \alpha^{2t}e_0^2 + V_\infty(1-\alpha^{2t})$。
减去 $(\mathbb{E}[e_t])^2 = \alpha^{2t}e_0^2$（注意这里 e_0 是确定的）：
$\mathrm{Var}[e_t] = V_\infty(1-\alpha^{2t})$。
从 0 开始单调递增到 V_∞。

手算例子. $\lambda = 1$，$\sigma_\varepsilon^2 = 0.01$，$B = 100$，$e_0 = 1$，$\eta = 0.5$。
$V_\infty = \frac{0.5\times0.01}{100\times1.5} = 3.33\times10^{-5}$，$\rho = 0.5$

t	$\mathrm{Bias}^2 = 0.25^t$	Variance	主导项	总误差
0	1	0	Bias	1
5	9.8×10^{-4}	3.3×10^{-5}	Bias	1.0×10^{-3}
10	9.5×10^{-7}	3.3×10^{-5}	**Variance**	3.4×10^{-5}
20	≈ 0	3.3×10^{-5}	Variance	3.3×10^{-5}

$t < 7$：Bias 主导，误差快速下降。$t > 10$：Variance 主导，误差不再下降 $\to$ 应降低 η!

9.2 线性缩放法则

核心结论：Linear Scaling Rule

$B \to kB$，$\eta \to k\eta$（受限于 $\eta < 2/L$），则稳态误差不变（η/B 不变），Bias 衰减更快。

$$\boxed{\frac{\eta}{B} = \text{const}}$$

10 在线学习视角：Regret 分析

上一节的偏差-方差分解告诉我们 SGD 最终会收敛到什么精度。但还有一个重要问题：**训练过程中**的累积表现如何？如果模型在训练过程中就在做预测（例如推荐系统、在线广告），我们关心的不只是最终模型有多好，还有训练过程中一共犯了多少错。

这正是**在线学习**（online learning）中 **regret** 理论研究的问题。我们接下来展示，regret 分析与偏差-方差分解是同一件事的两种语言。

10.1 Regret 的定义

在线学习的设定如下。在每一步 $t = 1, 2, \ldots, T$：

1. 学习器选择参数 $\mathbf{a}_t$
2. 环境给出样本 $(\mathbf{x}_t, y_t)$
3. 学习器承受损失 $\ell_t(\mathbf{a}_t) = \frac{1}{2}(y_t - \mathbf{x}_t^\top \mathbf{a}_t)^2$

学习器无法提前看到数据，只能用已有信息做决策——这正是 SGD 做的事情。

定义 10.1 (Regret)**.** *累积 regret 定义为学习器的总损失与"事后最优"之差：*

$$\mathrm{Regret}_T = \sum_{t=1}^{T} \ell_t(\mathbf{a}_t) - \min_{\mathbf{a}} \sum_{t=1}^{T} \ell_t(\mathbf{a}) \tag{61}$$

$\min_{\mathbf{a}} \sum_t \ell_t(\mathbf{a})$ 是" 上帝视角"——如果你在看完所有 T 个样本之后被允许选一个固定的最优参数 $\mathbf{a}^*$，你能做到多好。Regret 衡量的就是在线决策比这个事后最优差了多少。

好的算法应该让 Regret_T 增长尽量慢——理想情况下 $\mathrm{Regret}_T/T \to 0$，即平均 regret 趋于零。

10.2 SGD 就是在线梯度下降

注意 SGD 的更新规则 $\mathbf{a}_{t+1} = \mathbf{a}_t - \eta \nabla \ell_t(\mathbf{a}_t)$ 正好就是在线梯度下降（Online Gradient Descent, OGD）——每步只用当前样本的梯度更新。因此 SGD 的 regret 分析可以直接套用在线学习的经典结果。

10.3 固定步长的 Regret

10.3.1 期望过量损失

在我们的线性回归模型中，第 t 步的期望过量损失（excess loss）可以用误差 $\mathbf{e}_t = \mathbf{a}_t - \boldsymbol{\theta}^*$ 表示。利用上一节的结果：

$$\mathbb{E}[\ell_t(\mathbf{a}_t)] - \mathbb{E}[\ell_t(\boldsymbol{\theta}^*)] = \frac{1}{2} \sum_{i=1}^{d} \lambda_i \mathbb{E}[e_{t,i}^2] \tag{62}$$

代入我们已经推导过的偏差-方差分解：

$$\mathbb{E}[e_{t,i}^2] = \underbrace{(1 - \eta\lambda_i)^{2t} e_{0,i}^2}_{\mathrm{Bias}^2} + \underbrace{V_{\infty,i}\big(1 - (1 - \eta\lambda_i)^{2t}\big)}_{\mathrm{Variance}} \tag{63}$$

10.3.2 Regret 的两个组成部分

对 t 从 1 到 T 求和，期望累积 regret 为：

$$\mathbb{E}[\text{Regret}_T] = \frac{1}{2}\sum_{i=1}^{d}\lambda_i \sum_{t=1}^{T}\mathbb{E}[e_{t,i}^2] \tag{64}$$

分别计算 Bias 和 Variance 的贡献。

Bias 部分的求和. 设 $\rho_i = (1-\eta\lambda_i)^2$（注意这里是平方，因为 $\mathbb{E}[e_{t,i}^2]$ 的 Bias 项含 $(1-\eta\lambda_i)^{2t}$）。

$$\sum_{t=1}^{T}(1-\eta\lambda_i)^{2t}e_{0,i}^2 = e_{0,i}^2\sum_{t=1}^{T}\rho_i^t = e_{0,i}^2\cdot\frac{\rho_i(1-\rho_i^T)}{1-\rho_i} \tag{65}$$

当 T 足够大时 $\rho_i^T \to 0$，所以：

$$\sum_{t=1}^{T}(1-\eta\lambda_i)^{2t}e_{0,i}^2 \approx \frac{\rho_i}{1-\rho_i}e_{0,i}^2 \tag{66}$$

利用 $\rho_i = (1-\eta\lambda_i)^2$ 且 $\eta\lambda_i$ 较小时 $1-\rho_i \approx 2\eta\lambda_i$：

$$\frac{\rho_i}{1-\rho_i} \approx \frac{1}{2\eta\lambda_i} \tag{67}$$

因此 Bias 对 regret 的总贡献为：

$$R_{\text{bias}} = \frac{1}{2}\sum_i \lambda_i\cdot\frac{e_{0,i}^2}{2\eta\lambda_i} = \frac{1}{4\eta}\sum_i e_{0,i}^2 = \frac{\|\mathbf{e}_0\|^2}{4\eta} \tag{68}$$

这是一个**与 T 无关的常数**——Bias 指数衰减，几何级数求和后是有限值。η 越大，这项越小（大步长快速消除初始误差）。

Variance 部分的求和. 稳态后每步贡献 $V_{\infty,i}$，一共 T 步。精确地说：

$$\sum_{t=1}^{T}V_{\infty,i}(1-\rho_i^t) = T\cdot V_{\infty,i} - V_{\infty,i}\cdot\frac{\rho_i(1-\rho_i^T)}{1-\rho_i} \approx T\cdot V_{\infty,i} - \frac{V_{\infty,i}}{2\eta\lambda_i} \tag{69}$$

第二项是有限常数（可并入 Bias 项），主导项是：

$$R_{\text{var}} \approx \frac{T}{2}\sum_i \lambda_i V_{\infty,i} = \frac{T}{2}\cdot\text{预测误差}_\infty \approx T\cdot\frac{\eta\sigma_\varepsilon^2\,\text{tr}(\mathbf{\Sigma})}{4B} \tag{70}$$

这项**与 T 线性增长**——每步都在累积噪声代价。η 越小，每步代价越小。

10.3.3 总 Regret 与最优步长

合并两项：

$$\boxed{\mathbb{E}[\text{Regret}_T] \approx \underbrace{\frac{\|\mathbf{e}_0\|^2}{4\eta}}_{\text{Bias 总贡献 } O(1/\eta)} + \underbrace{\frac{T\eta\sigma_\varepsilon^2\,\text{tr}(\mathbf{\Sigma})}{4B}}_{\text{Variance 累积 } O(T\eta)}} \tag{71}$$

这就是偏差-方差 trade-off 的 regret 版本：

- η 大 $\to$ Bias 项小（快速忘记初始化），但 Variance 项大（噪声累积快）
- η 小 $\to$ Bias 项大（收敛慢），但 Variance 项小（噪声影响小）

对 η 求最小化：令 $\frac{\partial}{\partial\eta}\text{Regret}_T = 0$：

$$-\frac{\|\mathbf{e}_0\|^2}{4\eta^2} + \frac{T\sigma_\varepsilon^2\,\text{tr}(\mathbf{\Sigma})}{4B} = 0 \tag{72}$$

解得：

$$\eta^*_{\text{regret}} = \frac{\|\mathbf{e}_0\|}{\sigma_\varepsilon\sqrt{T\,\text{tr}(\mathbf{\Sigma})/B}} = O\left(\frac{1}{\sqrt{T}}\right) \tag{73}$$

代回 regret：

$$\boxed{\text{Regret}^*_T = O\left(\frac{\|\mathbf{e}_0\|\,\sigma_\varepsilon\sqrt{\text{tr}(\mathbf{\Sigma})}}{2\sqrt{B}}\cdot\sqrt{T}\right) = O(\sqrt{T})} \tag{74}$$

核心结论：$O(\sqrt{T})$ Regret 界

固定步长 SGD，最优选择 $\eta = O(1/\sqrt{T})$ 时，累积 regret 为 $O(\sqrt{T})$，即平均 regret $\text{Regret}_T/T = O(1/\sqrt{T}) \to 0$。
这是在线凸优化的经典结果（Zinkevich, 2003），对**任意**凸损失都成立。但它要求提前知道 T 来选择 η——这在实践中并不总是可能的。

10.4 衰减步长：$O(\log T)$ Regret

对于强凸损失（线性回归满足），可以用衰减步长做得更好。

10.4.1 $\eta_t = c/t$ 的分析

经典的 Robbins-Monro 条件要求 $\sum_t \eta_t = \infty$（保证能到达任意远的点）且 $\sum_t \eta_t^2 < \infty$（保证噪声累积有限）。$\eta_t = c/t$ 满足这两个条件。

在 μ-强凸情况下，取 $c = 1/\mu$，第 t 步的期望误差为：

$$\mathbb{E}[\|\mathbf{e}_t\|^2] = O\left(\frac{1}{t}\right) \tag{75}$$

直觉：随着 t 增大，η_t 衰减，噪声注入减小；同时 Bias 已在早期被消除。两个效应叠加使误差以 $1/t$ 速率下降。

10.4.2 Regret 的计算

每步期望 excess loss $= O(\frac{1}{t})$，对 t 从 1 到 T 求和：

$$\mathbb{E}[\text{Regret}_T] = \sum_{t=1}^{T} O\left(\frac{1}{t}\right) = O\left(\sum_{t=1}^{T} \frac{1}{t}\right) = O(\log T) \tag{76}$$

更精确地，Hazan, Agarwal & Kale (2007) 证明了：对 μ-强凸损失，OGD 用 $\eta_t = 1/(\mu t)$ 的 regret 满足：

$$\boxed{\text{Regret}_T \leq \frac{L}{2\mu}(1 + \log T)} \tag{77}$$

其中 L 是梯度的 Lipschitz 常数。

10.4.3 与固定步长的对比

	固定 $\eta = O(1/\sqrt{T})$	衰减 $\eta_t = c/t$
适用条件	凸（一般）	强凸
Regret	$O(\sqrt{T})$	$O(\log T)$
平均 Regret	$O(1/\sqrt{T})$	$O(\log T/T)$
需要知道 T?	需要（选 η）	不需要
最终误差	$O(1/\sqrt{T})$	$O(1/T)$

$O(\log T)$ 比 $O(\sqrt{T})$ 好得多！例如 $T = 10^6$：$\sqrt{T} = 1000$，但 $\log T \approx 14$。代价是需要强凸性——对线性回归是自然满足的（$\mu = \lambda_1 > 0$）。

10.4.4 手算例子

$d = 1$，$\lambda = 1$，$\sigma_\varepsilon^2 = 1$，$B = 1$，$e_0 = 10$。

固定步长 $\eta = 0.1$. Bias 贡献：$\frac{e_0^2}{4\eta} = \frac{100}{0.4} = 250$

Variance 贡献（$T = 1000$）：$\frac{T\eta\lambda\sigma_\varepsilon^2}{4} = \frac{1000\times0.1\times1}{4} = 25$

总 Regret ≈ 275，平均 0.275。

最优固定步长 $\eta^* = e_0/(\sigma_\varepsilon\sqrt{T}) = 10/\sqrt{1000} \approx 0.316$. Bias 贡献：$\frac{100}{4\times0.316} = 79$

Variance 贡献：$\frac{1000\times0.316}{4} = 79$

总 Regret ≈ 158，平均 0.158。注意 Bias = Variance——最优步长让两者平衡。

衰减步长 $\eta_t = 1/t$. 每步 excess loss $\approx c/t$，求和 $\sum_{t=1}^{1000} 1/t \approx \log(1000) + 0.577 \approx 7.5$。

总 Regret ≈ 7.5，平均 0.0075。比固定步长好了一个数量级以上！

10.5 Regret 视角的独特洞察

10.5.1 Learning Rate Decay 的必要性

从 regret 角度重新理解学习率衰减：

固定 η 时，Variance 项以 $O(T\eta)$ 线性增长——每步都在为噪声付代价。衰减 $\eta_t \to 0$ 使得后期每步的噪声代价 $O(\eta_t^2)$ 趋于零，累积求和收敛。

这就是为什么 Decay 是必要的：不是因为我们想让模型”收敛到一个点”（固定 η 也能做到，只是停在 V_∞ 附近），而是因为**训练过程中的累积代价**在固定 η 下是 $O(\sqrt{T})$，而衰减 η 下只是 $O(\log T)$。

10.5.2 与偏差-方差分解的对应

偏差-方差分析	Regret 分析
$\text{Bias}^2 = (1-\eta\lambda)^{2t}e_0^2$	Bias 总贡献 $= O(1/\eta)$
稳态 Variance $= V_\infty \propto \eta/B$	Variance 累积 $= O(T\eta/B)$
最优 η：平衡 Bias 衰减速度与稳态精度	最优 η：平衡 $O(1/\eta)$ 与 $O(T\eta)$
结论：前期大 η，后期小 η	结论：$\eta_t = O(1/t)$

两种分析完全一致，只是语言不同。偏差-方差分解更关注**最终状态**（$t \to \infty$ 时的误差），regret 分析更关注**过程**（1 到 T 的累积表现）。

10.5.3 $O(\log T)$ 是最优的

Hazan et al. (2007) 同时证明了：对强凸损失，**任何**在线算法的 regret 下界为 $\Omega(\log T)$。因此 SGD 用 $\eta_t = 1/(\mu t)$ 达到的 $O(\log T)$ 界是**渐近最优的**——不可能做得更好。

这个最优性为 SGD 提供了很强的理论保证：在线性回归上，SGD 不仅简单高效，而且在 regret 意义下是最优的在线学习算法。

10.6 文献指引

- **Zinkevich (2003)** - “Online Convex Programming and Generalized Infinitesimal Gradient Ascent”：在线梯度下降 $O(\sqrt{T})$ regret 的奠基工作。
- **Hazan, Agarwal & Kale (2007)** - “Logarithmic Regret Algorithms for Online Convex Optimization”：强凸损失 $O(\log T)$ regret 及匹配下界。
- **Shalev-Shwartz (2012)** - “Online Learning and Online Convex Optimization”, Foundations and Trends：系统综述，详细建立了 SGD 与在线学习的对应关系。
- **Hazan (2016)** - *Introduction to Online Convex Optimization*：教科书，包含完整的 regret 理论。

- **Bach (2024)** - *Learning Theory from First Principles*, Ch. 5-6：本讲义的主要参考，偏差-方差分解可逐项对应 regret 的两个组成部分。

11 临界 Batch Size 与 Scaling 的天花板

11.1 B_{crit} 的推导

稳态预测误差 $\approx \frac{\eta\sigma_\varepsilon^2}{2B}\text{tr}(\mathbf{\Sigma}) \le \epsilon$ 给出 $\frac{\eta}{B} \le \frac{2\epsilon}{\text{tr}(\mathbf{\Sigma})\sigma_\varepsilon^2}$。
同时 $\eta \le \eta_{\max}$。两条约束在临界点相交：

$$\boxed{B_{\text{crit}} = \frac{\eta_{\max}\,\text{tr}(\mathbf{\Sigma})\,\sigma_\varepsilon^2}{2\epsilon} \approx \underbrace{\frac{\text{tr}(\mathbf{\Sigma})}{\lambda_{\max}}}_{d_{\text{eff}}} \times \underbrace{\frac{\sigma_\varepsilon^2}{\epsilon}}_{\text{信噪比需求}}} \tag{78}$$

$B < B_{\text{crit}}$：增大 B 可等比增大 η，线性加速。
$B > B_{\text{crit}}$：η 已触顶，继续增大 B 收益递减。

数值例子. $d = 100$ 各向同性，$\sigma_\varepsilon^2 = 0.01$，$\epsilon = 10^{-4}$：$B_{\text{crit}} = 5000$。

核心结论：最大学习率有限 → 机器再多也不能无限加速小模型

η 有上界 → 再大的 B 也不能无限加速。$B \gg B_{\text{crit}}$ 时每步计算量线性增加，收敛速度不变。
机器变多时必须做大模型：小模型 d_{eff} 有限 → B_{crit} 有限 → 多出算力浪费；大模型 d_{eff} 大 → B_{crit} 大 → 能利用更多机器。

11.2 动态视角

训练中 $B_{\text{crit}}(t) \propto \text{tr}(\Sigma_{\text{noise}}(\theta_t))/\|\nabla L(\theta_t)\|^2$。初期梯度大，小 batch 够用；后期梯度小，需要大 batch。

12 统计物理连接：温度与 Gibbs 分布

SGD 的稳态行为与统计物理有深刻的类比。这个联系不仅是形式上的——它提供了理解学习率调度、batch size 选择和泛化性能的统一视角。

12.1 稳态分布的等温性

回顾小步长近似下的稳态方差：

$$V_{\infty,i} \approx \frac{\eta\sigma_\varepsilon^2}{2B} \tag{79}$$

一个值得注意的事实：$V_{\infty,i}$ **不依赖于曲率** λ_i。无论是平坦方向还是陡峭方向，稳态参数误差的方差都相同。

这让人联想到统计力学中的**能量均分定理**：在热平衡下，每个自由度分到的平均动能相同，都等于 $\frac{1}{2}k_BT$，与该自由度的”刚度”（弹簧常数）无关。

12.2 SGD 温度的定义

定义 SGD 的**等效温度**：

$$\boxed{T_{\text{SGD}} = \frac{\eta\,\sigma_\varepsilon^2}{2B}} \tag{80}$$

其中 σ_ε^2 是观测噪声方差（梯度噪声的来源），η 是学习率，B 是 batch size。

此时稳态方差统一写成：

$$V_{\infty,i} = T_{\text{SGD}} \quad (\text{小步长近似}) \tag{81}$$

更一般地（不做小步长近似），可以写成精确的”热力学”形式。对于二次函数 $f(\boldsymbol{x}) = \frac{1}{2}\sum \lambda_i x_i^2$，精确的稳态分布是高斯分布 $x_i \sim \mathcal{N}(0, V_{\infty,i})$，对应的”概率密度”为：

$$p(\boldsymbol{x}) \propto \exp\left(-\sum_i \frac{x_i^2}{2V_{\infty,i}}\right) \tag{82}$$

小步长下 $V_{\infty,i} \approx T/\lambda_i$（从精确公式 $V_{\infty,i} = \eta\sigma_\varepsilon^2/[B(2-\eta\lambda_i)]$ 在 $\eta\lambda_i \to 0$ 极限得到），所以：

$$p(\boldsymbol{x}) \propto \exp\left(-\frac{1}{T}\sum_i \frac{1}{2}\lambda_i x_i^2\right) = \exp\left(-\frac{f(\boldsymbol{x})}{T}\right) \tag{83}$$

这正是温度为 T 的 **Gibbs（玻尔兹曼）分布**。

12.3 温度的物理意义

	高温（T 大）	低温（T 小）
η	大	小
B	小	大
稳态分布	弥散，远离极小值	集中于极小值附近
探索能力	强：能翻越小的势垒	弱：被困在局部极小值
精度	低：稳态误差大	高：稳态误差小

12.4 与线性缩放法则的统一

线性缩放法则 $\eta/B = \text{const}$ 的物理意义现在清楚了：

$$T = \frac{\eta\sigma_\varepsilon^2}{2B} \propto \frac{\eta}{B} \tag{84}$$

$\eta/B = \textbf{const}$ **就是保持温度不变**。

batch size 加倍、学习率加倍 → 温度不变 → 稳态分布不变 → 最终精度不变。但 η 更大意味着 Bias 衰减更快，所以每步实际效率更高。

12.5 退火（Annealing）策略

训练过程中逐步”降温”的策略直接来自统计物理的**模拟退火**（simulated annealing）：

前期（高温阶段）：大 η、小 B。分布弥散，有利于探索损失景观，避免过早困在差的局部极小值。

后期（低温阶段）：小 η、大 B。分布收缩到好的极小值附近，提高最终精度。

降温的两种等价方式（Smith & Le, 2017）：

- 方式 A：保持 B 不变，衰减 η（传统 learning rate decay）
- 方式 B：保持 η 不变，增大 B（”Don’t Decay the Learning Rate, Increase the Batch Size”）

两者在数学上等价（都是降低 $T = \eta\sigma_\varepsilon^2/(2B)$），但方式 B 在分布式训练中更自然——加机器就是加 B。

12.6 温度与泛化的关系

统计物理视角还能解释一些关于泛化的经验观察：

小 batch 通常泛化更好（Keskar et al., 2017）。直觉：小 B → 高温 → SGD 在损失景观中探索更广 → 倾向于找到**宽**极小值（flat minima）。宽极小值对参数微扰更鲁棒，对应更好的泛化。

大 batch 倾向于找到尖极小值（sharp minima）。低温下 SGD 缺乏翻越势垒的能力，容易困在离初始点最近的极小值——这往往是尖的。尖极小值对训练数据过度拟合。

不过这一解释并不完全定论，仍有争议（Dinh et al., 2017 等）。但”SGD 温度”作为分析工具是被广泛认可的。

12.7 数值例子：温度对稳态的影响

$d = 2$，$\lambda_1 = 1$，$\lambda_2 = 10$，$\sigma_\varepsilon^2 = 1$。

η	B	$T = \eta/(2B)$	$V_{\infty,1} \approx T$	$V_{\infty,2} \approx T$
0.1	1	0.05	0.05	0.05
0.01	1	0.005	0.005	0.005
0.1	10	0.005	0.005	0.005
0.01	10	0.0005	0.0005	0.0005

注意第 2、3 行：$(\eta = 0.01, B = 1)$ 和 $(\eta = 0.1, B = 10)$ 温度相同，稳态方差相同。但后者 Bias 衰减更快（η 更大），所以总训练效率更高。这就是线性缩放法则的实际意义。

13 数据归一化：为什么对训练至关重要

13.1 条件数与归一化

$\kappa = \lambda_d/\lambda_1$。特征尺度差异大 $\to$ κ 大 $\to$ 收敛慢。例：" 年龄"($\lambda \sim 10^3$) vs " 收入"($\lambda \sim 10^9$)，$\kappa = 10^6$。标准化后各方向曲率接近。

13.2 深度网络的条件数爆炸

L 层网络无归一化时 $\kappa_{\text{total}} \sim \prod_l \kappa_l$。每层 $\kappa_l = 2$，10 层后 $\kappa = 1024$。

13.3 Batch Normalization

BN 对每个特征沿 batch 归一化：$\hat{h}_j^{(b)} = (h_j^{(b)} - \bar{h}_j)/s_j$。
$B \to \infty$ 时：$\text{Cov}[\hat{\mathbf{h}}] = \mathbf{I}$，$\kappa_{\text{BN}} = 1$。**直接降到 1**。

13.4 Layer Normalization

LN 对单样本沿特征归一化。d 大时 $\hat{h}_j \approx h_j/\bar{\sigma}$，$\kappa_{\text{LN}} = \kappa_{\text{原始}}$。LN **不直接降低条件数**，但保证尺度稳定、去相关。

	Batch Norm	Layer Norm
对条件数	$\kappa \to 1$	κ 不变
主要作用	降低条件数	尺度稳定 + 去相关
适用	CNN（大 batch）	Transformer

13.5 回归的无偏性分析

BN 的情况（$B \to \infty$）：$\hat{\mathbf{h}} = \mathbf{D}^{-1}(\mathbf{h} - \boldsymbol{\mu})$，$\mathbf{D} = \text{diag}(\sigma_1, \ldots, \sigma_d)$。
如果真实关系是 $y = \mathbf{h}^\top \boldsymbol{\theta}^*$，则 $y = \hat{\mathbf{h}}^\top(\mathbf{D}\boldsymbol{\theta}^*) + \boldsymbol{\mu}^\top \boldsymbol{\theta}^*$。
回归 $\hat{\mathbf{h}}$ 对 y 得到的 $\tilde{\boldsymbol{\theta}}$ 是 $\mathbf{D}\boldsymbol{\theta}^*$ 的无偏估计。原参数可通过 $\boldsymbol{\theta}^* = \mathbf{D}^{-1}\tilde{\boldsymbol{\theta}}^*$ 恢复。
LN 的情况（d 大）：$\hat{\mathbf{h}} \approx \mathbf{h}/\bar{\sigma}$。$y = \hat{\mathbf{h}}^\top(\bar{\sigma}\boldsymbol{\theta}^*)$。回归仍无偏，参数缩放 $\bar{\sigma}$ 倍。
结论：BN 和 LN 都是近似线性变换，不改变回归的无偏性。

13.6 可学习参数 γ，β

归一化后加可学习缩放和平移：$\tilde{h}_j = \gamma_j \hat{h}_j + \beta_j$。

作用：让网络在"完全归一化"和"保留原始分布"之间折中，保持表达能力。如果网络发现某个方向不需要归一化，可以学到 $\gamma_j = \sigma_j$，$\beta_j = \mu_j$，恢复原始分布。

13.7 手算例子：归一化前后的收敛速度

设置：$f(x, y) = \frac{1}{2}(100x^2 + y^2)$，$\kappa = 100$。

不归一化：$\eta^* = 2/101 \approx 0.02$，$\rho^* = 99/101 \approx 0.98$。

降到 1% 需要 $T = \log(100)/\log(1/0.98) \approx 228$ 步。

归一化后（令 $\tilde{x} = 10x$）：$f(\tilde{x}, y) = \frac{1}{2}(\tilde{x}^2 + y^2)$，$\kappa = 1$。

$\eta^* = 1$，$\rho^* = 0$，**一步收敛**！

加速比：228 步 vs 1 步 = **228 倍**！

实际中不可能总是 $\kappa = 1$，但即使把 κ 从 100 降到 10（通过归一化），步数从 228 降到约 23——仍然快了 10 倍。

核心结论：数据归一化对训练至关重要

三层面：输入标准化、中间层 Norm、输出缩放。归一化降低 κ，收敛步数 $\propto \kappa$。不做可能慢几十到几百倍。

14 初始化：Xavier/He 的方差传播推导

初始化的目标是让信号在前向传播和反向传播中保持稳定的幅度——不爆炸、不消失。推导分三步：先分析**无激活函数**的线性网络，再考虑 **Tanh/Sigmoid**，最后处理 **ReLU**。

14.1 第一步：线性网络的方差传播

14.1.1 前向传播

考虑单层线性变换（暂不加激活函数）：

$$h_j^{(l+1)} = \sum_{i=1}^{n_{\text{in}}} W_{ji}^{(l)} \, h_i^{(l)} \tag{85}$$

假设：

- 权重 W_{ji} 独立同分布，$\mathbb{E}[W_{ji}] = 0$，$\text{Var}[W_{ji}] = \sigma_W^2$
- 输入 $h_i^{(l)}$ 独立同分布，$\mathbb{E}[h_i^{(l)}] = 0$，$\text{Var}[h_i^{(l)}] = \sigma_h^2$

- W 与 h 独立

计算输出方差：

$$\begin{aligned}
\mathrm{Var}[h_j^{(l+1)}] &= \mathrm{Var}\left[\sum_{i=1}^{n_{\text{in}}} W_{ji}\, h_i^{(l)}\right] && (86)\\
&= \sum_{i=1}^{n_{\text{in}}} \mathrm{Var}[W_{ji}\, h_i^{(l)}] \quad (\text{独立性}) && (87)\\
&= \sum_{i=1}^{n_{\text{in}}} \mathbb{E}[W_{ji}^2]\,\mathbb{E}[(h_i^{(l)})^2] \quad (\text{独立 + 零均值：}\mathrm{Var}[XY]=\mathbb{E}[X^2]\mathbb{E}[Y^2]) && (88)\\
&= n_{\text{in}} \cdot \sigma_W^2 \cdot \sigma_h^2 && (89)
\end{aligned}$$

因此每过一层，方差被乘以 $n_{\text{in}} \cdot \sigma_W^2$。**方差保持条件**：

$$n_{\text{in}} \cdot \sigma_W^2 = 1 \quad \Rightarrow \quad \sigma_W^2 = \frac{1}{n_{\text{in}}} \tag{90}$$

14.1.2 反向传播

设损失对第 $l+1$ 层输出的梯度为 $\delta_j^{(l+1)} = \frac{\partial L}{\partial h_j^{(l+1)}}$。由链式法则：

$$\delta_i^{(l)} = \frac{\partial L}{\partial h_i^{(l)}} = \sum_{j=1}^{n_{\text{out}}} W_{ji}^{(l)}\, \delta_j^{(l+1)} \tag{91}$$

（注意转置：前向是 $h^{(l+1)} = Wh^{(l)}$，反向是 $\delta^{(l)} = W^\top \delta^{(l+1)}$。）
同样的方差计算：

$$\mathrm{Var}[\delta^{(l)}] = n_{\text{out}} \cdot \sigma_W^2 \cdot \mathrm{Var}[\delta^{(l+1)}] \tag{92}$$

梯度方差保持条件：

$$n_{\text{out}} \cdot \sigma_W^2 = 1 \quad \Rightarrow \quad \sigma_W^2 = \frac{1}{n_{\text{out}}} \tag{93}$$

14.1.3 冲突与 Xavier 折中

前向要求 $\sigma_W^2 = 1/n_{\text{in}}$，反向要求 $\sigma_W^2 = 1/n_{\text{out}}$。除非 $n_{\text{in}} = n_{\text{out}}$，否则两者矛盾。
Glorot & Bengio (2010) 的 **Xavier 初始化**取调和平均（折中）：

$$\boxed{\sigma_W^2 = \frac{2}{n_{\text{in}} + n_{\text{out}}}} \tag{94}$$

此时前向方差放大因子为 $n_{\text{in}} \cdot \frac{2}{n_{\text{in}}+n_{\text{out}}} = \frac{2n_{\text{in}}}{n_{\text{in}}+n_{\text{out}}}$，介于 1（当 $n_{\text{in}} = n_{\text{out}}$）和 2（当 $n_{\text{out}} \ll n_{\text{in}}$）之间，是一个合理的近似。

14.2 第二步：Tanh/Sigmoid 激活函数

以上推导没有涉及激活函数。为什么结论对 Tanh 网络也适用？

关键观察：如果初始化得当（方差不大），激活值 $z = Wh$ 集中在零附近。而 Tanh 在零附近近似线性：

$$\tanh(z) \approx z \quad (\text{当}|z| \ll 1) \tag{95}$$

此时激活函数几乎不改变方差：$\mathrm{Var}[\tanh(z)] \approx \mathrm{Var}[z]$，线性分析的结论近似成立。

Sigmoid 类似：$\sigma(z) \approx 0.5 + 0.25z$，有一个 0.25 的缩放因子，但 Glorot & Bengio 的分析中吸收了这个常数。

前提：这个近似成立的条件是激活值确实在线性区——如果初始化太大，z 的幅度很大，Tanh/Sigmoid 饱和，方差分析就失效了。这也是为什么正确的初始化如此重要——它让激活函数保持在" 好的工作区间"。

14.3 第三步：ReLU 激活函数

ReLU $\sigma(z) = \max(0, z)$ 不是" 近似线性"——它把所有负值砍成零。

对于零均值的输入 $z \sim \mathcal{N}(0, \sigma_z^2)$，恰好一半的值被置零。我们需要计算 ReLU 输出的**二阶矩**（而非方差，原因见下文）：

$$\mathbb{E}[\mathrm{ReLU}(z)^2] = \Pr(z > 0) \cdot \mathbb{E}[z^2 \mid z > 0] = \frac{1}{2} \cdot \sigma_z^2 \tag{96}$$

（对称分布，条件在 $z > 0$ 后，$\mathbb{E}[z^2 \mid z > 0] = \sigma_z^2$。）

因此：

$$\boxed{\mathbb{E}[\mathrm{ReLU}(z)^2] = \frac{1}{2}\,\mathbb{E}[z^2] = \frac{1}{2}\mathrm{Var}[z]} \tag{97}$$

ReLU 将**二阶矩**减半。

ReLU 的输出有非零均值 $\mathbb{E}[\mathrm{ReLU}(z)] = \sigma_z/\sqrt{2\pi}$，因此 $\mathrm{Var}[\mathrm{ReLU}(z)] = \frac{1}{2}\sigma_z^2 - \frac{\sigma_z^2}{2\pi} \approx 0.34\,\sigma_z^2$，并**不是**精确的一半。但在方差传播公式中，由于下一层权重 W 零均值，$\mathrm{Var}[Wh] = \sigma_W^2 \cdot \mathbb{E}[h^2]$，出现的是 h 的**二阶矩**而非方差。而 $\mathbb{E}[\mathrm{ReLU}(z)^2] = \frac{1}{2}\sigma_z^2$ 是**精确**的。这就是 He 初始化中 2 的真正来源。

14.3.1 He/Kaiming 初始化

加入 ReLU 后，前向二阶矩传播变为：

$$\mathbb{E}[(h^{(l+1)})^2] = n_{\text{in}} \cdot \sigma_W^2 \cdot \frac{1}{2} \cdot \mathbb{E}[(h^{(l)})^2] \tag{98}$$

二阶矩保持条件：

$$n_{\text{in}} \cdot \sigma_W^2 \cdot \frac{1}{2} = 1 \quad \Rightarrow \quad \boxed{\sigma_W^2 = \frac{2}{n_{\text{in}}}} \tag{99}$$

这就是 He et al. (2015) 的 **He/Kaiming 初始化**。

对比：Xavier 给出 $\sigma_W^2 \approx 1/n_{\text{in}}$（忽略 n_{out} 修正），He 给出 $\sigma_W^2 = 2/n_{\text{in}}$——正好是 Xavier 的两倍，补偿了 ReLU 的二阶矩减半。

14.4 三种初始化的总结

激活函数	二阶矩缩放因子	前向保持条件	初始化
无（线性）	1	$n_{\text{in}}\sigma_W^2 = 1$	$\sigma_W^2 = 1/n_{\text{in}}$
Tanh（$z \approx 0$ 附近）	≈ 1	$n_{\text{in}}\sigma_W^2 \approx 1$	Xavier: $2/(n_{\text{in}} + n_{\text{out}})$
ReLU	$1/2$	$n_{\text{in}}\sigma_W^2/2 = 1$	He: $2/n_{\text{in}}$

14.5 深度放大初始化偏差

L 层等宽网络（每层宽度 n），ReLU 激活。每层的二阶矩放大因子为 $\frac{n\sigma_W^2}{2}$。L 层后：

$$\mathbb{E}[(h^{(L)})^2] = \left(\frac{n\sigma_W^2}{2}\right)^L \cdot \mathbb{E}[x^2] \tag{100}$$

初始化	$n\sigma_W^2/2$	$L = 50$ 层后二阶矩	状态
Xavier ($n\sigma_W^2 = 1$)	0.5	$(0.5)^{50} \approx 10^{-15}$	**完全消失**
He ($n\sigma_W^2 = 2$)	1	$1^{50} = 1$	**完美稳定**

He 初始化是 ReLU 深度网络的唯一稳定选择。Xavier 在 Tanh 网络上适用，但在 ReLU 网络上会导致 50 层后信号衰减 10^{15} 倍。

14.6 手算练习：二阶矩传播的逐层计算

问题：3 层 MLP，结构 $100 \to 50 \to 20 \to 1$，ReLU 激活。

比较两种初始化：(A) 固定 $\sigma_W^2 = 0.01$，(B) He 初始化 $\sigma_W^2 = 2/n_{\text{in}}$。

假设输入二阶矩 $\mathbb{E}[x^2] = 1$。

(A) 固定方差：

层	n_{in}	$n_{\text{in}}\sigma_W^2$	ReLU 后	累积二阶矩
输入	—	—	—	1
第 1 层	100	1.0	$\times 0.5$	0.5
第 2 层	50	0.5	$\times 0.5$	0.125
第 3 层	20	0.2	—	0.025

输出二阶矩 $= 0.025$（衰减 40 倍！**信号消失**）。

(B) He 初始化：

层	n_{in}	$\sigma_W^2 = 2/n_{\text{in}}$	$n_{\text{in}}\sigma_W^2$	累积二阶矩
输入	—	—	—	1
第 1 层	100	0.02	2	$1 \times 2 \times 0.5 = 1$
第 2 层	50	0.04	2	$1 \times 2 \times 0.5 = 1$
第 3 层	20	0.1	2	$1 \times 2 = 2$

输出二阶矩 ≈ 1（**稳定**！最后一层没 ReLU 所以是 2）。

14.7 初始化与 Hessian 曲率的关系

两层线性网络 $f = vux$，Hessian $H = \begin{pmatrix} v^2 & 2uv-1 \\ 2uv-1 & u^2 \end{pmatrix}$。

初始化	$\lambda_{\max}$	$\eta_{\max}$	初始 Loss	初始梯度
$(u,v)=(1,1)$	2	1	0（已在最优解）	$(0,0)$
$(u,v)=(0.1,0.1)$	0.99	2	0.49	$(-0.099,-0.099)$
$(u,v)=(5,5)$	74	0.027	288	$(120,120)$

结论：初始化越大 → 曲率越大 → $\eta_{\max}$ 越小 → 越需要 Warmup。

Xavier/He 初始化让每层权重 $|W_{ji}| \sim O(1/\sqrt{n})$，保持曲率 $O(1)$，避免这个问题。

15 Warmup 的必要性：非线性的曲率困境

15.1 线性模型不需要 Warmup

Hessian $= \mathbf{\Sigma}$ 是常数。最优 η 从一开始就适用。只需 Decay（前期大 η 消 Bias，后期小 η 降 Variance）。

15.2 两层网络：Hessian 随位置变化

$f(x;u,v) = vux$，$L(u,v) = \frac{1}{2}(vu-1)^2$。

Hessian $H = \begin{pmatrix} v^2 & 2uv-1 \\ 2uv-1 & u^2 \end{pmatrix}$。$H_{uu} = v^2$，$H_{vv} = u^2$ 随参数大小变化！

手算：大初始化发散. $u_0 = v_0 = 5$，$\eta = 0.1$。$\lambda_{\max} = 74$，$\eta_{\max} = 0.027$，$\eta = 0.1$ 是 3.7 倍上界。

第 1 步：$(5,5) \to (-7,-7)$, Loss $288 \to 1152$。第 2 步：$\to (26.6, 26.6)$, Loss $\to 250000$。**发散！**

手算：Warmup 拯救. 前 3 步 $\eta_w = 0.01$：$(5,5) \to (3.8,3.8) \to (3.29,3.29) \to (2.97,2.97)$, Loss $288 \to 90 \to 48 \to 31$。

此时 $\lambda_{\max} \approx 25.5$，$\eta_{\max} = 0.078$——仍略超目标学习率 $\eta = 0.1$，但参数已进入快速收敛区域：第 4 步 $\eta = 0.1$ 一步跳到 $(0.65, 0.65)$，Loss $\to 0.17$，$\lambda_{\max}$ 骤降至 0.6，此后完全稳定。

15.3 带 Sigmoid 的两层网络：更真实的非线性

上面的两层**线性**网络已经展示了 Warmup 的必要性。加入激活函数后更加明显。

考虑 $f(x; w_1, w_2) = w_2 \cdot \sigma(w_1 x)$，其中 $\sigma(z) = 1/(1+e^{-z})$。
$(x, y) = (1, 1)$，$L(w_1, w_2) = \frac{1}{2}(w_2\sigma(w_1) - 1)^2$。

15.3.1 Sigmoid 参考表

z	$\sigma(z)$	$\sigma'(z)$	z	$\sigma(z)$	$\sigma'(z)$
-2	0.119	0.105	0.5	0.622	0.235
-1	0.269	0.197	1.0	0.731	0.197
0	0.500	0.250	2.0	0.881	0.105

$\sigma'(z) = \sigma(z)(1 - \sigma(z))$，$\sigma''(z) = \sigma'(z)(1 - 2\sigma(z))$。

15.3.2 手算：小初始化——稳定训练

初始化 $w_1 = 0$，$w_2 = 1$，$\eta = 1$。
$a = \sigma(0) = 0.5$，$\hat{y} = 1 \times 0.5 = 0.5$，$L = 0.125$。
梯度：$r = -0.5$, $\partial L/\partial w_2 = -0.5 \times 0.5 = -0.25$, $\partial L/\partial w_1 = -0.5 \times 1 \times 0.25 = -0.125$。
Hessian：$H_{22} = 0.25$，$H_{11} = 0.0625$，$\lambda_{\max} \approx 0.25$，$\eta_{\max} = 8$。$\eta = 1 \ll 8$，**非常安全**。

步	w_1	w_2	$\hat{y}$	Loss
0	0	1.00	0.500	0.125
1	0.125	1.25	0.664	0.056
2	0.230	1.43	0.795	0.021
3	≈ 0.31	≈ 1.55	≈ 0.88	≈ 0.007

稳定下降！

15.3.3 手算：大初始化——需要 Warmup

初始化 $w_1 = 2$，$w_2 = 4$，$\eta = 2$。
$a = \sigma(2) = 0.881$，$\hat{y} = 3.52$，$L = 3.19$。
$\partial L/\partial w_2 = 2.52 \times 0.881 = 2.22$，$\partial L/\partial w_1 = 2.52 \times 4 \times 0.105 = 1.06$。
$H_{22} = 0.776$，$\lambda_{\max} \approx 1.04$，$\eta_{\max} \approx 1.92$。$\eta = 2 > 1.92$，**勉强超出**！
第 1 步：$w_1 = 2 - 2 \times 1.06 = -0.12$，$w_2 = 4 - 2 \times 2.22 = -0.44$。
$\hat{y} = -0.44 \times \sigma(-0.12) = -0.207$。符号翻转！
第 2 步：$r = -1.207$，梯度方向又变了... 轨迹出现剧烈振荡。
用 Warmup（前 2 步 $\eta = 0.5$，之后 $\eta = 2$）：

步	w_1	w_2	Loss	阶段
0	2.00	4.00	3.19	
1	1.47	2.89	0.91	Warmup ($\eta = 0.5$)
2	1.17	2.34	0.31	Warmup ($\eta = 0.5$)
3	0.51	1.14	0.042	切到 $\eta = 2$
4	≈ 0.66	≈ 1.50	≈ 0.0001	$\eta = 2$

Warmup 2 步后参数进入小曲率区域，切到大学习率后一步几乎收敛到最优解。

对比线性回归：$f = \theta x$，$\theta_0 = 3.5$（同样初始 $\hat{y} \approx 3.5$），Hessian $= \sigma^2$（常数）。$\eta = 2$ 在稳定边界，会振荡但**不发散**——因为曲率不变。

	Sigmoid 网络	线性回归
Hessian	随 (w_1, w_2) 变化	常数
大 η 的后果	参数符号翻转、Hessian 剧变	振荡但幅度衰减
Warmup	**需要**	不需要

15.4 L 层网络：深度指数放大

L 层 $f = w_L \cdots w_1 x$，$w_l = s$。$H_{kk} = s^{2(L-1)}$，$\eta_{\max} \approx 2/(Ls^{2(L-1)})$。

深度 L	2	3	5	10
$s = 1.5$（稍大初始化）				
$s^{2(L-1)}$	2.25	5.06	25.6	1478
$L \cdot s^{2(L-1)}$	4.5	15.2	128	14780
$\eta_{\max} = 2/(L \cdot s^{2(L-1)})$	0.44	0.13	0.016	1.4×10^{-4}
$s = 1.1$（轻微偏大）				
$s^{2(L-1)}$	1.21	1.46	2.14	5.56
$\eta_{\max}$	0.83	0.46	0.19	0.036
$s = 1.0$（理想初始化）				
$s^{2(L-1)}$	1	1	1	1
$\eta_{\max}$	1.0	0.67	0.4	0.2

关键观察：

- $s = 1.5$，$L = 10$：$\eta_{\max} \approx 10^{-4}$，几乎无法训练！
- $s = 1.1$，$L = 10$：$\eta_{\max} = 0.036$，需要很小的学习率
- $s = 1.0$，$L = 10$：$\eta_{\max} = 0.2$，仍可训练
- s 从 1.0 变到 1.1（只偏了 10%），$\eta_{\max}$ 下降了 5.5 倍！

这就是为什么正确的初始化如此重要——深度网络指数放大初始化的微小偏差。

15.5 Warmup 步数的估计

15.5.1 从简单模型出发

回到 L 层线性网络，对称初始化 $w_l = s_0$。Warmup 的目标是把参数从 s_0 拉到接近 1（从而让 $\lambda_{\max}$ 降到可控范围）。

Warmup 期间用小学习率 η_w，每步更新量约为 $\eta_w \cdot |g|$，其中初始梯度：

$$|g| = (s_0^L - 1) \cdot s_0^{L-1} \tag{101}$$

参数需要变化 $\Delta s = s_0 - 1$，所以粗略估计 Warmup 步数为：

$$T_{\text{warmup}} \approx \frac{\Delta s}{\eta_w \cdot |g|} = \frac{s_0 - 1}{\eta_w \cdot (s_0^L - 1) \cdot s_0^{L-1}} \tag{102}$$

但 η_w 本身受稳定性约束：$\eta_w < 2/\lambda_{\max}^{(0)} = 2/(L \cdot s_0^{2(L-1)})$。取 $\eta_w \sim 1/(L \cdot s_0^{2(L-1)})$ 代入：

$$T_{\text{warmup}} \sim \frac{(s_0 - 1) \cdot L \cdot s_0^{2(L-1)}}{(s_0^L - 1) \cdot s_0^{L-1}} = \frac{(s_0 - 1) \cdot L \cdot s_0^{L-1}}{s_0^L - 1} \tag{103}$$

当 s_0 接近 1 时，$s_0^L - 1 \approx L(s_0 - 1)$，上式简化为：

$$T_{\text{warmup}} \sim s_0^{L-1} \tag{104}$$

含义：对于这个简单模型，Warmup 步数主要取决于 s_0^{L-1}，即**初始曲率** $H_{kk} = s_0^{2(L-1)}$ **的平方根**。等价地说，$T_{\text{warmup}} \sim \sqrt{\lambda_{\max}^{(0)}/L}$。

15.5.2 推广到实际网络的困难

以上分析基于极简模型（标量权重、对称初始化、线性网络），实际网络有几个本质区别：

- **矩阵权重**：实际网络中 $\mathbf{W}_l \in \mathbb{R}^{n \times n}$，曲率不仅取决于权重大小，还取决于矩阵的谱结构。宽度 n 进入 $\lambda_{\max}$ 的方式与标量模型不同。
- **非线性激活**：Sigmoid/ReLU 等激活函数使得 Hessian 的位置依赖性更复杂。
- **非对称初始化**：Xavier/He 初始化下各层权重的范数不完全相同。
- **随机梯度**：SGD 的噪声在 Warmup 阶段也会影响动力学。

因此，无法从上述标量模型直接推导出实际网络的 Warmup 步数公式。

15.5.3 经验观察

实践中观察到的 Warmup 步数规律：

网络类型	典型深度	典型宽度	典型 Warmup
浅层 MLP	2–3 层	$\sim 10^2$	0–100 步
ResNet-50	50 层	$\sim 10^2$–10^3	2000–5000 步
Transformer-Base	6 层	512	$\sim$ 4000 步
Transformer-Large	24 层	1024	$\sim$ 8000 步
GPT-3 (175B)	96 层	12288	$\sim$ 375M tokens

从表中可以观察到：Warmup 步数大致随深度和宽度增加。一个粗略的经验拟合是：

$$T_{\text{warmup}} \sim c \cdot L \cdot \log(n) \tag{105}$$

其中 L 是深度，n 是宽度，c 是依赖于初始化质量和目标学习率的常数。

15.5.4 从标量模型推导 $T_{\text{warmup}} \sim L \log n$

标量模型中 s 在矩阵网络中对应权重矩阵的**谱范数** $\bar{\sigma} = \|\mathbf{W}\|_{\text{op}}$。沿着这个对应，分三步推导。

Step 1：曲率中的 $O(n)$ 因子. 标量模型给出 $\lambda_{\max} \sim L \cdot s^{2(L-1)}$，矩阵版本中 $s \to \bar{\sigma}$。但矩阵网络还有一个标量模型没有的因子。

对一层全连接 $\mathbf{h} = \mathbf{W}\mathbf{a}$，梯度 $\partial L/\partial W_{ji} = \delta_j \cdot a_i$。单样本 Hessian 的最大特征值为：

$$\lambda_{\max}^{\text{sample}} = \|\boldsymbol{\delta}\|^2 \cdot \|\mathbf{a}\|^2 \tag{106}$$

He 初始化保持每个分量 $a_i = O(1)$，但 n 个分量加起来 $\|\mathbf{a}\|^2 = O(n)$。类似地 $\|\boldsymbol{\delta}\|^2 = O(n)$。取 mini-batch 平均后，$\lambda_{\max}^{\text{sample}}$ 介于 n 的一次和二次方之间，先假设为一次方，曲率公式变为：

$$\lambda_{\max} \sim \underbrace{n}_{\|\mathbf{a}\|^2} \cdot \underbrace{L \cdot \bar{\sigma}_{\text{eff}}^{2(L-1)}}_{\text{深度（与标量模型相同）}} \tag{107}$$

Step 2：有 LN + 残差时 $\bar{\sigma}_{\text{eff}} \approx 1$. He 初始化下裸谱范数 $\bar{\sigma} = 2\sqrt{2} \approx 2.83$（Marchenko-Pastur 律），远大于 1——**方差保持 $\neq$ 谱范数保持**。但 LN + 残差连接将其压缩到 $\bar{\sigma}_{\text{eff}} \approx 1 + O(n^{-2/3})$。当 $L \ll n^{2/3}$ 时（现代 Transformer 通常满足），$(1+\epsilon)^{2(L-1)} \approx 1$，因此：

$$\boxed{\lambda_{\max} \sim nL, \quad \eta_{\max} \sim \frac{1}{nL}} \tag{108}$$

Step 3：$\log n$ 来自目标条件. 标量模型给出 $T_{\text{warmup}} \sim L \cdot \log(\bar{\sigma}_0/\bar{\sigma}_{\text{target}})$（谱范数做比例缩小，需要对数步数）。$\bar{\sigma}_{\text{target}}$ 由稳定性条件 $nL \cdot \bar{\sigma}_{\text{target}}^{2(L-1)} < 2/\eta_{\text{target}}$ 决定。代入：

$$T_{\text{warmup}} \sim L \cdot \log\left(\bar{\sigma}_0^{2(L-1)} \cdot \frac{nL\eta_{\text{target}}}{2}\right) = L \cdot \left[2(L-1)\log\bar{\sigma}_0 + \log n + \log L + \text{const}\right] \tag{109}$$

好的初始化下 $\bar{\sigma}_0 \approx 1$，第一项与 n 弱相关。主导的 n 依赖来自 $\log n$(这里也可以发现之前假设的 $\lambda_{\max}^{\text{sample}}$ 的量级不影响 warm up 的大致时间)：

$$\boxed{T_{\text{warmup}} \sim L \log n} \tag{110}$$

直觉：$L \log n$ 的物理来源

$\log n$ 不是来自谱范数（有 LN 后 $\bar{\sigma} \approx 1$），而是来自**目标条件**：曲率 $\lambda_{\max} \sim nL$ 中有 $O(n)$ 的前置因子（来自 $\|\mathbf{a}\|^2 = O(n)$），为了将 $\lambda_{\max}$ 降到 $2/\eta_{\text{target}}$，$\bar{\sigma}^{2(L-1)}$ 必须额外补偿 n，在对数尺度上多走 $\log n$ 的距离。

一句话：宽度放大了曲率，谱范数要降得更多，多出的量正好是 $\log n$。

核心结论：宽度增大曲率

对宽度为 n 的网络，Hessian 的最大特征值有一个 $O(n)$ 的前置因子。因此：

- 宽度翻倍 $\to \lambda_{\max}$ 约翻倍 $\to \eta_{\max}$ 约减半
- 若目标学习率不变，Warmup 需要从更小的 η_w 开始
- 在标准参数化下，更宽的网络确实需要更长的 Warmup
- μP 通过让 $\eta \propto 1/n$ 来抵消这个效应，使得 Warmup 需求与宽度解耦

这也解释了为什么宽网络通常使用更小的学习率——不是因为”模型太大需要小心”，而是因为 Hessian 的曲率确实更大。

实践建议：

1. 使用标准初始化（Xavier/He）使 $\bar{\sigma} \approx 1$（在方差意义下）
2. Warmup 步数取总训练步数的 1%–5%
3. 深度越大、宽度越大、目标学习率越大 $\to$ Warmup 越长
4. 如有可能，监控梯度范数或 loss 的变化率来判断何时结束 Warmup

核心结论：Warmup 对非线性至关重要

	线性模型	两层网络	L 层网络
Hessian	常数	$\propto u^2, v^2$	$\propto s^{2(L-1)}$
Warmup	不需要	需要	更需要

Warmup 步数 $\propto \log(\lambda_{\max}^{(0)}/\lambda_{\text{target}})$。正确初始化 + Norm 可大幅缩短。

16 实用技巧速览

16.1 Gradient Clipping

裁剪梯度范数：$\mathbf{g} \leftarrow \min(1, C/\|\mathbf{g}\|) \cdot \mathbf{g}$。限制每步最大移动距离。Transformer 必备，通常 $C = 1.0$。

16.2 Cosine Annealing

$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos\frac{\pi t}{T})$。开始慢降，中间快降，末尾慢降。比 step decay 更平滑。

16.3 Gradient Accumulation

累积 K 个 micro-batch 梯度再更新，等价于 batch size KB_{micro}。时间换空间。

17 本周总结

核心结论：核心公式速查

量	公式
步长上界	$\eta < 2/L$
最优步长	$\eta^* = 2/(\mu + L)$
最优收敛因子	$\rho^* = (\kappa - 1)/(\kappa + 1)$
稳态方差	$V_{\infty,i} = \eta\sigma_\varepsilon^2/[B(2 - \eta\lambda_i)]$
小步长近似	$V_{\infty,i} \approx \eta\sigma_\varepsilon^2/(2B)$
预测误差	$\approx \eta\sigma_\varepsilon^2 \mathrm{tr}(\mathbf{\Sigma})/(2B)$
SGD 温度	$T = \eta\sigma^2/(2B)$
临界 batch	$B_{\mathrm{crit}} \approx d_{\mathrm{eff}} \cdot \sigma_\varepsilon^2/\epsilon$
Xavier	$\sigma_W^2 = 2/(n_{\mathrm{in}} + n_{\mathrm{out}})$
He	$\sigma_W^2 = 2/n_{\mathrm{in}}$

进一步阅读

- **Bach (2024)** - *Learning Theory from First Principles*, Ch. 5-6.
- **Bottou, Curtis & Nocedal (2018)** - *Optimization Methods for Large-Scale ML*, SIAM Review.
- **McCandlish et al. (2018)** - *An Empirical Model of Large-Batch Training.*
- **Smith & Le (2017)** - *Don't Decay the Learning Rate, Increase the Batch Size.*
- **Santurkar et al. (2018)** - *How Does BN Help Optimization?*
- **Glorot & Bengio (2010)** - Xavier 初始化.
- **He et al. (2015)** - He/Kaiming 初始化.
- **Martens & Grosse (2015)** - KFAC: Kronecker-Factored Approximate Curvature.
- **Yang et al. (2022)** - Tensor Programs V: μP 与零样本超参数迁移.

A 宽度、深度与 Warmup 步数的详细推导

本附录给出正文中 $T_{\mathrm{warmup}} \sim L \log n$ 结论的完整推导细节。

A.1 标量模型回顾

L 层线性网络 $f = w_L \cdots w_1 x$，对称初始化 $w_l = s_0 > 1$。

A.1.1 Hessian 与稳定性

乘积 $P = s_0^L$。对第 k 层权重，Hessian 对角元：

$$H_{kk} = \left(\frac{P}{w_k}\right)^2 = s_0^{2(L-1)} \tag{111}$$

考虑非对角项，Hessian 的最大特征值近似为：

$$\lambda_{\max} \approx L \cdot s_0^{2(L-1)} \tag{112}$$

（L 个对角元各为 $s_0^{2(L-1)}$，非对角项在对称初始化下贡献一个 $O(L)$ 的放大。）
稳定性上界：

$$\eta_{\max} = \frac{2}{\lambda_{\max}} = \frac{2}{L \cdot s_0^{2(L-1)}} \tag{113}$$

A.1.2 Warmup 动力学

Warmup 期间用 $\eta_w \le \eta_{\max}$，参数的更新（利用对称性 $w_l = s$ 保持）：

$$s_{t+1} = s_t - \eta_w \cdot (s_t^L - 1) \cdot s_t^{L-1} \tag{114}$$

当 s_t 接近 1 时，$s_t^L - 1 \approx L(s_t - 1)$，$s_t^{L-1} \approx 1$，所以：

$$s_{t+1} - 1 \approx (s_t - 1)(1 - \eta_w L) \tag{115}$$

这是一个收敛因子为 $(1 - \eta_w L)$ 的线性递推。取 $\eta_w = c/(L s_t^{2(L-1)})$（在稳定性边界附近），当 $s_t \approx 1$ 时 $\eta_w \approx c/L$，收敛因子 $\approx 1 - c$。

定义 $u_t = s_t - 1$（偏离量），则 $u_t \approx u_0(1-c)^t$，要求 $u_T < u_{\text{target}}$ 的步数为：

$$T = \frac{\log(u_0/u_{\text{target}})}{\log(1/(1-c))} \approx \frac{1}{c} \log \frac{u_0}{u_{\text{target}}} \tag{116}$$

由于 $\eta_w \approx c/L$，而 $\Delta s/s \sim \eta_w L \sim c$，所以实际上每 $1/c$ 步 s 缩小一个 e 倍。用 L 来表达：

$$\boxed{T_{\text{warmup}}^{\text{scalar}} \sim \frac{L}{c} \cdot \log \frac{s_0 - 1}{s_{\text{target}} - 1} \sim L \cdot \log \frac{s_0}{s_{\text{target}}}} \tag{117}$$

（最后一步在 s_0, s_{target} 接近 1 时，$\log(s_0 - 1)/(s_{\text{target}} - 1) \sim \log s_0/s_{\text{target}}$ 在量级上等价。）

A.2 从标量到矩阵：谱范数替换

A.2.1 对应关系

矩阵网络中，s 的角色由各层权重矩阵的谱范数 $\sigma_l = \|\mathbf{W}_l\|_{\text{op}}$ 扮演。标量模型的所有结论在形式上成立，$s \to \bar{\sigma}$（各层谱范数的几何平均）：

$$\lambda_{\max}^{(\text{来自深度})} \sim L \cdot \bar{\sigma}^{2(L-1)}, \quad T_{\text{warmup}} \sim L \cdot \log \frac{\bar{\sigma}_0}{\bar{\sigma}_{\text{target}}} \tag{118}$$

A.2.2 He 初始化下的谱范数

$\mathbf{W} = \sqrt{2/n}\,\mathbf{Z}$，$Z_{ji} \sim \mathcal{N}(0,1)$ i.i.d.。$n \times n$ 标准高斯矩阵的最大奇异值由 Marchenko-Pastur 律给出：

$$\sigma_{\max}(\mathbf{Z}) = 2\sqrt{n}\left(1 + O(n^{-2/3})\right) \tag{119}$$

因此：

$$\bar{\sigma} = \sqrt{\frac{2}{n}} \cdot 2\sqrt{n}\left(1 + O(n^{-2/3})\right) = 2\sqrt{2}\left(1 + O(n^{-2/3})\right) \approx 2.83 \tag{120}$$

方差保持 vs 谱范数：He 初始化保证 $\mathbb{E}[\|\mathbf{W}\mathbf{h}\|^2] = 2\|\mathbf{h}\|^2$（平均方差保持），但最大方向的放大率是 $\bar{\sigma}^2 \approx 8$。这两者不矛盾——方差是所有方向的平均，谱范数是最大方向。

A.2.3 激活函数和架构的修正

ReLU：置零一半分量，等效地 $\bar{\sigma} \to \bar{\sigma}/\sqrt{2} = 2$。仍然 > 1。

Layer Normalization：将激活范数强制归一化为 $O(\sqrt{n})$。LN 后的等效谱范数：

$$\bar{\sigma}_{\text{LN}} = 1 + O(n^{-2/3}) \tag{121}$$

$O(n^{-2/3})$ 修正的来源：LN 将 $\|\mathbf{h}\|$ 归一化为 $\sqrt{n}$（固定范数），但方向仍保留了矩阵乘法的结构。最大方向的相对放大率由随机矩阵的 Tracy-Widom 波动决定，量级为 $n^{-2/3}$。

残差连接：$\mathbf{h}^{(l+1)} = \mathbf{h}^{(l)} + f_l(\mathbf{h}^{(l)})$，$\|f_l\|_{\text{op}} = \sigma_f$。总谱范数为 $1 + \sigma_f$ 而非 σ_f，将乘法累积变为近似加法。综合 LN 后，$\sigma_f \approx O(n^{-2/3})$，所以 $\bar{\sigma}_{\text{eff}} = 1 + O(n^{-2/3})$。

A.3 矩阵网络中的 $O(n)$ 曲率因子

标量模型的曲率只有”深度”贡献 $L \cdot \bar{\sigma}^{2(L-1)}$。矩阵网络还多了一个”宽度”因子。

A.3.1 单层 Hessian 的 Kronecker 结构

对全连接层 $\mathbf{h} = \mathbf{W}\mathbf{a}$，$\mathbf{W} \in \mathbb{R}^{n\times n}$，损失对 W_{ji} 的梯度为 $\partial L/\partial W_{ji} = \delta_j a_i$。

将 $\mathbf{W}$ 展平为 n^2 维向量，Hessian 近似为 Kronecker 积：

$$\mathbf{H}_W \approx \underbrace{\mathbb{E}[\boldsymbol{\delta}\boldsymbol{\delta}^\top]}_{\mathbf{G}\in\mathbb{R}^{n\times n}} \otimes \underbrace{\mathbb{E}[\mathbf{a}\mathbf{a}^\top]}_{\mathbf{A}\in\mathbb{R}^{n\times n}} \tag{122}$$

Kronecker 积的特征值是两个矩阵特征值的所有两两乘积：

$$\lambda_{\max}(\mathbf{H}_W) = \lambda_{\max}(\mathbf{G}) \cdot \lambda_{\max}(\mathbf{A}) \tag{123}$$

A.3.2 $\lambda_{\max}(\mathbf{A})$ 的分析

He 初始化保持每个分量 $\mathrm{Var}[a_i] = O(1)$。如果各分量近似独立（LN 后近似成立）：

$$\mathbf{A} \approx O(1) \cdot \mathbf{I}_n, \quad \lambda_{\max}(\mathbf{A}) = O(1) \tag{124}$$

A.3.3 $\lambda_{\max}(\mathbf{G})$ 的分析

反向梯度 $\boldsymbol{\delta} \in \mathbb{R}^n$ 同样每个分量 $O(1)$。$\mathbf{G}$ 的结构取决于 loss landscape：

最坏情况（单样本）：$\mathbf{G} = \boldsymbol{\delta}\boldsymbol{\delta}^\top$，秩 1，$\lambda_{\max} = \|\boldsymbol{\delta}\|^2 = O(n)$。

Mini-batch 平均：$\mathbf{G} = \frac{1}{B}\sum_{b=1}^{B} \boldsymbol{\delta}^{(b)}\boldsymbol{\delta}^{(b)\top}$。当 B 足够大且 $\boldsymbol{\delta}$ 的分布接近各向同性时，$\lambda_{\max}(\mathbf{G}) \approx \mathrm{tr}(\mathbf{G})/n = O(1)$。但在训练初期，$\boldsymbol{\delta}$ 的方向高度集中（loss 的曲率集中在少数方向），此时 $\lambda_{\max}(\mathbf{G})$ 可显著大于 $O(1)$。

更直接的论证：不经过 $\mathbf{G} \otimes \mathbf{A}$ 分解，直接看单样本 Hessian 的最大特征值：

$$\lambda_{\max}^{\text{sample}} = \|\boldsymbol{\delta}\|^2 \cdot \|\mathbf{a}\|^2 = O(n) \cdot O(n) = O(n^2) \tag{125}$$

Mini-batch 中 B 个独立样本的 Hessian 平均后，有效秩 $\sim \min(B, n)$。当 $B \gg n$ 时趋于 $\mathrm{tr}(\mathbf{H})/n^2 \sim O(1)$；当 $B \sim O(1)$（小 batch）时接近 $O(n^2)$。实际训练中 B 通常为几百到几千，n 为几千到几万，$B < n$，所以 $\lambda_{\max}$ 介于 $O(n)$ 和 $O(n^2)$ 之间。

取 $\lambda_{\max} = O(n)$ 作为典型量级（这与实验观察一致），得到完整的曲率公式：

$$\lambda_{\max}(\mathbf{H}) \sim n \cdot L \cdot \bar{\sigma}_{\text{eff}}^{2(L-1)} \tag{126}$$

A.4 主定理：$T_{\text{warmup}} \sim L \log n$

A.4.1 合并所有因子

有 LN + 残差时 $\bar{\sigma}_{\text{eff}} = 1 + \epsilon$，$\epsilon = O(n^{-2/3})$。当 $\epsilon L \ll 1$（即 $L \ll n^{2/3}$）：

$$\lambda_{\max} \sim nL \cdot (1+\epsilon)^{2(L-1)} \approx nL \tag{127}$$

A.4.2 目标条件

Warmup 结束条件：$\lambda_{\max} < 2/\eta_{\text{target}}$。写成对 $\bar{\sigma}$ 的约束：

$$nL \cdot \bar{\sigma}_{\text{target}}^{2(L-1)} < \frac{2}{\eta_{\text{target}}} \quad \Rightarrow \quad \bar{\sigma}_{\text{target}}^{2(L-1)} < \frac{2}{nL\eta_{\text{target}}} \tag{128}$$

A.4.3 Warmup 步数

由标量模型的结果 $T \sim L \cdot \log(\bar{\sigma}_0/\bar{\sigma}_{\text{target}})$，我们需要计算 $\log(\bar{\sigma}_0^{2(L-1)}/\bar{\sigma}_{\text{target}}^{2(L-1)})$：

$$\log \frac{\bar{\sigma}_0^{2(L-1)}}{\bar{\sigma}_{\text{target}}^{2(L-1)}} > \log\left(\bar{\sigma}_0^{2(L-1)} \cdot \frac{nL\eta_{\text{target}}}{2}\right) \tag{129}$$

$$= 2(L-1)\log\bar{\sigma}_0 + \log n + \log L + \log\eta_{\text{target}} - \log 2 \tag{130}$$

因此：

$$T_{\text{warmup}} \sim L \cdot \Big[\underbrace{2(L-1)\log\bar{\sigma}_0}_{\text{(I)}} + \underbrace{\log n}_{\text{(II)}} + \underbrace{\log L + \text{const}}_{\text{(III)}}\Big] \tag{131}$$

各项的含义：

- **(I)**：初始谱范数的贡献。有 LN 时 $\bar{\sigma}_0 \approx 1 + O(n^{-2/3})$，$\log\bar{\sigma}_0 \approx O(n^{-2/3})$，所以 (I) $\approx O(L \cdot n^{-2/3})$——对 n 的依赖很弱。无 LN 时 $\bar{\sigma}_0 \approx 2\sqrt{2}$，(I) $\approx 2L\log(2\sqrt{2}) \approx 2L$——与 n 无关但与 L 线性。
- **(II)**：$\log n$。这是宽度对 Warmup 的**主要贡献**。来源：曲率中 $O(n)$ 的前置因子要求 $\bar{\sigma}^{2(L-1)}$ 额外补偿 $1/n$。
- **(III)**：$\log L$ 及常数项。深度的对数修正。

$$\boxed{T_{\text{warmup}} \sim L\log n + L\log L + O(L^2 n^{-2/3})} \tag{132}$$

当 $n \gg L$（典型情况）时，主导项为 $L\log n$。

A.5 数值验证

用上述公式估算几个实际网络的 Warmup 步数（取 $c = 500$ 作为总体常数的拟合值）：

网络	L	n	$L\log_2 n$	公式估算	实际 Warmup
ResNet-50	50	512	450	~ 2000	2000–5000
Transformer-Base	6	512	54	~ 3000	~ 4000
Transformer-Large	24	1024	240	~ 6000	~ 8000
GPT-2 (1.5B)	48	1600	510	~ 8000	~ 5000

量级基本吻合。偏差来自几个简化：(1) 实际网络有注意力机制，不是纯全连接；(2) LN 的效果不是瞬时的，初期 $\bar{\sigma}_0$ 可能偏离我们的近似；(3) Adam 的二阶矩估计需要额外的预热时间（$\sim 1/(1-\beta_2) \approx 1000$ 步）。

A.6 讨论：推导的局限性

1. $O(n)$ **因子的精确系数**：我们只确定了 $\lambda_{\max} = O(nL)$ 的量级关系，精确系数取决于 loss landscape 的结构（$\mathbf{G}$ 的谱分布），无法从简单模型精确确定。

2. **LN 的动态效应**：我们假设 LN 在整个 Warmup 期间保持 $\bar{\sigma}_{\text{eff}} \approx 1$，但训练初期 LN 的统计量（running mean/var）尚未稳定，实际的 $\bar{\sigma}_0$ 可能更大。

3. **Adam 的影响**：Adam 的自适应学习率隐式地为每个参数做了预条件，可能改变"等效 η_w" 的量级。特别是 Adam 的二阶矩估计偏差修正需要 $\sim 1/(1-\beta_2)$ 步才能稳定，这提供了一个与宽度/深度无关的 Warmup 下界。

4. **注意力机制**：Transformer 的自注意力层不是简单的全连接，其 Hessian 结构更复杂。QK 乘积 $\mathbf{QK}^\top/\sqrt{d}$ 引入了额外的非线性和尺度依赖。

尽管如此，$T_{\text{warmup}} \sim L \log n$ 的定性结论——深度线性贡献、宽度对数贡献、$\log n$ 来自曲率中的 $O(n)$ 因子——提供了一个有用的理论框架，至少能解释为什么 Warmup 步数随模型变大而增加。