从范数约束看优化器：SGD → Muon

目录

0 本讲义的主线 **5**

1 一层网络的梯度与 Hessian：一切的起点 **5**

1.1 单层模型 5

1.2 梯度：秩 1 外积 5

1.3 在我们数据上 6

1.4 Hessian：逐元素推到 Kronecker 积 6

1.5 用具体数字看 H_h 7

1.6 H_h 分解与 Gauss-Newton 近似 9

1.7 回到我们的数据 9

1.8 这个结构为什么重要? 10

1.9 从单样本到多样本：秩如何增长 10

1.10 后续使用的矩阵参数例子 11

2 曲率、安全性与进步 **11**

2.1 什么是曲率? 11

2.2 为什么曲率是优化的核心困难? 11

2.3 安全性 vs 进步 12

3 ℓ_2 范数 → GD **12**

3.1 推导 12

3.2 在我们数据上 12

3.3 GD 的根本问题：特征方向的学习率冲突 13
3.4 牛顿法：每方向用最优学习率 13
3.5 手算验证 14
3.6 代价 14

4 动量与权重衰减：在 ℓ_2 范数内的改进 14

4.1 Heavy Ball（Polyak, 1964） 15
4.2 Nesterov 加速梯度（NAG, 1983） 17
4.3 动量的学习率视角 20
4.4 权重衰减（Weight Decay） 21
4.5 权重衰减 + 不同优化器的交互 23
4.6 小结：在 ℓ_2 范数内能走多远 23

5 ℓ_∞ 范数 → SignGD 24

5.1 推导 24
5.2 在我们数据上 24
5.3 几何图示 24
5.4 SignGD 的优势与代价 25
5.5 SignGD ≈ Adam（在二次函数上） 25

6 Adam 的完整分析 25

6.1 算法 25
6.2 Adam = 动量 + SignGD 思想 25
6.3 在我们数据上 25
6.4 为什么 Adam 能用比 SGD 大得多的学习率? 26
6.5 Adam/SignGD 的稳定性精确分析 27
6.6 损失地板（loss floor） 27
6.7 随机梯度下的噪声地板 28
6.8 AdamW：权重衰减创造平衡点 29
6.9 存储代价与近年变体 29

7 预条件路线：从对角到 Kronecker **31**

7.1 统一视角：$\Delta w = -P_t \cdot m_t$ 31

7.2 对角预条件（Adam）的局限 32

7.3 自然梯度：另一种” 曲率” 32

7.4 从自然梯度到 KFAC 35

7.5 KFAC：利用 §1 推导的 Kronecker 结构 35

7.6 在我们数据上验证 KFAC 35

7.7 KFAC 的局限 36

8 从预条件到范数约束：两条路线的汇合 **36**

8.1 Shampoo：预条件路线的终点 36

8.2 $UV^\top$ 也是范数约束路线的结果 36

8.3 参数空间的” 小”$\neq$ 函数空间的” 小” 36

9 诱导范数（Induced Norm） **37**

9.1 定义 37

9.2 $\ell_2 \to \ell_2$ 诱导范数 = 谱范数 37

9.3 用诱导范数做约束 37

10 谱范数约束下的最优更新 $\to UV^\top$ **38**

10.1 准备：矩阵参数的例子 38

10.2 严格推导 38

10.3 在我们例子上 39

10.4 SignGD vs 矩阵 sign 的本质区别 39

11 Shampoo 恒等式：不做 SVD 也能算 $UV^\top$ **40**

11.1 恒等式 40

11.2 前置知识：矩阵函数 40

11.3 逐步证明 40

11.4 在我们例子上逐元素验证 41

11.5 一般幂次 p 42
11.6 从恒等式到实践 42

12 RMS→RMS 诱导范数 **43**
12.1 从 RMS 范数说起 43
12.2 诱导范数的推导 43
12.3 在我们例子上 43
12.4 RMS→RMS 约束下的最优更新 44
12.5 层形状自动进入缩放因子 44

13 Muon = 动量 + Newton-Schulz 正交化 **44**
13.1 Newton-Schulz 迭代 44
13.2 手算 45
13.3 完整算法 45

14 总结 **45**

15 参考文献 **46**

0 本讲义的主线

所有优化器都可以看成在解同一个问题:

$$u = \arg\min_{\|\Delta\theta\|<\eta} \nabla L(\theta)^\top \Delta\theta$$

** 选什么范数 $\|\cdot\|$，就得到什么优化器。**

范数	约束集形状	最优方向	对应优化器
ℓ_2（Frobenius）	超球	$-g/\|g\|_2$	GD
ℓ_∞（逐元素）	超盒	$-\mathrm{sign}(g)$	SignGD / Adam
spectral $\|B\|_2 \le 1$	正交矩阵集	$-UV^\top$	Shampoo / Muon
RMS→RMS induced	缩放后正交集	$-\sqrt{d_{\mathrm{out}}/d_{\mathrm{in}}}\,UV^\top$	Muon (带 muP 缩放)

我们用一个**具体的线性回归**把每个范数约束的含义、最优解、收敛行为全部手算出来。

1 一层网络的梯度与 Hessian：一切的起点

在讨论任何优化器之前，必须先搞清楚：**梯度长什么样？Hessian 长什么样？**它们的结构决定了哪些优化器有效、哪些没用。

1.1 单层模型

$$h = Wx, \quad z = \sigma(h)$$

$x \in \mathbb{R}^d$（输入），$W \in \mathbb{R}^{m\times d}$（权重），$h \in \mathbb{R}^m$（预激活），$z \in \mathbb{R}^m$（激活后输出）。损失 $L(z)$。

1.2 梯度：秩 1 外积

链式法则:

$$\frac{\partial L}{\partial W_{ij}} = \frac{\partial L}{\partial h_i} \cdot \frac{\partial h_i}{\partial W_{ij}} = \delta_i \cdot x_j$$

其中 $\delta = \frac{\partial L}{\partial h} = \frac{\partial L}{\partial z} \odot \sigma'(h) \in \mathbb{R}^m$。

写成矩阵形式:

$$\boxed{\nabla_W L = \delta \cdot x^\top \in \mathbb{R}^{m \times d}}$$

单样本梯度是秩 1 外积：上游梯度 δ（$m \times 1$）$\times$ 输入激活 $x^\top$（$1 \times d$）。

Mini-batch 的梯度 $= \sum_{i=1}^{B} \delta^{(i)} x^{(i)\top}$，** 秩 $\leq B$**。$B = 32$、$\min(m, d) = 768 \to$ 梯度在 768 维空间中只有 32 个方向有信号。

1.3 在我们数据上

取线性回归（$\sigma = \mathrm{id}$，$m = 1$，$d = 2$）：$\hat{y} = w^\top x$，$L = \frac{1}{2}(\hat{y} - y)^2$。

$$X = \begin{pmatrix} 2 & 1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad y = \begin{pmatrix} 5 \\ 1 \\ 2 \end{pmatrix}, \quad w_0 = \begin{pmatrix} -1 \\ 3 \end{pmatrix}$$

单样本梯度（第 1 个样本 $x_1 = (2, 1), y_1 = 5$）:

$$\delta_1 = w_0^\top x_1 - y_1 = (-2 + 3) - 5 = -4, \quad \nabla_w^{(1)} = \delta_1 \cdot x_1 = -4 \cdot \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} -8 \\ -4 \end{pmatrix}$$

秩 1 （向量的" 秩 1" 就是一个方向)。

Full-batch 梯度 $= \sum_{s=1}^{3} \delta_s x_s$，秩 ≤ 2（因为 $d = 2$)。实际计算:

$$g = X^\top (X w_0 - y) = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} -3 \\ 2 \end{pmatrix} = \begin{pmatrix} -11 \\ -2 \end{pmatrix}$$

1.4 Hessian：逐元素推到 Kronecker 积

将 W 向量化为 $\mathrm{vec}(W) \in \mathbb{R}^{md}$。我们逐步推导 $H = \frac{\partial^2 L}{\partial \mathrm{vec}(W)^2}$。

Step 1：已知 $\frac{\partial L}{\partial W_{ij}} = \delta_i x_j$。对 W_{kl} 再求导:

$$\frac{\partial^2 L}{\partial W_{ij} \partial W_{kl}} = \frac{\partial (\delta_i x_j)}{\partial W_{kl}} = \frac{\partial \delta_i}{\partial W_{kl}} \cdot x_j$$

Step 2：$\delta_i = \frac{\partial L}{\partial h_i}$。$h_k = \sum_l W_{kl} x_l$，所以 $\frac{\partial h_k}{\partial W_{kl}} = x_l$。链式法则:

$$\frac{\partial \delta_i}{\partial W_{kl}} = \frac{\partial^2 L}{\partial h_i \partial h_k} \cdot x_l$$

Step 3：代入：

$$\frac{\partial^2 L}{\partial W_{ij} \partial W_{kl}} = \underbrace{\frac{\partial^2 L}{\partial h_i \partial h_k}}_{(H_h)_{ik}} \cdot x_j \cdot x_l$$

Step 4：写成 Kronecker 积——$(H_h)_{ik}$ 是关于输出神经元的索引 (i,k)，$x_j x_l$ 是关于输入特征的索引 (j,l)：

$$\boxed{H = (xx^\top) \otimes H_h}$$

1.5 用具体数字看 H_h

$H_h = \frac{\partial^2 L}{\partial h^2}$ 是损失对预激活 h 的 Hessian。它的大小是 $m \times m$（$m =$ 输出神经元数）。具体长什么样?

例子 A：单输出线性层（我们的线性回归）

$m = 1$，$\sigma = \mathrm{id}$，$L = \frac{1}{2}(h-y)^2$。

$$H_h = \frac{\partial^2 L}{\partial h^2} = \frac{\partial^2}{\partial h^2} \frac{1}{2}(h-y)^2 = 1 \quad \text{（标量）}$$

取第 1 个样本 $x_1 = (2,1)$：

$$H^{(1)} = (x_1 x_1^\top) \otimes 1 = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix}$$

Full-batch 求和：$H = \sum_s (x_s x_s^\top) = X^\top X = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$。**$H_h = 1$ 太简单了，看不出结构。**

例子 B：2 输出 + ReLU（有趣的情况）

$m = 2$，$d = 2$，$W \in \mathbb{R}^{2\times 2}$。$h = Wx$，$z = \mathrm{ReLU}(h)$，$L = \frac{1}{2}\|z-y\|^2$。

取 $W = I_2$，$x = (2,1)^\top$，$y = (1,1)^\top$。则 $h = Wx = (2,1)^\top$。

H_z（损失对 z 的 Hessian）：$L = \frac{1}{2}\|z - y\|^2 \to H_z = \frac{\partial^2 L}{\partial z^2} = I_2$。

$D_{\sigma'}$（ReLU 导数的对角阵）：$h = (2, 1)$，两个都 > 0，所以 $\sigma'(h) = (1, 1)$，$D_{\sigma'} = I_2$。

σ''：ReLU 的二阶导 $= 0$ 处处成立。

$$H_h = D_{\sigma'} H_z D_{\sigma'} + \underbrace{\mathrm{diag}(\frac{\partial L}{\partial z} \odot \sigma'')}_{=0} = I_2 \cdot I_2 \cdot I_2 = I_2$$

完整 Hessian（$\mathrm{vec}(W)$ 有 4 个元素，所以 H 是 4×4）：

$$H = (xx^\top) \otimes H_h = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 4 & 0 & 2 & 0 \\ 0 & 4 & 0 & 2 \\ 2 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \end{pmatrix}$$

Kronecker 积规则：$A \otimes B$ 的第 (i, j) 块 $= A_{ij} \cdot B$。所以左上角 $4 \times I_2 = \mathrm{diag}(4, 4)$，右上角 $2 \times I_2 = \mathrm{diag}(2, 2)$，等等。

现在让第 2 个神经元不活跃：改 $W = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$，$x = (2, 1)^\top$，$h = (2, -1)^\top$。

$\mathrm{ReLU}(-1) = 0$，所以 $\sigma'(h) = (1, 0)$：

$$D_{\sigma'} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

$$H_h = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$$

** 不活跃神经元的行和列被 $D_{\sigma'}$ 直接置零！** H_h 从秩 2 变成了秩 1。

$$H = \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \otimes \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 4 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

整个 4×4 Hessian 秩为 1（只有一行一列非零模式）。**ReLU 的稀疏激活让 Hessian 更加低秩**。

1.6 H_h 分解与 Gauss-Newton 近似

链式法则对 $H_h = \frac{\partial^2 L}{\partial h^2}$ 展开（$z = \sigma(h)$）：

$$H_h = \underbrace{D_{\sigma'} H_z D_{\sigma'}}_{\text{第一项}} + \underbrace{\operatorname{diag}\left(\frac{\partial L}{\partial z} \odot \sigma''(h)\right)}_{\text{二阶项}}$$

什么是 Gauss-Newton（GN）近似? 丢掉第二项，只保留第一项 $D_{\sigma'} H_z D_{\sigma'}$。

这个名字来自非线性最小二乘。考虑 $L = \frac{1}{2}\|r(w)\|^2$（$r$ 是残差向量），完整 Hessian 为：

$$\nabla^2 L = \underbrace{J^\top J}_{\text{GN 项}} + \underbrace{\sum_i r_i \nabla^2 r_i}_{\text{二阶项}}$$

$J = \partial r / \partial w$ 是 Jacobian。GN 近似丢掉第二个求和（它含二阶导 $\nabla^2 r_i$，且乘以残差 r_i——在最优点附近 $r_i \approx 0$，所以很小）。

GN 近似的三个好处：

- **总是半正定**（$J^\top J \succeq 0$），而完整 Hessian 可能不定
- **只需一阶导数**（Jacobian J），不需二阶导
- **线性模型上精确**（$\nabla^2 r_i = 0$，二阶项恒为零）

回到我们的 H_h：第一项 $D_{\sigma'} H_z D_{\sigma'}$ 就是 GN 项（$D_{\sigma'}$ 是激活函数 Jacobian 的对角形式），第二项含 σ''（二阶导）乘以 $\partial L / \partial z$（类比残差 r_i）。

激活函数	σ''	二阶项	结论
恒等	0	0	$H_h = H_z$（精确）
ReLU	0	**精确为 0**	$H_h = D_{\sigma'} H_z D_{\sigma'}$（GN 精确）
Sigmoid/GELU	$\neq 0$	$\propto \frac{\partial L}{\partial z}$，最优点附近 $\to 0$	$H_h \approx$ GN 项（近似）

1.7 回到我们的数据

$$H = \sum_{s=1}^{3} (x_s x_s^\top) \otimes 1 = X^\top X = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$$

特征分解：$H = V \operatorname{diag}(6, 1) V^\top$，$V = \frac{1}{\sqrt{5}} \begin{pmatrix} 2 & -1 \\ 1 & 2 \end{pmatrix}$，$\kappa = 6$。$w^* = (2, 1)^\top$。

1.8 这个结构为什么重要?

$$H = \underbrace{(xx^\top)}_{\text{输入协方差}} \otimes \underbrace{H_h}_{\text{输出曲率}}$$

性质	推论
$xx^\top$ 秩 1（单样本）	$\mathrm{rank}(H) \le \mathrm{rank}(H_h) \to$ **Hessian 极度低秩**
Kronecker 积	$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1} \to$ **KFAC 可行**
输入协方差 $\times$ 输出曲率	两个因子分别可估计 $\to$ **Shampoo 可行**
奇异值分解可分离	左右因子独立正交化 $\to$ **Muon 有意义**

1.9 从单样本到多样本：秩如何增长

上面的 $H = (xx^\top) \otimes H_h$ 是**单样本**的 Hessian。$xx^\top$ 秩 $1 \to H$ 的秩 $\le \mathrm{rank}(H_h) \le m$。对于 md 个参数，这意味着 md 维空间中只有 $\le m$ 个方向有曲率信息——其余方向完全"看不见"。

多样本求和：full-batch 的 Hessian 是各样本 Hessian 的平均:

$$H_{\text{full}} = \frac{1}{N} \sum_{s=1}^{N} (x_s x_s^\top) \otimes H_h^{(s)}$$

如果 $H_h^{(s)}$ 对所有样本相同（如线性回归中 $H_h = 1$），简化为:

$$H_{\text{full}} = \underbrace{\left(\frac{1}{N} \sum_s x_s x_s^\top \right)}_{\text{秩} \le \min(N,d)} \otimes H_h$$

在我们例子上：$N = 3, d = 2 \to \frac{1}{N} X^\top X$ 秩 $\le \min(3,2) = 2$（满秩）。$H_h = 1 \to$ 总 Hessian 秩 $= 2$（填满了参数空间）。

Mini-batch 的情况（B 个样本）:

$$H_B = \frac{1}{B} \sum_{s \in \mathcal{B}} (x_s x_s^\top) \otimes H_h^{(s)}, \quad \mathrm{rank}(H_B) \le B \cdot m$$

样本数	输入协方差的秩	总 Hessian 秩（上界）	含义

1	1	m	只” 看到”1 个输入方向
B（mini-batch）	$\min(B,d)$	$\min(B,d)\cdot m$	看到 B 个方向
N（full-batch）	$\min(N,d)$	$\min(N,d)\cdot m$	看到所有数据方向

梯度也有同样的秩限制：单样本梯度 $G=\delta x^\top$ 秩 1，B 个样本的平均梯度秩 $\le B$。当 $B \ll \min(m,d)$ 时（如 Transformer 中 $B=32, d=768$），梯度矩阵在 768 维空间中只覆盖 32 个方向——这直接影响 Muon 的有效性。

1.10 后续使用的矩阵参数例子

后半部分（§8 起）分析矩阵参数时，我们取 $G\in\mathbb{R}^{3\times 4}$（$d_{\text{out}}=3, d_{\text{in}}=4$），指定 SVD 为 $\sigma=(6,3,1)$，条件数 $\kappa_G=6$——与线性回归的 κ 相同。

2 曲率、安全性与进步

2.1 什么是曲率?

Taylor 展开：

$$L(\theta+\Delta\theta)=L(\theta)+\underbrace{\nabla L(\theta)^\top\Delta\theta}_{\text{一阶：斜率}}+\underbrace{\frac{1}{2}\Delta\theta^\top H\Delta\theta}_{\text{二阶：曲率}}+\cdots$$

梯度 $g=\nabla L$ 告诉你” 哪个方向下降”。**Hessian** $H=\nabla^2 L$ 告诉你” 梯度本身变化有多快”——这就是**曲率**。

一维直觉：$f(x)=\frac{1}{2}\lambda x^2$，$f'=\lambda x$，$f''=\lambda$。$\lambda$ 大 $\to$ 函数弯得厉害 $\to$ 梯度变化快 $\to$ 需要小步长。λ 小 $\to$ 几乎平坦 $\to$ 可以大步走。

多维时不同方向曲率不同——这正是 H 有多个特征值的含义。§1 中我们的 H 有 $\lambda_1=6$（陡方向）和 $\lambda_2=1$（平方向），曲率差 6 倍。

2.2 为什么曲率是优化的核心困难?

如果所有方向曲率相同（$H=\lambda I$，条件数 $\kappa=1$），GD 一步最优——不需要任何高级优化器。

困难完全来自**曲率的不均匀**：$\kappa = \lambda_{\max}/\lambda_{\min}$ 越大，不同方向需要的步长差异越大，全局 η 的折中越差。

$$\text{优化器的全部历史} = \text{应对不同方向曲率不同的历史}$$

2.3 安全性 vs 进步

GD 基于一阶近似来选步。两个矛盾的目标：

- **安全性**：步长足够小，保证线性近似成立（不超出曲率允许的范围）
- **进步**：步长足够大，收敛才快

将此形式化为约束优化（Bernstein & Newhouse 2024）：

$$u = \arg\min_{\|\Delta\theta\|<\eta} \nabla L(\theta)^\top \Delta\theta$$

** 选什么范数 $\|\cdot\|$，就决定了" 小" 的含义，也就决定了优化器。**

3 ℓ_2 范数 $\to$ GD

3.1 推导

$$u = \arg\min_{\|\Delta w\|_2<\eta} g^\top \Delta w$$

约束集是半径 η 的**超球**。Cauchy-Schwarz 不等式：

$$g^\top \Delta w \geq -\|g\|_2\|\Delta w\|_2 \geq -\eta\|g\|_2$$

等号成立当 $\Delta w = -\eta\frac{g}{\|g\|_2}$。

这就是梯度下降（归一化版本）。用 Lagrangian 松弛替代约束，回到经典 GD $\Delta w = -\eta g$。

3.2 在我们数据上

$g_0 = (-11, -2)$，$\|g_0\|_2 = \sqrt{125} \approx 11.18$。

ℓ_2 最优方向 $= -g_0/\|g_0\| = (0.984, 0.179)$。这个方向**完全由梯度幅值最大的分量主导**——$g_1 = -11$ 远大于 $g_2 = -2$，所以更新几乎全在 w_1 方向上。

特征基下的问题：最优全局 $\eta^* = 2/(\lambda_1 + \lambda_2) = 2/7$，收敛率 $r = (\kappa - 1)/(\kappa + 1) = 5/7 \approx 0.714$。

**ℓ_2 范数的问题 **：它不区分参数的" 重要程度"。w_1 方向梯度大不代表该方向需要大步长——可能恰恰相反（该方向曲率大，需要小步长）。ℓ_2 球是各向同性的，不适应非各向同性的损失曲面。

3.3 GD 的根本问题：特征方向的学习率冲突

在特征基 $\tilde{w} = V^\top w$ 下,损失解耦为独立的一维问题,每方向的演化为 $\tilde{e}_{t+1,i} = (1-\eta\lambda_i)\tilde{e}_{t,i}$。

每方向有自己的最优和最大学习率：

方向	λ_i	最优 $\eta_i = 1/\lambda_i$	最大 $\eta_i = 2/\lambda_i$
1（陡）	6	0.167	0.333
2（平）	1	1.000	2.000
差距	6×	6×	6×

GD 只有一个全局 η。最优折中 $\eta^* = 2/7 \approx 0.286$：

- 方向 1：$\eta^*/\eta_1^{\text{opt}} = 0.286/0.167 = 1.71$（偏大 71%→ 振荡）
- 方向 2：$\eta^*/\eta_2^{\text{opt}} = 0.286/1.000 = 0.29$（只有最优的 29%→ 慢）

$\kappa = 10^4$ 时慢方向只用了最优 η 的 0.02%。

3.4 牛顿法：每方向用最优学习率

二阶 Taylor 展开：

$$L(w + \Delta w) \approx L(w) + g^\top \Delta w + \frac{1}{2}\Delta w^\top H \Delta w$$

对 Δw 求导令其为零：$g + H\Delta w = 0$。

$$\Delta w^* = -H^{-1} g$$

在特征基下看清楚：$H = V\text{diag}(\lambda_1, \lambda_2)V^\top$，$H^{-1} = V\text{diag}(1/\lambda_1, 1/\lambda_2)V^\top$。

$$\tilde{e}_{t+1,i} = \tilde{e}_{t,i} - \frac{1}{\lambda_i} \cdot \lambda_i \tilde{e}_{t,i} = 0$$

** 每方向用 $\eta_i = 1/\lambda_i$——方向 1 用 1/6，方向 2 用 1——各取所需，一步全部归零。** H^{-1} 的几何含义：它将椭圆等高线（长轴对应 $\lambda_{\min}$ 方向）" 拉圆"。GD 沿梯度走会被椭圆" 带偏"，牛顿法修正了这个偏差。

3.5 手算验证

$$H^{-1} = \frac{1}{\det(H)} \begin{pmatrix} H_{22} & -H_{12} \\ -H_{21} & H_{11} \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 2 & -2 \\ -2 & 5 \end{pmatrix}$$

$$H^{-1} g_0 = \frac{1}{6} \begin{pmatrix} 2 & -2 \\ -2 & 5 \end{pmatrix} \begin{pmatrix} -11 \\ -2 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} -22+4 \\ 22-10 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} -18 \\ 12 \end{pmatrix} = \begin{pmatrix} -3 \\ 2 \end{pmatrix}$$

$$w_1 = w_0 - \Delta w^* = (-1, 3) - (-3, 2) = (2, 1) = w^* \quad \checkmark$$

对比 GD 的方向:

方法	更新方向	归一化	与 $w^* - w_0 = (3, -2)$ 的夹角
GD	$-g_0 = (11, 2)$	$(0.984, 0.179)$	$\arccos \frac{33-4}{\sqrt{125}\sqrt{13}} \approx 44°$
牛顿	$-H^{-1} g_0 = (3, -2)$	$(0.832, -0.555)$	$0°$（精确指向 w^*）

GD 方向与最优方向差了 44°——因为 $g_0 = He_0$，Hessian 的非对角元素 $H_{12} = 2$ 把方向" 扭偏" 了。牛顿法用 H^{-1} 把这个扭曲反转回来。

3.6 代价

$H^{-1} \in \mathbb{R}^{d \times d}$：存储 $O(d^2)$，求逆 $O(d^3)$。$d = 10^9$ 时不可行。但牛顿法告诉我们目标是什么：**给每方向自己的最优学习率**。接下来的所有方法都在逼近这个目标。

4 动量与权重衰减：在 ℓ_2 范数内的改进

牛顿法不可行，换范数的方案留到 §5。有没有不换范数、不算 H^{-1}、只修改迭代动力学就能加速的办法?

4.1 Heavy Ball（Polyak, 1964）

$$v_t = \mu v_{t-1} + g_t, \quad w_{t+1} = w_t - \eta v_t$$

v_t 累积了历史梯度。物理直觉：球在损失曲面上滚动，μ 是惯性。

特征基下第 i 方向满足二阶递推：

$$\tilde{e}_{t+1,i} = (1 + \mu - \eta\lambda_i)\tilde{e}_{t,i} - \mu\tilde{e}_{t-1,i}$$

特征方程 $z^2 - (1 + \mu - \eta\lambda_i)z + \mu = 0$，令 $a_i = 1 + \mu - \eta\lambda_i$：

$$z_\pm = \frac{a_i \pm \sqrt{a_i^2 - 4\mu}}{2}$$

GD 的稳定性（复习）

$\mu = 0$ 时退化为一阶：$z = 1 - \eta\lambda_i$。稳定条件 $|z| < 1$，即 $0 < \eta\lambda_i < 2$。

方向 1（$\lambda_1 = 6$）：$\eta < 2/6 = 0.333$。** 全局最大 η 被最大特征值卡死。**

Heavy Ball 的稳定性：两种 regime

实数根 regime（$a_i^2 > 4\mu$，即 $\eta\lambda_i$ 很小或很大）：$|z_+|$ 和 $|z_-|$ 分别控制。稳定条件仍然受 $\eta\lambda_i$ 约束。

复数根 regime（$a_i^2 < 4\mu$）：$z_\pm$ 是共轭复数，$|z_+| = |z_-| = \sqrt{\mu}$。

关键：复数根时衰减率 $= \sqrt{\mu}$，** 完全不取决于 $\eta\lambda_i$ 的值 **——只要它落在复数根区域内。

复数根条件：$a_i^2 < 4\mu$，展开后：

$$(1 - \sqrt{\mu})^2 < \eta\lambda_i < (1 + \sqrt{\mu})^2$$

这是一个 ** 关于 $\eta\lambda_i$ 的区间 **。令所有方向都在区间内：

$$\eta\lambda_{\min} > (1 - \sqrt{\mu})^2, \quad \eta\lambda_{\max} < (1 + \sqrt{\mu})^2$$

第二个不等式给出**最大学习率**：

$$\eta_{\text{HB}}^{\max} = \frac{(1+\sqrt{\mu})^2}{\lambda_{\max}}$$

在我们数据上对比

	GD ($\mu = 0$)	HB ($\mu = 0.176$, $\sqrt{\mu} = 0.420$)
最大 η 的公式	$2/\lambda_1$	$(1+\sqrt{\mu})^2/\lambda_1$
最大 η 的值	$2/6 = 0.333$	$(1.420)^2/6 = 0.336$
最优 η 的值	$2/7 = 0.286$	0.336（恰好在边界上）

HB 的最优 $\eta = 0.336$ 超过了 GD 的最大 $\eta = 0.333$。 GD 在 0.336 会发散（方向 1 的 $|1 - 0.336 \times 6| = |1 - 2.016| = 1.016 > 1$），但 HB 不会——因为方向 1 进入了复数根 regime，$|z_\pm| = \sqrt{0.176} = 0.420 < 1$。

物理图像：振荡变成了阻尼振荡

GD 在 $\eta = 0.336$ 时，方向 1 的 $1 - \eta\lambda_1 = 1 - 2.016 = -1.016$，**振幅每步放大 1.6%** $\rightarrow$ 发散。

HB 同样 $\eta = 0.336$, 方向 1 的 $a_1 = 1 + 0.176 - 2.016 = -0.840$。$a_1^2 = 0.706 < 4\mu = 0.704...$ 刚好在边界上，$|z_\pm| = \sqrt{0.176} = 0.420$。

GD 的硬振荡（$z = -1.016$，每步放大）变成了 HB 的阻尼振荡（$|z| = 0.420$，每步衰减 58%）。 动量把陡方向的能量”吸收”了，而不是让它越振越大。

最优参数：为什么恰好在边界?

复数根区域内, **所有方向的衰减率都是** $\sqrt{\mu}$——与 $\eta\lambda_i$ 的具体值无关。所以收敛率 $= \sqrt{\mu}$。

我们想让 $\sqrt{\mu}$ 尽量小（收敛快）。但 μ 越小，复数根区间 $(1-\sqrt{\mu})^2 < \eta\lambda < (1+\sqrt{\mu})^2$ 越窄。如果窄到装不下 $[\eta\lambda_{\min}, \eta\lambda_{\max}]$，就有方向掉到实数根区域——实数根的衰减率可能比 $\sqrt{\mu}$ 更差。

所以最优策略：选最小的 μ 使得所有方向**刚好都在复数根区域内**。”刚好”就是边界：

$$\eta\lambda_{\min} = (1-\sqrt{\mu})^2, \quad \eta\lambda_{\max} = (1+\sqrt{\mu})^2$$

两式相除消去 η：$\kappa = (1+\sqrt{\mu})^2/(1-\sqrt{\mu})^2$，解出 $\sqrt{\kappa} = (1+\sqrt{\mu})/(1-\sqrt{\mu})$，

$$\boxed{\sqrt{\mu^*} = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}}$$

代回：$\eta^* = (1+\sqrt{\mu^*})^2/\lambda_{\max}$。

如果 μ 取大了呢?

在我们数据上（$\kappa = 6$）对比不同 μ：

μ	$\sqrt{\mu}$	复数根区间 $(\eta\lambda)$	能容纳 $\kappa = 6$?	收敛率
0.05	0.224	$[0.60, 1.50]$（比值 2.5）	×（太窄）	> 0.5
0.176	**0.420**	$[0.34, 2.02]$（比值 ≈ 6）	✓（刚好）	**0.420**
0.3	0.548	$[0.20, 2.40]$（比值 11.8）	✓（富余）	0.548
0.5	0.707	$[0.09, 2.91]$（富余很多）	✓	0.707（≈GD）
0.9	0.949	$[0.003, 3.80]$	✓	0.949

$\mu = 0.176$ 恰好让区间宽度比等于 $\kappa = 6$。更小装不下，更大则 $\sqrt{\mu}$ 比必要的大（浪费）。$\mu = 0.5$ 时收敛率 $0.707 \approx$ GD 的 0.714——动量白加了。

$\kappa = 6$：$\sqrt{\mu^*} \approx 0.420$，$\mu^* \approx 0.176$，$\eta^* = (1.420)^2/6 \approx 0.336$。

	GD	Heavy Ball
最优 η	0.286	0.336
最大 η	0.333	0.336（最优恰在边界）
收敛率 r	0.714	0.420
步数到 10^{-6}	~ 41	~ 16

总结：最优 μ 使复数根区间**刚好装下** $[\lambda_{\min}, \lambda_{\max}]$——刚好就是最小的 $\sqrt{\mu}$，收敛最快。

4.2 Nesterov 加速梯度（NAG, 1983）

$$v_t = \mu v_{t-1} + \nabla L(w_t + \mu(w_t - w_{t-1}))$$

$$w_{t+1} = w_t - \eta v_t$$

与 Heavy Ball 的区别：**先 look ahead**（在预测位置 $w_t + \mu(w_t - w_{t-1})$ 计算梯度），再更新。

在我们数据上逐步对比

取 $\eta = 0.336$，$\mu = 0.176$（HB 的最优参数），$w_0 = (-1, 3)$，$v_{-1} = 0$，$w_{-1} = w_0$。

第 0 步（两者相同，因为还没有动量历史）：

$g_0 = H(w_0 - w^*) = (-11, -2)$。

HB：$v_0 = g_0 = (-11, -2)$，$w_1 = w_0 - 0.336 \cdot (-11, -2) = (-1+3.70,\ 3+0.67) = (2.70, 3.67)$。

NAG：look-ahead 位置 $= w_0 + \mu(w_0 - w_0) = w_0$（还没有历史），$v_0$ 和 w_1 与 HB 相同。

第 1 步（差异出现）：

$e_1 = w_1 - w^* = (0.70, 2.67)$。$g_1 = He_1 = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} 0.70 \\ 2.67 \end{pmatrix} = \begin{pmatrix} 8.84 \\ 6.74 \end{pmatrix}$。

HB：在当前位置 w_1 计算梯度。$v_1 = 0.176 \cdot (-11, -2) + (8.84, 6.74) = (-1.94 + 8.84,\ -0.35 + 6.74) = (6.90, 6.39)$。

$w_2 = w_1 - 0.336 \cdot (6.90, 6.39) = (2.70 - 2.32,\ 3.67 - 2.15) = (0.38, 1.52)$。

NAG：先 look ahead 到 $w_1^{\text{ahead}} = w_1 + \mu(w_1 - w_0) = (2.70, 3.67) + 0.176 \cdot (3.70, 0.67) = (3.35, 3.79)$。

在 w_1^{ahead} 计算梯度：$g_1^{\text{ahead}} = H(w_1^{\text{ahead}} - w^*) = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} 1.35 \\ 2.79 \end{pmatrix} = \begin{pmatrix} 12.33 \\ 8.28 \end{pmatrix}$。

look-ahead 位置的梯度**更大**——因为它探测到了前方更远处的曲率信息。这让 NAG 的 v_1 更大，导致更强的修正。

$v_1 = 0.176 \cdot (-11, -2) + (12.33, 8.28) = (10.39, 7.93)$。

$w_2 = w_1 - 0.336 \cdot (10.39, 7.93) = (2.70 - 3.49,\ 3.67 - 2.66) = (-0.79, 1.01)$。

	HB w_2	NAG w_2	w^*
w_1	0.38	-0.79	2
w_2	1.52	1.01	1
$\|w_2 - w^*\|$	1.68	2.82	0

第 1 步 NAG 的修正更猛——它" 看到了" 前方更陡的梯度。在二次函数上这不一定更好（HB 在这一步更接近 w^*）。**NAG 的优势在非二次情况**：如果前方曲率突然变化（如碰到鞍点、悬崖），look-ahead 提前预警，而 HB 要等碰到了才反应。

在二次函数上，两者的最优收敛率相同——$r^* = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1) = 0.420$。差异在于到达稳态的前几步的瞬态行为。

Nesterov 下界的证明思路

定理（Nesterov, 1983）：对于 κ-条件数的二次问题，任何只用一阶导数的方法，t 步后的最坏情况误差满足：

$$\frac{\|w_t - w^*\|_H}{\|w_0 - w^*\|_H} \geq 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^t$$

（其中 $\|e\|_H = \sqrt{e^\top He}$ 是 H-范数。）等价地，收敛率 $r \geq (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$。

证明分两步：

Step 1：一阶方法的迭代必须在 Krylov 子空间中

任何一阶方法的第 t 步迭代只能用到 $g_0, g_1, \ldots, g_{t-1}$。对于二次函数 $g_k = He_k = H(w_k - w^*)$。

如果 w_k 只依赖 w_0 和 $g_0, \ldots, g_{k-1}$，则归纳可知：

$$w_t - w_0 \in \operatorname{span}(g_0, Hg_0, H^2 g_0, \ldots, H^{t-1} g_0) \equiv \mathcal{K}_t(H, g_0)$$

这叫 **Krylov 子空间**。不管怎么选动量系数和学习率，w_t 都被锁在 $w_0 + \mathcal{K}_t$ 里。

误差 $e_t = w_t - w^*$ 的形式：$e_t = e_0 - \sum_{k=0}^{t-1} c_k H^k g_0 = e_0 - \sum_k c_k H^{k+1} e_0 = p_t(H) e_0$。

其中 p_t 是 t 次多项式，满足 $p_t(0) = 1$（因为 $t = 0$ 时没有更新，$e_0 = e_0$）。

Step 2：在 Hessian 的特征基下，问题归结为多项式逼近

设 H 的特征值为 $\lambda_1, \ldots, \lambda_d$，$e_0$ 在特征基下的分量为 $\tilde{e}_{0,i}$。

$$\|e_t\|_H^2 = \sum_i \lambda_i |p_t(\lambda_i)|^2 \tilde{e}_{0,i}^2$$

要使这个量尽量小，需要 $p_t(\lambda_i)$ 对所有 i 都尽量小——也就是找一个 t 次多项式 p_t，满足 $p_t(0) = 1$，在 $[\lambda_{\min}, \lambda_{\max}]$ 上尽量接近零。

这是经典的 **Chebyshev 多项式逼近问题**。

最优多项式是平移缩放后的 Chebyshev 多项式 T_t:

$$p_t^*(\lambda) = \frac{T_t\left(\frac{\lambda_{\max}+\lambda_{\min}-2\lambda}{\lambda_{\max}-\lambda_{\min}}\right)}{T_t\left(\frac{\lambda_{\max}+\lambda_{\min}}{\lambda_{\max}-\lambda_{\min}}\right)}$$

T_t 在 $[-1,1]$ 上的最大值为 1，在 $[-1,1]$ 外增长极快。$p_t^*(0) = 1$ 。

Chebyshev 多项式在分母处的值:

$$T_t\left(\frac{\kappa+1}{\kappa-1}\right) \geq \frac{1}{2}\left(\frac{\sqrt{\kappa}+1}{\sqrt{\kappa}-1}\right)^t$$

(用 $T_t(x) = \cosh(t \operatorname{arccosh}(x))$ 对 $x > 1$ 的估计。)

因此，在 $[\lambda_{\min}, \lambda_{\max}]$ 上满足 $p_t(0) = 1$ 的 t 次多项式的最小最大值为:

$$\min_{p_t:\, p_t(0)=1} \max_{\lambda\in[\lambda_{\min},\lambda_{\max}]} |p_t(\lambda)| = \frac{1}{T_t\left(\frac{\kappa+1}{\kappa-1}\right)} \leq 2\left(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\right)^t$$

** 任何一阶方法都不可能比这更好——因为它的误差多项式也必须满足 $p_t(0) = 1$。**

Step 3：构造最坏情况

取 d 维三对角矩阵（特征值等间距分布在 $[\lambda_{\min}, \lambda_{\max}]$），$e_0 = (1, 0, \ldots, 0)^\top$。此时 Krylov 子空间 $\mathcal{K}_t$ 只有前 t 个坐标非零——第 t 步完全不知道第 $t+1, \ldots, d$ 方向的信息。误差恰好等于 Chebyshev 下界。□

在我们例子上（$\kappa = 6$, $d = 2$）:

$T_1(x) = x$，下界 $= 2 \cdot \frac{7/5}{7/5} \cdot (\frac{\sqrt{6}-1}{\sqrt{6}+1})^1$... 实际上 $d = 2$ 时一步就能跑完整个 Krylov 空间（$\mathcal{K}_2 = \mathbb{R}^2$），所以下界很松。** 下界在 $d \gg t$ 时才紧 **——高维问题中前 t 步只能探索到 t 个方向，剩下的完全未知。

这正是高维优化困难的本质：**维度是敌人，不是因为每方向的计算变贵了，而是因为前几步的信息不足以覆盖所有方向**。

NAG 达到了这个下界——它是 ℓ_2 范数下一阶方法的**理论极限**。

4.3 动量的学习率视角

动量 ** 没有给不同方向不同的 η**。它改变的是动力学:

$$\text{GD}: r = \frac{\kappa-1}{\kappa+1} \xrightarrow{\text{动量}} r = \frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}$$

κ	GD 步数	HB/NAG 步数	加速比
6	41	16	2.6×
100	690	70	10×
10^4	~ 69000	~ 690	100×

κ 越大加速越显著。但 r 仍然依赖 κ——椭圆还是那个椭圆，只是球在上面滚得更聪明了。

** 要从根本上消除 κ 的影响，必须改变坐标系（预条件）或改变范数。**

4.4 权重衰减（Weight Decay）

$$w_{t+1} = (1-\lambda)w_t - \eta g_t$$

等价于在损失函数中加 $\frac{\lambda}{2\eta}\|w\|^2$（L2 正则）。记 $\alpha = \lambda/\eta$（正则强度）。

特征基下的精确解

正则化后的最优点不再是 w^*，而是：

$$\tilde{w}_i^{\text{reg}} = \frac{\lambda_i}{\lambda_i + \alpha}\,\tilde{w}_i^*$$

每方向都被**向零收缩**，收缩因子 $= \lambda_i/(\lambda_i+\alpha)$。曲率大的方向（$\lambda_i$ 大）收缩少，曲率小的方向（λ_i 小）收缩多。

偏差（Bias）

$$\text{bias}_i = |\tilde{w}_i^{\text{reg}} - \tilde{w}_i^*| = \frac{\alpha}{\lambda_i+\alpha}|\tilde{w}_i^*|$$

小 λ_i 方向偏差大——正则化把” 平坦方向” 上的参数往零拉了很多。

方差（Variance）

SGD 的随机梯度引入噪声。在方向 i 上，稳态方差 $\propto \eta/(\lambda_i+\alpha)$。

没有正则化时（$\alpha = 0$）：方差 $\propto \eta/\lambda_i$——**小 λ_i 方向方差大**。加正则化后：分母从 λ_i 变成 $\lambda_i + \alpha$——**小 λ_i 方向方差大幅降低**。

偏差-方差折衷

$$\mathrm{MSE}_i = \mathrm{bias}_i^2 + \mathrm{var}_i = \left(\frac{\alpha}{\lambda_i + \alpha}\right)^2 |\tilde{w}_i^*|^2 + c\,\frac{\eta}{\lambda_i + \alpha}$$

在我们数据上（$w^* = (2, 1)$，特征基下 $\tilde{w}^* = V^\top w^* = (\sqrt{5}, 0)$）：

方向	λ_i	$\tilde{w}_i^*$	$\alpha = 0$: bias/var	$\alpha = 1$: bias/var
1（陡）	6	$\sqrt{5}$	0 / $\eta/6$	0.32 / $\eta/7$
2（平）	1	0	0 / η	0 / $\eta/2$

方向 1：$\alpha = 1$ 引入偏差 0.32，但方差从 $\eta/6$ 降到 $\eta/7$（改善 17%）。方向 2：$\tilde{w}_2^* = 0$ 偏差始终为零，方差从 η 降到 $\eta/2$（**降了一半**）。

方差大的方向（小 λ_i）获益最多，偏差大的方向（小 λ_i 且 $\tilde{w}_i^* \neq 0$）代价也最多。

有效条件数

权重衰减改变了有效特征值 $\lambda_i \to \lambda_i + \alpha$：

$$\kappa_{\mathrm{eff}} = \frac{\lambda_{\max} + \alpha}{\lambda_{\min} + \alpha}$$

α	κ_{eff}	偏差	方差	收敛
0	$6/1 = 6$	零	大	慢
0.035	5.83	极小	略降	略快
1	$7/2 = 3.5$	中等	大幅降低	快
5	$11/6 = 1.83$	大	极低	极快
$\to \infty$	$\to 1$	$\to w^*$（全错）	$\to 0$	一步（但去错地方）

$\alpha \to \infty$ **时 $\kappa_{\mathrm{eff}} \to 1$——条件数完美，但解收敛到零而非 w^***。正则化的极限：可以让优化问题变得任意好条件，但代价是目标函数已经不是你原来想解的。

4.5 权重衰减 + 不同优化器的交互

关键问题：权重衰减是加在梯度里（$g + \lambda w$）还是直接作用在参数上（$(1-\lambda)w$）?

SGD：两者等价。$w_{t+1} = w_t - \eta(g_t + \frac{\lambda}{\eta} w_t) = (1-\lambda)w_t - \eta g_t$。

Adam：**不等价！**如果加到梯度里：$\hat{g} = g + \frac{\lambda}{\eta} w$，$\hat{v}_t$ 会包含 w 的平方项——λ 和 η 通过 v_t 耦合，调一个会影响另一个。

AdamW（解耦版）：直接在参数上做衰减，不进入 Adam 的动量和二阶矩：

$$w_{t+1} = (1-\lambda')w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

在我们数据上的 AdamW 平衡点（§5 已分析）：$|e_{\text{eq}}| = \eta/\lambda'$，与 λ_i 无关——Adam 的归一化掉了 Hessian 信息，权重衰减的效果也变成各向同性的。

4.6 小结：在 ℓ_2 范数内能走多远

方法	修改了什么	收敛率	还差什么
GD	—	$(\kappa-1)/(\kappa+1)$	被 κ 限死
+ 动量	动力学	$(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$	仍依赖 κ
+ 权重衰减	有效 κ	$(\kappa_{\text{eff}}-1)/(\kappa_{\text{eff}}+1)$	引入偏差

** 一阶方法在 ℓ_2 范数下的理论极限就是 $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$（Nesterov 下界）。** 要突破它，需要：

1. 预条件（近似 H^{-1}）→ §6 的路线
2. 换范数（重新定义" 安全"）→ §5 开始的路线

从此开始, 优化器设计分为两条路线: - **预条件路线**: 用可算的 P 近似 H^{-1}（AdaGrad → Adam → KFAC → Shampoo）- **范数约束路线**：换一个更好的范数定义" 安全步长"（ℓ_∞ → 谱范数 → RMS→RMS）
两条路线在 Shampoo/Muon 处汇合：$UV^\top$ 既是 Shampoo 预条件的极限，又是谱范数约束下的最优解。

5 ℓ_∞ 范数 $\to$ SignGD

5.1 推导

$$u = \arg\min_{\|\Delta w\|_\infty < \eta} g^\top \Delta w$$

约束集是边长 2η 的**超盒**（ℓ_∞ 球）。

$g^\top \Delta w = \sum_j g_j \Delta w_j$。每个 $|\Delta w_j| \le \eta$。为使总和最小，每个分量独立取最优：

$$\Delta w_j^* = -\eta \cdot \mathrm{sign}(g_j)$$

这就是 SignGD：每个参数走 $\pm\eta$，步长相同，只看方向不看大小。

5.2 在我们数据上

$g_0 = (-11, -2)$。

ℓ_∞ 最优方向 $= -\mathrm{sign}(g_0) = (+1, +1)$。

** 对比 ℓ_2**：ℓ_2 给出方向 $(0.984, 0.179)$——几乎全在 w_1 方向。ℓ_∞ 给出方向 $(1,1)/\sqrt{2} = (0.707, 0.707)$——两个方向**等权**。

5.3 几何图示

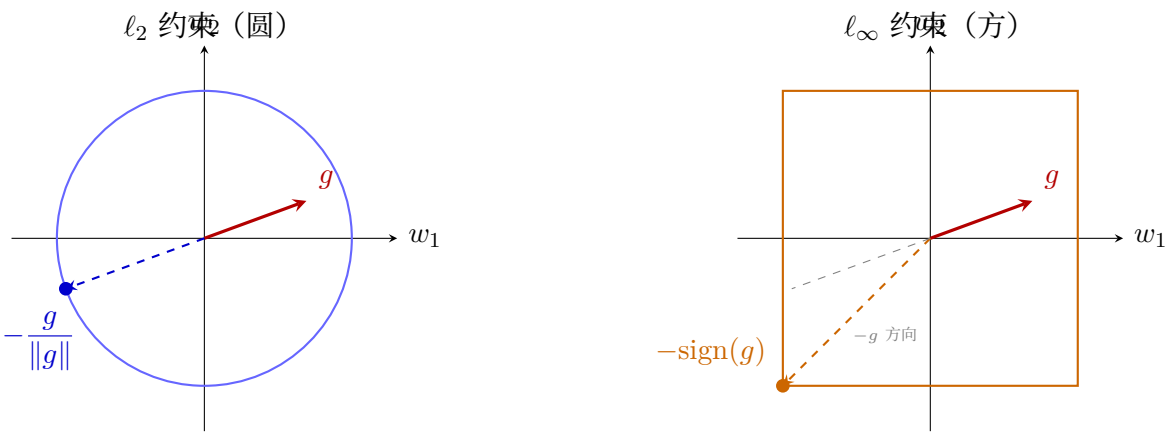

ℓ_2 球上最优点沿 $-g$ 方向碰到边界。ℓ_∞ 盒上最优点在角 $(-\eta, -\eta)$——偏离了 $-g$ 方向，因为方框的角比边能" 走更远"。右图中灰色虚线标出了 $-g$ 方向作为对比。

ℓ_2 球上的最优点在 $-g$ 方向（沿梯度）。ℓ_∞ 盒上的最优点在**角上**（每个坐标推到极限 $=$ sign）。

5.4 SignGD 的优势与代价

优势：每个参数方向步长相同 $= \eta$。如果 g_1 很大但方向 1 的曲率也大（需要小步长），g_2 很小但方向 2 的曲率小（需要大步长），那么 ℓ_∞ 自动**抹平了梯度幅值的差异**，一定程度上缓解了条件数问题。

代价：在最优点附近，g_j 很小时 sign 会频繁翻转 $\to$ 振荡/弹跳。需要学习率衰减。

5.5 SignGD $\approx$ Adam（在二次函数上）

Adam 的更新 $\Delta w_j = -\eta \frac{\hat{m}_j}{\sqrt{\hat{v}_j}+\epsilon}$。当动量 EMA 稳定后，$\hat{m}_j \approx g_j$，$\hat{v}_j \approx g_j^2$：

$$\Delta w_j \approx -\eta \frac{g_j}{\sqrt{g_j^2}+\epsilon} = -\eta \cdot \mathrm{sign}(g_j) \cdot \frac{1}{1+\epsilon/|g_j|}$$

当 $\epsilon \to 0$，$\Delta w_j \to -\eta \cdot \mathrm{sign}(g_j)$。**Adam 在二次函数上退化为 SignGD**。

6 Adam 的完整分析

6.1 算法

两个 EMA：一阶矩 $m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$，二阶矩 $v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$。

偏差修正：$\hat{m}_t = m_t/(1-\beta_1^t)$，$\hat{v}_t = v_t/(1-\beta_2^t)$。

更新：$w_{t+1} = w_t - \eta \hat{m}_t/(\sqrt{\hat{v}_t}+\epsilon)$。

6.2 Adam = 动量 + SignGD 思想

- $\hat{m}_t$：梯度的 EMA $\to$ 动量（平滑轨迹）
- $\hat{v}_t$：梯度平方的 EMA $\to$ 逐参数归一化（SignGD 精神）
- 两者结合：先用动量降噪，再用二阶矩归一化

$\beta_1 = 0.9$（一阶矩少平均）vs $\beta_2 = 0.999$（二阶矩多平均）。这意味着**方向信息（一阶矩）变化快，尺度信息（二阶矩）变化慢**——合理，因为梯度方向随 mini-batch 波动大，但各参数的" 尺度" 是相对稳定的。

6.3 在我们数据上

$g_0 = (-11, -2)$。经偏差修正后第一步 $\hat{m}_0 = (-11, -2)$，$\hat{v}_0 = (121, 4)$：

$$\Delta w = -\eta \frac{(-11,-2)}{(\sqrt{121},\sqrt{4})+\epsilon} = -\eta \frac{(-11,-2)}{(11,2)} = \eta(1,1)$$

两方向步长完全相同——这就是 SignGD 行为。

6.4 为什么 Adam 能用比 SGD 大得多的学习率?

这是实践中最重要的区别之一。我们用数据精确分析。

SGD 的最大学习率受 Hessian 最大特征值约束:

$$\eta_{\text{SGD}}^{\max} = \frac{2}{\lambda_{\max}} = \frac{2}{6} = 0.333$$

超过这个值，$\lambda_1 = 6$ 方向上的缩减因子 $|1-\eta\cdot 6| > 1 \to$ 发散。

Adam 的有效更新是 $\Delta w_j \approx -\eta \cdot \text{sign}(g_j)$。每步每参数的变化量恒为 η——**与梯度大小无关，与 Hessian 特征值无关**。

在我们的例子上对比同一个 $\eta = 0.5$:

	SGD	Adam
更新	$\Delta w = -0.5 \times (-11,-2) = (5.5, 1.0)$	$\Delta w \approx -0.5 \times \text{sign}(-11,-2) = (0.5, 0.5)$
w_1 方向变化量	5.5（巨大）	0.5（温和）
$\eta = 0.5$ 是否稳定?	**发散**（> 0.333）	**稳定**

SGD 在 $\eta = 0.5$ 时，w_1 方向一步走了 5.5——远超最优点距离 $|w_1 - w_1^*| = 3$，严重过冲。Adam 走了 0.5，温和得多。

根本原因: SGD 的步长 $= \eta|g_j|$，$|g_1| = 11$ 放大了步长。Adam 的步长 $= \eta$，$|g_1|$ 被归一化掉了。

数值验证:

η	SGD 能否收敛	Adam 能否收敛
0.1	✓ 慢	✓
0.3	✓ 接近最快	✓
0.5	× **发散**	✓
1.0	×	✓

3.0	×	✓ 慢（振荡）

Adam 的可用 η 范围比 SGD 宽一个数量级。这就是实践中 Adam" 好调" 的核心原因——**$\lambda_{\max}$ 不再是瓶颈 **。

代价：Adam 把所有方向的有效步长拉平到 η，丢失了梯度幅值信息。在方向 2（$\lambda_2 = 1$）上，SGD 用 $\eta = 0.3$ 时有效步长 $0.3 \times 2 = 0.6$，接近最优的 1；Adam 也只有 0.5——**没有更快，只是更安全**。

6.5 Adam/SignGD 的稳定性精确分析

SGD 的最大 η 来自 $|1 - \eta\lambda_{\max}| < 1$。Adam 呢?

在特征基下分析（先假设 H 对角，使 sign 沿特征方向操作）。第 i 方向：

$$\tilde{e}_{t+1,i} = \tilde{e}_{t,i} - \eta\,\mathrm{sign}(\lambda_i\,\tilde{e}_{t,i}) = \tilde{e}_{t,i} - \eta\,\mathrm{sign}(\tilde{e}_{t,i})$$

注意 $\lambda_i > 0$ 不影响 sign。这是一个**定步长趋零迭代**，每步误差减少恒定量 η：

- $|\tilde{e}| > \eta$：$|\tilde{e}_{t+1}| = |\tilde{e}_t| - \eta$（线性下降，总在接近 0）
- $|\tilde{e}| = \eta$：$\tilde{e}_{t+1} = 0$（恰好到达）
- $0 < |\tilde{e}| < \eta$：$|\tilde{e}_{t+1}| = \eta - |\tilde{e}_t|$（**过冲！**跳到另一侧）

** 关键结论：$|\tilde{e}|$ 永远不会超过 η。** 一旦进入 $(-\eta, \eta)$ 区间就在里面振荡。

$$\boxed{\text{Adam/SignGD 在确定性二次函数上无条件稳定——没有最大}\eta\text{的限制}}$$

对比 SGD：$\eta > 2/\lambda_{\max} = 1/3$ 就发散。Adam 的 $\eta = 100$ 都不会发散——只是收敛到的精度差。

6.6 损失地板（loss floor）

Adam 在每个方向上的稳态误差 $|\tilde{e}_{\infty,i}| \le \eta$。损失地板：

$$L_{\text{floor}} = \frac{1}{2}\sum_i \lambda_i\,\tilde{e}_{\infty,i}^2 \le \frac{\eta^2}{2}\sum_i \lambda_i = \frac{\eta^2}{2}\,\mathrm{tr}(H)$$

在我们数据上：$\mathrm{tr}(H) = \lambda_1 + \lambda_2 = 6 + 1 = 7$。

η	SGD 状态	Adam 损失地板 $\leq \eta^2 \cdot 7/2$
0.01	收敛极慢	3.5×10^{-4}
0.1	收敛中	0.035
0.3	接近最优	0.315
1.0	**发散**	3.5（很粗糙）
10	发散	350（没有意义）

Adam 的 η 越大，到达地板越快，但地板越高。 这就是为什么实践中需要学习率衰减——先用大 η 快速下降，再用小 η 降低地板。

SGD 没有这个问题：$\eta < 2/\lambda_{\max}$ 时可以指数收敛到精确最优点（$L_{\text{floor}} = 0$）。

6.7 随机梯度下的噪声地板

实际中用 mini-batch 梯度 $\hat{g} = g + \xi$，ξ 是零均值噪声。

SGD 的噪声地板：在 $\eta < 2/\lambda_{\max}$ 时，SGD 收敛到一个噪声驱动的稳态。稳态损失：

$$L_{\text{SGD}}^{\text{floor}} \approx \frac{\eta}{2} \operatorname{tr}(H\Sigma_\xi) \approx \frac{\eta}{2B} \operatorname{tr}(H\Sigma_g)$$

其中 Σ_g 是单样本梯度协方差，B 是 batch size。** 与 η 线性关系。**

Adam 的噪声地板：当 $|g_j| \lesssim |\xi_j|$（信号被噪声淹没）时，$\operatorname{sign}(\hat{g}_j)$ 约一半时间取错方向——等效于随机走步。

对于方向 i，噪声主导的条件：$|\lambda_i \tilde{e}_i| \lesssim \sigma_{\xi,i}$，即 $|\tilde{e}_i| \lesssim \sigma_{\xi,i}/\lambda_i$。

此时该方向的误差被噪声锁定在 $O(\sigma_\xi/\lambda_i)$ 量级，对应损失贡献：

$$L_{\text{Adam},i}^{\text{floor}} \sim \frac{1}{2}\lambda_i \left(\frac{\sigma_{\xi,i}}{\lambda_i}\right)^2 = \frac{\sigma_{\xi,i}^2}{2\lambda_i}$$

总噪声地板：

$$L_{\text{Adam}}^{\text{floor}} \sim \sum_i \frac{\sigma_{\xi,i}^2}{2\lambda_i}$$

注意这**不依赖** η（只要 η 大到能到达这个区域）。确定性地板（SignGD 振荡）和噪声地板**同时存在，是叠加关系**：

$$L_{\text{floor}} = \frac{\eta^2}{2}\text{tr}(H) + \sum_i \frac{\sigma_{\xi,i}^2}{2\lambda_i}$$

在我们数据上（假设 $\sigma_\xi = 1$，即梯度噪声标准差为 1）：

地板来源	公式	数值
确定性（SignGD 振荡）	$\eta^2 \cdot 7/2$	$3.5\eta^2$
随机性（噪声）	$\sigma_\xi^2(1/\lambda_1 + 1/\lambda_2)/2$	0.583
总地板	**两项之和**	$3.5\eta^2 + 0.583$

$\eta = 0.1$ 时：$L_{\text{floor}} = 0.035 + 0.583 = 0.618$。**噪声主导**。

$\eta = 1$ 时：$L_{\text{floor}} = 3.5 + 0.583 = 4.08$。**振荡主导**。需要衰减 η。

6.8 AdamW：权重衰减创造平衡点

$$w_{t+1} = (1 - \lambda')w_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

权重衰减将参数向零拉，梯度将参数向 w^* 推。两者平衡时：

$$(1 - \lambda')w_{\text{eq}} = w_{\text{eq}} - \eta\,\text{sign}(g_{\text{eq}}) \implies \lambda' w_{\text{eq}} = \eta\,\text{sign}(\lambda_i e_{\text{eq},i})$$

在特征基下第 i 方向（$w_i^* = 0$ 简化分析）：

$$\lambda'\, e_{\text{eq},i} = \eta\,\text{sign}(e_{\text{eq},i}) \implies |e_{\text{eq},i}| = \frac{\eta}{\lambda'}$$

** 均衡误差 $= \eta/\lambda'$，与 Hessian 特征值无关 **（又一次体现了 Adam 对曲率的不敏感性）。

在我们例子上，$\eta = 0.001, \lambda' = 0.01$：$|e_{\text{eq}}| = 0.1$ per 方向。对应损失贡献 $\sim \frac{1}{2}(6+1)\times 0.01 = 0.035$。

6.9 存储代价与近年变体

方法	存储量

SGD	1×
SGD+ 动量	2×
Adam	3×（$+m+v$）
Lion	2×
Cautious Adam	3×（同 Adam）

Lion（Chen et al., 2023）

Lion 保留了 SignGD+ 动量的精神，但省掉了二阶矩 v：

$$c_t = \beta_1 m_{t-1} + (1-\beta_1)\nabla L(w_t)$$

$$w_{t+1} = w_t - \eta\,\mathrm{sign}(c_t) - \eta\lambda w_t$$

$$m_t = \beta_2 m_{t-1} + (1-\beta_2)\nabla L(w_t)$$

注意：c_t(用于 sign)和 m_t(存到下一步)用**不同的动量系数** β_1, β_2(通常 $\beta_1 = 0.9, \beta_2 = 0.99$)。$c_t$ 用较小的 $\beta_1 \to$ 更快跟踪当前梯度方向；m_t 用较大的 $\beta_2 \to$ 更平滑的历史积累。

与 Adam 的区别：没有 v_t，直接对动量取 sign。省了 1× 存储。**但需要更大的权重衰减**（λ 通常比 AdamW 大 3-10 倍），因为 sign 操作丢失了幅值信息后，权重衰减成为控制参数范数的主要手段。

在我们例子上：$g_0 = (-11, -2)$, $m_{-1} = 0$。$c_0 = 0.1 \times (-11, -2) = (-1.1, -0.2)$。$\mathrm{sign}(c_0) = (-1, -1)$。更新方向 $= (+1, +1)$——与 Adam/SignGD 相同。

Cautious Optimizers（Liang et al., 2024）

核心思想：Adam/Lion 的更新方向有时与当前梯度方向**冲突**——更新的某些分量在远离梯度指向的方向走。Cautious 方法" 掩码掉" 这些冲突分量：

$$\mathrm{mask}_t = \mathbb{1}[\mathrm{sign}(\Delta w_t) = \mathrm{sign}(g_t)]$$

$$w_{t+1} = w_t - \eta\,(\Delta w_t \odot \mathrm{mask}_t) \cdot \frac{d}{\|\mathrm{mask}_t\|_1}$$

Δw_t 是原始 Adam/Lion 的更新步。mask 保留与当前梯度" 同向" 的分量，丢弃反向的。最后乘 $d/\|\text{mask}\|_1$ 做归一化补偿（保持总步长不变）。

可以应用在任何基础优化器上：C-Adam、C-Lion、C-SGD 等。

在我们例子上：Adam 步 $\Delta w = \eta(1,1)$。$g_0 = (-11,-2)$，$-g_0 = (11,2)$，$\text{sign} = (+1,+1)$。$\text{sign}(\Delta w) = (+1,+1) = \text{sign}(-g_0)$。**全部同向，mask 全 1**——Cautious 不做任何修改。

当动量累积导致某些分量与当前梯度反向时，Cautious 才介入。这主要发生在损失曲面快速变化时（如学习率 warmup 阶段、loss spike 后）。

其他值得了解的变体

ADOPT（Taniguchi et al., 2024）：修复 Adam 在非平稳目标上不收敛的理论缺陷。关键改动：v_t 用 g_{t-1}（而非 g_t）更新，保证 v_t 和 m_t 的条件独立性。更新公式：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_{t-1}^2$$

$$w_{t+1} = w_t - \eta \frac{m_t}{\sqrt{v_t} + \epsilon}$$

Sophia（Liu et al., 2023）：用 Hessian 对角的随机估计替代 v_t：

$$h_t = \text{diag}(\hat{H}_t), \quad w_{t+1} = w_t - \eta \,\text{clip}\left(\frac{m_t}{h_t}, \rho\right)$$

$\hat{H}_t$ 通过 Hutchinson 估计器（$\hat{H} \approx v^\top H v$，$v$ 是随机 Rademacher 向量）每隔 k 步更新。**clip** 限制每参数步长在 $[-\rho, \rho]$ 内——类似 SignGD 的精神，但用真实曲率信息替代了 Adam 的 $\sqrt{g^2}$ 近似。

7 预条件路线：从对角到 Kronecker

7.1 统一视角：$\Delta w = -P_t \cdot m_t$

所有基于预条件的优化器都可以写成：

$$w_{t+1} = w_t - \eta \, P_t \, m_t$$

m_t 是某种动量估计，P_t 是预条件矩阵——近似 H^{-1}。

优化器	P_t	m_t
SGD	I	g_t
牛顿法	H^{-1}（精确，$O(d^3)$）	g_t
AdaGrad	$\mathrm{diag}(\sum g^2)^{-1/2}$	g_t
Adam	$\mathrm{diag}(\mathrm{EMA}(g^2))^{-1/2}$	$\mathrm{EMA}(g)$
KFAC	$B^{-1} \otimes A^{-1}$（Kronecker）	g_t

7.2 对角预条件（Adam）的局限

Adam 的 $P = \mathrm{diag}(1/\sqrt{\hat{v}})$ 只有对角元素——它逐参数归一化，但**不处理参数间耦合**。

在我们例子上：$H = \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix}$，对角预条件 $P = \mathrm{diag}(1/5, 1/2)$。

预条件后有效 Hessian $PH = \begin{pmatrix} 1 & 0.4 \\ 1 & 1 \end{pmatrix}$，特征值 $(1.63, 0.37)$，条件数 4.4（原来 6，改善有限）。

** 非对角元素 $H_{12} = 2$ 完全没被处理。** 极端例子：$H' = \begin{pmatrix} 3 & 2 \\ 2 & 3 \end{pmatrix}$, $\kappa = 5$, 但 $\mathrm{diag}(H') = (3, 3) \to$ 对角预条件零效果。

7.3 自然梯度：另一种” 曲率”

对角预条件不够，需要完整的矩阵 P。但用什么 P?

** 牛顿法用 $P = H^{-1}$**——H 是损失函数在参数空间中的曲率（§2.1 定义的）。但 H 有两个问题：(1) 可能不半正定（非凸区域），(2) 依赖于参数化方式——同一个模型换一种写法，H 就变了。

有没有一种更” 本质” 的曲率?

三个层次的曲率

曲率	度量的是	对应矩阵	依赖参数化?
损失曲率	$L(\theta)$ 在参数空间中弯曲程度	Hessian $H = \nabla^2 L$	是
统计曲率	模型分布 p_θ 在概率空间中弯曲程度	Fisher 信息 F	**否**
函数曲率	输出 $f_\theta(x)$ 在函数空间中弯曲程度	Gauss-Newton $J^\top J$	否

Fisher 信息矩阵是统计流形上的 Riemannian 度量——它度量的不是" 参数 θ 变了多少"，而是" 模型的输出分布 p_θ 变了多少"。

历史线索

1. **Fisher (1925)**：定义 $F_{ij} = \mathbb{E}\left[\frac{\partial \log p}{\partial \theta_i}\frac{\partial \log p}{\partial \theta_j}\right]$——Score 函数的协方差。最初用于参数估计的 Cramér-Rao 下界：$\mathrm{Var}(\hat{\theta}) \geq F^{-1}$。
2. **Rao (1945)**：发现 F 可以作为参数空间上的 Riemannian 度量——两个参数点的" 统计距离"$ds^2 = d\theta^\top F\, d\theta$。** 同一个模型的不同参数化（如用 θ 还是用 $\phi = g(\theta)$）给出不同的欧氏距离但相同的统计距离。**
3. **Amari (1998)**：将 Rao 的想法用于优化——在统计距离而非欧氏距离下做最速下降，得到**自然梯度** $\Delta\theta = -F^{-1}\nabla L$。

为什么 Fisher 是" 正确的" 曲率?

核心论证：F 是 KL 散度的二阶展开。

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+\Delta\theta}) = \mathbb{E}_{p_\theta}\left[\log \frac{p_\theta}{p_{\theta+\Delta\theta}}\right]$$

对 $\Delta\theta$ Taylor 展开（利用 $\mathbb{E}[\nabla \log p] = 0$）：

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+\Delta\theta}) \approx \frac{1}{2}\Delta\theta^\top F\, \Delta\theta$$

F 是 KL 散度的 Hessian。 而 KL 散度度量的是" 两个分布有多不同"——这正是我们想控制的：一步更新后模型的行为不能变太多。

$$\underbrace{H = \nabla^2 L}_{\text{损失曲面的曲率}} \quad \text{vs} \quad \underbrace{F = \nabla^2 D_{\mathrm{KL}}}_{\text{模型分布的曲率}}$$

类比 §2.3 的框架：H 告诉你" 参数空间中走多远是安全的"，F 告诉你" 分布空间中走多远是安全的"。后者更本质——因为我们训练模型是为了得到好的分布，不是为了得到好看的参数值。

自然梯度

在 F-度量下做最速下降:

$$\Delta w^* = \arg\min_{\Delta w^\top F \Delta w \le \eta^2} g^\top \Delta w = -\eta \frac{F^{-1} g}{\sqrt{g^\top F^{-1} g}}$$

松弛为无约束：$\Delta w = -F^{-1} g$。

在我们数据上

高斯模型 $p(y|x,w) = \mathcal{N}(w^\top x, \sigma^2)$。$\nabla_w \log p = \frac{1}{\sigma^2}(y - w^\top x)x$。

$$F = \mathbb{E}\left[\frac{1}{\sigma^4}(y - w^\top x)^2 x x^\top\right] = \frac{1}{\sigma^2}\mathbb{E}[x x^\top] = \frac{1}{N\sigma^2} X^\top X$$

取 $\sigma^2 = 1$：$F = H/N = H/3$。

Fisher $\propto$ Hessian！这不是巧合——对于**指数族 **（高斯、Bernoulli 等），F 和负对数似然的 H 恰好成正比。线性回归是最简单的例子。

深层网络不是指数族，$F \neq H$——但 F 近似于 Gauss-Newton 矩阵（H 的半正定近似，丢掉了 §1.6 中的二阶项），实践中差距不大。

$$F^{-1} g_0 = 3\, H^{-1} g_0 = 3 \times \begin{pmatrix} -3 \\ 2 \end{pmatrix} = \begin{pmatrix} -9 \\ 6 \end{pmatrix}$$

方向与牛顿法完全相同（差标量倍数），精确指向 w^*。

Fisher vs Hessian

	Hessian H	Fisher F
定义	$\nabla^2 L$	$\mathbb{E}[(\nabla \log p)(\nabla \log p)^\top]$
度量的曲率	损失曲面	统计流形（KL 散度）
半正定?	不一定	**总是**（外积的期望）
依赖参数化?	是	**否**（Riemannian 不变量）
线性回归	$X^\top X$	$X^\top X/N$（$\propto H$）
深层网络	含 σ'' 项	$\approx$ Gauss-Newton
计算量	$O(d^3)$	同样 $O(d^3)$

** 自然梯度的代价和牛顿法一样——F^{-1} 也是 $d \times d$ 矩阵，$O(d^3)$ 求逆。** 所以需要近似——这正是 KFAC 的动机。

7.4 从自然梯度到 KFAC

F 不可行。但 §1 告诉我们 $G = \delta a^\top$，所以:

$$F = \mathbb{E}[(a \otimes \delta)(a \otimes \delta)^\top] = \mathbb{E}[(aa^\top) \otimes (\delta\delta^\top)]$$

KFAC 就是自然梯度的 Kronecker 因子近似：假设 a 和 δ 独立，$F \approx A \otimes B$。

7.5 KFAC：利用 §1 推导的 Kronecker 结构

§1 已经证明了 $H = (xx^\top) \otimes H_h$——Hessian 天然是 Kronecker 积。KFAC 将这个结构用于优化。

对于全连接层 $z = Wa$，梯度 $G = \delta a^\top$。Fisher 矩阵（从 §7.4）:

$$F = \mathbb{E}[(a \otimes \delta)(a \otimes \delta)^\top] \approx \underbrace{\mathbb{E}[aa^\top]}_{A} \otimes \underbrace{\mathbb{E}[\delta\delta^\top]}_{B}$$

逆利用 Kronecker 积性质：$(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$。

$$\mathrm{vec}(\Delta W) = (A^{-1} \otimes B^{-1})\mathrm{vec}(G) \iff \Delta W = B^{-1} G A^{-1}$$

** 从 $(d_{\text{in}} d_{\text{out}})^3$ 的求逆变成了 $d_{\text{in}}^3 + d_{\text{out}}^3$ ——大幅降低。**

7.6 在我们数据上验证 KFAC

把线性回归看成单层网络 ($d_{\text{out}} = 1, d_{\text{in}} = 2$)。$A = X^\top X/N = H/3$, 特征值 $\alpha_1 = 2, \alpha_2 = 1/3$。

KFAC 的有效学习率比：$\eta_2/\eta_1 = \alpha_1/\alpha_2 = 6 = \kappa$。**精确匹配 Hessian 频谱**。对角预条件只给出比值 $H_{11}/H_{22} = 5/2 = 2.5$，差 2.4 倍。

KFAC 的方向 $\propto A^{-1}g \propto H^{-1}g$——**就是牛顿方向**。（单层线性模型上 KFAC 精确恢复牛顿法。）

7.7 KFAC 的局限

1. **独立性假设**：a 和 δ 不完全独立，近似有误差
2. **周期性特征分解**：A^{-1}, B^{-1} 需要每隔 T 步重算，$O(d_{\text{in}}^3 + d_{\text{out}}^3)$
3. **不同层形状导致不同的有效学习率**——但没有自动调节

8 从预条件到范数约束：两条路线的汇合

8.1 Shampoo：预条件路线的终点

Shampoo 用 $(GG^\top)^{-1/4}G(G^\top G)^{-1/4}$ 做预条件。如果统计量仅由当前 G 决定：

$$(GG^\top)^{-1/4}G(G^\top G)^{-1/4} = UV^\top$$

（推导见 §12。）这把 Shampoo 和 $UV^\top$ 连接了起来。

8.2 $UV^\top$ 也是范数约束路线的结果

同时，我们下面将证明：在谱范数约束 $\|\Delta W\|_2 \le \eta$ 下，

$$\arg\min_{\|B\|_2 \le 1} \langle G, B\rangle_F = -UV^\top$$

两条路线在同一个终点汇合。接下来我们从范数约束路线严格推导这个结果。

8.3 参数空间的" 小"$\neq$ 函数空间的" 小"

这是切换到范数约束视角的关键动机。ΔW 在参数空间中小（$\|\Delta W\|_F$ 小）不代表它对输出的影响小：

$$\|\Delta W\|_F \text{ 小} \quad \not\Rightarrow \quad \|\Delta W \cdot x\| \text{ 对典型 } x \text{ 小}$$

我们需要一种范数，** 直接度量 ΔW 对输出的最大影响 **。

9 诱导范数（Induced Norm）

9.1 定义

给定输入空间的范数 $\|\cdot\|_p$ 和输出空间的范数 $\|\cdot\|_q$，矩阵 A 的**诱导范数**（也叫算子范数）定义为:

$$\|A\|_{p\to q} = \max_{\|x\|_p \le 1} \|Ax\|_q$$

含义：A 将输入 x（$\|x\|_p \le 1$）映射到输出 Ax 时，输出范数最大能有多大。

9.2 $\ell_2 \to \ell_2$ 诱导范数 = 谱范数

取 $p = q = 2$:

$$\|A\|_{2\to 2} = \max_{\|x\|_2 \le 1} \|Ax\|_2 = \sigma_1(A)$$

就是最大奇异值。**谱范数度量了矩阵作为线性映射的最大放大率**。

在我们的 $G \in \mathbb{R}^{3\times 4}$（$\sigma = (6, 3, 1)$）上：$\|G\|_{2\to 2} = 6$。

含义：存在一个单位向量 $x = v_1$（G 的第一右奇异向量），使得 $\|Gx\|_2 = 6$。

9.3 用诱导范数做约束

将 §2 的框架推广到矩阵参数。目标函数的一阶近似:

$$L(W + \Delta W) \approx L(W) + \langle \nabla_W L, \Delta W \rangle_F$$

其中 $\langle A, B\rangle_F = \mathrm{tr}(A^\top B) = \sum_{ij} A_{ij} B_{ij}$ 是 Frobenius 内积。

安全性约束：要求更新对输出的影响有界，即 $\|\Delta W\|_{2\to 2} \le \eta$。

$$\Delta W^* = \arg \min_{\|\Delta W\|_{2\to 2} \le \eta} \langle G, \Delta W \rangle_F$$

** 这就从" 参数空间的安全"（ℓ_2 或 ℓ_∞）切换到了" 函数空间的安全"（谱范数）。**

Frobenius 内积. 设 $G, B \in \mathbb{R}^{m\times n}$，其 Frobenius 内积定义为

$$\langle G, B\rangle_F = \sum_{i=1}^{m}\sum_{j=1}^{n} G_{ij}B_{ij}.$$

该内积等价于 trace 形式

$$\langle G, B\rangle_F = \mathrm{trace}(G^\top B).$$

证明. 注意到

$$(G^\top B)_{jj} = \sum_{i=1}^{m} G_{ij}B_{ij},$$

因此

$$\mathrm{trace}(G^\top B) = \sum_{j=1}^{n}(G^\top B)_{jj} = \sum_{j=1}^{n}\sum_{i=1}^{m} G_{ij}B_{ij} = \sum_{i=1}^{m}\sum_{j=1}^{n} G_{ij}B_{ij}.$$

从而

$$\langle G, B\rangle_F = \mathrm{trace}(G^\top B).$$

10 谱范数约束下的最优更新 $\to UV^\top$

10.1 准备：矩阵参数的例子

取 $G \in \mathbb{R}^{3\times 4}$，SVD 为:

$$G = U\Sigma V^\top, \quad U = \frac{1}{3}\begin{pmatrix} 2 & 1 & 2 \\ -2 & 2 & 1 \\ 1 & 2 & -2 \end{pmatrix}, \quad \Sigma = \mathrm{diag}(6,3,1), \quad V^\top = (I_3 \mid 0)$$

10.2 严格推导

命题: $\arg\min_{\|B\|_2\le 1} \mathrm{tr}(G^\top B) = -UV^\top$。

证明:

Step 1. 展开目标函数。$G = \sum_{i=1}^{r}\sigma_i u_i v_i^\top$，所以 $G^\top = \sum_i \sigma_i v_i u_i^\top$。

$$\mathrm{tr}(G^\top B) = \mathrm{tr}\left(\sum_i \sigma_i v_i u_i^\top B\right) = \sum_i \sigma_i \cdot \mathrm{tr}(v_i u_i^\top B) = \sum_i \sigma_i \cdot u_i^\top B v_i$$

最后一步用了 $\mathrm{tr}(v_i u_i^\top B) = \mathrm{tr}(u_i^\top B v_i) = u_i^\top B v_i$（标量的 trace 等于自身）。

Step 2. 上下界。$\|B\|_2 \le 1$ 意味着对任何单位向量 x, y：$|y^\top Bx| \le \|y\|_2 \|Bx\|_2 \le \|B\|_2 \le 1$。

特别地，$|u_i^\top B v_i| \le 1$（因为 $\|u_i\| = \|v_i\| = 1$）。

因此 $\mathrm{tr}(G^\top B) = \sum_i \sigma_i (u_i^\top B v_i) \ge -\sum_i \sigma_i$（每项取下界 -1）。

Step 3. 取等条件。令 $B^* = -UV^\top = -\sum_i u_i v_i^\top$。验证：

- $\|B^*\|_2 = \|UV^\top\|_2 = 1$ （$UV^\top$ 的奇异值全为 1）
- $u_i^\top B^* v_i = u_i^\top (-\sum_j u_j v_j^\top) v_i = -\sum_j (u_i^\top u_j)(v_j^\top v_i) = -\delta_{ii} = -1$

所以 $\mathrm{tr}(G^\top B^*) = -\sum_i \sigma_i$，达到下界。□

最优更新：$\Delta W^* = \eta B^* = -\eta UV^\top$。

10.3 在我们例子上

$$UV^\top = \frac{1}{3}\begin{pmatrix} 2 & 1 & 2 & 0 \\ -2 & 2 & 1 & 0 \\ 1 & 2 & -2 & 0 \end{pmatrix}$$

$\|UV^\top\|_2 = 1$。三个奇异方向上的更新幅度 ** 都是 η**。

** 与 ℓ_2, ℓ_∞ 约束的对比 **:

范数约束	更新	三方向幅度比	条件数	方向保持
$\|\Delta W\|_F \le \eta$（ℓ_2）	$-\eta G/\|G\|_F$	$6:3:1$	6	✓
$\|\Delta W\|_\infty \le \eta$（逐元素）	$-\eta\,\mathrm{sign}(G)$	$\approx 2:2:1$*	2	×
$\|\Delta W\|_2 \le \eta$（谱范数）	$-\eta UV^\top$	$1:1:1$	1	✓

*Adam/SignGD 的 $\mathrm{sign}(G)$ 的奇异值为 $(2, 2, 1)$，且其奇异向量与 G 的不同（§7.3 已验证 $\mathrm{sign}(G)\mathrm{sign}(G)^\top$ 的特征空间与 $GG^\top$ 不同）。

10.4 SignGD vs 矩阵 sign 的本质区别

$\mathrm{sign}_{\mathrm{elem}}(G)$：逐元素取符号。$\ell_\infty$ 约束下的最优解。**打乱了矩阵的旋转结构**。

$\mathrm{sign}_{\mathrm{matrix}}(G) = UV^\top$：矩阵符号函数（保留奇异向量，奇异值 $\to 1$）。**谱范数约束下的最优解**。

在向量上两者一致（$\mathrm{sign}(g) = g/|g|$ 对每个分量）。在矩阵上两者不同——因为逐元素 sign 不尊重矩阵的行列结构。

11 Shampoo 恒等式：不做 SVD 也能算 $UV^\top$

11.1 恒等式

$$(GG^\top)^{-1/4}\, G\, (G^\top G)^{-1/4} = UV^\top$$

11.2 前置知识：矩阵函数

对称半正定矩阵 A 有特征分解 $A = Q\Lambda Q^\top$（Q 正交，Λ 对角非负）。任意幂次 α 定义为：

$$A^\alpha = Q\,\Lambda^\alpha\, Q^\top, \quad (\Lambda^\alpha)_{ii} = \lambda_i^\alpha$$

直觉：在特征基下，矩阵幂就是对每个特征值独立取幂。

例如 $A = \begin{pmatrix} 4 & 0 \\ 0 & 9 \end{pmatrix}$：$A^{1/2} = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$，$A^{-1/4} = \begin{pmatrix} 4^{-1/4} & 0 \\ 0 & 9^{-1/4} \end{pmatrix} = \begin{pmatrix} 0.707 & 0 \\ 0 & 0.577 \end{pmatrix}$。

非对角矩阵也一样——先旋转到特征基，取幂，旋转回来。

11.3 逐步证明

设 $G \in \mathbb{R}^{m\times n}$，SVD 为 $G = U\Sigma V^\top$。

**Step 1：计算 $GG^\top$ 及其 $-1/4$ 次幂 **

$$GG^\top = (U\Sigma V^\top)(V\Sigma^\top U^\top) = U\Sigma\Sigma^\top U^\top = U\,\mathrm{diag}(\sigma_1^2, \ldots, \sigma_m^2)\, U^\top$$

（$\Sigma\Sigma^\top$ 是 $m \times m$ 对角阵，对角元素 $= \sigma_i^2$。$V^\top V = I$ 因为 V 列正交。）

$GG^\top$ 的特征分解已知：特征向量 $= U$ 的列，特征值 $= \sigma_i^2$。所以：

$$(GG^\top)^{-1/4} = U\,\mathrm{diag}(\sigma_1^{2\times(-1/4)}, \ldots)\, U^\top = U\,\mathrm{diag}(\sigma_1^{-1/2}, \ldots, \sigma_m^{-1/2})\, U^\top$$

在我们例子上（$\sigma = (6, 3, 1)$）：

$$(GG^\top)^{-1/4} = U\,\mathrm{diag}(6^{-1/2},\,3^{-1/2},\,1^{-1/2})\,U^\top = U\,\mathrm{diag}(0.408,\,0.577,\,1)\,U^\top$$

**Step 2：计算 $G^\top G$ 及其 $-1/4$ 次幂 **

$$G^\top G = V\Sigma^\top\Sigma V^\top = V\,\mathrm{diag}(\sigma_1^2,\ldots,\sigma_n^2)\,V^\top$$

（如果 $m<n$，多出的 $\sigma_i=0$。$U^\top U=I$ 因为 U 列正交。）

$$(G^\top G)^{-1/4} = V\,\mathrm{diag}(\sigma_1^{-1/2},\ldots,\sigma_r^{-1/2},0,\ldots)\,V^\top$$

在我们例子上（$r=3,n=4$）：

$$(G^\top G)^{-1/4} = V\,\mathrm{diag}(0.408,\,0.577,\,1,\,0)\,V^\top$$

Step 3：三个矩阵相乘

$$(GG^\top)^{-1/4}\cdot G\cdot(G^\top G)^{-1/4}$$

$$= \left[U\,\mathrm{diag}(\sigma_i^{-1/2})\,U^\top\right]\cdot\left[U\,\mathrm{diag}(\sigma_i)\,V^\top\right]\cdot\left[V\,\mathrm{diag}(\sigma_i^{-1/2})\,V^\top\right]$$

逐步合并（利用 $U^\top U=I$，$V^\top V=I$）：

$$= U\,\mathrm{diag}(\sigma_i^{-1/2})\,\underbrace{U^\top U}_{I}\,\mathrm{diag}(\sigma_i)\,\underbrace{V^\top V}_{I}\,\mathrm{diag}(\sigma_i^{-1/2})\,V^\top$$

$$= U\,\underbrace{\mathrm{diag}(\sigma_i^{-1/2})\,\mathrm{diag}(\sigma_i)\,\mathrm{diag}(\sigma_i^{-1/2})}_{\text{对角阵相乘}}\,V^\top$$

对角阵相乘就是逐元素乘：$\sigma_i^{-1/2}\cdot\sigma_i\cdot\sigma_i^{-1/2}=\sigma_i^{-1/2+1-1/2}=\sigma_i^0=1$。

$$= U\,\mathrm{diag}(1,1,1)\,V^\top = UV^\top \quad \square$$

11.4 在我们例子上逐元素验证

$\sigma_1=6$：$6^{-1/2}\cdot 6\cdot 6^{-1/2}=\frac{1}{\sqrt{6}}\cdot 6\cdot\frac{1}{\sqrt{6}}=\frac{6}{6}=1$

$\sigma_2=3$：$3^{-1/2}\cdot 3\cdot 3^{-1/2}=\frac{3}{3}=1$

$\sigma_3 = 1$：$1^{-1/2} \cdot 1 \cdot 1^{-1/2} = 1$

每个奇异值被”左右夹击”消去了。 $-1/4$ 次幂从左右各贡献 $\sigma^{-1/2}$，加上中间 G 自带的 σ^1，总幂次 $= -1/2 + 1 + (-1/2) = 0$。

11.5 一般幂次 p

如果用 $(GG^\top)^{-p}G(G^\top G)^{-p}$，每个奇异值的总幂次变为：

$$\sigma_i^{-2p} \cdot \sigma_i^1 \cdot \sigma_i^{-2p} = \sigma_i^{1-4p}$$

（$GG^\top$ 的特征值是 σ^2，取 $-p$ 次幂得 σ^{-2p}。左右各一个 $-2p$，中间一个 $+1$。）

p	奇异值变换 $\sigma \to$	$\sigma_1 = 6$	$\sigma_2 = 3$	$\sigma_3 = 1$	效果
0	σ^1	6	3	1	SGD（原样）
1/8	$\sigma^{1/2}$	2.45	1.73	1	温和压缩
1/4	$\sigma^0 = 1$	**1**	**1**	**1**	** 完全均衡 $\to UV^\top$**
3/8	$\sigma^{-1/2}$	0.41	0.58	1	频谱反转
1/2	σ^{-1}	0.17	0.33	1	完全反转（Newton 式）

$p = 1/4$ 是使 $1 - 4p = 0$ 的唯一解——所有奇异值变为 $\sigma^0 = 1$。

$p < 1/4$：大奇异值仍然主导（SGD 的方向）。$p > 1/4$：小奇异值反而更大（过度补偿）。$p = 1/4$ 恰好在临界点。

11.6 从恒等式到实践

直接计算 $(GG^\top)^{-1/4}$ 需要对 $m \times m$ 矩阵做特征分解：$O(m^3)$。$(G^\top G)^{-1/4}$ 需要 $O(n^3)$。

两种绕开方式：

Shampoo（Gupta et al., 2018）：不用每步的 G，而是用 EMA 缓存 $L_t \approx \mathbb{E}[GG^\top]$，每 T 步做一次特征分解更新 $L_t^{-1/4}$。好处：统计量更稳定（时间平均降噪）。代价：每 T 步 $O(m^3 + n^3)$。

Muon（Jordan et al., 2024）：完全不做特征分解——用 Newton-Schulz 多项式迭代直接逼近 $UV^\top$（下一节详述）。好处：全 matmul, GPU 利用率极高。代价：每步 $O(mn \min(m, n))$ 的 matmul。

12 RMS→RMS 诱导范数

12.1 从 RMS 范数说起

$$\|x\|_{\text{RMS}} = \sqrt{\frac{1}{d}\sum_{i=1}^{d} x_i^2} = \frac{\|x\|_2}{\sqrt{d}}$$

控制" 每个坐标的平均尺度"。与 Xavier/He 初始化直接相关——保持每层 $\|Wx\|_{\text{RMS}} = O(1)$ 是训练稳定的关键。

12.2 诱导范数的推导

$\|A\|_{\text{RMS}\to\text{RMS}}$ 是 A 将 RMS 范数为 1 的输入映射到输出的最大 RMS 范数。

设 $A \in \mathbb{R}^{d_{\text{out}}\times d_{\text{in}}}$。$\|x\|_{\text{RMS}} = 1$ 意味着 $\|x\|_2 = \sqrt{d_{\text{in}}}$。

$$\|A\|_{\text{RMS}\to\text{RMS}} = \max_{\|x\|_{\text{RMS}}=1} \|Ax\|_{\text{RMS}} = \max_{\|x\|_2=\sqrt{d_{\text{in}}}} \frac{\|Ax\|_2}{\sqrt{d_{\text{out}}}}$$

做变量替换 $x = \sqrt{d_{\text{in}}}\,\hat{x}$（$\|\hat{x}\|_2 = 1$）：

$$= \frac{\sqrt{d_{\text{in}}}}{\sqrt{d_{\text{out}}}} \max_{\|\hat{x}\|_2=1} \|A\hat{x}\|_2 = \sqrt{\frac{d_{\text{in}}}{d_{\text{out}}}}\|A\|_2$$

$$\boxed{\|A\|_{\text{RMS}\to\text{RMS}} = \sqrt{\frac{d_{\text{in}}}{d_{\text{out}}}}\|A\|_2}$$

12.3 在我们例子上

$G \in \mathbb{R}^{3\times 4}$：$d_{\text{out}} = 3$，$d_{\text{in}} = 4$，$\|G\|_2 = 6$。

$$\|G\|_{\text{RMS}\to\text{RMS}} = \sqrt{4/3} \times 6 \approx 6.93$$

验证：取 $x = v_1$（G 的第一右奇异向量），$\|x\|_2 = 1$。RMS 输入 $\|x\|_{\text{RMS}} = 1/\sqrt{4} = 0.5$。要让 $\|x\|_{\text{RMS}} = 1$，需要 $x' = 2v_1$。$\|Gx'\|_2 = 12$，$\|Gx'\|_{\text{RMS}} = 12/\sqrt{3} = 6.93$ 。

12.4 RMS→RMS 约束下的最优更新

$$\Delta W^* = \arg \min_{\|\Delta W\|_{\mathrm{RMS}\to\mathrm{RMS}} \le \eta} \langle G, \Delta W \rangle_F$$

约束等价于 $\|\Delta W\|_2 \le \eta\sqrt{d_{\mathrm{out}}/d_{\mathrm{in}}}$。从 §8 的结果（谱范数约束下最优解为 $-UV^\top$），直接代入：

$$\boxed{\Delta W^* = -\eta\sqrt{\frac{d_{\mathrm{out}}}{d_{\mathrm{in}}}}\, UV^\top}$$

我们例子：$\sqrt{3/4} \approx 0.866$，所以 $\Delta W^* = -0.866\eta\, UV^\top$。

12.5 层形状自动进入缩放因子

层	d_{in}	d_{out}	$\sqrt{d_{\mathrm{out}}/d_{\mathrm{in}}}$
注意力 W_Q	768	64	0.29
MLP 上投影	768	3072	2.0
MLP 下投影	3072	768	0.5

宽 → 窄层自动小步长，窄 → 宽层自动大步长——这是 RMS→RMS 范数作为" 安全性度量" 的自然结果。

13 Muon = 动量 + Newton-Schulz 正交化

13.1 Newton-Schulz 迭代

目标：给定 $G = U\Sigma V^\top$，不做 SVD，高效逼近 $UV^\top$。

关键性质：奇多项式 p 作用在矩阵上时，$p(G) = U\,p(\Sigma)\,V^\top$——奇异向量不变，只有奇异值被变换。所以如果 $p(\sigma) \to 1$，则 $p(G) \to UV^\top$。

经典 NS 多项式：$p(x) = \frac{3}{2}x - \frac{1}{2}x^3$。

验证性质：$p(1) = 1$（不动点），$p'(1) = \frac{3}{2} - \frac{3}{2} = 0$（超线性收敛），$(0, \sqrt{3})$ 上 $p(x) > x$（单调推向 1）。

矩阵形式：$X_{k+1} = \frac{1}{2}X_k(3I - X_k^\top X_k)$。全部是矩阵乘法。

13.2 手算

先归一化 $\hat{G} = G/\|G\|_F$，$\|G\|_F = \sqrt{46} \approx 6.78$。奇异值变为 $\hat{\sigma} = (0.885, 0.442, 0.147)$。

迭代	$\hat{\sigma}_1$	$\hat{\sigma}_2$	$\hat{\sigma}_3$	计算（以 $\hat{\sigma}_1$ 为例）
0	0.885	0.442	0.147	归一化
1	0.981	0.620	0.219	$\frac{3}{2}(0.885) - \frac{1}{2}(0.885)^3 = 1.328 - 0.347$
2	**1.000**	0.811	0.324	$\frac{3}{2}(0.981) - \frac{1}{2}(0.981)^3 \approx 1.000$
3	1.000	0.950	0.469	
5	1.000	**1.000**	0.839	

σ_1 2 步收敛，σ_3 5 步还差——小奇异值（可能是噪声方向）天然得到**更小的更新幅度**。

13.3 完整算法

```
for t = 1, 2, ... do
    G = mini-batch梯度
    B =  • B_{t-1} + (1- ) • G # 动量
    X = B / ‖B‖_F # 归一化 →    (0,1]
    for k = 1..5: X = X(3I - X^TX)/2 # NS正交化
    W_{t+1} = W_t -  √(d_out/d_in) • X # 更新
```

存储 2×（权重 + 动量缓冲），比 Adam 的 3× 少 1×。

14 总结

范数	”安全”的含义	最优更新	条件数	muP 缩放
ℓ_2	参数变化量小	$-g/\|g\|$	κ	—
ℓ_∞	每个参数变化量小	$-\mathrm{sign}(g)$	↓（但方向偏）	$\eta \propto 1/d_{\text{in}}$
$\|B\|_2$（谱范数）	对任何输入，输出变化小	$-UV^\top$	1	内建
$\|B\|_{\text{RMS}\to\text{RMS}}$	对 RMS=1 的输入，输出 RMS 变化小	$-\sqrt{d_{\text{out}}/d_{\text{in}}}\,UV^\top$	1	η 不变

从 GD 到 Muon，”安全的一步”的定义逐步进化：
参数空间安全（ℓ_2: 参数总变化有界）→ **逐参数安全**（ℓ_∞: 每个参数变化有界）→ **函数空间安全**（谱范数/RMS→RMS: 对任何输入，层输出变化有界）。
每一步进化都对应一个更强的优化器。

15 参考文献

1. Bernstein & Newhouse (2024). Old optimizer, new norm. *arXiv:2409.20325*.
2. Gupta et al. (2018). Shampoo. *ICML*.
3. Jordan et al. (2024). Muon.
4. Yang et al. (2022). Tensor Programs V (muP).
5. Kingma & Ba (2015). Adam. *ICLR*.
6. Loshchilov & Hutter (2019). AdamW. *ICLR*.